Universidad Nacional Autónoma de México
FACULTAD DE ESTUDIOS SUPERIORES ACATLÁN

LiteraLevel

Medición automática de la dificultad de lectura en inglés y su entrega a un lector real

Proyecto integrador — Módulo 5

Alumno:
Miguel Reyes Carrillo

Profesor:
Mtro. Fernando Barranco Rodríguez

Diplomado en Ciencia de Datos — Generación 34

0,908	A1 < · · · < C1	97,2 %
Spearman, validación ciega	orden MCER creciente en corpus externo	dentro de ±1 nivel

Ciudad de México, septiembre de 2026

Resumen

Aprender inglés leyendo funciona, pero solo si el libro está al nivel de quien lo abre. Un lector que elige un libro demasiado difícil no aprende: lo abandona. Y hoy no hay forma sencilla de saber, antes de empezar, si *ese* libro concreto está a su alcance.

LiteraLevel es una aplicación que responde esa pregunta. Le da al lector un número entre 0 y 2 que dice cuánta dificultad tiene un texto en inglés, y lo hace leyendo el texto de verdad, no contando páginas. Con ese número le busca libros que le queden a mano, se los abre dentro de la propia aplicación, le enseña la dificultad capítulo a capítulo —los libros no son igual de difíciles de principio a fin—, le explica cualquier palabra en la frase en la que aparece y le corrige la pronunciación cuando lee en voz alta.

Debajo hay un modelo de lenguaje pequeño (`distilroberta-base`) afinado para predecir dificultad como un número continuo. En validación ciega alcanza una correlación de Spearman de 0,908 con el nivel de referencia y, sobre un corpus externo que no se usó para ajustar los pesos —aunque sí se exploró durante el desarrollo, y eso se detalla en la limitación 6—, ordena los niveles del Marco Común Europeo de forma estrictamente creciente: A1 0,5040 (n=3) · A2 0,5561 (n=8) · B1 0,9276 (n=12) · B2 1,2414 (n=12) · C1 1,4952 (n=12). Ese orden —no el acierto exacto— es el resultado que sostiene el trabajo, **con una salvedad que conviene leer junto a las cifras**: el escalón A1–A2 es de 0,052 sobre desviaciones de 0,111 y 0,223, y descansa en tres textos. Está dentro del ruido. Los tres escalones siguientes, no.

Conviene decirlo desde la primera página: **la escala 0–2 es propia y LiteraLevel no certifica ningún nivel del Marco Común Europeo**. Las letras A1 a C2 fueron el ancla con la que se entrenó el modelo, no un título que la aplicación expida. Sirven para elegir qué leer, no para acreditar nada.

La entrega usa **Angular como interfaz y una API FastAPI sobre el motor Python**; Gradio 6.26 (Abid y col., 2019) se conserva como respaldo. Las pruebas de usabilidad de la interfaz anterior con Esmeralda y Laura motivaron esta separación, pero no equivalen a una validación de usuario de todos los cambios posteriores. El catálogo medido contiene **53.179 libros** en inglés de dominio público de Project Gutenberg, leídos enteros por el modelo, capítulo a capítulo. La última tanda, en una GPU gratuita, tardó 55 minutos: el cuello de botella nunca fue el modelo, sino leer y guardar los archivos.

Palabras clave: legibilidad automática, MCER, adquisición de segundas lenguas, lectura extensiva, transformers, Project Gutenberg, Angular.

Nota sobre la estructura de la entrega. La *Estrategia*, que la rúbrica pide como entregable propio y como sección exigida del documento, se desarrolla completa en el **apartado 3** y no en un anexo: ocupa el lugar que le corresponde en el orden de secciones y sostiene por sí sola el resto del texto. Las cifras que allí se citan y que se miden más adelante van referidas con su cuadro o figura. **Todas las figuras de este documento están dibujadas en LaTeX** (TikZ/pgfplots) a partir de los datos medidos que acompañan a la entrega; no hay ninguna captura de pantalla ni imagen externa.

Índice

Resumen **1**

1. Introducción y motivación **5**

2. Planteamiento del problema **5**
2.1. Formulación . . . 5
2.2. Lo que el problema no es . . . 6
2.3. Criterio de éxito . . . 7

3. Estrategia **7**
3.1. El marco: Peldaño, una compañía ficticia . . . 7
3.2. La apuesta, en un párrafo . . . 8
3.3. Descripción de usuarios . . . 8
3.3.1. Usuaria primaria: la estudiante de preparatoria . . . 8
3.3.2. Usuario secundario: el adulto autodidacta . . . 9
3.3.3. Usuario institucional: el docente de inglés . . . 9
3.4. El ciclo de usuario real: Esmeralda . . . 10
3.4.1. Lo que ya se había corregido antes, por la misma vía . . . 11
3.4.2. El segundo ciclo: Laura . . . 12
3.4.3. La lección, en una línea . . . 13
3.5. Usabilidad del modelo . . . 13
3.5.1. La espera se traslada, no se pide . . . 13
3.5.2. La incertidumbre se comunica en bandas . . . 14
3.5.3. Nada falla en silencio, y nada se rompe del todo . . . 14
3.5.4. Cada número dice de dónde viene . . . 14
3.5.5. La latencia se reparte para que la pantalla no se quede quieta . . . 14
3.5.6. La interfaz entregada: un *front* de Angular sobre una API . . . 15
3.6. Accionables . . . 16
3.7. Métricas de éxito . . . 19
3.8. Riesgos . . . 19

4. Descripción de los datos **19**
4.1. Inventario de fuentes . . . 19
4.2. Relevancia de cada fuente . . . 19
4.3. Calidad de los datos: lo que está bien y lo que no . . . 20

5. Análisis exploratorio **23**
5.1. Análisis univariado . . . 24
5.2. Análisis bivariado . . . 24
5.3. Análisis multivariado . . . 25

6. Procesamiento de datos **26**
6.1. Sobre el texto de entrada . . . 26
6.2. Sobre las variables del modelado clásico . . . 27
6.3. Sobre el corpus de vocabulario (procesamiento distribuido) . . . 27
6.4. Sobre el diccionario . . . 27

7. Modelación **28**
7.1. Diseño experimental . . . 28
7.2. Progresión de modelos . . . 28
7.3. Dónde funciona y dónde no: análisis por dominio . . . 29
7.4. El modelo desplegado y su validación . . . 31
7.5. El *baseline* propio, y qué aporta el modelo por encima de él . . . 34
7.6. Cuadro de decisiones metodológicas . . . 37
7.7. Qué filtra el validador local y qué filtra la aplicación . . . 38

8. Resolución del problema **39**
8.1. De la métrica a la decisión del lector . . . 39
8.2. Un recorrido completo, con números reales . . . 39
8.3. Escalado: el catálogo entero, precalculado . . . 41
8.4. Dos decisiones de producto que merecen argumento . . . 44
8.5. Contra quién compite esto . . . 44

9. Limitaciones **45**

10. Trabajo futuro **47**

11. Conclusiones **48**

Declaración de alcance **49**

Referencias **51**

Índice de figuras

1. Cadena de medición de LiteraLevel 6
2. La escala 0–2 y sus anclas MCER 6
3. Reparto de niveles del catálogo heredado 22
4. Progresión de modelos: la representación manda 29
5. Sobreajuste visto y controlado 30
6. Matriz modelo × dominio 30
7. Validación externa por nivel MCER 33
8. La escala comprimida 36
9. El recorrido del lector 40
10. Curva de dificultad de *War and Peace* 41
11. Curvas de dificultad en modo vistazo 42
12. Velocidad de inferencia por entorno 42
13. Comparación con las alternativas 45

1 Introducción y motivación

Unos 1.500 millones de personas estudian inglés como segunda lengua. De todos los métodos con respaldo empírico, la **lectura extensiva** —leer mucho, por gusto, en textos ligeramente por encima del nivel actual— es uno de los que mejor se sostiene: el metaanálisis de Nakanishi (2015) sobre décadas de estudios encuentra efectos consistentes en comprensión y vocabulario, y Day y Bamford (1998) la formalizan como programa de aula. Krashen (1985) llamó a esa franja «*input* comprensible»: material que se entiende casi todo, con lo justo de novedad para aprender.

El problema es operativo, no teórico. Para que la lectura extensiva funcione, el texto tiene que caer en esa franja, y Hu y Nation (2000) la cuantifican: se necesita reconocer alrededor del 98 % de las palabras corridas de un texto para comprenderlo sin ayuda —umbral coherente con el trabajo posterior de Nation (2013) sobre tamaño de vocabulario y cobertura léxica—. Un punto porcentual por debajo y la lectura se convierte en trabajo de diccionario. Es decir: **el mismo libro es excelente para un lector y una pérdida de tiempo para otro que está dos niveles por debajo**, y nada en la portada lo dice.

Hoy el lector hispanohablante que quiere leer en inglés se enfrenta a decenas de miles de libros gratuitos en dominio público y a ninguna señal fiable sobre cuál le corresponde. Las etiquetas que circulan (A2, B1, C1) casi nunca las puso alguien que haya leído la obra completa, y además tratan el libro como si tuviera una sola dificultad, cuando en realidad cambia de capítulo a capítulo. La figura 10 lo muestra sobre un libro entero medido: la dificultad de *War and Peace* recorre casi setenta centésimas de la escala pública entre su capítulo más llevadero y el más exigente.

Pregunta que guía el trabajo: ¿es posible estimar automáticamente, con un modelo de lenguaje entrenado sobre corpus públicos, una medida de dificultad de un texto en inglés que (a) ordene correctamente los niveles del MCER (Council of Europe, 2020) en material externo que no intervino en el ajuste de los pesos, y (b) sea lo bastante rápida y comprensible para ponerse en manos de un lector adolescente sin entrenamiento previo?

Este documento responde a las dos mitades. La primera es un problema de modelado y se resuelve en los apartados 4 a 7. La segunda es un problema de producto y de usabilidad, que es lo que el módulo declara evaluar, y se desarrolla en los apartados 3 y 8.

2 Planteamiento del problema

2.1 Formulación

Sea T un texto en inglés en prosa continua. Se busca una función $f(T) \to [0, 2]$ tal que, para dos textos T_i y T_j cuyos niveles oficiales de referencia cumplen $\text{nivel}(T_i) < \text{nivel}(T_j)$, se cumpla $f(T_i) < f(T_j)$ con la mayor frecuencia posible.

Obsérvese que **el objetivo es ordinal, no de clasificación exacta**. La frontera entre B1 y B2 es una convención pedagógica, no un hecho físico: confundir B1 con B2 es un error muy distinto de confundir B1 con C2. Por eso las métricas principales del trabajo son la correlación de Spearman y el **error ordinal medio** (distancia media en niveles entre lo predicho y lo real), y no la exactitud de clase.

Un texto largo no se puntúa de una vez. Se parte en bloques de 250 palabras (mínimo 150) y se puntúa cada bloque; la salida del documento es la media sin ponderar de sus bloques. Formalmente, si $B(T) = \{b_1, \ldots, b_n\}$ son los bloques de T y g es el modelo por bloque,

$$f(T) \;=\; 0{,}4 \cdot \frac{1}{n} \sum_{k=1}^{n} \text{clip}(g(b_k),\ 0,\ 5)\,, \tag{1}$$

donde el factor 0,4 convierte la escala interna del modelo (0–5, un valor por cada nivel A1…C2) en la escala pública 0–2 que ve el usuario.

El recorte va dentro del sumatorio, y el orden importa. Cada bloque se lleva a 0–5 *antes* de promediar, no después. No es un detalle de notación: la cabeza de regresión no tiene ninguna activación que la obligue a quedarse en el intervalo, y el **13,96 %** de las ventanas de prosa literaria puntúa por encima de 5 —medido sobre 530 ventanas de *Alicia*, *Orgullo y prejuicio* y *Crimen y castigo*; ninguna baja de 0—. Recortar después de promediar dejaría que un bloque que puntúa 5,3 arrastrase hacia arriba a todo el capítulo. Las dos versiones de la fórmula llegan a separarse **0,021** en un libro real, cinco veces la diferencia de cualquier otra decisión de agregación del sistema. El recorte va dentro del sumatorio, que es lo que hace el código. La figura 1 recorre esa cadena completa, del texto crudo a la banda que se muestra en pantalla, y la figura 2 sitúa las anclas MCER sobre la recta 0–2 resultante.

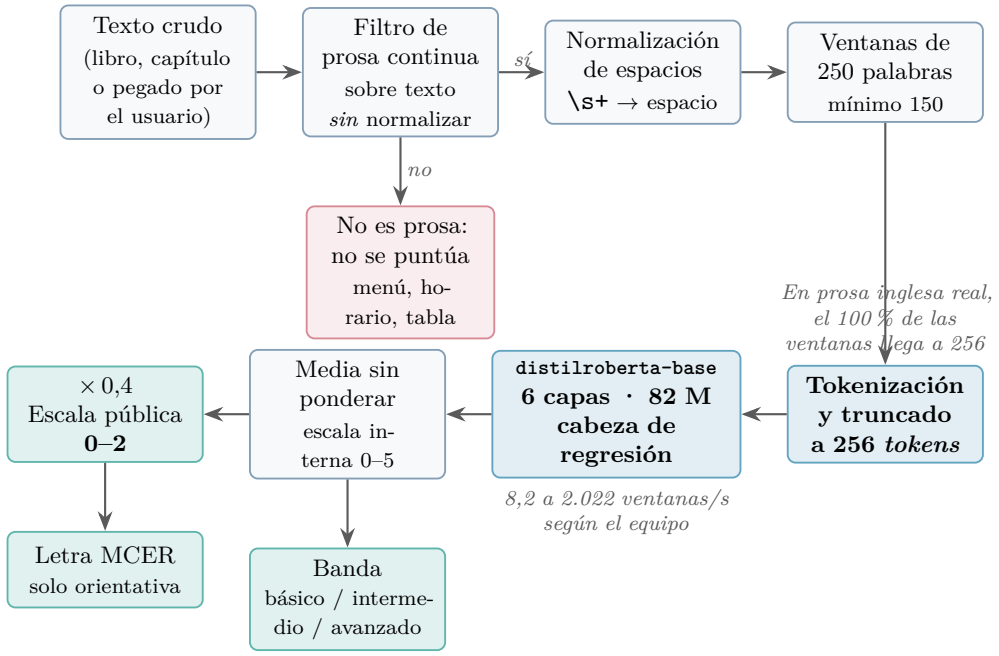


Figura 1: Cadena de medición, de la ecuación (1) al número que ve el lector. El filtro de prosa se aplica sobre el texto crudo, antes de normalizar espacios: hacerlo al revés lo desactivaba en producción (cuadro 12, T1). En prosa inglesa real, las ventanas de un texto de más de 250 palabras ocupan siempre 256 *tokens* tras truncar, así que no llevan relleno y reagruparlas no movió ningún decimal en la comprobación de 300 ventanas del apartado 8.3. Cuando se mezclan capítulos cortos en un mismo lote sí hay relleno, y la diferencia medida es de $4{,}8 \times 10^{-7}$: por debajo de los tres decimales que se guardan.

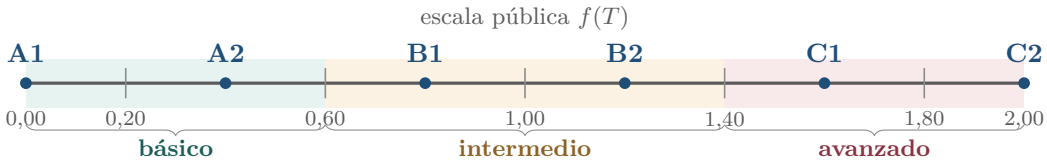


Figura 2: La escala pública 0–2 y sus anclas. Los puntos azules son los seis niveles MCER tal como los coloca la ecuación (1) (nivel entero × 0,4); las marcas grises son los cortes que decide qué letra se muestra, y las llaves inferiores, las tres bandas con las que la interfaz comunica la incertidumbre en lugar de fingir dos decimales de precisión. *La letra es orientación, no certificación.* Cortes tomados de `datos_figuras/escala_cefr.dat`.

2.2 Lo que el problema no es

Tres delimitaciones que evitan malentendidos y que la aplicación repite en pantalla:

1. **No es certificación.** El modelo se ancló a etiquetas MCER durante el entrenamiento; eso no lo convierte en un examinador acreditado. Devuelve una posición en una recta continua, y la letra que muestra es simplemente el ancla más cercana.
2. **No es un medidor universal de texto.** El modelo solo vio prosa continua. Una carta de menú, un horario de vuelos o una tabla no son prosa, y puntuarlos daría un número sin significado. La aplicación los rechaza con un filtro estructural explícito (apartado 6.1).
3. **No mide el interés ni la calidad literaria.** Mide dificultad de lectura. Un libro fácil puede ser magnífico y uno difícil, aburrido.

2.3 Criterio de éxito

El proyecto se considera resuelto si se cumplen tres condiciones simultáneas, recogidas en el cuadro 1.

#	Condición	Cómo se verifica
C1	El orden por nivel MCER se conserva en corpus externo no visto	Medias por nivel estrictamente crecientes
C2	La señal supera a la trivial	Correlación parcial descontando la longitud del texto
C3	Un usuario sin formación técnica completa el recorrido	Prueba con lectora ajena al proyecto

Cuadro 1: Criterios de éxito del proyecto. Se cumplen y se documentan, respectivamente, en los apartados 7.4, 7.5 y 3.4.

3 Estrategia

3.1 El marco: Peldaño, una compañía ficticia

Este trabajo se plantea como el primer producto de **Peldaño**, una compañía ficticia de inteligencia artificial aplicada a la educación. La ficción es un requisito del módulo y conviene decir desde el principio **qué es ficticio y qué no**: la empresa lo es; el modelo, la aplicación desplegada, el corpus, las métricas y cada cifra de este documento, no. Todo lo que se afirma aquí está medido, y qué parte se puede además *reproducir* desde este repositorio y cuál no está dicho sin adornos en el apartado 7.4 y en las limitaciones: el código, la inferencia desde los pesos públicos y las métricas del entrenamiento del v4 se rehacen desde el repositorio, con datos públicos; lo único que no se redistribuye es el corpus de British Council, que se reconstruye con su manifiesto.

El nombre no es decorativo. En adquisición de segundas lenguas, la hipótesis del *input* comprensible sostiene que se aprende con material que está justo un escalón por encima de lo que uno ya domina (Krashen, 1985). Ese escalón es el peldaño, y encontrarlo es exactamente el problema que el lector no puede resolver solo.

Nicho

Peldaño no compite en el mercado general de aprendizaje de idiomas, que está saturado y lo dominan aplicaciones de repetición espaciada. Se sitúa en un hueco más estrecho y peor atendido: **la lectura extensiva en inglés para hispanohablantes que ya tienen base**, entre A2 y B2. Es el tramo donde el estudiante ya no cabe en el material graduado, todavía no aguanta una novela sin ayuda, y abandona. El apartado 8.5 documenta contra quién se compite y dónde se pierde.

Propuesta de valor, en una frase

Convertir una biblioteca gratuita e inabarcable —Project Gutenberg— en una estantería personal ordenada por lo que cada lector puede leer hoy.

Cómo se sostendría

La pregunta de negocio no es cómo cobrar por el modelo, que es pequeño y replicable, sino quién paga la parte cara. Medido en este proyecto: **medir un libro, leerlo, buscar y consultar el diccionario no cuestan nada** —corren en local sobre datos abiertos—, y solo tres acciones salen a un servicio externo de pago: explicar una palabra en su frase, resumir un libro y corregir la pronunciación. Esa separación, que en la aplicación es una puerta de acceso con cupo por perfil, es también la frontera natural entre un nivel gratuito y uno de pago, y no hubo que diseñarla: salió de medir qué costaba cada cosa.

El cliente institucional —el docente de inglés del apartado 3.3.3— es el que justificaría una tarifa, porque su necesidad no es leer sino *asignar*: repartir lecturas de dificultad medida, y medida capítulo a capítulo, sin tener que leerse cuarenta libros antes. Conviene decir qué es esto y qué no: hoy el producto **no hace seguimiento de alumnos**, ni puede hacerlo tal como está construido —los datos de cada lector se guardan separados y no se comparten—, y la Declaración de alcance del final de este documento descarta expresamente usar esta medida para decisiones con consecuencias para el evaluado. El producto que hay sirve al docente para *elegir textos*; un panel de seguimiento sería otro producto, y está en Trabajo futuro.

Lo que Peldaño no promete

No promete enseñar inglés, ni certificar un nivel, ni sustituir a un profesor. Mide la dificultad de un texto en una escala propia de 0 a 2 y la pone al lado del nivel estimado del lector. El apartado 9 enumera los límites de esa medida, y la aplicación los dice en pantalla en vez de esconderlos.

3.2 La apuesta, en un párrafo

La lectura extensiva es uno de los métodos con más respaldo para aprender una segunda lengua, y sin embargo casi nadie la practica bien, porque elegir el libro adecuado es un problema que el lector no puede resolver solo. LiteraLevel convierte una medida continua de dificultad —producida por un modelo que lee el texto entero, no la portada— en tres decisiones cotidianas: **qué leer ahora**, **por dónde se va a complicar** y **qué significa esta palabra en esta frase**. El activo defendible no es el modelo, que es pequeño y replicable: es la cadena completa desde el corpus hasta el pulgar de una persona de quince años en un teléfono.

3.3 Descripción de usuarios

Tres perfiles, con lo que cada uno necesita y con lo que hoy hace en su lugar. No son personas inventadas para rellenar: el primero está observado directamente (apartado 3.4) y los otros dos se derivan de las peticiones reales recogidas durante el desarrollo.

3.3.1 Usuaria primaria: la estudiante de preparatoria

Perfil. 14 a 18 años. Estudia inglés en la escuela, entiende bastante más de lo que cree, no sabe qué es el MCER y no le interesa. Entra desde el teléfono, casi siempre en vertical, y en pantallas de unos 390 px de ancho. Su tolerancia a la fricción es de segundos. Sus necesidades y la respuesta del producto están en el cuadro 2.

Necesidad	Cómo se atiende
Saber por dónde empezar sin sentirse examinada	Seis preguntas sobre hábitos observables —con qué frecuencia lee, si necesita diccionario, si ve series sin subtítulos, si ha terminado un libro entero— y **cero jerga gramatical**
Juzgarse ante algo real y no ante una descripción	Tres fragmentos literarios en escalera (*Alice*, Sherlock Holmes, *Frankenstein*), pintados con la tipografía del lector para que se lean como un libro y no como un formulario. Pesan 0,65 en el cálculo del nivel: delante de un texto real la gente se juzga mejor que describiéndose
Que le propongan algo, no una biblioteca	Un botón de «Sorpréndeme con algo de mi nivel» además de la búsqueda
Poder usarlo con el pulgar	Objetivos táctiles de 44 px, controles repartidos en filas que caben en 390 px, mandos de navegación también debajo del texto
No perderse	Al terminar el cuestionario, un enlace que salta directamente al buscador **con la recomendación ya hecha**

Cuadro 2: Necesidades de la usuaria primaria y respuesta del producto. Qué hace hoy en su lugar: elige por portada o por título conocido, abandona a las tres páginas y concluye que el problema es ella.

3.3.2 Usuario secundario: el adulto autodidacta

Perfil. 25 a 55 años. Ya lee en inglés con esfuerzo. Su problema no es empezar, es **subir de escalón sin abandonar**. Tiene libros a medias y no recuerda por dónde iba en ninguno.

- **Continuidad.** «Mis libros» guarda cada libro empezado con su barra de avance y el capítulo por el que iba, y lo reabre exactamente ahí. Es la petición literal que originó el módulo: *«un apartado con mis libros, los que estoy leyendo, que se queden guardados, en qué partes voy»*.
- **Saber a qué se enfrenta antes de comprometerse.** La ficha del libro dice cuánto tarda en leerlo **a 180 o 110 palabras por minuto** según le quede por debajo o por encima de su nivel, cuánto es diálogo y qué palabras se repiten. Las palabras y el tiempo salen del fichero completo; la longitud de frase, el diálogo y el vocabulario, de una muestra con tope de 60.000 palabras.
- **Vocabulario que persista.** «Mis palabras» guarda cada consulta con su frase y su libro, que es la unidad que sirve para recordar. Deliberadamente **no hay puntos ni rachas**: la evidencia sobre recompensas externas (Deci y col., 1999) indica que premiar una actividad que ya gusta la deteriora, y leer ya es gratificante.
- **Pronunciación.** Lee bien y suena mal, y nadie se lo corrige. La aplicación marca palabra por palabra qué sonó bien y qué no.

3.3.3 Usuario institucional: el docente de inglés

Perfil. Da clase a grupos heterogéneos y necesita repartir lecturas graduadas. No puede leerse cuarenta libros para clasificarlos.

- Un catálogo **medido**, no etiquetado a ojo, con la dificultad por capítulo para poder asignar fragmentos y no obras completas.
- Una declaración honesta de lo que la herramienta no es, para poder usarla sin incurrir en una promesa que no puede cumplir: **LiteraLevel no certifica ningún nivel del MCER**.
- Reproducibilidad: poder comprobar de dónde salen los números.

Este perfil es el que justifica dos decisiones que a un usuario final le dan igual: publicar el guion de validación y mantener el aviso de alcance visible.

3.4 El ciclo de usuario real: Esmeralda

La única prueba que vale es la que hace alguien que no sabe dónde hay que pulsar. **Esmeralda, 15 años, estudiante de preparatoria**, prima del autor, fue la primera persona ajena al proyecto que usó la aplicación. Lo que dijo, sin edulcorar:

> *«Está bien difícil de usar en celular.» — ¿Qué parte? — «Casi todo.»*
>
> *«No me gustan los colores… la página se siente antigua, todo muy recto, muy marcado.»*
>
> *«¿Qué es eso de 10?»*
>
> *«O yo soy muy tonta para esto.»*

La cuarta frase es la importante, y es la que ordena todo lo que vino después. **Cuando un usuario concluye que el tonto es él, el fallo es del diseño.** Krug (2014) formula la misma idea como regla de producto: si el usuario tiene que pensar para entender un control, el control está mal. A partir de ahí se diagnosticó qué producía cada queja y se corrigió (cuadro 3).

Lo que dijo	Diagnóstico	Corrección	Verificación
«¿Qué es eso de 10?»	La etiqueta «Resultados» junto a un número no dice qué cuenta	«¿Cuántos te propongo?», con explicación	Etiqueta reescrita
Creyó que «Recomiéndame por nivel» tendría en cuenta sus gustos	La etiqueta prometía más de lo que hacía	«Sorpréndeme con algo de mi nivel»	Etiqueta reescrita
—	«Ajustar a mi nivel» es abstracto	«Acercar los resultados a mi nivel · no descarta libros»	Etiqueta reescrita **dos veces**: la primera versión, «Solo libros que pueda leer», prometía un filtro que la búsqueda no hace
—	«Medir la dificultad de este capítulo» es lenguaje de laboratorio	«¿Cómo de difícil es este capítulo?»	Etiqueta reescrita
—	«Vistazo rápido a la dificultad» no dice cuánto tarda	«Vistazo rápido (unos segundos)»	Etiqueta reescrita
—	«Analizar el libro entero» no advierte del coste	«Leer el libro entero (tarda más)»	Etiqueta reescrita

Lo que dijo	Diagnóstico	Corrección	Verificación
«No me gustan los colores»	El color es gusto, y el gusto no se discute: se ofrece	**Cinco paletas** con pestaña propia y cambio instantáneo: *hielo* (la original), *amanecer* (clara, crema y naranja), *menta*, *papel* (para leer horas) y *medianoche*	Una prueba automática comprueba las cinco contra el criterio de contraste **WCAG AA (4,5:1)** (World Wide Web Consortium, 2023). Las cinco pasan en las **ochenta y cinco parejas** de color que se comprueban —diecisiete por paleta, cada una con su umbral: 4,5:1 para el texto normal y 3:1 para el título grande—. La más ajustada del texto normal mide **4,53** y la del título, **3,11**
«Todo muy recto, muy marcado»	Esto no es gusto, es diseño, y se corrige para todas las paletas	Esquinas de 14 px, bordes finos, sombras suaves y las opciones de lista como fichas tocables	—
«Difícil de usar en celular… casi todo»	En un móvil, el círculo de un botón de radio es un blanco de 12 px	La ficha entera pasa a ser el blanco: **44 px**	—

Cuadro 3: Del comentario de una usuaria a un cambio verificable.

3.4.1 Lo que ya se había corregido antes, por la misma vía

El ciclo de Esmeralda no fue el primero. Probar la aplicación en un teléfono real —y no en el navegador del escritorio— había descubierto antes fallos que **ninguna de las 303 pruebas automáticas podía encontrar, porque todos necesitaban un dedo y una pantalla pequeña**:

- El doble toque para consultar una palabra **no funcionaba en el móvil**: el código escuchaba solo el evento del ratón, que iOS no emite al seleccionar con el dedo. La instrucción en pantalla prometía algo que el dispositivo no hacía.
- Los títulos de la tabla de resultados eran enlaces a `gutenberg.org`, así que tocarlos **sacaba al lector fuera de la aplicación**.
- El resultado del nivel se pintaba en la parte superior de la página, fuera de la pantalla: la usuaria no se enteraba de que había terminado.

- Al pedir «traer una frase del capítulo» sin frase disponible, el campo se vaciaba y **borraba lo que el usuario había escrito**, sin decir nada.
- «Mis libros» mostraba 24 entradas llamadas `vacio.txt`, `falso.txt` y similares: la batería de pruebas anotaba sus ficheros de ataque en la biblioteca **real** de quien las ejecutara. Los datos personales del usuario eran el banco de pruebas.

3.4.2 El segundo ciclo: Laura

El 12 de septiembre de 2026 la probó **Laura**, hermana del autor y desarrolladora web, sobre la aplicación **desplegada**: primero en la laptop y después en su teléfono Android. Mandó tres capturas y dos notas de voz, que se transcribieron y se conservan íntegras en el repositorio (`auditoria/feedback_laura_2026-09-12.md`). Su crítica es de usuaria y de diseñadora a la vez:

> *«Hago el movimiento de deslizar con el dedo y dos, tres segundos y la página se empieza a mover.»*
>
> *«No dejas un espacio entre el cuadro y lo que escribes… se come el palito de la P.»*
>
> *«Doy a siguiente capítulo y me deja ahí mismo abajo.»*
>
> *«Lo que pones en los tres circulitos son configuraciones, no son funcionalidades.»*
>
> *«No entiendo el sonido W que es diferente a la letra B.»*

Lo que dijo	**Diagnóstico**	**Corrección**	**Verificación**
Retraso de 2–3 s al deslizar en el teléfono	`backdrop-filter` en más de cien bloques y fondo con `background-attachment:fixed`: repintado completo en cada fotograma	Los dos efectos, solo en dispositivos con ratón	Con emulación táctil quedan desactivados; **falta confirmarlo en un teléfono real**
El texto toca el borde redondeado	Los bloques de Markdown de la interfaz de entonces (Gradio) no tienen relleno, pero aquí todos llevan fondo de panel	Relleno interior a los bloques con contenido	Medido y capturado a 390 y 1440 px
En modo oscuro no distingue las secciones	Panel al 72 % sobre casi negro y borde al 16 % en *hielo*, la paleta por defecto	Panel y borde más claros en las dos paletas oscuras	Las 85 parejas de contraste WCAG siguen pasando
Quiere una barra de navegación con las funciones y los ajustes aparte	*Colores* y *Estado* eran pestañas como leer o pronunciar. **El profesor había dicho lo mismo**: «Colores toma demasiada presencia»	Botón **Ajustes** en la cabecera; barra de pestañas fija arriba al bajar y centrada en escritorio	Probado en el navegador; a 390 px «Pronunciar» sigue en el menú «…»
«Siguiente capítulo» la deja al final	Los botones no movían la página	Al cambiar de capítulo sube al principio del texto	Teléfono: el lector queda justo bajo la barra con el capítulo nuevo

Lo que dijo	Diagnóstico	Corrección	Verificación
Borrar a mano la frase para practicar otra	No había forma de empezar de nuevo	Botón **«Otra frase»** bajo la corrección	Probado en el navegador
No entiende «/w/ diferente a la b» y pide «los símbolos»	La explicación comparaba con una letra, no enseñaba el AFI y ni siquiera sabía qué se había oído	Explicación anclada a palabras del español y a lo que se entendió; símbolo AFI; transcripción de la palabra del diccionario local; 41 audios pregrabados, uno por fonema, que no gastan créditos (≈0,19 USD una sola vez)	Probada de punta a punta con «fix» por «fox»: ahora culpa a la vocal y no a la /f/. **Los audios aún no los ha escuchado nadie**
Captura: «don't» marcado como «don» y «t»	El apóstrofo tipográfico de los libros partía la contracción	Se normaliza antes de comparar	Dos pruebas nuevas
Captura: «Tolstoy, Leo, graf»	El título nobiliario de Gutenberg se tomaba por parte del nombre	El autor corto se queda con apellido y nombre	Prueba nueva

Cuadro 4: El segundo ciclo, de la crítica a la verificación.

Dos de las correcciones fallaron la primera vez, y las 306 pruebas automáticas no lo vieron. La primera versión del arreglo del lector sacaba la cabecera del libro letra a letra. La del botón de siguiente capítulo no movía nada, porque el texto nuevo llega después y los botones que pulsó Laura eran los de debajo del texto. Las dos se descubrieron midiendo la página en un navegador controlado a ancho de teléfono: es la misma lección del apartado anterior, repetida.

Lo que vino después de ese ciclo cambió la interfaz entera. Ese mismo 12 de septiembre, en la revisión del avance, el profesor Barranco pidió que la aplicación entregada no fuera la de Gradio sino un *front* propio, separado del motor. La interfaz pasó a Angular sobre una API (apartado 3.5.6). Las correcciones del cuadro 4 se hicieron primero en Gradio, que sigue en marcha como motor, y las que tocan la pantalla se llevaron al *front*: los ajustes fuera de la navegación, el lector que sube al cambiar de capítulo, «Otra frase» y la ficha de cada sonido.

3.4.3 La lección, en una línea

El valor de una prueba de usuario no está en el promedio de satisfacción, sino en la frase que duele. Con $n = 2$ no se puede estimar nada, pero se pueden encontrar los fallos que hacen que una persona se culpe a sí misma, y ya hay una coincidencia: a las dos lectoras les costó el móvil y a ninguna le gustó la paleta por defecto (cuadros 3 y 4). Nielsen (2000) sitúa en cinco usuarios el punto donde se detecta la mayor parte de los problemas de usabilidad; el accionable A8 lleva la prueba hasta ahí.

3.5 Usabilidad del modelo

Un modelo es usable cuando el usuario puede confiar en él sin entenderlo. Eso se construye con cinco decisiones, todas medidas, y con la interfaz que las pone delante del lector (apartado 3.5.6).

3.5.1 La espera se traslada, no se pide

Medir un libro largo son minutos. Pedirle esos minutos al lector en el momento en que quiere leer es perderlo. La estrategia es **mover el cómputo antes de la consulta**: el catálogo se

precalcula fuera de línea y, cuando el lector busca, el trabajo ya está hecho. Los números que hacen viable esa decisión están en el cuadro 25 y en la figura 12: 8,19 ventanas/s en CPU, 112,7 en la GPU local y **2.022 en una A100**, con lo que los 61.642 libros en inglés de Project Gutenberg son **unas tres horas** de cómputo puro. De extremo a extremo son **unas diecisiete**, y la diferencia no la pone la tarjeta sino el disco; el §8.3 lo desglosa.

Cuando el cómputo sí tiene que ocurrir en vivo, se ofrecen **dos velocidades y se dice cuál se usó**: un vistazo (30 capítulos repartidos, 2 ventanas de cada uno) o el libro entero sin muestrear. Y el atajo está cuantificado, no prometido: 8 ventanas dan **1,784** y el recorrido completo del mismo capítulo, **1,743**.

3.5.2 La incertidumbre se comunica en bandas

El modelo devuelve un número continuo, pero su escala está comprimida (predicho $\approx 0{,}72 \times$ real $+ 0{,}38$; véase la figura 8). Presentar «1,27 sobre 2» como si fueran dos decimales de precisión sería mentir con exactitud. La interfaz muestra **bandas** —básico $< 0{,}6 \leq$ intermedio $< 1{,}4 \leq$ avanzado, tal como las dibuja la figura 2— y la letra MCER únicamente como orientación, siempre junto al número y con la tabla de correspondencia a la vista.

Un fallo real de esta decisión, encontrado y corregido, ilustra el nivel de cuidado que exige: el redondeo por defecto de Python resuelve los empates hacia el par, de modo que un 1,00 exacto caía en un nivel y la tabla publicada decía otro. Un usuario que comparase su cifra con la tabla habría encontrado dos respuestas para el mismo número. Ahora hay una sola regla, y una prueba fija los cinco límites.

3.5.3 Nada falla en silencio, y nada se rompe del todo

La regla transversal del sistema es la **degradación elegante**: sin clave de servicio externo, la aplicación sigue dando diccionario, fonética, buscador y puntuación, porque nada de eso sale a la red; el audio de Wiktionary es un enlace a `upload.wikimedia.org` que descarga el navegador del lector, así que necesita conexión, pero no clave ni servicio de pago. Solo se apagan tres cosas —la explicación en contexto, la corrección de pronunciación y el resumen de «¿de qué trata?» de la ficha—, y se dice con palabras que el lector entienda —«se ha agotado el presupuesto mensual de explicaciones; el diccionario, la fonética y el audio siguen funcionando»— en lugar del error técnico en crudo.

La regla de diseño es que los fallos vuelvan como texto legible en vez de excepciones sin tratar. Las pruebas cubren escenarios concretos; no demuestran que ningún manejador pueda fallar. El corte de verificación actual se distingue de las baterías históricas en el apartado 3.5.6.

3.5.4 Cada número dice de dónde viene

En la ficha del libro conviven dos clases de información y **la separación se ve en pantalla**: lo *contado* sobre el fichero (palabras, tiempo de lectura, proporción de diálogo, vocabulario) sale solo al abrirlo, es instantáneo y no necesita red; el *resumen* escrito por un modelo generativo va detrás de un botón, se guarda en disco y viene marcado como lo que es. **Ninguna cifra de la ficha la dice un modelo generativo.** En el diccionario, la regla equivalente: el modelo de lenguaje explica el contexto y la gramática sin sustituir una acepción utilizable de Wiktionary. Si no existe, desde el 13 de septiembre puede proponer una definición marcada como generada por IA, solo con acceso autorizado. La definición de diccionario y el texto generado no son lo mismo.

3.5.5 La latencia se reparte para que la pantalla no se quede quieta

En una consulta léxica nueva, casi todo el tiempo es **espera al servicio externo**: la explicación contextual se midió en **14,9 segundos** con el esfuerzo de razonamiento `low` que usa la

aplicación —eran 67,7 con el esfuerzo medio de antes—, mientras todo el trabajo local —lema, diccionario, desambiguación, fonética— son **40 milisegundos**. Por eso la ficha se pinta en dos etapas: lo local aparece al instante y la explicación se añade cuando llega. El trabajo tarda lo mismo; deja de parecer que la aplicación se colgó. La misma idea gobierna la curva de dificultad, que se repinta cada pocos capítulos mientras mide (el repintado cuesta 25 ms, medido) y los recursos pesados, que se cargan al primer uso y no al arrancar.

3.5.6 La interfaz entregada: un *front* de Angular sobre una API

Hasta el 12 de septiembre de 2026 la aplicación era una sola pieza: ocho pestañas de Gradio que hacían de interfaz y de motor a la vez. En la revisión del avance de ese día, el profesor Barranco pidió que la entrega fuera un *front* propio, separado del motor. Se hizo al día siguiente, y es lo que se entrega:

- **El *front*** es una aplicación de Angular 22 (componentes independientes, sin `zone.js`) publicada como **Space estático** de Hugging Face (`MikeMaki1763/literalevel-front`), gratuito y siempre despierto: es HTML, CSS y JavaScript ya compilados. Tiene cuatro sitios en vez de ocho pestañas —*Leer*, *Encontrar*, *Pronunciar* y *Tu nivel*—, más *Mis palabras*; los ajustes (paleta, tamaño de letra, idioma de las explicaciones) y el estado del servicio salen de la navegación, que es lo que Laura y el profesor habían pedido por separado.
- **La API** es un servicio FastAPI (`app/api.py`, 37 rutas bajo `/api`) **montado en el mismo Space de Gradio** que ya existía, con Gradio en la raíz como motor y respaldo. **Reutiliza el motor y ayudantes de Gradio**, pero sus adaptadores contienen lógica propia: topes, cobro, aislamiento y degradación requieren pruebas también en la API. Compartir funciones no basta para demostrar equivalencia. La identidad del lector viaja en una cabecera (`X-Lector`) y sus datos siguen en el bucket montado en `/data`. El primer montaje falló —el proxy de renderizado en servidor de Gradio no dejaba pasar `/api`— y el segundo, sin ese proxy, es el que está en marcha.
- **Regla de entrega:** una función existe cuando tiene ruta en la API **y** pantalla en el *front*. Lo que solo vive en Gradio no cuenta como entregado.
- **Verificación del 13 de septiembre, corte actualizado el 14:** 32 de 35 pruebas API pasaron en el entorno aislado; tres quedaron sin validar por dependencias NLP ausentes. Pasaron además 7 pruebas de concurrencia de voz, 10 del despliegue y 11 del pipeline de portadas. No se suman como una prueba completa de usuario ni sustituyen la batería histórica del motor. El backend publicado `e56cf08` se cotejó por hash y se comprobó salud JSON, lectura de Alicia en Angular, diccionario sin perfil y rechazo de voz anónima. No se probó OpenAI real ni micrófono físico en ese cierre. Evidencia: `auditoria/despliegue_codex_2026-09-13_noche.md`.

Lo que el *front* añadió a la usabilidad en un día. Tres cosas, y las tres salieron de mirar cómo se usa un teléfono:

- **Uso con una sola mano.** Un estudio propio (`investigacion/una_mano.md`) fijó diez reglas a partir de la literatura sobre el alcance del pulgar y el tamaño de los objetivos; las primeras ya están en el *front*: en el lector, una barra única abajo con capítulo y página anterior y siguiente y el índice, que se esconde con la navegación; nada primario en el cuarto superior de la pantalla; en *Pronunciar*, una barra de acción fija abajo con el micrófono en el centro, que no se mueve entre grabar, parar y corregir.

- **Corrección de pronunciación con fonema determinista.** Con la misma grabación, el modelo generativo señalaba un sonido distinto en cada llamada. Ahora el fonema que falla sale de **alinear la transcripción de lo que había que decir con la de lo que se entendió** —las dos de diccionario: Wiktionary y, donde no la trae, CMUdict, 126.052 palabras bajo licencia BSD— y el consejo de boca, lengua y aire sale de una ficha fija por fonema. Del modelo queda el resumen. La selección del fonema es determinista dadas las mismas palabras y transcripciones; esto no hace determinista al reconocimiento de voz.
- **Animación del corte de la boca.** Para cada uno de los 41 sonidos del inglés americano (y los 44 del británico), un corte sagital animado —labios, dientes, paladar, velo, lengua y mandíbula— que va del reposo a la posición del sonido y vuelve; y para la palabra entera, la secuencia de sus sonidos a partir de su transcripción. Son SVG animados con CSS, sin JavaScript, generados una vez en el servidor y servidos por la API; el *front* los enseña en la ficha de cada sonido y en la corrección —primero el sonido que falla y después la palabra—, y con «reducir movimiento» del sistema los deja quietos.

Corte técnico pendiente de publicación. Al cierre anterior, Blender tenía una demo local del corte 3D, pendiente de integración pública y revisión anatómica; el respaldo publicado seguía siendo 2D. Las portadas FLUX no se generaron: el pipeline exige saldo, tarifa actual, aprobación de muestras y permiso separado para publicar. La selección local de 1.200 libros contiene 746 motivos temáticos y 454 genéricos. Su calidad visual sigue sin comprobarse. El enlace del lector es https://mikemaki1763-literalevel-front.static.hf.space/.

El 14 de septiembre se volvieron a contar con pandas **53.179 IDs únicos y 585.111 capítulos** en el catálogo local. Es una comprobación del artefacto, no una nueva inferencia. Las 37 rutas API se contaron en el código. En el cierre remoto anterior, *house* eligió un sentido no adecuado para una frase sobre la ubicación de un edificio: disponibilidad del diccionario no demuestra desambiguación correcta en todos los casos. Estos límites también forman parte de la entrega.

3.6 Accionables

Diez acciones concretas (cuadro 5), ordenadas por puntos de rúbrica protegidos u obtenidos por hora de trabajo. Cada una lleva coste real y criterio de terminado. No son «se podría»: son «se hace».

#	Acción	Por qué	Coste	Terminado cuando
A1	**Publicar el modelo y el diccionario** como repositorios abiertos	Desbloquea que el cuaderno corra en un Colab ajeno. Es el mayor rendimiento por hora de todo el proyecto	∼30 min; gratuito. Requiere un token que solo el autor puede crear	**HECHO a medias**: el modelo está en `MikeMaki1763/literalevel-v4`, público y con la descarga sin credenciales verificada; el diccionario (243 MB) sigue sin publicar

#	Acción	Por qué	Coste	Terminado cuando
A2	**Desplegar en enlace permanente**	El enlace anterior era un túnel temporal que moría al apagar el equipo, y era el mayor riesgo de la entrega	**7 USD/mes**: el Space de Gradio que aloja el motor y la API exige cuenta Hugging Face Pro (9 USD de tarifa, 7 con descuento); el hardware `cpu-basic` no añade coste, y el Space estático del *front* es gratuito	**HECHO**: `MikeMaki1763/literalevel-front` (el *front*) y `MikeMaki1763/literalevel` (API y motor), públicos y en marcha; el disco persistente es A4
A3 · HECHO	**Terminar la remedición del catálogo** con el modelo v4, libro entero	Sustituye las etiquetas heredadas —predicciones de un modelo v1 sobre las primeras ∼190 palabras— por medidas reales	T4 gratuita; la descarga por el volcado de Common Pile (57.226 textos en 7,7 minutos) y los resultados en Hugging Face, no en Drive, que pedía un permiso en cada sesión (§8.3)	**Cumplido el 12 de septiembre de 2026**: 53.179 libros y 585.111 capítulos medidos, y la aplicación los usa
A4 · HECHO	**Montar almacenamiento persistente** para los datos del lector	Un servicio que duerme y despierta con la estantería vacía deja en ridículo «Mis libros»	18 USD por TB y mes en repositorio privado; los datos del lector ocupan 10,9 MB medidos, así que el coste es despreciable	**Cumplido y verificado**: bucket montado en `/data`; se fijó un perfil, se reinició el Space y el perfil seguía ahí

#	Acción	Por qué	Coste	Terminado cuando
A5	**Conseguir un micrófono** (auriculares con micro)	El equipo actual no tiene. Sin él no se puede demostrar la corrección de pronunciación, que es la función más vistosa y la que mejor encaja con «usabilidad para el usuario final»	Coste mínimo de hardware	Se graba una frase desde el equipo del autor y la corrección palabra por palabra aparece en pantalla
A6 · HECHO	**Sustituir el catálogo heredado** de 1.197 registros	Incluía 1.049 registros sin texto descargable, el 87,6 % de aquella versión, no de la actual	Incluido en A3	El catálogo medido actual contiene 53.179 IDs de Gutenberg; se mantienen las exclusiones de índices y obras no literarias en la recomendación
A7	**Calibrar la escala** con una transformación afín de dos parámetros ajustada sobre entrenamiento, sin tocar los pesos	La escala está comprimida y un A2 puntúa cerca de B1. La técnica ya se aplicó con éxito a una variante anterior	Una tarde	Las medias por nivel siguen estrictamente crecientes **y** se acercan a sus anclas
A8	**Repetir la prueba de usuario con cinco lectores** de perfiles distintos sobre Angular, con guion de tareas y observación en silencio	Los dos ciclos previos encontraron fallos graves; no validan todos los cambios del nuevo front (Nielsen, 2000)	Cinco sesiones de 20 min	Existe una lista priorizada de hallazgos y las tres primeras correcciones están hechas
A9	**Instrumentar la métrica que de verdad importa**: proporción de libros empezados que se terminan, con recomendación y sin ella	Todo lo demás son métricas de proceso. Esta es la única que valida la propuesta de valor	Una jornada de instrumentación, respetando el aislamiento por sesión	Hay una cifra base con la que comparar dentro de un mes
A10	**Ampliar el corpus de anclaje MCER** más allá de los 654 documentos actuales	Es el eslabón más delgado de la cadena de evidencia y el que limita la confianza en la letra que se muestra	Trabajo de corpus, sin coste de cómputo	El corpus de anclaje supera los 1.000 documentos con niveles de fuente institucional

Cuadro 5: Accionables, con coste y criterio de terminado.

Orden de ejecución actualizado: ensayar la voz con micrófono real (A5), recorrer Angular con usuarios (A8), grabar el video y comprobar los archivos de entrega. A2, A3, A4 y la sustitución del catálogo de A6 ya tienen evidencia de cierre; no se vuelven a presentar como trabajo por

empezar. Las mejoras visuales pendientes no deben desplazar el ensayo de la demo.

3.7 Métricas de éxito

Nivel	Métrica	Estado
Modelo	Orden estrictamente creciente por nivel MCER en corpus externo	**Cumplido**: 0,5040 · 0,5561 · 0,9276 · 1,2414 · 1,4952
Modelo	Señal por encima de la longitud del texto	**Cumplido**: correlación parcial 0,668
Producto	Un usuario sin formación técnica completa el recorrido	**Cumplido con reservas**: lo completó, y de esa sesión salieron las nueve correcciones del Cuadro 1 de la estrategia —seis de ellas etiquetas—
Producto	Accesibilidad de color	**Cumplido**: las ochenta y cinco parejas de color de las cinco paletas superan WCAG AA; las más ajustadas, 4,53 (texto) y 3,11 (título)
Producto	Robustez	**Parcial, corte 13–14 sep**: API 32/35 en entorno aislado; tres sin validar por dependencias NLP. Voz concurrente 7/7, despliegue 10/10 y portadas 11/11; no equivalen a una prueba completa de usuario
Operación	Enlace permanente disponible	**Cumplido**: el *front* en `MikeMaki1763/literalevel-front` y la API con el motor en `MikeMaki1763/literalevel`, los dos en Hugging Face Spaces, públicos y en marcha, con los datos del lector en un bucket montado en `/data`
Operación	Catálogo medido, no heredado	**Cumplido** el 12 de septiembre de 2026: 53.179 libros y 585.111 capítulos medidos por el v4 (A3)
Impacto	Proporción de libros terminados	**Sin instrumentar** (A9)

Cuadro 6: Métricas por nivel, con su estado real.

3.8 Riesgos

4 Descripción de los datos

Todos los datos de este trabajo provienen de **corpus académicos publicados, APIs y descarga directa de repositorios de dominio público**. No se usó Kaggle como fuente de datos en ningún punto del proyecto, conforme a la restricción del módulo. Cuando un corpus tiene licencia restrictiva se dice, y su texto crudo nunca sale del entorno de cómputo: solo estadísticas agregadas.

4.1 Inventario de fuentes

4.2 Relevancia de cada fuente

CLEAR es el corpus central del modelado. Su variable objetivo, `BT_easiness`, no es una fórmula de legibilidad: es una escala construida a partir de comparaciones pareadas juzgadas por lectores humanos, lo que evita que el modelo aprenda a reproducir un contador de sílabas. Además trae precalculadas once métricas clásicas (Flesch, Flesch-Kincaid, ARI, SMOG, Dale-Chall, CAREC, CAREC_M, CML2RI, conteos de palabras, oraciones y párrafos) y dos variables de estratificación —`Categ` (literario/informativo) y `Lexile Band`— que permiten comprobar si el

Riesgo	Impacto	Mitigación
El enlace de la demostración muere durante la evaluación	Alto	A2: despliegue permanente, probado desde un dispositivo ajeno antes de la fecha
El servicio externo de lenguaje agota su presupuesto en mitad de una demostración	Medio	Ya mitigado: la aplicación degrada con un mensaje legible y conserva diccionario, fonética, audio, buscador y puntuación
Que la letra MCER se lea como una certificación	Alto, reputacional	Declaración de alcance en el documento y aviso permanente en pantalla
Que la remedición del catálogo no termine a tiempo	**Resuelto**	Terminada el 12 de septiembre de 2026: sin Drive, con los resultados en Hugging Face tras cada lote, 0 errores y ningún libro medido dos veces
Sobrecarga del espejo de descarga de Project Gutenberg	Medio, ético	Seis hilos y no treinta, cada uno con su pausa entre peticiones; y el vocabulario se obtuvo del SPGC, no rascando el sitio
Contenido inapropiado para una lectora menor de edad	Medio	Decisión razonada de **no filtrar por contenido** y avisar en la ficha; se argumenta en el apartado 8.4

Cuadro 7: Riesgos y mitigaciones.

modelo funciona igual de bien en narrativa que en divulgación. Esa comprobación por dominio se hizo y aparece en el apartado 7.3.

OneStopEnglish aporta algo que CLEAR no puede: el mismo artículo reescrito en tres niveles. Como el contenido es idéntico y solo cambia la complejidad lingüística, permite medir el orden dentro de cada artículo, una prueba mucho más exigente y limpia que comparar textos distintos entre sí.

British Council es la única fuente con niveles MCER asignados por una institución de enseñanza de idiomas, que es exactamente la escala que el producto muestra al usuario. Es el juez final.

SPGC existe por una razón de higiene: descargar decenas de miles de libros uno a uno desde `gutenberg.org` viola su política de acceso automatizado. El SPGC publica los conteos de palabras ya calculados, con lo que se obtiene la distribución léxica del catálogo completo sin tocar el servidor de Gutenberg.

Kaikki/Wiktionary sustituyó a una API comercial de diccionario. La decisión fue de producto y de derechos: un SQLite local de 1,48 millones de entradas no tiene límite de peticiones, no cuesta dinero por consulta y no puede desaparecer si un proveedor cambia sus condiciones. Se descartó explícitamente Oxford Dictionaries.

4.3 Calidad de los datos: lo que está bien y lo que no

Un apartado de calidad que solo diga «los datos están limpios» no informa. Estos son los problemas reales encontrados y qué se hizo con cada uno.

(a) El corpus de validación MCER no es homogéneo. De los 59 textos de British Council, una parte no es prosa: en A1 hay un menú de restaurante, un horario de estudio, un tablero de salidas de aeropuerto, tarjetas de visita y mensajes de texto. Se definió un filtro de prosa continua por dos vías independientes —por palabras clave del título y por estructura (≥ 7 palabras por línea y densidad de puntuación final de frase en el intervalo $(0;\ 0{,}11]$)—, que coinciden en 53 de 59 casos, el 89,8 %.

Ese filtro es el del análisis, no el que aplica la aplicación, y conviene no confundirlos porque dan resultados distintos. Lo que corre en producción es `scoring.continuous_prose`, con otras reglas: al menos 150 palabras, al menos cuatro frases, entre 5 y 55 palabras de media por frase, y rechazo si más del 17,5% de las palabras viven en líneas de maquetado —viñetas o líneas

Fuente	Qué aporta	Tamaño	Origen	Licencia / acceso
CLEAR Corpus	Etiqueta continua de legibilidad (`BT_easiness`) para el modelado supervisado	4.724 extractos	Repositorio público del proyecto CLEAR (Crossley y col., 2023)	Uso investigador, descarga directa
OneStop-English	Corpus de **afinado** de la variante v2 (151 artículos), validación ordinal en 3 niveles sobre los 38 reservados y **validación externa del v4** (560 unidades)	567 textos (189 por nivel)	GitHub (Vajjala & Lučić, 2018)	CC BY-SA 4.0
British Council LearnEnglish	Validación externa contra niveles MCER oficiales	59 textos A1–C1	Descarga de los PDF públicos, con la URL y el SHA-256 de cada uno en un manifiesto	Con derechos: no se distribuye ni se imprime texto, pero se reconstruye y se verifica byte a byte
SPGC (Standardized Project Gutenberg Corpus)	Lista global de frecuencia de palabras (solo conteos, sin texto)	45.345 libros en inglés de 55.905	Zenodo, registro 2422561 (Gerlach & Font-Clos, 2018, 2020)	Abierta
Project Gutenberg	Catálogo de obras a medir y a leer dentro de la app	79.337 entradas; 61.642 libros de texto en inglés, instantánea del 7 de septiembre de 2026	Catálogo oficial (Project Gutenberg, 2026) + espejo `gutenberg.pglaf.org`	Dominio público
Kaikki / Wiktionary	Diccionario, IPA británica y americana, audio	1.487.639 filas en SQLite (243 MB); IPA en 46.794 y audio en 7.003	Volcado de kaikki.org (Ylönen, 2022)	Libre
StoryWeaver / Global Digital Library	Lecturas graduadas del catálogo heredado, retirado el 12 de septiembre de 2026	1.049 registros	API pública de contenidos	Abierta, pero sin descarga de texto

Cuadro 8: Fuentes de datos, con volumen y procedencia.

de cuatro palabras o menos— o más del 35 % de líneas cortas. Coinciden en el propósito —tirar menús, listas y tablas— pero no en los umbrales.

Y aquí hay que contar la secuencia real, porque el filtro no se fijó antes de mirar ningún resultado. El orden fue el contrario: primero se puntuaron los 59 textos, se vio que el modelo daba resultados absurdos con el menú y el tablero de salidas, y **de ese diagnóstico salió la idea del filtro**. Que las dos vías se definieran sin volver a mirar las puntuaciones, y que coincidan entre sí en el 89,8 % de los casos, es lo que impide que sea un filtro hecho a medida de las notas. Pero no es un criterio *a priori*, y llamarlo así sería regalarse una garantía que no se tiene.

(b) Las etiquetas del catálogo heredado no eran fiables, y por eso se sustituyó. El catálogo con el que la aplicación funcionó hasta el 12 de septiembre de 2026 tenía **1.197 libros** —no 12.752, como sugiere un `wc -l` ingenuo: el campo `hook` contiene saltos de línea entrecomillados y hay que contar con un lector de CSV real—. Su columna `nivel_cefr` **no es anotación humana ni metadato del editor**: son predicciones de un modelo anterior (v1) sobre las primeras ∼190 palabras de cada obra, con cortes MCER obtenidos por cuantiles. El resultado es un reparto que no resiste el sentido común (cuadro 9 y figura 3).

Nivel	Libros	%
A1	723	60,4
A2	185	15,5
C2	115	9,6
B1	69	5,8
C1	53	4,4
B2	52	4,3
Total	**1.197**	**100**

Cuadro 9: Reparto de niveles del catálogo heredado. Son predicciones de un modelo v1 sobre las primeras ∼190 palabras, no anotación fiable.

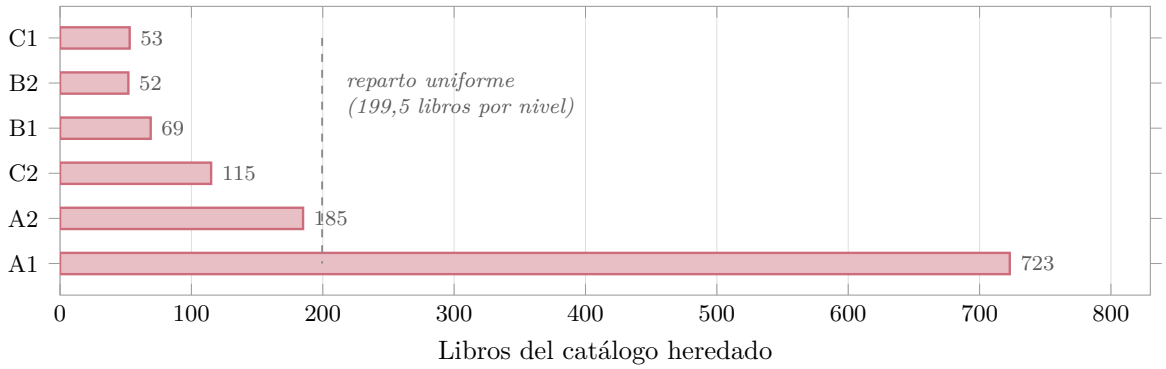


Figura 3: El sesgo del clasificador v1, visto de una vez. Seis de cada diez libros de dominio público quedaron etiquetados A1 y el tramo B1–B2 —donde está la mayoría de los lectores reales— reúne 121 de 1.197 obras. Una distribución así no describe la literatura en dominio público: describe el clasificador que la produjo. Datos del cuadro 9.

Hay cuentos infantiles etiquetados C1 y clásicos muy distintos entre sí todos en C2. Y el tramo B1–B2, donde está la mayoría de los lectores reales, eran 121 libros de 1.197. Esas etiquetas servían para ordenar y filtrar de forma aproximada, **no eran una medida fiable libro a libro**. Es la razón de ser del precálculo descrito en 8.3: remedir todo el catálogo, libro entero, con el modelo final.

Y se remidió. El 12 de septiembre de 2026 terminó: **53.179 libros de Project Gutenberg y 585.111 capítulos**, medidos enteros por el v4, sin un solo libro medido dos veces. Es lo que usa hoy la aplicación, y su reparto dice lo contrario que el heredado (cuadro 10).

Nivel	Libros medidos	Libros literarios
A1	1	
A2	40	
B1	558	290 entre A1 y B1
B2	3.127	1.676
C1	23.454	
C2	25.999	
Total	**53.179**	

Cuadro 10: Reparto del catálogo medido por el v4 (media 1,742 sobre 2). «Literarios» son los que la aplicación ofrece al recomendar por nivel: ficción, cuentos, lecturas escolares, poesía y teatro. Entre los libros «fáciles» había índices, anuarios, mapas y tablas de números, que puntúan bajo precisamente porque son listas.

La literatura del XIX es, sobre todo, C1–C2, y un lector B1 apenas tiene libros enteros a su medida. Lo que sí tiene son **capítulos**: 3.644 en 1.499 libros quedan a su alcance, y la aplicación se los ofrece. Dos cautelas: la letra es orientativa, porque la escala del modelo sale comprimida y desplazada hacia arriba, y el reparto describe el catálogo de Gutenberg, no la dificultad de la lectura en inglés en general.

(c) De aquellos 1.197 libros, solo 148 se podían abrir. Eran los de Project Gutenberg. Los otros 1.049 provenían de StoryWeaver y no tenían fichero descargable, de modo que aparecían en el desplegable de lectura como opciones muertas. Peor aún: su identificador se había usado para construir enlaces a Gutenberg extrayendo sus dígitos, con lo que `SWgdlgdl201` apuntaba al libro 201 de Gutenberg, que es otra obra. Un enlace al libro equivocado es peor que ningún enlace. **En el catálogo medido los 53.179 libros se pueden abrir**, y la aplicación los descarga en `.txt`, el mismo texto con el que se midieron, para que los capítulos del lector sean los de la curva.

(d) La licencia de Project Gutenberg se estaba puntuando como si fuera novela. El texto legal viene pegado al último capítulo: en *Alice's Adventures in Wonderland*, 2.900 de las 5.042 palabras del capítulo XII son licencia. Eso contaminaba tanto la puntuación como las estadísticas de la ficha (`gutenberg` y `project` aparecían entre las palabras más repetidas del libro). Se recorta por las marcas START/END dentro del capítulo, sin descartar el capítulo, que contiene el final de la obra.

(e) La portada no es un capítulo. En un `.txt` de Gutenberg, las 4.957 palabras previas al capítulo I (portada, índice, pies de ilustración) se estaban puntuando como si fueran la novela. En el análisis de *War and Peace*, el «capítulo más fácil del libro» resultó ser la portadilla. Se descarta con la etiqueta que el propio lector de ficheros asigna, «Antes del primer capítulo». Se probó descartar por el filtro de prosa continua y **no sirve**: se llevaba por delante dos capítulos reales de *Alice*.

5 Análisis exploratorio

Siguiendo la organización canónica del módulo, el análisis se presenta en tres niveles: univariado, bivariado y multivariado. Todas las figuras y cuadros citados se generan en el cuaderno

que acompaña a este documento.

5.1 Análisis univariado

La variable objetivo. `BT_easiness` es continua y aproximadamente simétrica alrededor de cero. No hay clases desbalanceadas que corregir porque no hay clases: el problema es de regresión. Cuando se necesitó una versión categórica para comparar modelos, se construyó por cuantiles (`qcut`), lo que garantiza seis grupos equifrecuentes y hace que la exactitud sea comparable entre modelos.

Las variables textuales derivadas. Sobre cada extracto se calcularon, a partir de sus *tokens*, seis variables de ingeniería propia: longitud media de oración, *type-token ratio*, longitud media de palabra, proporción de palabras raras, sílabas medias por palabra y porcentaje de polisílabos. Todas son positivas y con cola derecha, como es habitual en variables de conteo sobre texto.

La distribución del vocabulario inglés. El agregado de los 45.345 libros del SPGC arroja **2.838.258.803 palabras** y un vocabulario único de **3.295.146 formas**. La distribución sigue la ley de Zipf (Zipf, 1949) con precisión: unas pocas miles de palabras cubren la mayor parte del texto corrido. Este hecho, que parece de trivia, tiene una consecuencia práctica que se documenta en 5.2.

El catálogo. El cuadro 9 y la figura 3 muestran el reparto de niveles del catálogo heredado. Su forma —60 % en A1— es en sí misma un hallazgo del análisis exploratorio: una distribución así no describe la literatura en dominio público, describe el sesgo del clasificador que la produjo. El catálogo medido por el v4 (cuadro 10) lo confirma por el lado contrario: 53.179 libros, y solo 599 por debajo de B2.

La dificultad dentro de un libro. La unidad de análisis del producto no es el libro sino el capítulo, y la figura 10 muestra por qué: los 362 capítulos de *War and Peace*, medidos sin muestrear, se reparten entre 1,333 y 1,990 con media 1,735. La figura 11 añade dos libros más y confirma que la dispersión interna es la norma, no la excepción.

5.2 Análisis bivariado

Cada variable frente a la dificultad. La matriz de correlación de las variables derivadas contra `BT_easiness` confirma el sentido esperado: los textos más fáciles tienen oraciones más cortas, palabras más cortas, menos polisílabos y menor proporción de palabras raras. La correlación de `rare_word_ratio` con `BT_easiness` es negativa, como debe ser.

El experimento de saturación léxica. La variable «palabra rara» depende de qué lista de palabras familiares se use. Se probaron tres, de menor a mayor (cuadro 11).

Lista de palabras familiares	Libros	Correlación de `rare_word_ratio` con `BT_easiness`
Corpus Gutenberg de NLTK	18	−0,379
Muestra propia de Gutenberg	397	−0,330
SPGC completo, en inglés	**45.345**	**−0,326**

Cuadro 11: Efecto de escalar el corpus de referencia léxica. La correlación no mejora.

Este es un **resultado negativo y se reporta como tal**: multiplicar por 2.500 el corpus de referencia no mejora la señal, e incluso la baja marginalmente. La exactitud del clasificador de tres clases se mantuvo en 0,51 con las tres listas. La explicación está en la ley de Zipf: la distribución de frecuencias del inglés converge muy rápido, así que las 3.000 palabras más frecuentes de 18 libros y las de 45.345 libros son casi el mismo conjunto. El valor del paso

no está en la métrica sino en la cobertura: la lista del SPGC generaliza mejor a texto nuevo arbitrario, que es lo que la aplicación recibe.

Dificultad frente a longitud, la variable incómoda. Sobre los 47 textos de British Council medibles en local, contar las palabras del texto —sin modelo alguno— alcanza una correlación de Spearman de **0,807** con el nivel oficial. El modelo alcanza 0,860. Es decir: en ese corpus, nivel y longitud están confundidos, porque los materiales de examen gradúan también la extensión de la tarea. Publicar ese *baseline* antes de que lo pregunte el evaluador es más creíble que omitirlo; en el apartado 7.5 se cuantifica cuánta señal aporta el modelo por encima de él.

Dificultad frente a dominio. El nivel del texto está correlacionado con su tipo documental. Al filtrar los 59 textos de British Council a prosa continua, el nivel A1 desaparece casi por completo y el rango evaluable **de esa tanda de análisis** se encoge de cinco niveles a cuatro (A2–C1): el catálogo gratuito de British Council no tiene C2, así que el corpus nunca tuvo seis. La reproducción local del cuadro 18 sí conserva los cinco, con tres textos en A1, porque filtra con otras reglas. Por eso el *baseline* de contar palabras cae de 0,879 a 0,765 al filtrar: parte de la señal del conjunto completo era simplemente que los textos A1 son cortos. Las correlaciones antes y después del filtro **no son comparables entre sí**, y se reportan por separado. Los conjuntos de textos que aparecen aquí y en el apartado 7.4 están todos, con lo que se puede y no se puede hacer con cada uno, en el cuadro 16.

5.3 Análisis multivariado

Las variables clásicas se estorban entre sí. Las métricas de legibilidad tradicionales (Flesch, Flesch-Kincaid, ARI, SMOG, Dale-Chall) son transformaciones distintas de los mismos dos ingredientes —longitud de oración y longitud de palabra— y por tanto están fuertemente correlacionadas entre ellas. Meterlas todas en un modelo lineal no añade información: añade multicolinealidad. Por eso el conjunto de trabajo se redujo a **tres** variables poco redundantes entre sí y con interpretación distinta: `avg_sentence_length` (complejidad sintáctica), `rare_word_ratio` (carga léxica) y `type_token_ratio` (diversidad de vocabulario).

Hasta dónde llegan las variables clásicas. Con esas tres variables, un clasificador de seis clases alcanza 0,29 de exactitud con regresión logística (Pedregosa y col., 2011) y 0,28 con XGBoost (Chen & Guestrin, 2016). Que un ensamble de árboles —capaz de capturar interacciones no lineales arbitrarias— no supere a un modelo lineal es la prueba de que **el cuello de botella no era el modelo sino la representación del texto**. Tres números por documento no bastan para separar seis clases.

Conviene decir qué sostiene ese argumento y qué no. Lo que se comprueba es que **subir la capacidad del algoritmo sobre estas variables no mueve el resultado**, y eso se ve en cuatro modelos distintos. Lo que no se demuestra es que exista un límite teórico: nadie ha probado todas las combinaciones posibles de conteos, y el cuadernillo enseña un caso donde ampliar de tres a diecisiete variables sí mejora. La conclusión honesta es empírica, no un techo.

Representación densa. Al sustituir las tres variables por un *embedding* de 384 dimensiones de `all-MiniLM-L6-v2` (Reimers & Gurevych, 2019), la exactitud salta a 0,37 y el error ordinal medio baja de 1,39 a 0,93 niveles. El modelo híbrido (*embedding* + las tres variables clásicas) da 0,37 y 0,91: prácticamente lo mismo. Esto indica que **el *embedding* ya contiene la información que aportaban las tres variables**, y bastante más. La figura 4 recoge la progresión completa.

Estructura por dominio. La comparación por subconjuntos de CLEAR (literario frente a informativo, y por banda Lexile) muestra que el rendimiento no es uniforme: el modelo funciona mejor en texto informativo que en literario, y peor en la banda más fácil (Lexile 500) que en la más difícil (Lexile 1300). Los números están en el cuadro 15.

6 Procesamiento de datos

Cada transformación se documenta con su justificación. La regla que se siguió es la del módulo 1 del diplomado: **no se transforma sin medir qué se rompió**.

6.1 Sobre el texto de entrada

El cuadro 12 recoge las ocho transformaciones que sufre el texto antes de llegar al modelo; la figura 1 las sitúa en la cadena completa.

#	Transformación	Por qué	Evidencia / consecuencia
T1	**Filtro de prosa continua** antes de puntuar: se rechaza si más del 17,5% de las palabras viven en líneas de maquetado o más del 35% de las líneas son cortas	El modelo solo vio prosa; puntuar un menú da un número sin significado	El filtro estaba muerto en producción: se normalizaba *antes* de comprobar, y `normalize()` colapsa los saltos de línea, así que el detector recibía siempre una sola línea. Una carta de menú de 432 palabras se puntuaba como prosa. Corregido: el filtro va sobre el texto crudo
T2	**Normalización de espacios** (`\s+` → espacio) después del filtro	Estabiliza el troceado en bloques	Sin efecto sobre la puntuación; solo sobre el corte
T3	**Troceado en bloques de 250 palabras, mínimo 150**	Es la unidad con la que se entrenó; un bloque más corto no tiene señal suficiente	Constante del entrenamiento: cambiarla invalidaría las métricas reportadas
T4	**Truncado a 256 *tokens***	Límite de contexto del modelo	Medido: de 200 bloques de 250 palabras, el **100 %** llega exactamente a 256 *tokens* tras truncar, porque en prosa inglesa real 250 palabras superan siempre los 256 BPE. Dentro de un texto troceado así no hay relleno; agrupando ventanas de capítulos distintos sí lo hay, y eso se trata en el §8.3
T5	**Recorte de la licencia de Gutenberg** por las marcas START/END, dentro del capítulo	2.900 de las 5.042 palabras del capítulo XII de *Alice* son texto legal	Sin esto, el modelo puntuaba texto jurídico como narrativa y la ficha listaba «gutenberg» entre las palabras más frecuentes del libro
T6	**Descarte de portada, índice y portadilla** por la etiqueta «Antes del primer capítulo»	4.957 palabras de paratexto se puntuaban como novela	Se probó descartar por el filtro de prosa continua y se rechazó: eliminaba dos capítulos reales de *Alice*
T7	**Muestreo de hasta 8 bloques repartidos por el documento** para la puntuación rápida	Dar un número en segundos, no en minutos	Cuantificado: 8 bloques dan 1,784 y el recorrido completo de las 23 ventanas del mismo capítulo da 1,743. El atajo se desvía 0,041 sobre una escala de 0 a 2

#	Transformación	Por qué	Evidencia / consecuencia
T8	**Recorte de entradas del usuario en el servidor** (40 caracteres por palabra, 400 por oración, 20 MB por fichero)	El límite del navegador es una sugerencia, no una defensa	Una cadena de 3.000 caracteres pasaba el filtro de «máximo cuatro palabras» y se pintaba como encabezado: 9.312 caracteres llenando la pantalla del móvil

Cuadro 12: Transformaciones sobre el texto, con su justificación y su evidencia.

6.2 Sobre las variables del modelado clásico

#	Transformación	Por qué
T9	**Partición agrupada por libro** (`GroupShuffleSplit` sobre `Title`, 20 % de prueba, semilla 42)	Un mismo libro aporta varios extractos a CLEAR. Con una partición aleatoria por fila, fragmentos del mismo libro caerían a ambos lados y el modelo memorizaría el estilo del autor en lugar de aprender dificultad. Es fuga de datos por diseño, y se evita por diseño
T10	**Estandarización** (`StandardScaler`) ajustada solo en entrenamiento	Ajustar el escalador con los datos de prueba filtra su distribución al modelo
T11	**Discretización por cuantiles** (`qcut`) para las versiones categóricas	Produce grupos equifrecuentes, con lo que la exactitud entre modelos es comparable y el azar tiene una probabilidad conocida ($1/6 = 16{,}7\,\%$)
T12	**Lista de palabras familiares construida solo con el conjunto de entrenamiento**	Si se cuentan también las palabras de los extractos de prueba, esas palabras entran en la definición de una variable de entrada: es fuga de datos. Medida la diferencia, resulta despreciable —cambian 228 de 3.000 palabras y los resultados se mueven en la tercera decimal—, pero era fuga y se quitó
T13	**Lista alternativa a escala**: las 3.000 más frecuentes del SPGC	Sustituye una lista de 18 libros por una de 45.345. Es un experimento de cobertura, no la lista que usan los modelos del cuadernillo, y **el sistema desplegado no consulta ninguna lista de palabras**: puntúa con el transformador

Cuadro 13: Transformaciones sobre las variables tabulares.

6.3 Sobre el corpus de vocabulario (procesamiento distribuido)

Los conteos del SPGC son 45.345 ficheros pequeños. Agregarlos secuencialmente es un mal uso del tiempo y del sistema de ficheros, de modo que la agregación se hizo con **PySpark** (Zaharia y col., 2016): los ficheros se distribuyen en 200 particiones, un `flatMap` los convierte en pares (palabra, conteo) y un `reduceByKey` los suma en una única lista global de frecuencia. Es el patrón canónico de conteo distribuido y es lo que hace tratable un corpus de 2.838 millones de palabras en una sesión de Colab.

6.4 Sobre el diccionario

El volcado de Kaikki llega como JSONL de líneas independientes. Se filtra a entradas en inglés con palabra no vacía y se ingesta en SQLite con un esquema plano (`palabra`, `pos`, `sentidos` como JSON, `ipa_uk`, `ipa_us`, `audio_uk`, `audio_us`) y un índice por `palabra`. La justificación es de

latencia: la primera consulta sobre 1.487.639 filas tarda **0,001 s** con el índice puesto y la base abierta en modo solo lectura. Los 243 MB del fichero no cuestan nada en tiempo de respuesta.

Dos datos de cobertura que condicionan el diseño de la aplicación. Sobre las 1.487.639 entradas, solo **7.003 (0,5 %) traen audio de pronunciación** y **46.794 (3,1 %) traen transcripción fonética**; con las dos variantes —la británica y la americana— quedan **33.635 (2,3 %)**. Pero eso cuenta entradas, y el diccionario es en su mayoría palabra rara mientras que un libro es en su mayoría palabra corriente. Medido por el lado del lector —400 palabras tomadas al azar del texto de *Crime and Punishment* y resueltas por el mismo camino que usa la aplicación, lematización incluida—, **el 58 % llega con fonética y el 32 % con audio grabado**.

Las dos mediciones apuntan a lo mismo desde sitios distintos: **dos de cada tres consultas necesitan síntesis de voz**, y esa es la medición que justificó paralelizar las dos llamadas de red de una consulta en lugar de encadenarlas. La ficha de la palabra lo dice cuando toca: si no hay ni transcripción ni audio ni clave para generarlo, escribe *«de esta palabra no hay pronunciación»* en lugar de dejar el hueco en blanco.

7 Modelación

7.1 Diseño experimental

Todos los modelos comparten la **misma partición agrupada por libro** (3.774 extractos de entrenamiento y 950 de prueba) y la misma semilla, de modo que las diferencias entre ellos son atribuibles al modelo y no al reparto de los datos. Se comparan sobre los mismos 950 extractos reservados, con dos métricas: exactitud sobre seis clases y **error ordinal medio**, que penaliza proporcionalmente a la distancia del fallo.

Dos precisiones sobre ese conjunto, porque cambian cómo hay que leer las cifras. La primera: esos 950 extractos son también los que sirvieron para **elegir la época** del transformador, de modo que funcionan como validación de selección y no como un test independiente; sus números pueden ser algo optimistas. La segunda: las seis clases salen de partir `BT_easiness` en **sextiles de este corpus**, no de anotaciones del Marco Común Europeo. Se les dan nombres A1–C2 para poder ordenarlos, pero no son niveles MCER certificados ni equivalen a los del modelo desplegado, que se ancla con otro corpus. Las dos cosas son ciertas.

7.2 Progresión de modelos

Modelo	Representación del texto	Exactitud (6 clases)	Error ordinal medio	Tanda
Regresión logística	3 variables clásicas	0,29	1,39	histórica
XGBoost	3 variables clásicas	0,28	1,42	histórica
Regresión logística	3 variables clásicas	**0,313**	**1,295**	recalculada
Regresión logística	**17 variables**	**0,352**	**1,061**	recalculada
XGBoost	**17 variables**	**0,340**	**1,081**	recalculada
Regresión logística	*Embedding* MiniLM (384 d)	0,37	0,93	histórica
Regresión logística	Híbrido (*embedding* + 3 variables)	0,37	0,91	histórica
`roberta-base` afinado	**Texto crudo, atención**	**0,46**	**0,67**	histórica

Cuadro 14: Progresión de modelos sobre los mismos 950 extractos reservados, con la tanda de la que procede cada fila. La mejora acompaña siempre al enriquecimiento de la representación, no a la complejidad del clasificador.

La lectura del cuadro 14 es la tesis metodológica del trabajo: **cada vez que se le dio al modelo una representación más rica del texto, el desempeño subió; y cuando solo**

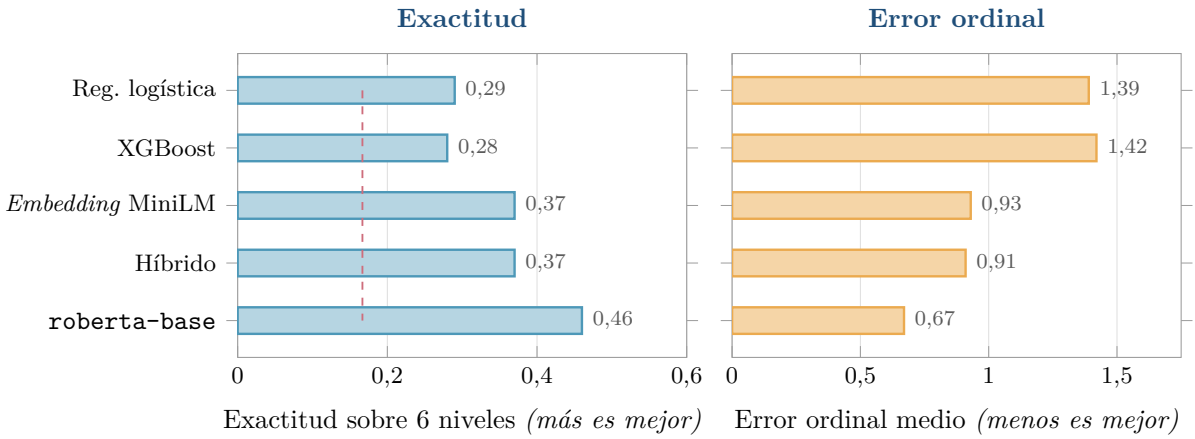


Figura 4: La tesis metodológica del trabajo, en dos ejes. Los dos primeros modelos comparten *representación* (tres variables clásicas) y solo cambian de clasificador: XGBoost no mejora a la regresión logística, incluso empeora el error ordinal. Los saltos ocurren cuando cambia la representación del texto: *embedding* denso primero, texto crudo con atención después. La línea roja discontinua del panel izquierdo marca el azar ($1/6 = 0{,}167$), que es lo que acertaría un clasificador que no leyese nada. Datos del cuadro 14.

se aumentó la potencia del clasificador sobre la misma representación pobre, no subió. XGBoost sobre tres variables es marginalmente peor que una regresión logística sobre las mismas tres variables.

El modelo afinado directamente sobre el texto es un `roberta-base` de 125 millones de parámetros con cabeza de regresión sobre `BT_easiness`, y alcanza además **RMSE 0,560** y **correlación de Pearson 0,89** con la etiqueta continua real.

Y aquí hay que evitar una confusión que el documento invitaba a hacer. Ese `roberta-base` **no es el modelo que se despliega**. El que va en la aplicación es un `distil roberta-base` —la mitad de capas, 82 millones de parámetros— y se entrenó sobre otro corpus, el de anclaje MCER, no sobre `BT_easiness`. Las cifras de este apartado son del experimento sobre CLEAR; las del modelo desplegado están en el §7.4 y no se pueden encadenar con estas. La diferencia de calidad entre las dos arquitecturas sobre CLEAR **no se midió**, así que la decisión de usar la destilada se tomó por tamaño y velocidad, no porque se comprobara que costaba poco.

Sobreajuste, visto y controlado. El entrenamiento corrió seis épocas con tasa de aprendizaje 2e-5, decaimiento de pesos 0,01, calentamiento y precisión mixta. El RMSE de validación mejoró hasta la época 3 (0,560) y a partir de ahí empeoró de forma monótona —época 4: 0,578; época 5: 0,637; época 6: 0,660— mientras la pérdida de entrenamiento seguía bajando (figura 5). Es un caso de libro. Como se guardaba un punto de control por época y se cargaba automáticamente el mejor al terminar, **el modelo reportado es el de la época 3, no el de la última**.

7.3 Dónde funciona y dónde no: análisis por dominio

Un modelo que se evalúa solo en agregado esconde sus propios puntos ciegos. Se midió la correlación con la dificultad real por subconjunto, comparando dos variantes del modelo entrenadas sobre corpus distintos (v1 sobre `BT_easiness`, v2 afinado sobre material graduado para aprendices).

Por qué la casilla de OneStopEnglish está vacía para v2, y no es un olvido. La cifra que ocupaba ese hueco —un 0,840 que hacía ganar a v2 con holgura— estaba medida sobre los 567 textos completos, y **v2 se afinó precisamente con 151 de los 189 artículos de ese corpus**. El 80 % de esos textos era su propio entrenamiento, y se comparaban contra un v1 que no los había visto nunca. No es que la cifra fuera falsa: es que no medía lo que la tabla decía

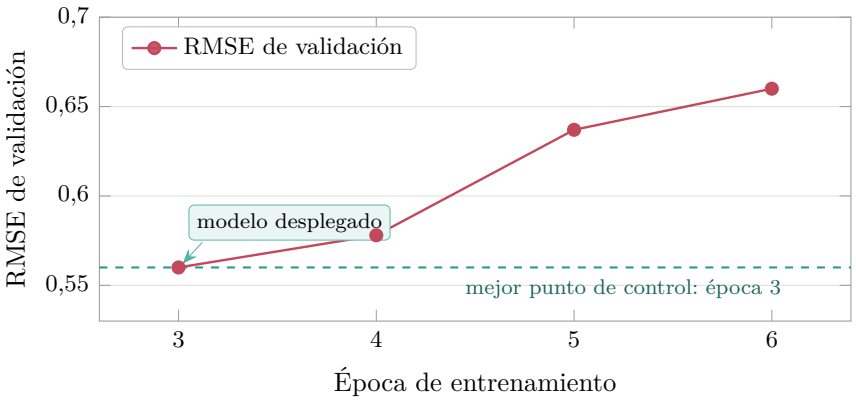


Figura 5: El sobreajuste, medido. El RMSE de validación toca su mínimo en la época 3 y empeora de forma monótona después, mientras la pérdida de entrenamiento seguía bajando. Se guardó un punto de control por época y se cargó automáticamente el mejor: el modelo desplegado es el de la época 3, no el de la sexta.

Dominio	**n**	**v1**	**v2**
Literatura (CLEAR, `Lit`)	461	**0,848**	0,760
Informativo (CLEAR, `Info`)	489	**0,905**	0,837
Banda Lexile 500 (más fácil)	62	**0,651**	0,459
Banda Lexile 1300 (más difícil)	272	**0,877**	0,773
Periodístico (OneStopEnglish)	567	0,458	*no comparable*
Exámenes MCER (British Council)	59	−0,239	**0,175**

Cuadro 15: Matriz modelo × dominio. Correlación orientada con la dificultad real; más alto es mejor.

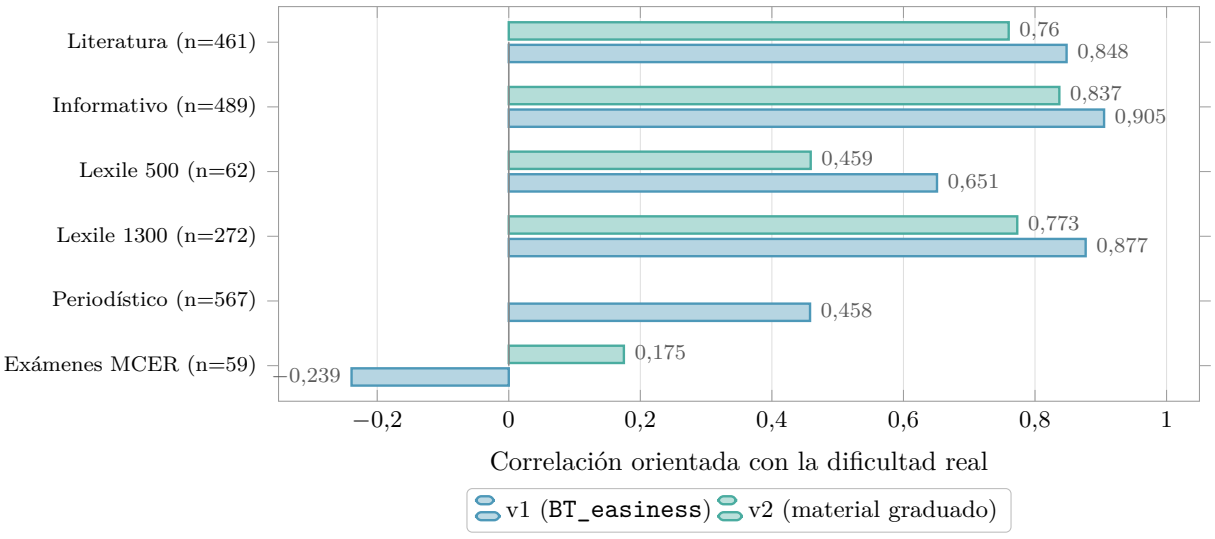


Figura 6: v1 domina en las cuatro filas de CLEAR, donde la etiqueta son juicios de lectores nativos sobre prosa continua. **A v2 le falta la barra de la fila periodística a propósito**: la cifra que ocupaba ese hueco estaba medida sobre los 567 textos de OneStopEnglish, y v2 se afinó con 151 de sus 189 artículos, así que el 80 % de ese conjunto era su propio entrenamiento. Lo detectó una auditoría externa y se retira en lugar de maquillarse. Queda por tanto sin respaldo la lectura simétrica —que v2 gane donde la etiqueta es una graduación para aprendices—, porque la única fila que la sostenía estaba contaminada. Datos del cuadro 15.

medir. Se retira en lugar de maquillarla.

Eso obliga a rebajar la conclusión que colgaba de ella. Lo que sigue en pie es que **v1 gana en dificultad de lectura tipo CLEAR** —juicios de lectores nativos sobre prosa continua—, con ventaja en las cuatro filas medidas limpiamente. Lo que **ya no se sostiene con esta evidencia** es la afirmación simétrica de que v2 gane donde la etiqueta es una graduación para aprendices: la única fila que la respaldaba estaba contaminada, y la de British Council, donde v2 sí aventaja a v1, tiene una correlación de 0,175, demasiado baja para sostener nada por sí sola.

La decisión de qué escala presentar al usuario precede a la de qué modelo desplegar; se eligió la escala anclada al MCER, y con ella el modelo correspondiente. Esa decisión no cambia, pero conviene saber que se tomó con menos evidencia de la que este cuadro aparentaba dar.

7.4 El modelo desplegado y su validación

El modelo en producción, **v4**, es un `distilroberta-base` (Liu y col., 2019; Sanh y col., 2019) de seis capas y 82 millones de parámetros, con cabeza de regresión, servido con *Transformers* (Wolf y col., 2020) y cuyos pesos ocupan 328 MB en disco. Puntúa bloques de 250 palabras truncados a 256 *tokens* y promedia sin ponderar, con un tope de **ocho ventanas por documento** repartidas a lo largo del texto: es lo que mantiene el análisis en **alrededor de un segundo** en una CPU —0,96 a 1,04 s medidos sobre ocho ventanas en el equipo del autor, un Ryzen 5 2600—, y por eso un vistazo mide una muestra del texto y no el texto entero. El precálculo del catálogo, en cambio, recorre el libro completo sin muestrear y publica una dificultad por capítulo; esa remedición **terminó el 12 de septiembre de 2026** (accionable A3), y las letras del catálogo son ya las medidas por el v4. Su escala interna es 0–5 —un valor por nivel MCER, con posiciones intermedias (A1+, A2+, B1+, B2+)— y la pública es esa misma escala multiplicada por 0,4. **El modelo es final y no se reentrena.**

Antes de las cifras, las reglas del juego. Por este apartado y por el siguiente circulan **cinco conjuntos de textos distintos**, y confundirlos es fácil porque cuatro de los cinco salen del mismo material de British Council. No son subconjuntos ordenados unos de otros y sus tamaños no se restan entre sí. El cuadro 16 dice qué es cada uno, qué se mide con él y qué *no* se puede hacer con él; el resto del apartado los cita por su nombre.

Cuadro 16: Los cinco conjuntos de textos que aparecen en la validación. Cuatro de los cinco salen del mismo catálogo de British Council, con extracciones y filtros distintos: no son subconjuntos unos de otros y sus tamaños no se restan.

Conjunto	n	De dónde sale	Qué se mide con él	Qué *no* se puede hacer con él
Validación ciega (interno)	144	Partición de validación del corpus de anclaje MCER: 654 documentos aceptados, 510 de entrenamiento y 144 reservados	Exactitud, acierto dentro de ±1 nivel y Spearman 0,908 del modelo desplegado (cuadro 17)	Presentarlo como validación externa. Sale del mismo corpus con el que se afinaron los pesos, y sobre él se eligió el punto de control, así que su 0,908 no es comparable con las cifras de British Council
British Council, tanda de Colab	38	Extracción de los PDF hecha en Colab durante el entrenamiento, con su propio filtro	Spearman 0,829 y el 100 % dentro de ±1 (cuadro 17); las cuatro medias por nivel que ajustan la recta de compresión (figura 8)	Restarlo de los 47. Es otra tanda, con otra extracción y otro filtro: la diferencia no son «nueve textos concretos» que se puedan nombrar

Conjunto	n	De dónde sale	Qué se mide con él	Qué *no* se puede hacer con él
British Council, reproducción local	47	Los 59 publicados, menos 2 sin cuerpo localizable al extraer el PDF y 10 rechazados por el filtro de prosa (cuadro 19)	**El resultado principal**: el orden creciente por nivel (cuadro 18) y las tres cifras del *baseline* —0,860, 0,807 y 0,668— del cuadro 20	Leerlo como «los textos que la aplicación aceptaría». El validador local filtra más flojo que la app (§7.7)
Los que pasan el filtro completo	36	Esos mismos 47 refiltrados conservando los saltos de línea, es decir con las cuatro reglas del filtro de prosa continua activas	Cuánto depende el conjunto evaluado de una regla que el validador desactiva: sobreviven 36 y A1 se queda con un solo texto (§7.7)	Sostener el orden sobre cinco niveles. No se usa para ninguna cifra publicada en este documento
Publicados por British Council	59	Todos los PDF descargados del catálogo gratuito. Los nombres de los 59 están en el manifiesto del corpus externo	El diagnóstico del §4.3: que el corpus no es homogéneo, y el 89,8 % de coincidencia entre las dos vías con que se definió el filtro	Usarlo como corpus de validación. Incluye menús, pósters y horarios, y las correlaciones medidas sobre él no se comparan con las de después de filtrar

El corpus de anclaje MCER con el que se afinó es **ELG CEFR English** (CC BY-NC-SA 4.0), una sola fuente: 712 documentos, de los que se aceptan 654 como prosa —57 son cortos y 1 tiene forma de frase anómala—, repartidos por documento y con semilla fija en 510 de entrenamiento y 144 de validación. Esos 144 producen las cifras de la primera fila del cuadro 17.

De dónde salen esas cifras, y cómo se comprueban. Del guion de entrenamiento del v4 y de su tarjeta de métricas, que desde el 12 de septiembre de 2026 están en el repositorio (`entrenamiento_v4/`). Ese día se **recalcularon** con el guion, los pesos publicados y los datos públicos de ELG: la misma partición y las cuatro métricas idénticas a cuatro decimales (exactitud 0,5347, dentro de un nivel 0,9722, MAE 0,4985, Spearman 0,9084). Las 144 parejas de nivel y predicción están en `entrenamiento_v4/validacion_144_recalculada.csv`. Y un matiz que no se esconde: **no es un conjunto de prueba virgen**, porque el entrenamiento se quedó con el punto de control que mejor puntuaba en esos mismos 144 documentos.

Conjunto	n	Exacto	Dentro de ±1 nivel	Spearman
Validación interna (ELG reservado)	144	53,5 %	**97,2 %**	**0,908**
British Council (desarrollo)	38	50,0 %	**100 %**	0,829

Cuadro 17: Métricas del modelo desplegado. MAE de 0,499 niveles de la escala interna 0–5 —0,200 en la escala pública 0–2— en el conjunto de validación.

Un 97,2 % suena a mucho, y conviene poner al lado con qué se compara. Con seis niveles, acertar «dentro de ±1» es más fácil de lo que parece: contestar **al azar** acierta el 44,4 % de las veces, y contestar **siempre B1**, sin mirar el texto, el 50 % —ambas cifras suponiendo el nivel verdadero repartido por igual entre los seis—. El modelo llega al 97,2 %.

Esas dos referencias son teóricas y hay que leerlas como tales. Suponen el nivel verdadero repartido por igual entre los seis, y **la distribución real de los 144 documentos de validación no está publicada**. Si ese conjunto estuviera concentrado en los niveles centrales, «contestar siempre B1» acertaría bastante más del 50 %. Lo honesto es decir que un 97,2 % está muy por encima de lo que da el azar bajo una hipótesis razonable, no que la ventaja empírica

sobre un predictor constante esté medida: no lo está, porque faltan los recuentos por nivel de ese conjunto.

El resultado que de verdad sostiene el trabajo no es ninguno de esos porcentajes, sino el orden. Esto es lo que se midió: los **47 textos de la reproducción local de British Council**, cada uno con un nivel MCER oficial asignado por la institución que lo publica y ninguno usado para ajustar los pesos, puntuados con `validar_local.py` y agrupados después por su nivel. Y esto es lo que salió: **las medias por nivel quedan estrictamente crecientes en los cinco niveles disponibles**, de A1 a C1 —0,5040 · 0,5561 · 0,9276 · 1,2414 · 1,4952 en la escala 0–2—, y la correlación de Spearman con el nivel oficial es de **0,860** (cuadro 18, figura 7 y cuadro 20). Ese orden —no el acierto exacto— es el resultado que el trabajo afirma haber conseguido, y es el que se cita en las conclusiones.

Nivel oficial	n (local)	Media en escala 0–2	Desviación
A1	3	0,5040	0,111
A2	8	0,5561	0,223
B1	12	0,9276	0,198
B2	12	1,2414	0,236
C1	12	1,4952	0,172

Cuadro 18: Reproducción local de la validación externa, sobre los 47 textos que quedan tras la extracción de los PDF **y el filtro de prosa continua**. Fuente: `datos_figuras/validacion.dat`.

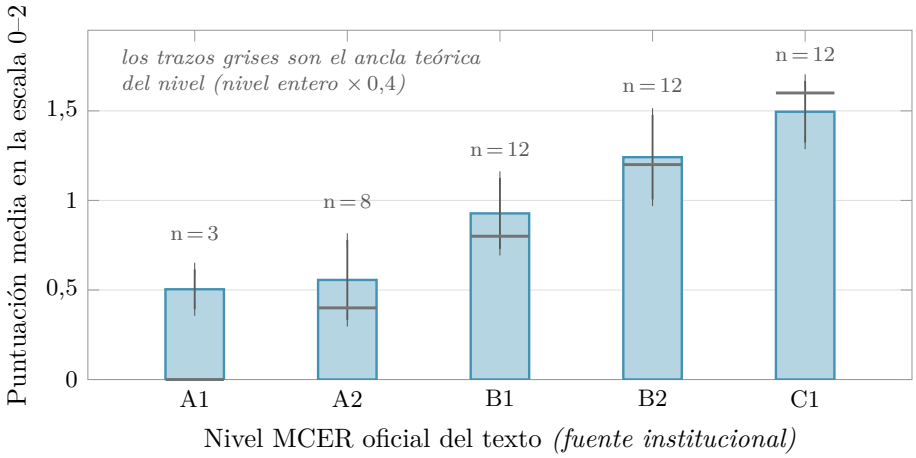


Figura 7: El resultado que sostiene el trabajo: las medias por nivel quedan **estrictamente crecientes** sobre textos externos con nivel MCER asignado por una institución de enseñanza. Las barras de error son la desviación dentro de cada nivel; con n de 3 a 12 textos, lo que se afirma es el orden global y no cada comparación por pares. Datos de `datos_figuras/validacion.dat` (cuadro 18).

La letra pequeña de ese resultado

Aquí empieza la letra pequeña, y conviene leerla antes de citar la cifra. Son cuatro salvedades. Ninguna anula la afirmación anterior, pero cada una acota lo que puede hacerse con ella.

Una: el escalón A1–A2 está dentro del ruido. Es de 0,052 sobre desviaciones de 0,111 y 0,223, y descansa en tres textos. Los tres escalones siguientes, no. Lo que se afirma es el orden global de las cinco medias, no cada comparación por pares: con n de 3 a 12 textos por nivel, el primer escalón no se sostendría por sí solo.

Dos: es una reproducción local, no una reproducción independiente. El cuadro 18 se **recalcula** con `validar_local.py` en cualquier máquina que tenga los mismos PDF y los mismos pesos, pero los PDF de British Council tienen derechos y no acompañan al repositorio: quien quiera rehacerla los descarga con el navegador y los verifica por hash con `tools/bajar_corpus_bc.py`. Lo que se reproduce exactamente es **el orden**; las medias difieren ligeramente de las obtenidas en Colab (C1 coincide hasta la tercera cifra decimal —1,4952 frente a 1,4950—, A2 se desvía 0,09).

Tres: los 38 de Colab y los 47 de aquí son dos tandas distintas, y no se restan. La diferencia tiene dos causas —otra extracción de los PDF y otro filtro—, así que $47 - 38$ no son nueve textos que se puedan nombrar. Contado sobre los archivos reales, el balance de esta tanda cierra así:

	Textos
Publicados por British Council	59
menos: sin cuerpo localizable al extraer el PDF	−2
menos: **rechazados por `scoring.continuous_prose`**	**−10**
Evaluados	**47**

Cuadro 19: De 59 a 47, paso a paso. La primera resta es de extracción; la segunda es el filtro de prosa continua.

Y cuatro: el validador local filtra más flojo que la propia aplicación. Con el filtro completo de la app sobreviven **36 de esos 47** y A1 se queda con un solo texto, de modo que el orden creciente sobre cinco niveles está medido sobre un conjunto que la aplicación habría filtrado más. Por qué ocurre, qué regla se desactiva y qué textos caen se explica entero en el §7.7, al final del §7.

7.5 El *baseline* propio, y qué aporta el modelo por encima de él

Señal	**Spearman con el nivel oficial (47 textos)**
Modelo v4	**0,860**
Contar las palabras del texto, sin modelo	0,807
Modelo, descontando la longitud (correlación parcial)	**0,668**

Cuadro 20: El modelo frente a la señal trivial. Las tres cifras las calcula `validar_local.py` sobre los mismos 47 textos, con Spearman sobre rangos y la correlación parcial en la misma escala.

Un contador de palabras llega casi tan lejos como el modelo en ese corpus, y omitirlo sería deshonesto. Lo que sostiene al modelo es la tercera fila: **aporta señal por encima de la longitud**, que es precisamente lo que un contador de palabras no puede hacer —y conviene decirlo con precisión: no es que su correlación parcial sea peor, es que **no está definida**, porque descontar la longitud de la propia longitud deja un residuo de varianza cero—. Además, el modelo no recibe la longitud del documento como variable —puntúa bloques de tamaño fijo y promedia—, aunque su salida correlacione 0,732 con ella, porque los corpus de examen gradúan también la extensión de la tarea.

La escala está comprimida, y la aplicación lo asume. Contra el ancla real, el ajuste ronda predicho $\approx 0{,}72 \times \text{real} + 0{,}38$ (figura 8). Conviene decir de dónde sale esa recta, porque no está ajustada sobre los textos uno a uno: son **mínimos cuadrados sobre las cuatro medias por nivel que reportó Colab** (A2 a C1; el catálogo gratuito de British Council no tiene C2 y aquella tanda no traía A1), y dan $0{,}7196x + 0{,}3760$. Rehecha sobre las cinco medias locales de

hoy sale $0{,}67x + 0{,}41$: cambian los decimales, no la conclusión, que es que la pendiente está muy por debajo de 1. De modo que un texto A2 tiende a puntuar cerca de B1. Por eso la interfaz muestra **bandas** (básico $< 0{,}6 \leq$ intermedio $< 1{,}4 \leq$ avanzado) y la letra MCER solo como orientación, en lugar de fingir una precisión de dos decimales que el modelo no tiene.

Los cortes de esas bandas salen del MCER, y esa es una corrección posterior. Al principio estaban en 0,8 y 1,6, que además **ni siquiera partían el 0–2 en tres partes iguales**: dejaban dos tramos de 0,8 y uno de 0,4. Pero como el modelo comprime sus predicciones, con esos cortes un texto C1 caía en «intermedio» y «avanzado» solo lo alcanzaba un C2: tres de los cinco niveles medidos compartían banda. Ahora la banda se deriva del ancla MCER, con el agrupamiento del propio marco —usuario básico A1–A2, independiente B1–B2, competente C1–C2—, y las fronteras quedan en **0,6 y 1,4**. Así la palabra y la letra no pueden contradecirse por construcción. Ninguna puntuación cambió: solo cambió cómo se agrupan.

Un intento de ampliar la validación que hubo que retirar, y por qué se deja escrito. El 12 de septiembre de 2026 se midió el v4 sobre los dos conjuntos ingleses de referencia de UniversalCEFR (Imperial et al., 2025), `cambridge_exams_en` y `elg_cefr_en`: 739 textos, Spearman **0,946**. Era más alto que la validación interna (0,908), y eso bastó para no creérselo. Leyendo el guion de entrenamiento del v4 salió la causa: **el v4 se entrenó con ELG CEFR English**, que es exactamente `elg_cefr_en` (654 aceptados + 57 cortos + 1 descartado = 712, el tamaño del conjunto). Y los 325 textos distintos de Cambridge están **todos** dentro de él: 130 idénticos y 195 casi idénticos, con una mediana del 92 % de sus 8-gramas compartidos y el mismo nivel en los 195. Aquel 0,946 medía el modelo sobre su propio entrenamiento. No hay en UniversalCEFR un subconjunto inglés limpio para el v4, y la validación de este apartado sigue siendo la del cuadro 18.

Una validación externa de verdad: OneStopEnglish. Con la composición del anclaje ya conocida se pudo buscar un corpus que los pesos del v4 no hubieran visto, y comprobarlo en vez de suponerlo: ninguno de los textos de OneStopEnglish (Vajjala & Lučić, 2018) comparte con ELG CEFR English ni una secuencia de ocho palabras. Son 189 artículos de prensa escritos tres veces, en nivel Elementary, Intermediate y Advanced. Se mide una puntuación por artículo y nivel —560 unidades— con `validar_onestop.py`, que repite la comprobación de fuga cada vez que se ejecuta (cuadro 21).

Nivel	n	Media v4	Señal	Modelo	Palabras
Elementary	185	0,934	Spearman con el nivel	**0,800**	0,692
Intermediate	189	1,272	Parcial, sin la longitud	**0,688**	—
Advanced	186	1,515	Artículos en orden (de 185)	**183**	179

Cuadro 21: Validación externa con OneStopEnglish, un corpus que los pesos del v4 no vieron. La media va en la escala pública 0–2; «Palabras» es contar palabras, sin modelo.

Las medias suben en los tres niveles y el modelo conserva 0,688 descontando la longitud: aporta señal propia en un corpus que no vio. **Pero la última fila hay que leerla con cuidado**, porque es tentadora: dentro de cada artículo el modelo ordena bien las tres versiones en 183 de 185, y **la longitud sola ya acierta 179**, porque las versiones avanzadas son más largas (523, 667 y 809 palabras de media). Donde la longitud falla —seis artículos— el modelo acierta en cinco. Es una ventaja real, y es pequeña. Dos matices más: la escala vuelve a salir comprimida y desplazada hacia arriba —un texto Elementary puntúa 0,93, en la banda intermedia—, y OneStopEnglish **sí se usó para desarrollar los modelos anteriores** (el v2 se afinó con él), así que es externo para los pesos del v4, no virgen para el proyecto.

Lectura graduada por sus editores. Tres bibliotecas infantiles abiertas ponen a cada libro un nivel propio: StoryWeaver del 1 al 4, African Storybook y Let's Read del 1 al 5. **No son niveles del MCER**, así que solo se puede validar el orden. Se midieron con `validar_graduados.py`, con la misma comprobación de fuga contra ELG CEFR English (0 textos contaminados en las

tres) y dos decisiones que hay que declarar: los cuentos de menos de 250 palabras se unen en bloques de al menos 250 *sin mezclar fuente ni nivel*, y la longitud que se descuenta es la natural de los cuentos, no la del bloque. Los intervalos son bootstrap al 95 % con 2.000 remuestreos (cuadro 22).

Fuente	Unid.	Spearman v4	Longitud	Parcial sin longitud	Medias crecientes
StoryWeaver (1–4)	467	**0,426** (0,348 a 0,502)	0,542	**0,206** (0,111 a 0,295)	99,6 %
African Storybook (1–5)	174	0,416 (0,279 a 0,537)	0,810	0,133 (−0,029 a 0,289)	54 %
Let's Read (1–5)	1.000	0,178 (0,118 a 0,235)	0,620	−0,083 (−0,144 a −0,026)	1,8 %

Cuadro 22: Validación con lectura graduada por sus editores. «Longitud» es el Spearman de la longitud natural con el nivel; «Medias crecientes», la proporción de remuestreos en que las medias por nivel salen en orden. Entre paréntesis, el intervalo bootstrap al 95 por ciento. StoryWeaver es una muestra aleatoria de 649 libros intercalada por niveles.

Las tres dicen cosas distintas, y conviene no promediarlas. **StoryWeaver valida**: los cuatro niveles salen separados y en orden, y el modelo aporta orden *además* de la longitud (la parcial excluye el cero). **En African Storybook la longitud predice el nivel mucho mejor que el modelo**, y eso describe al corpus: sus niveles son casi una escala de longitud. El v4 no ve la longitud —puntúa ventanas fijas de 250 palabras— y dentro de cada nivel su correlación con ella es prácticamente nula; ordena por contenido, pero no se puede afirmar que aporte orden más allá de la longitud, y el orden entre los niveles 1 y 2 no está establecido. **Let's Read no valida, y no por el modelo**: más de la mitad de sus libros son traducciones al inglés que heredan el nivel del original en laosiano, jemer o indonesio; en esas 459 traducciones la correlación es 0,023, y en los 360 originales, 0,207. Su etiqueta describe el libro en su idioma.

Esta sección se corrigió tras una revisión metodológica independiente: la primera redacción leía la parcial de African Storybook como «lo explica sobre todo la longitud», daba sus medias por «estrictamente crecientes» sin intervalos y no advertía que el filtro de prosa rechazaba 42 de sus 65 cuentos de nivel 1, sesgando ese nivel hacia arriba. Los detalles están en `auditoria/validacion_graduados_2026-09-12.md`.

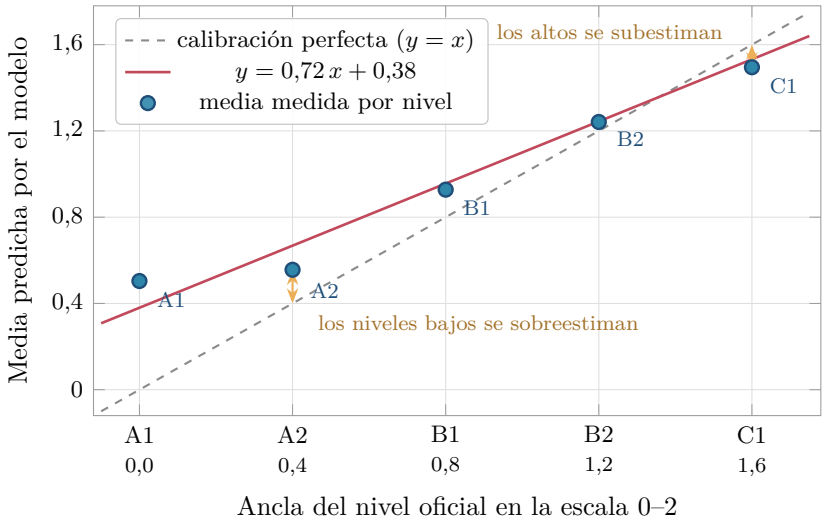


Figura 8: Por qué la interfaz muestra bandas y no decimales. Los puntos son las medias medidas por nivel (cuadro 18) frente al ancla teórica de ese nivel. El orden se conserva —que es el objetivo—, pero la pendiente es claramente menor que 1: los niveles bajos se sobreestiman y los altos se subestiman. La recta dibujada es $0{,}72x + 0{,}38$, ajustada sobre las **cuatro medias que reportó Colab** (A2 a C1); ajustada sobre los **cinco puntos locales** que se ven aquí sale $0{,}67x + 0{,}41$. Se dibuja la primera porque es la que cita el texto, y las dos dicen lo mismo: la pendiente está muy por debajo de 1. Calibrar esa recta afín sin tocar los pesos del modelo es el accionable A7 (cuadro 5).

7.6 Cuadro de decisiones metodológicas

Incluye las hipótesis que se probaron y se rechazaron (cuadro 23). Reportarlas es parte del resultado.

Decisión	**Razón**	**Evidencia / consecuencia**
Regresión, no clasificación	La dificultad es continua; clasificar tira información ordinal	El error ordinal medio baja de 1,39 a 0,67 en la progresión completa
Partición agrupada por libro	Evitar fuga de datos entre extractos **del mismo libro**. No separa autores: dos obras del mismo autor pueden caer a ambos lados, y eso no se comprobó	Aplicada a *todos* los modelos comparados, no solo al final
`distilroberta` y no `roberta-base` completo	La aplicación debe correr en CPU en el equipo de un estudiante	328 MB y 0,9 s de carga, frente a 1,5× más parámetros (125 M contra 82 M). **La diferencia de calidad entre las dos no se midió**: la decisión se tomó por tamaño y velocidad, no porque se comprobara que costaba poco
Promediar bloques sin ponderar, con la **ventana** como unidad	Simplicidad y reproducibilidad; ponderar por longitud reintroduce la longitud como señal	Constante del entrenamiento. La app y el precálculo del catálogo usan ahora el mismo estimador: durante un tiempo la app promedió las medias de cada capítulo y el catálogo todas las ventanas, y con capítulos de tamaño desigual **no son el mismo número** (0,004 de diferencia máxima sobre cinco libros; la medición se hizo en su momento y **no queda guion que la reproduzca**, así que se da como orden de magnitud, no como cifra auditable)
Rechazada: XGBoost sobre variables clásicas	Se esperaba que un ensamble superase al modelo lineal	No lo hace: 0,28 frente a 0,29, y error ordinal peor (1,42 *vs.* 1,39). El límite estaba en las variables
Rechazada: modelo híbrido *embedding* + variables	Se esperaba complementariedad	Ganancia nula (0,37 y 0,37; 0,91 *vs.* 0,93). El *embedding* ya contiene esa información
Rechazada: escalar la lista léxica al SPGC completo por rendimiento	Se esperaba mejorar `rare_word_ratio`	La correlación pasa de −0,330 a −0,326. Se conserva igualmente por cobertura, no por métrica
Rechazada: cuantización dinámica int8	+18 % de velocidad en CPU	MAE de 0,210 sobre una escala de 0 a 2 y sesgo sistemático de −0,21. Un desplazamiento así cambia la letra MCER en el **52 %** de la escala y la banda en el **21 %**: no degrada la cifra, le cambia la etiqueta al libro. Inaceptable

Decisión	Razón	Evidencia / consecuencia
Rechazada: precisión media (fp16) en la GPU local	Se esperaba acelerar	Es **4,8× más lenta** que fp32 en una GTX 1650 SUPER: el chip TU116 no tiene *tensor cores*. En una A100 sí compensa, y allí la desviación observada fue de unos 0,00037 de media; **tampoco quedó guardada**: mismo caso que la fila de arriba
Rechazada: `inference_mode` en lugar de `no_grad`	Se esperaba menos sobrecarga	0,4 % de diferencia, por debajo del ruido
Rechazado: esfuerzo de razonamiento «mínimo» en la explicación léxica	Es el doble de rápido (7,4 s frente a 14,9 s)	Con él, «had peeped» se explicó como pasado simple cuando es pasado perfecto. La gramática es justo lo que se evalúa
Filtrar prosa continua para la validación externa	Excluir textos porque el modelo falla en ellos invalida la validación	El criterio salió del diagnóstico, no es *a priori*, y así se dice en §4.3. Lo que lo sostiene es que se definió por **dos vías independientes** —título y estructura— que coinciden en el 89,8 % sin volver a mirar las puntuaciones

Cuadro 23: Decisiones metodológicas, incluidas las hipótesis rechazadas.

7.7 Qué filtra el validador local y qué filtra la aplicación

Este apartado desarrolla la cuarta salvedad del §7.4: el guion que reproduce el cuadro 18 no aplica el mismo filtro que la aplicación, y conviene ponerlo aquí y no esconderlo en el código.

Qué regla se desactiva, y por qué. El guion de reproducción une las líneas del PDF con un espacio, y eso **desactiva una de las cuatro reglas** de `scoring.continuous_prose`, la del maquetado de lista: sus dos comprobaciones —más del 17,5% de las palabras en líneas de maquetado, o más de un tercio de líneas muy cortas— necesitan saltos de línea para ver nada. Es decir, este validador filtra **más flojo que la propia aplicación**, que sí recibe saltos de párrafo. Medido cambiando una cosa y solo una: con saltos de línea sobreviven **36 textos en vez de 47**, y A1 se queda con uno solo, con lo que la comprobación de orden creciente ya no se puede hacer sobre cinco niveles.

Por qué se conserva así. Porque la unión con espacio es la que reproduce el cuadro 18 de este documento, que es la reproducción local. **No reproduce las cifras de Colab**, y nada aquí lo hace: aquella tanda son 38 textos y A2 se desvía 0,09. Pero el guion imprime las dos cuentas en cada ejecución, así que la diferencia queda a la vista de quien lo ejecute.

Qué textos se caen, y por qué regla. En el cuadro 19, la primera resta es de extracción. La segunda no: son **diez textos —nueve de A1 y uno de B1— que rechaza** `scoring.continuous_prose`, y conviene decir con qué regla, porque el filtro tiene cuatro. Los diez caen por la misma: **se quedan por debajo de las 150 palabras** una vez recortados entre «Reading text» y «Tasks». Son pósters, menús, horarios y tarjetas, es decir, textos que en el original ya son cortos; el detector de maquetado de lista ni siquiera llega a dispararse, porque el de longitud actúa antes. Los dos entornos filtraron con reglas distintas, no solo extrajeron distinto.

Lo que esto le hace al resultado principal. Los tres textos A1 que sostienen el escalón más débil del cuadro 18 **no pasan el filtro de la aplicación**: pasan el de este guion, que es el más flojo de los dos. Con el filtro completo, dos de los tres caen por maquetado de lista. Dicho de otro modo: una parte de esos 47 son textos que la app rechazaría por pare-

cer listas, y el escalón A1 es justo donde más pesa. Los nombres de los 59 archivos están en `entrega/manifiesto_corpus_externo.md`, y `validar_local.py` imprime los diez rechazados con su motivo.

8 Resolución del problema

8.1 De la métrica a la decisión del lector

Una correlación de 0,908 no le sirve de nada a un adolescente. Lo que le sirve son tres decisiones, y el producto está construido para producir exactamente esas tres (cuadro 24).

Pregunta del lector	**Qué la responde**	**Coste para él**
¿Cuál es mi nivel?	Seis preguntas sobre hábitos observables y tres fragmentos reales en escalera; o bien subir un libro que ya lee cómodo	Menos de dos minutos
¿Qué leo ahora?	Búsqueda semántica en español sobre el catálogo, acotada al rango de lectura del perfil	Segundos
¿Por dónde se va a complicar?	Curva de dificultad capítulo a capítulo, medida sobre el libro entero sin muestrear (figura 10)	De 12,7 s (vistazo, medido sobre *Crime and Punishment*) a minutos (libro completo)
¿Qué significa esta palabra *aquí*?	Doble toque sobre la palabra: lema, IPA británica y americana cuando el diccionario la trae (el 58 % de las consultas sobre un libro real), definición de Wiktionary, el sentido concreto en esa frase, gramática y audio	Instantáneo en local; la explicación contextual tarda más
¿Lo estoy pronunciando bien?	Lectura en voz alta marcada palabra por palabra, con el sonido concreto que falla	Una frase

Cuadro 24: Del modelo a las decisiones del usuario.

8.2 Un recorrido completo, con números reales

Tomemos el caso concreto de una lectora cuyo perfil da 1,20 sobre 2 (banda intermedia, ancla B2). La figura 9 resume el recorrido completo, empezando por el cuestionario de perfil; los seis pasos que siguen arrancan ya con ese perfil hecho y detallan el resto.

1. Busca. Escribe *«dostoyevski»*, mal escrito, y el rescate por parecido ortográfico la lleva igualmente a quien busca —«chejov» y «Shakespear» funcionan igual— sin estorbar a las búsquedas por tema, porque el buscador no busca por título sino por significado, sobre *embeddings* multilingües. Podría haber escrito en español lo que le apetece —*«una novela de detectives victoriana»*— y el buscador respondería igual. Medido el 11 de septiembre de 2026 con su perfil de 1,20 y la casilla de acercar al nivel puesta, esa frase en español devuelve *The Secret Adversary* (Christie, B2), un cuento infantil A1 de StoryWeaver, *Great Expectations*, *North and South*, *Bleak House* y, en séptimo lugar, *The Memoirs of Sherlock Holmes*. Que el segundo puesto sea un A1 para una lectora de 1,20 no es un fallo del buscador: es el libro cuyo texto más se parece a la palabra «detective», la casilla **acerca y no filtra**, y su nivel va escrito al lado.

   Y aquí conviene decir algo que el propio recorrido enseña. Lo que devuelve la búsqueda **no está filtrado por el nivel del lector**: ordena por cercanía al tema, y la dificultad va

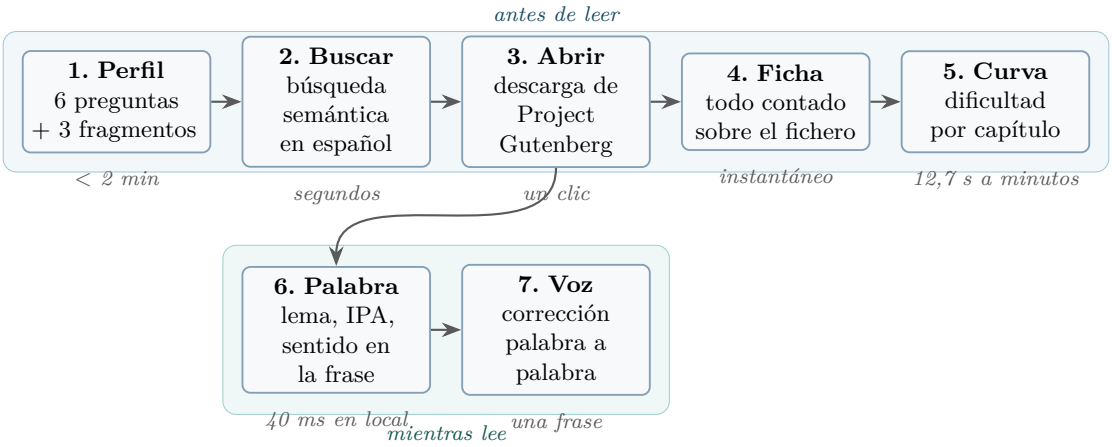


Figura 9: El recorrido completo, con los tiempos medidos de cada paso. No es un modelo con una interfaz encima: es una secuencia de decisiones que el lector no podía tomar antes. Lo único lento es la explicación contextual, que sale a la red; por eso la ficha se pinta en dos etapas.

al lado de cada resultado para que el lector decida. En este recorrido eso importa, porque el libro que abre mide 1,70 y ella está en 1,20: le queda por encima, y el valor de la herramienta es precisamente que **lo sabe antes de la primera página**.

2. Abre el libro. Se descarga de Project Gutenberg y se abre dentro de la aplicación, sin salir a buscarlo.

3. Aparece la ficha, **contada sobre el texto y no sobre metadatos**, aunque no toda sobre el libro entero: las palabras y el tiempo de lectura salen del fichero completo, y la longitud de frase, el diálogo y el vocabulario se calculan sobre una muestra con **tope de 60.000 palabras**, repartido a partes iguales entre los capítulos —la variedad léxica, sobre las primeras 20.000 de esa muestra—, porque recorrer *Guerra y paz* entero para pintar una ficha haría esperar al lector. Lo que trae: palabras reales, tiempo de lectura estimado a 180 o 110 palabras por minuto según el texto le quede por debajo o por encima de su nivel —no es su ritmo medido, que la aplicación no conoce—, longitud media de frase, proporción de diálogo, variedad de vocabulario y palabras más repetidas. La proporción de diálogo distingue de verdad entre obras —*Alice* 73 %, *Pride and Prejudice* 28 %, *Crime and Punishment* 31 %—, cosa que no hacía cuando se medía por párrafo en lugar de por oración, porque un epub no conserva los saltos de párrafo y las tres daban 100 %.

4. Pide la curva de dificultad. Sobre *Crime and Punishment* (PG2554), el modelo recorre **840 ventanas de 203.699 palabras en 134 segundos** y devuelve una media de **1,70 sobre 2** —orientativo C1—, además de decir si el libro se va complicando o soltando y cuáles son su capítulo más llevadero (el **19**, 1,52) y su capítulo más exigente (el **36**, 1,87). La segunda vez tarda 0,02 s porque queda guardada. Las figuras 10 y 11 muestran ese producto sobre tres libros medidos.

5. Toca una palabra que no conoce. El trabajo local —lema, categoría gramatical, consulta al diccionario, desambiguación por similitud, IPA— son **40 milisegundos** *en caliente*; la primera consulta de la sesión carga el diccionario, spaCy y el modelo de similitud, y eso tarda. La explicación contextual, que sale a la red, es lo único lento siempre, y por eso la ficha se pinta en dos etapas: lo local aparece al instante y la explicación se añade cuando llega.

   Esa explicación se pide con **salidas estructuradas** (*structured outputs*): un esquema Pydantic con un campo por cada cosa que se va a pintar —definición en contexto, explicación

gramatical, versión adaptada al nivel y ejemplo simplificado— en lugar de texto libre que luego haya que trocear. El esquema fija la forma de la respuesta, **no garantiza su veracidad**. Si Kaikki trae una acepción utilizable, la definición se conserva y el servicio explica y traduce el contexto; ante una elección dudosa solo puede seleccionar otra glosa existente. Desde el 13 de septiembre, si no hay acepción utilizable y se autoriza la llamada, puede ofrecer una definición **marcada como generada por IA**, nunca atribuida al diccionario. Sin clave se conserva la ficha local y el aviso de ausencia. Las salidas estructuradas también se usan en pronunciación y en «¿de qué trata?».

6. Lee una frase en voz alta y recibe la corrección palabra por palabra.

Ese recorrido es la unidad de valor del producto: **no es un modelo con una interfaz encima, es una secuencia de decisiones que el lector no podía tomar antes**.

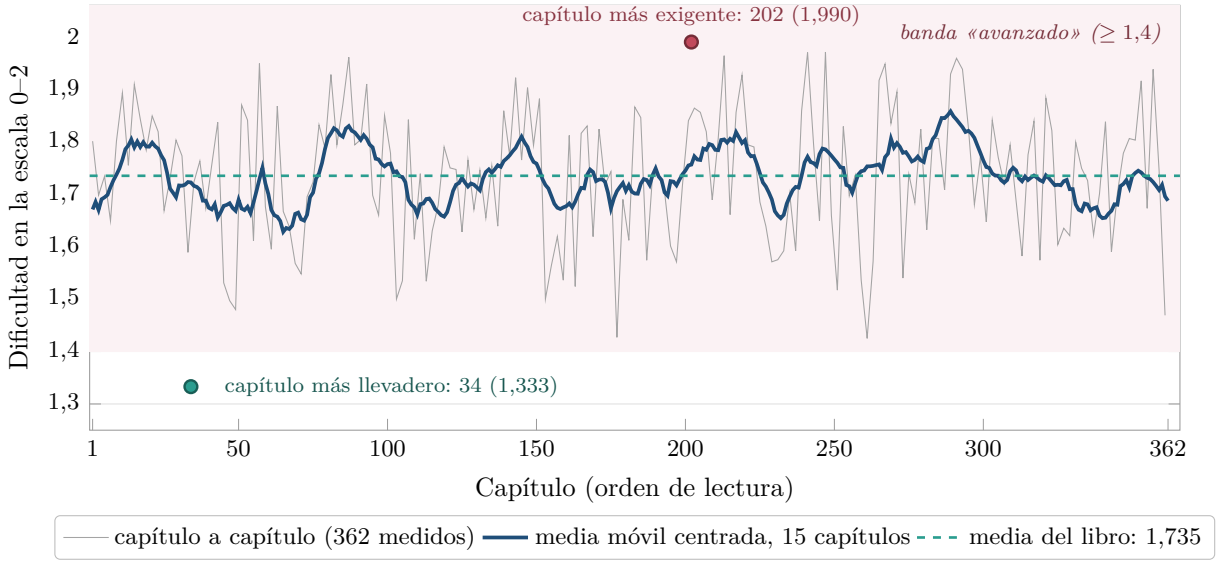


Figura 10: La figura que mejor explica el producto. Los 362 capítulos de *War and Peace* medidos sin muestrear —2.459 ventanas de 250 palabras, análisis completo— sobre la escala pública 0–2. La serie fina es la medición capítulo a capítulo (dibujada con un punto de cada dos por legibilidad); la línea gruesa es la media móvil centrada de 15 capítulos, calculada sobre *todos* los puntos. Un libro no tiene una dificultad: tiene un recorrido. Aquí va de 1,333 a 1,990 —0,657 de la escala— con media 1,735. Lo que la curva enseña no es una pendiente sino una meseta con dientes: los tres tercios promedian 1,723, 1,733 y 1,747, y el máximo de la media móvil cae en el capítulo 289, ya en el último tercio. La variación que importa al lector está entre capítulos vecinos, no entre el principio y el final. Fuente: `datos_figuras/curva_War_and_Peace.dat`.

8.3 Escalado: el catálogo entero, precalculado

La curva de dificultad de un libro largo son minutos de cómputo. Hacer esperar eso a cada visitante no es aceptable, de modo que el catálogo se precalcula. Las mediciones que hicieron viable esa decisión están en el cuadro 25 y en la figura 12.

Dos comprobaciones acompañan a ese cuadro, porque acelerar no puede costar exactitud:

- **La GPU da los mismos números que la CPU.** Sobre 840 ventanas de *Crime and Punishment*, 839 son idénticas a tres decimales y una difiere en 0,001; el MAE es 0,000001 sobre la escala 0–2.
- **Reagrupar en lotes distintos no mueve ninguna cifra que se publique**, y conviene decirlo con precisión, porque hay dos casos y solo uno es exacto. Cuando se trocea **un texto**

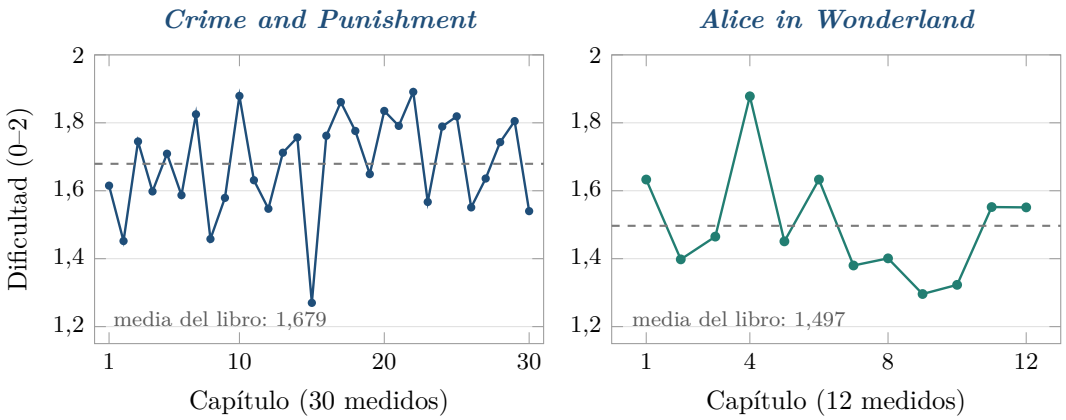


Figura 11: La dispersión interna es la norma, no la excepción. Dos libros más, medidos en *modo rápido* (el vistazo que la aplicación ofrece en segundos): *Crime and Punishment* recorre 1,270–1,891 y *Alice* 1,296–1,878, pese a que sus medias las separa casi dos décimas. Elegir libro por su media esconde justamente esto. Fuente: `datos_figuras/curva_Crime_and_Punishment.dat` y `datos_figuras/curva_Alice_s_Adventures_in_Wonder.dat`.

Entorno	Configuración	Ventanas/s	Factor
CPU (Ryzen 5 2600)	12 hilos, lote 64	8,19	1×
GPU local (GTX 1650 SUPER)	fp32, lote 128	112,7	13,8×
GPU A100 (Colab)	fp16, lote grande	2.022	247×

Cuadro 25: Rendimiento medido de extremo a extremo, incluida la tokenización y las transferencias. Son cifras del precálculo, que agrupa en lotes fijos de 64 en CPU y 128 en GPU. **La aplicación en vivo no llega a esos lotes**: agrupa por capítulo, y no por conveniencia sino para poder ir repintando la curva mientras mide; un capítulo son unas veinte ventanas, así que el rendimiento interactivo real está más cerca de las 6,96 ventanas/s del agrupado por capítulo que de las 8,19 de esta fila. Fuente: `datos_figuras/velocidad.dat`.

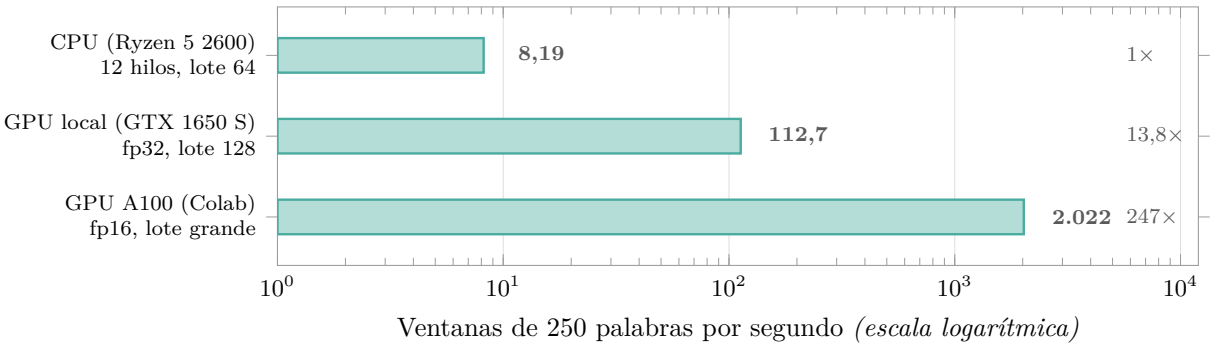


Figura 12: Tres órdenes de magnitud entre el equipo del autor y la GPU alquilada, medidos de extremo a extremo (tokenización y transferencias incluidas). La escala es logarítmica porque el rango va de 8,19 a 2.022 ventanas por segundo. Es lo que convierte «medir los 61.642 libros en inglés de Project Gutenberg» en unas pocas horas de cómputo en lugar de un mes seguido de CPU: a 8,19 ventanas/s y 350 ventanas por libro son **731,7 h**, o sea **30,5 días**. Datos de `datos_figuras/velocidad.dat` (cuadro 25).

de más de 250 palabras, todas sus ventanas miden 250 palabras exactas y, en prosa inglesa real, pasan siempre de 256 *tokens* BPE, así que se truncan a 256 —comprobado: la ventana más corta de un texto de prueba da 258; un texto artificial de 250 monosílabos daría 252 y no llegaría, pero eso no es prosa—: no hay relleno, y la fila de cada ventana no depende de con quién vaya agrupada. Es el caso de la comprobación: las mismas **300 ventanas** puntuadas de una en una y en un solo lote de 300 salen **300/300 idénticas**, con MAE 0,000000. El precálculo del catálogo, en cambio, mete en el mismo lote las ventanas de **todos los capítulos** de un libro, y un capítulo de menos de 250 palabras aporta una ventana corta: ahí el relleno sí actúa hasta la ventana más larga del lote, y el resultado **no es idéntico bit a bit**. También está medido, sobre *Alicia en el País de las Maravillas*, 112 ventanas: **103 coinciden exactamente y el resto difiere como mucho en** $4{,}8 \times 10^{-7}$. Las cifras del catálogo se guardan con tres decimales, así que una diferencia de ese tamaño no puede mover ninguna.

Con 2.022 ventanas por segundo, medir los 61.642 libros en inglés de Project Gutenberg salían **entre 3 y 5 horas de A100**, y en su momento se dijo de qué dependía esa horquilla en vez de dar una cifra sola: del número medio de ventanas por libro. Con las 350 que asume el código del precálculo salen **2,96 h**; con las 606,4 que promedian las cinco novelas largas medidas en local —una muestra sesgada hacia arriba, porque son clásicos extensos— salen **5,14 h**.

Después se ejecutó, y la estimación resultó ser la mitad de la respuesta. El ritmo real medido en la A100 fue de **61 libros por minuto**, o sea **unas 17 horas** para los 61.642 —cinco veces la cifra de tarjeta—. Y el desglose dice exactamente dónde se va el tiempo: un libro medio son **0,17 s de GPU** contra **~1 s de reloj**, así que **el 80 % del tiempo la tarjeta está parada** esperando a que el sistema de archivos de Google Drive entregue el `.txt`.

La estimación no era falsa: era **incompleta**, y de una manera que conviene nombrar porque es un error de método y no de aritmética. Medía la parte del sistema que se sabía medir —el modelo— y daba por supuesto que era la que manda. No lo era. Es la misma lección que la agrupación por capítulo en vez de por libro, y la misma que la descarga: **el cuello de botella de este proyecto nunca ha estado en el modelo**. En serie, a 0,3 libros/s, la descarga tardaría 57 horas. Y no era la pausa de cortesía entre peticiones, era la latencia —cada petición al espejo se pasa casi todo su tiempo esperando la ida y vuelta—, así que con seis hilos esas esperas se solapan. Seis y no treinta a propósito: el espejo lo mantiene alguien de forma gratuita, y cada hilo conserva su pausa.

Después se buscó una vía más rápida, y la decisión que importa no fue técnica. El archivo único de Gutenberg —11,3 GB, una petición en lugar de las 29.668 que faltaban el 9 de septiembre— parecía el atajo evidente y no lo era: medido en dos máquinas distintas, el espejo entrega **0,29 MB/s**, o sea **casi once horas**, y con seis conexiones simultáneas sube a 0,46 y rechaza la séptima. No es el ancho de banda de nadie: es un servidor que mantiene un voluntario. La lección es del mismo tipo que las dos anteriores: **un atajo no es un atajo hasta que se cronometra**.

La vía rápida existe y también se midió: pedir los libros uno a uno a `www.gutenberg.org` con treinta y dos hilos da **3.362 libros por minuto**, unos nueve minutos para lo que faltaba. **Se descartó.** La política del sitio lo dice sin ambigüedad —«está pensado para usuarios humanos; cualquier uso aparente de herramientas automatizadas resultará en el bloqueo de su dirección IP»— y autoriza tres caminos: un espejo privado, el punto de acceso `/robot/harvest` con dos segundos de espera entre ficheros, o el catálogo. Que una puerta esté abierta y sea rápida no la convierte en una entrada.

Lo que sí resuelve el problema es no pedirle nada a Gutenberg. `common-pile/project_gutenberg` es un volcado ya publicado de esos mismos textos de dominio público, servido por una red de distribución de contenidos. Medido sobre el primer fragmento: **8,0 MB/s**, unos **veintidós minutos** para los 10,5 GB, y el identificador de cada documento **es** el número de Gutenberg

—239 de 239 cruzaron con el catálogo oficial en la comprobación, sin una sola excepción—. Veintisiete veces más rápido que el archivo único, y con la infraestructura de los voluntarios intacta.

8.4 Dos decisiones de producto que merecen argumento

Se ofrecen dos velocidades de análisis y siempre se dice cuál se usó. El vistazo rápido toma 30 capítulos repartidos por la obra y 2 ventanas de cada uno; el análisis completo no muestrea. El número 30 no es redondo por gusto: sale de la velocidad medida de la máquina. Y el resumen declara cuál de los dos se ejecutó, porque un vistazo que presumiera de haber leído el libro entero acabaría citado como si lo hubiera hecho. La diferencia entre ambos modos se ve al comparar la figura 10 (completo, 362 capítulos) con la figura 11 (vistazo).

No se filtra el catálogo por contenido. Se implementó un filtro basado en las materias que asigna el propio Project Gutenberg —90 libros de 61.642— y después se retiró, deliberadamente. El razonamiento: esto es una plataforma de literatura, y la literatura es donde esas cosas aparecen. Filtrar por etiqueta habría eliminado también obras que son literatura por derecho propio, como *Fanny Hill*, perseguida judicialmente y relevante precisamente por eso. En su lugar se usa un mecanismo que ya existía: la ficha de cada libro trae un campo de aviso que se muestra como «Antes de empezar». **Se informa al lector y se le deja elegir; no se elige por él.** Es una decisión discutible y por eso se argumenta en lugar de ocultarse.

8.5 Contra quién compite esto

Un proyecto que no sabe contra qué compite no puede decir qué aporta. La versión larga está en el documento de estrategia; aquí van las tres alternativas reales y la cifra que resume cada una.

Alternativa	Cifra publicada	La nuestra
Fórmulas clásicas (FKGL, ARI)	Pearson **0,517** en CLEAR	**0,89**
Mejor LLM *zero-shot* publicado	Pearson **0,725** en CLEAR	**0,89**
Lexile, tarifa de creador de contenido	**3.824–54.636** USD/año	3 h de A100

Cuadro 26: Cifras publicadas frente a las de este proyecto. **No son comparaciones cara a cara**: las dos primeras filas vienen de un estudio ajeno sobre el mismo corpus, con otra partición y otro protocolo. Justifican la decisión de afinar un codificador; no demuestran una victoria medida.

Los 53.179 libros del catálogo medido caen en el tramo más alto de la tarifa de Lexile; medirlos aquí cabe en la cuota de una suscripción de unos 10 USD al mes. **No es una razón monetaria estricta** —una licencia anual y unas horas de cómputo no se dividen— y tampoco son servicios equivalentes: Lexile vende una escala aceptada por instituciones. Lo que sí se sostiene es que el **coste de procesamiento está en otro orden de magnitud**, y eso es lo que hace viable medir un catálogo entero en un trabajo de estudiante.

Dónde se pierde, que también hay que decirlo. Lexile tiene treinta años de validación y una escala que **acepta un colegio**; la de aquí no la acepta nadie. *TeakReader* ya da nivel MCER por capítulo y es una aplicación publicada en dos tiendas, mientras esto vive en un enlace. Y las lecturas graduadas de editorial tienen algo que ningún modelo da: el nivel se lo puso una persona que leyó la obra.

Lo que queda, y basta para justificar el trabajo, son tres cosas: se recorre el libro **entero, capítulo a capítulo**, en lugar de dar un número global; está escrito para un **hispanohablante que elige qué leer**, no para un profesor que clasifica textos; y es **auditable en**

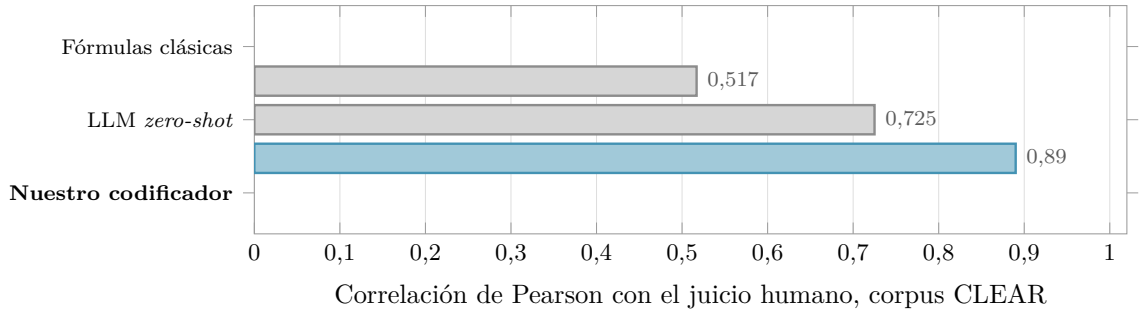


Figura 13: Las fórmulas clásicas cuentan sílabas y llegan a 0,517. Un modelo de lenguaje grande con un buen *prompt*, sin afinar, llega a 0,725. El codificador afinado de este proyecto, a 0,89. Las tres cifras son sobre el mismo corpus, pero —y esto hay que repetirlo aquí, no solo en el pie del cuadro 26— **no son comparaciones cara a cara**: las dos primeras vienen de un estudio ajeno, con otra partición y otro protocolo, y el 0,89 es el del `roberta-base` afinado sobre CLEAR del §7.2, que **no es el modelo que se despliega**. Justifican la decisión de afinar un codificador; no demuestran una victoria medida.

lo que se puede auditar y de acceso gratuito para el lector, con el modelo publicado y el código a la vista.

Esa tercera hay que acotarla: el código, la inferencia desde los pesos públicos **y** las métricas internas del v4 se pueden rehacer —recalculadas el 12 de septiembre de 2026, idénticas a cuatro decimales—. Y las fórmulas clásicas también son gratuitas y reproducibles, así que la ventaja no está en la auditabilidad sola, sino en tenerla junto con un modelo que lee el texto. Lo que ninguna alternativa reúne son las **tres a la vez**.

9 Limitaciones

Antes de la lista, de dónde sale. Este trabajo se sometió a **quince auditorías externas** hechas por modelos de dos familias distintas, con el encargo explícito de ser duros y **a ciegas**: sin decirles qué se había corregido antes, para que lo que volviera a salir fuera lo que seguía mal. Entre todas señalaron más de un centenar de hallazgos: fugas de datos, cifras que no cuadraban entre archivos, métricas atribuidas al corpus equivocado, pruebas que no podían fallar y conclusiones más fuertes que su evidencia. Los informes están en `auditoria/` y las correcciones, en el historial del repositorio.

Varias de las limitaciones que siguen no las encontró el autor, y algunas contradicen lo que este mismo documento afirmaba en una versión anterior. Parece razonable decirlo una vez, al principio de la lista, en lugar de repetirlo en cada párrafo corregido.

1. **La escala 0–2 es propia y no es una certificación.** El MCER fue el ancla del entrenamiento. LiteraLevel no acredita ningún nivel, y decirlo en el documento no basta: la aplicación lo repite en pantalla.

2. **La escala está comprimida.** El ajuste contra el ancla real ronda predicho $\approx 0{,}72\times\text{real}+0{,}38$ (figura 8; mínimos cuadrados sobre las cuatro medias por nivel de Colab, y $0{,}67x + 0{,}41$ con las cinco locales), así que los niveles bajos se sobreestiman y los altos se subestiman. Es la razón de mostrar bandas y no decimales.

3. **Las letras del catálogo son orientativas.** Ya no son heredadas: los 53.179 libros están medidos enteros por el v4 (cuadro 10). Pero la escala del modelo sale comprimida y desplazada hacia arriba —un texto Elementary de OneStopEnglish puntúa 0,93—, así que la letra de un libro fácil tiende a subir. La aplicación lo dice al pie de cada tabla, en la pantalla y no solo en el PDF. Hasta el 12 de septiembre de 2026 esta limitación era peor: con perfil 1,20,

«Sorpréndeme» proponía *The Secret Adversary* con etiqueta heredada **B2**, y el v4 leyendo el texto devolvía **C1**.

4. **La literatura del catálogo es, en su inmensa mayoría, C1–C2**: 1 libro A1, 40 A2 y 558 B1 de 53.179. Para un lector B1 la respuesta no son libros enteros sino capítulos (3.644 en 1.499 libros), y por nivel solo se ofrecen lecturas literarias: 290 entre A1 y B1.

5. **Los tamaños muestrales de la validación externa son pequeños**: 38 textos en Colab, 47 en local, con 3 textos en A1. Una diferencia de 0,05 entre dos niveles adyacentes con esas n no es significativa; lo que se afirma es el orden global, no cada comparación por pares.

6. **La validación no es enteramente independiente de la exploración.** El corpus de British Council se usó primero para diagnosticar (descubrir que el modelo no sabe leer menús) y después para validar. El filtro de prosa se definió por dos vías independientes precisamente para acotar ese problema, pero salió de ese diagnóstico y el conjunto ha sido mirado y ya no es virgen.

7. **La longitud del texto es un confusor en el corpus de examen.** Contar palabras alcanza 0,807 donde el modelo alcanza 0,860 (cuadro 20).

8. **El modelo solo mide prosa continua en inglés.** Poesía, teatro, diálogo muy fragmentado y cualquier lengua distinta del inglés quedan fuera.

9. **El corpus de anclaje MCER es pequeño y de una sola fuente**: 654 documentos aceptados de ELG CEFR English. Hasta el 12 de septiembre de 2026 ni su composición ni el guion de entrenamiento estaban en el repositorio, y una auditoría externa lo señaló con razón: sin esa lista nadie podía comprobar que las fuentes de validación fueran ajenas a las de entrenamiento. **Ya están**: guion, tarjeta de métricas y las 144 predicciones, en `entrenamiento_v4/`. Y la comprobación resultó necesaria de verdad: la primera validación con UniversalCEFR se hizo sobre este mismo corpus y hubo que retirarla.

10. **British Council no se puede redistribuir, pero sí reconstruir.** Tiene derechos y no acompaña al repositorio; se reconstruye desde su manifiesto de URLs y SHA-256 y se verifica archivo por archivo con `tools/bajar_corpus_bc.py`. Comprobado desde una carpeta vacía el 12 de septiembre de 2026: da las mismas cifras del cuadro 18. Las cifras internas del v4 (0,908 y 97,2 %) también se recalculan desde el repositorio.

11. **El cuaderno corre entero en un Colab limpio, pero correr no es recalcular.** Los pesos del v4 están publicados en Hugging Face (`MikeMaki1763/literalevel-v4`, repositorio público, descarga sin credenciales), así que el cuaderno se ejecuta de principio a fin y demuestra la inferencia sobre texto real. El cuaderno no reentrena el v4, que pide una GPU, pero **sus métricas sí se recalculan fuera de él**: los datos de entrenamiento son públicos (ELG CEFR English, en Hugging Face), el guion está en `entrenamiento_v4/` y las 144 parejas de nivel y predicción están publicadas. Recalculadas en CPU en menos de un minuto, dan las mismas cifras a cuatro decimales.

12. **El despliegue está en el escalón más barato, y eso tiene dos consecuencias.** La aplicación está publicada en dos Spaces de Hugging Face con dirección fija que sobrevive a apagar el equipo del autor: el *front* de Angular en un Space estático (`MikeMaki1763/literalevel-front`), gratuito y sin suspensión, y la API con el motor de Gradio en `MikeMaki1763/literalevel`, hardware `cpu-basic`. Este segundo cuesta **7 USD al mes**: un Space de Gradio exige cuenta Pro, y `cpu-basic` es el hardware que no añade coste sobre esa suscripción. Pero ese hardware **suspende el servicio tras 48 h sin visitas** (`gcTimeout` = 172.800 s según la API de Hugging Face), de modo que el *front* abre al instante, pero su primera llamada a la API después de una pausa paga un arranque en frío mientras se cargan *torch* y los 328 MB del modelo;

el *front* lo dice con palabras («tarda unos 30 segundos en despertar») en vez de fallar. Está medido: reiniciando el Space, **31 s hasta que el runtime dice `RUNNING` y 32 s hasta que la página responde**. Es la cota inferior, porque ahí la imagen del contenedor ya estaba construida; despertar de una suspensión de 48 h añade traerla. El disco del contenedor **sí es efímero**, y por eso la estantería, el avance de lectura, el cuaderno y el perfil del lector se guardan en un **bucket de almacenamiento montado en `/data`** (18 USD por TB y mes en repositorio privado, y esto ocupa megas). Verificado de punta a punta: se fijó un perfil, se reinició el Space y el perfil seguía ahí. Era la acción A4 de la estrategia y está cerrada.

13. **La prueba de usuario tiene $n = 2$.** Esmeralda y Laura son dos lectoras. Su valor es cualitativo y de diagnóstico, no estadístico: sirve para encontrar fallos de usabilidad graves —y encontraron varios—, no para estimar satisfacción media.

14. **La explicación contextual depende de un servicio externo de pago.** Sin clave, la aplicación sigue funcionando en todo lo que no sale a la red desde el servidor: diccionario, fonética, buscador y puntuación. Los enlaces de audio de Wiktionary son aparte, porque los descarga el navegador del lector: necesitan conexión, aunque no clave. Lo que se apaga sin clave son tres cosas: la explicación en contexto, la corrección de pronunciación y el resumen de «¿de qué trata?» de la ficha.

10 Trabajo futuro

1. **Hecho el 12 de septiembre de 2026:** remedir el catálogo completo y sustituir las etiquetas heredadas por medidas del v4 sobre el libro entero (53.179 libros, 585.111 capítulos).

2. **Hecho el 12 de septiembre de 2026:** publicar el guion de entrenamiento y la composición del corpus de anclaje, que resultó ser público (ELG CEFR English). Las métricas del v4 ya se recalculan en lugar de citarse.

3. Ampliar el corpus de anclaje MCER, que hoy es el eslabón más delgado de la cadena de evidencia.

4. Calibrar explícitamente la escala comprimida (una transformación afín de dos parámetros ajustada sobre entrenamiento, sin tocar los pesos) y comprobar si el orden se conserva tras calibrar.

5. Repetir la prueba de usuario con cinco o seis lectores de perfiles distintos, que según Nielsen (2000) es donde se detecta la mayor parte de los problemas de usabilidad.

6. Medir el efecto real sobre el abandono: comparar la tasa de libros terminados entre lectores que eligen con recomendación y sin ella. Es la única métrica que verdaderamente valida la propuesta.

7. **Convertir las cinco acciones en herramientas de un agente** (*function calling*). Hoy cada una tiene su botón: medir un capítulo, buscar por significado, abrir un libro, explicar una palabra y corregir la pronunciación. Las cinco ya son funciones con argumentos y salida tipada —que es justo lo que un esquema de herramienta necesita—, así que el trabajo no sería reescribirlas sino declararlas y dejar que el modelo elija: «quiero algo de misterio victoriano que pueda leer» debería encadenar la búsqueda, el filtro por nivel y la ficha sin que el lector sepa que hay tres pasos. **No se hizo por una razón de calendario, no de diseño**: la aplicación llevaba dos días congelada y auditada cuando esto se planteó, y meter un bucle de herramientas en el camino que ya funciona habría cambiado el riesgo de la entrega por una mejora que no estaba medida.

11 Conclusiones

Se cumplió el objetivo ordinal, que era el objetivo. Hay dos resultados y vienen de corpus distintos, así que conviene no mezclarlos. Sobre **textos externos con nivel MCER oficial** —los 47 de British Council— el modelo ordena los niveles de forma estrictamente creciente (0,5040 · 0,5561 · 0,9276 · 1,2414 · 1,4952; figura 7) y alcanza Spearman **0,829** con 38 textos, **0,860** con los 47. El **0,908 y el 97,2 %** son otra cosa: salen del conjunto de validación de **144 documentos del propio corpus de anclaje**, que es interno. Atribuirlos a los externos sería un error. Para el problema planteado —elegir qué leer— acertar el orden es lo que importa; acertar la letra exacta es un lujo.

Y aquí hay que poner un límite que el documento no ponía. Ese orden está medido sobre **textos de examen**, de A1 a C1 y sin C2, no sobre novelas. La aplicación puntúa novelas y dibuja sus curvas, pero **la dificultad de una novela no se ha contrastado contra ninguna etiqueta externa ni contra ningún lector**. Que el modelo ordene bien cinco niveles de material de examen es una señal razonable de que la escala tiene sentido; no es una demostración de que ayude a elegir mejor un libro. Ese vínculo queda pendiente.

En las configuraciones probadas, el cuello de botella no estuvo en el algoritmo sino en la representación del texto. Aumentar la potencia del clasificador sobre las mismas variables no mejoró nada —XGBoost con trescientos árboles queda por detrás de una regresión logística, en las dos tandas—, mientras que cada vez que se enriqueció la representación el resultado subió: de conteos a *embedding* y de ahí a leer el texto crudo con atención, hasta 0,67 niveles de error ordinal (figura 4).

Dicho eso, esto no es un experimento controlado y no conviene venderlo como tal. Entre la fila del *embedding* y la del transformador cambian a la vez la representación, la arquitectura, el preentrenamiento y el objetivo —clasificación de seis clases frente a regresión—, así que el salto no se puede atribuir a un solo factor. Lo que la evidencia sostiene es la observación: **subir la potencia del clasificador no movió el resultado y cambiar la representación sí**. Aislar cuál de los cuatro factores pesa más exigiría comparaciones que este trabajo no hizo.

Sobre el tamaño de ese salto conviene ser preciso, porque el cuadro 14 tiene dos tandas y es fácil restar filas que no se pueden restar. Contra las tres variables clásicas de la tanda histórica, el paso al *embedding* va de 1,39 a 0,93. Pero el cuadernillo entregado ejecuta una regresión logística sobre tres variables clásicas, sobre esa misma partición, y obtiene **1,295**; con diecisiete variables en vez de tres baja a **1,061**.

No son exactamente el mismo modelo, y decir que sí lo eran era impreciso. Las tres variables se llaman igual en las dos tandas, pero `palabras_raras` no contiene lo mismo: en el cuadernillo se calcula contra las 3.000 palabras más frecuentes **del entrenamiento de CLEAR**, y en la tanda histórica contra las listas externas de NLTK y del SPGC (cuadro 11). Misma partición y misma semilla, sí; misma definición de las variables, no. Esa es la razón más probable de los 0,10 de diferencia.

Medido así, contra unas variables clásicas bien surtidas, la ventaja del *embedding* es bastante menor de lo que sugiere la comparación con tres. **La brecha que no se cierra con más conteos es la del transformador.** La conclusión cualitativa se sostiene; la cifra con la que se vendía, no.

Escalar el corpus no siempre mejora nada, y conviene decirlo. Multiplicar por 2.500 el corpus de referencia léxica —de 18 libros a los 45.345 del SPGC— llevó la correlación de −0,379 a −0,326: **empeoró**. La muestra intermedia de 397 libros daba −0,330. La ley de Zipf explica por qué. El paso se conservó por cobertura, no por métrica, y así se reporta.

La velocidad se ganó sin mover ninguna cifra publicada, y con la salvedad dicha. Doce hilos y lotes de 64 en CPU, fp32 con lote 128 en GPU: +33 % y ×13,8 respectivamente (figura 12), con 839 de 840 ventanas idénticas a tres decimales y la restante a 0,001. No es exactitud bit a bit —eso sería falso— sino diferencias por debajo del redondeo con el que se

guarda todo. Y se rechazaron dos palancas más rápidas —int8 y fp16 en la tarjeta local— porque una desviaba 0,210 sobre una escala de 0 a 2 y la otra era 4,8 veces más lenta. **Medir antes de optimizar, y medir también lo que se descarta.**

Lo que convierte esto en un producto no es el modelo, es lo que se hizo con lo que dijo una lectora de quince años. Un ciclo completo —observar, escuchar la queja, diagnosticar el fallo propio y corregirlo— vale más que un punto de correlación. Ese ciclo se documenta en el apartado 3.4, y su resultado son seis etiquetas reescritas, cinco paletas verificadas contra el criterio de contraste WCAG AA y una interfaz que se puede usar con el pulgar.

Y queda pendiente lo que más pesa. La aplicación funciona y ya tiene dirección fija —el *front* de Angular en un Space estático y la API con el motor en otro—, pero el motor corre sobre el hardware más barato: se suspende por inactividad. El catálogo ya está medido entero —53.179 libros— y las métricas del v4, que el documento citaba sin poder recalcular, ya se recalculan desde el repositorio. Lo que queda está planificado con coste y criterio de terminado en el cuadro 5.

Y para qué sirve esto, dicho como decisión y no como métrica. Un lector que hoy elige libro por la portada puede, con esta herramienta, hacer tres cosas que antes no podía: saber **antes de empezar** si un libro concreto le queda grande, ver **en qué capítulo** se va a atascar y decidir si lo salta o lo prepara, y llevarse las palabras que consultó **con la frase en la que aparecieron**, que es la unidad con la que se recuerda un idioma. Para quien enseña, el cambio es de otro tipo: un catálogo de dominio público con dificultad medida convierte «lee algo de tu nivel» en una lista concreta, y el coste marginal de añadir un libro es de segundos de cómputo, no de una tarifa por título.

Lo que este proyecto recomienda hacer a continuación, en orden de valor por hora de trabajo, está en el cuadro 5 con coste y criterio de terminado. La remedición del catálogo, que era lo que separaba un prototipo de un producto, ya está hecha, y el almacenamiento persistente también; lo siguiente es calibrar la escala, que es la diferencia entre decirle a alguien que un libro es A2 y que lo sea.

Declaración de alcance

LiteraLevel es una herramienta de apoyo a la lectura. **No es un instrumento de evaluación ni de certificación lingüística.** No debe usarse para asignar calificaciones, para decidir la admisión de una persona a un programa, para acreditar un nivel del Marco Común Europeo de Referencia ni para ninguna decisión con consecuencias para el evaluado. La escala 0–2 es propia; las letras A1 a C2 son el ancla con la que se entrenó el modelo y se muestran únicamente como orientación.

El sistema mide dificultad lingüística de prosa continua en inglés. No mide calidad literaria, no mide comprensión del lector y no emite juicios sobre el contenido de las obras. El catálogo no se filtra por contenido: se informa al lector mediante un aviso en la ficha del libro y la decisión queda en sus manos.

Los datos personales del lector —los libros empezados, el vocabulario consultado y el perfil de nivel— se guardan separados por sesión y no se comparten entre visitantes. Solo la caché de definiciones se comparte, por ser contenido de diccionario y no historial de nadie. Ningún texto con derechos se distribuye ni se imprime fuera del entorno de cómputo: de los corpus con licencia restrictiva solo salen estadísticas agregadas.

Referencias

Abid, A., Abdalla, A., Abid, A., Khan, D., Alfozan, A., & Zou, J. (2019). *Gradio: Hassle-free sharing and testing of ML models in the wild*. arXiv: 1906.02569. https://arxiv.org/abs/1906.02569

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794. https://doi.org/10.1145/2939672.2939785

Council of Europe. (2020). *Common European Framework of Reference for Languages: Learning, teaching, assessment — companion volume*.

Crossley, S., Heintz, A., Choi, J. S., Batchelor, J., Karimi, M., & Malatinszky, A. (2023). A large-scaled corpus for assessing text readability. *Behavior Research Methods*, *55*(2), 491-507. https://doi.org/10.3758/s13428-022-01802-x

Day, R. R., & Bamford, J. (1998). *Extensive reading in the second language classroom*. Cambridge University Press.

Deci, E. L., Koestner, R., & Ryan, R. M. (1999). A meta-analytic review of experiments examining the effects of extrinsic rewards on intrinsic motivation. *Psychological Bulletin*, *125*(6), 627-668. https://doi.org/10.1037/0033-2909.125.6.627

Gerlach, M., & Font-Clos, F. (2018). *Standardized Project Gutenberg Corpus (SPGC)*. Zenodo. https://doi.org/10.5281/zenodo.2422561

Gerlach, M., & Font-Clos, F. (2020). A standardized Project Gutenberg corpus for statistical analysis of natural language and quantitative linguistics. *Entropy*, *22*(1), 126. https://doi.org/10.3390/e22010126

Hu, M., & Nation, P. (2000). Unknown vocabulary density and reading comprehension. *Reading in a Foreign Language*, *13*(1), 403-430.

Krashen, S. D. (1985). *The input hypothesis: Issues and implications*. Longman.

Krug, S. (2014). *Don't make me think, revisited: A common sense approach to web usability* (3.ª ed.). New Riders.

Liu, Y., Ott, M., Goyal, N., Du, J., Joshi, M., Chen, D., Levy, O., Lewis, M., Zettlemoyer, L., & Stoyanov, V. (2019). *RoBERTa: A robustly optimized BERT pretraining approach*. arXiv: 1907.11692. https://arxiv.org/abs/1907.11692

Nakanishi, T. (2015). A meta-analysis of extensive reading research. *TESOL Quarterly*, *49*(1), 6-37. https://doi.org/10.1002/tesq.157

Nation, I. S. P. (2013). *Learning vocabulary in another language* (2.ª ed.). Cambridge University Press.

Nielsen, J. (2000, 18 de marzo). *Why you only need to test with 5 users*. Nielsen Norman Group. https://www.nngroup.com/articles/why-you-only-need-to-test-with-5-users/

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, *12*, 2825-2830.

Project Gutenberg. (2026). *Project Gutenberg*. https://www.gutenberg.org

Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using Siamese BERT-networks. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*, 3982-3992. https://doi.org/10.18653/v1/D19-1410

Sanh, V., Debut, L., Chaumond, J., & Wolf, T. (2019). *DistilBERT, a distilled version of BERT: Smaller, faster, cheaper and lighter*. arXiv: 1910.01108. https://arxiv.org/abs/1910.01108

Vajjala, S., & Lučić, I. (2018). OneStopEnglish corpus: A new corpus for automatic readability assessment and text simplification. *Proceedings of the 13th Workshop on Innovative Use*

of NLP for Building Educational Applications, 297-304. https://doi.org/10.18653/v1/W18-0535

Wolf, T., Debut, L., Sanh, V., Chaumond, J., Delangue, C., Moi, A., Cistac, P., Rault, T., Louf, R., Funtowicz, M., Davison, J., Shleifer, S., von Platen, P., Ma, C., Jernite, Y., Plu, J., Xu, C., Le Scao, T., Gugger, S., … Rush, A. M. (2020). Transformers: State-of-the-art natural language processing. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, 38-45. https://doi.org/10.18653/v1/2020.emnlp-demos.6

World Wide Web Consortium. (2023). *Web content accessibility guidelines (WCAG) 2.2*. W3C. https://www.w3.org/TR/WCAG22/

Ylönen, T. (2022). Wiktextract: Wiktionary as machine-readable structured data. *Proceedings of the 13th Language Resources and Evaluation Conference*, 1317-1325.

Zaharia, M., Xin, R. S., Wendell, P., Das, T., Armbrust, M., Dave, A., Meng, X., Rosen, J., Venkataraman, S., Franklin, M. J., Ghodsi, A., Gonzalez, J., Shenker, S., & Stoica, I. (2016). Apache Spark: A unified engine for big data processing. *Communications of the ACM*, *59*(11), 56-65. https://doi.org/10.1145/2934664

Zipf, G. K. (1949). *Human behavior and the principle of least effort*. Addison-Wesley.