Universidad Nacional Autónoma de México
FACULTAD DE ESTUDIOS SUPERIORES ACATLÁN

LiteraLevel

Medición automática de la dificultad de lectura en inglés y su entrega a un lector real

Proyecto integrador — Módulo 5

Alumno:
Miguel Reyes Carrillo

Profesor:
Mtro. Fernando Barranco Rodríguez

Diplomado en Ciencia de Datos — Generación 34

0,908	A1 < · · · < C1	97,2 %
Spearman, validación ciega	orden MCER creciente en corpus externo	dentro de ±1 nivel

Ciudad de México, septiembre de 2026

Resumen

Aprender inglés leyendo funciona, pero solo si el libro está al nivel de quien lo abre. Un lector que elige un libro demasiado difícil no aprende: lo abandona. Y hoy no hay forma sencilla de saber, antes de empezar, si *ese* libro concreto está a su alcance.

LiteraLevel es una aplicación que responde esa pregunta. Le da al lector un número entre 0 y 2 que dice cuánta dificultad tiene un texto en inglés, y lo hace leyendo el texto de verdad, no contando páginas. Con ese número le busca libros que le queden a mano, se los abre dentro de la propia aplicación, le enseña la dificultad capítulo a capítulo —los libros no son igual de difíciles de principio a fin—, le explica cualquier palabra en la frase en la que aparece y le corrige la pronunciación cuando lee en voz alta.

Debajo hay un modelo de lenguaje pequeño (`distilroberta-base`) afinado para predecir dificultad como un número continuo. En validación ciega alcanza una correlación de Spearman de 0,908 con el nivel de referencia y, sobre un corpus externo que no se usó para ajustar los pesos —aunque sí se exploró durante el desarrollo, y eso se detalla en la limitación 6—, ordena los niveles del Marco Común Europeo de forma estrictamente creciente: A1 0,5040 (n=3) · A2 0,5561 (n=8) · B1 0,9276 (n=12) · B2 1,2414 (n=12) · C1 1,4952 (n=12). Ese orden —no el acierto exacto— es el resultado que sostiene el trabajo, **con una salvedad que conviene leer junto a las cifras**: el escalón A1–A2 es de 0,052 sobre desviaciones de 0,111 y 0,223, y descansa en tres textos. Está dentro del ruido. Los tres escalones siguientes, no.

Conviene decirlo desde la primera página: **la escala 0–2 es propia y LiteraLevel no certifica ningún nivel del Marco Común Europeo**. Las letras A1 a C2 fueron el ancla con la que se entrenó el modelo, no un título que la aplicación expida. Sirven para elegir qué leer, no para acreditar nada.

El proyecto se cierra con una aplicación funcionando —ocho pestañas en Gradio 6.26 (Abid y col., 2019), probada por una lectora de quince años ajena al proyecto— y con un catálogo en curso de remedición: los 61.642 libros en inglés de dominio público de Project Gutenberg, leídos enteros por el modelo, que a la velocidad medida en una GPU A100 son entre tres y cinco horas de cómputo.

Palabras clave: legibilidad automática, MCER, adquisición de segundas lenguas, lectura extensiva, transformers, Project Gutenberg, Gradio.

Nota sobre la estructura de la entrega. La *Estrategia*, que la rúbrica pide como entregable propio y como sección exigida del documento, se desarrolla completa en el **apartado 3** y no en un anexo: ocupa el lugar que le corresponde en el orden de secciones y sostiene por sí sola el resto del texto. Las cifras que allí se citan y que se miden más adelante van referidas con su cuadro o figura. **Todas las figuras de este documento están dibujadas en LaTeX** (TikZ/pgfplots) a partir de los datos medidos que acompañan a la entrega; no hay ninguna captura de pantalla ni imagen externa.

Índice

Resumen **1**

1. Introducción y motivación **5**

2. Planteamiento del problema **5**
2.1. Formulación . . . 5
2.2. Lo que el problema no es . . . 6
2.3. Criterio de éxito . . . 7

3. Estrategia **7**
3.1. La apuesta, en un párrafo . . . 7
3.2. Descripción de usuarios . . . 7
3.2.1. Usuaria primaria: la estudiante de preparatoria . . . 7
3.2.2. Usuario secundario: el adulto autodidacta . . . 8
3.2.3. Usuario institucional: el docente de inglés . . . 8
3.3. El ciclo de usuario real: Esmeralda . . . 9
3.3.1. Lo que ya se había corregido antes, por la misma vía . . . 10
3.3.2. La lección, en una línea . . . 11
3.4. Usabilidad del modelo . . . 11
3.4.1. La espera se traslada, no se pide . . . 11
3.4.2. La incertidumbre se comunica en bandas . . . 11
3.4.3. Nada falla en silencio, y nada se rompe del todo . . . 11
3.4.4. Cada número dice de dónde viene . . . 12
3.4.5. La latencia se reparte para que la pantalla no se quede quieta . . . 12
3.5. Accionables . . . 12
3.6. Métricas de éxito . . . 14
3.7. Riesgos . . . 14

4. Descripción de los datos **15**
4.1. Inventario de fuentes . . . 15
4.2. Relevancia de cada fuente . . . 15
4.3. Calidad de los datos: lo que está bien y lo que no . . . 17

5. Análisis exploratorio **18**
5.1. Análisis univariado . . . 18
5.2. Análisis bivariado . . . 19
5.3. Análisis multivariado . . . 20

6. Procesamiento de datos **20**
6.1. Sobre el texto de entrada . . . 20
6.2. Sobre las variables del modelado clásico . . . 22
6.3. Sobre el corpus de vocabulario (procesamiento distribuido) . . . 22
6.4. Sobre el diccionario . . . 22

7. Modelación **22**
7.1. Diseño experimental . . . 23
7.2. Progresión de modelos . . . 23
7.3. Dónde funciona y dónde no: análisis por dominio . . . 24
7.4. El modelo desplegado y su validación . . . 26
7.5. El *baseline* propio, y qué aporta el modelo por encima de él . . . 29

7.6. Cuadro de decisiones metodológicas 30
7.7. Qué filtra el validador local y qué filtra la aplicación 32

8. Resolución del problema **32**
8.1. De la métrica a la decisión del lector 32
8.2. Un recorrido completo, con números reales 32
8.3. Escalado: el catálogo entero, precalculado 34
8.4. Dos decisiones de producto que merecen argumento 36
8.5. Contra quién compite esto 37

9. Limitaciones **38**

10. Trabajo futuro **39**

11. Conclusiones **40**

Declaración de alcance **41**

Referencias **44**

Índice de figuras

1. Cadena de medición de LiteraLevel 6
2. La escala 0–2 y sus anclas MCER 6
3. Reparto de niveles del catálogo heredado 18
4. Progresión de modelos: la representación manda 23
5. Sobreajuste visto y controlado 24
6. Matriz modelo × dominio 25
7. Validación externa por nivel MCER 28
8. La escala comprimida 30
9. El recorrido del lector 33
10. Curva de dificultad de *War and Peace* 35
11. Curvas de dificultad en modo vistazo 35
12. Velocidad de inferencia por entorno 36
13. Comparación con las alternativas 37

1 Introducción y motivación

Unos 1.500 millones de personas estudian inglés como segunda lengua. De todos los métodos con respaldo empírico, la **lectura extensiva** —leer mucho, por gusto, en textos ligeramente por encima del nivel actual— es uno de los que mejor se sostiene: el metaanálisis de Nakanishi (2015) sobre décadas de estudios encuentra efectos consistentes en comprensión y vocabulario, y Day y Bamford (1998) la formalizan como programa de aula. Krashen (1985) llamó a esa franja «*input* comprensible»: material que se entiende casi todo, con lo justo de novedad para aprender.

El problema es operativo, no teórico. Para que la lectura extensiva funcione, el texto tiene que caer en esa franja, y Hu y Nation (2000) la cuantifican: se necesita reconocer alrededor del 98 % de las palabras corridas de un texto para comprenderlo sin ayuda —umbral coherente con el trabajo posterior de Nation (2013) sobre tamaño de vocabulario y cobertura léxica—. Un punto porcentual por debajo y la lectura se convierte en trabajo de diccionario. Es decir: **el mismo libro es excelente para un lector y una pérdida de tiempo para otro que está dos niveles por debajo**, y nada en la portada lo dice.

Hoy el lector hispanohablante que quiere leer en inglés se enfrenta a decenas de miles de libros gratuitos en dominio público y a ninguna señal fiable sobre cuál le corresponde. Las etiquetas que circulan (A2, B1, C1) casi nunca las puso alguien que haya leído la obra completa, y además tratan el libro como si tuviera una sola dificultad, cuando en realidad cambia de capítulo a capítulo. La figura 10 lo muestra sobre un libro entero medido: la dificultad de *War and Peace* recorre casi setenta centésimas de la escala pública entre su capítulo más llevadero y el más exigente.

Pregunta que guía el trabajo: ¿es posible estimar automáticamente, con un modelo de lenguaje entrenado sobre corpus públicos, una medida de dificultad de un texto en inglés que (a) ordene correctamente los niveles del MCER (Council of Europe, 2020) en material externo que no intervino en el ajuste de los pesos, y (b) sea lo bastante rápida y comprensible para ponerse en manos de un lector adolescente sin entrenamiento previo?

Este documento responde a las dos mitades. La primera es un problema de modelado y se resuelve en los apartados 4 a 7. La segunda es un problema de producto y de usabilidad, que es lo que el módulo declara evaluar, y se desarrolla en los apartados 3 y 8.

2 Planteamiento del problema

2.1 Formulación

Sea T un texto en inglés en prosa continua. Se busca una función $f(T) \to [0, 2]$ tal que, para dos textos T_i y T_j cuyos niveles oficiales de referencia cumplen $\text{nivel}(T_i) < \text{nivel}(T_j)$, se cumpla $f(T_i) < f(T_j)$ con la mayor frecuencia posible.

Obsérvese que **el objetivo es ordinal, no de clasificación exacta**. La frontera entre B1 y B2 es una convención pedagógica, no un hecho físico: confundir B1 con B2 es un error muy distinto de confundir B1 con C2. Por eso las métricas principales del trabajo son la correlación de Spearman y el **error ordinal medio** (distancia media en niveles entre lo predicho y lo real), y no la exactitud de clase.

Un texto largo no se puntúa de una vez. Se parte en bloques de 250 palabras (mínimo 150) y se puntúa cada bloque; la salida del documento es la media sin ponderar de sus bloques. Formalmente, si $B(T) = \{b_1, \ldots, b_n\}$ son los bloques de T y g es el modelo por bloque,

$$f(T) \;=\; 0{,}4 \cdot \frac{1}{n} \sum_{k=1}^{n} \text{clip}(g(b_k),\ 0,\ 5)\,, \tag{1}$$

donde el factor 0,4 convierte la escala interna del modelo (0–5, un valor por cada nivel A1…C2) en la escala pública 0–2 que ve el usuario.

El recorte va dentro del sumatorio, y el orden importa. Cada bloque se lleva a 0–5 *antes* de promediar, no después. No es un detalle de notación: la cabeza de regresión no tiene ninguna activación que la obligue a quedarse en el intervalo, y el **13,96 %** de las ventanas de prosa literaria puntúa por encima de 5 —medido sobre 530 ventanas de *Alicia*, *Orgullo y prejuicio* y *Crimen y castigo*; ninguna baja de 0—. Recortar después de promediar dejaría que un bloque que puntúa 5,3 arrastrase hacia arriba a todo el capítulo. Las dos versiones de la fórmula llegan a separarse **0,021** en un libro real, cinco veces la diferencia de cualquier otra decisión de agregación del sistema. El recorte va dentro del sumatorio, que es lo que hace el código. La figura 1 recorre esa cadena completa, del texto crudo a la banda que se muestra en pantalla, y la figura 2 sitúa las anclas MCER sobre la recta 0–2 resultante.

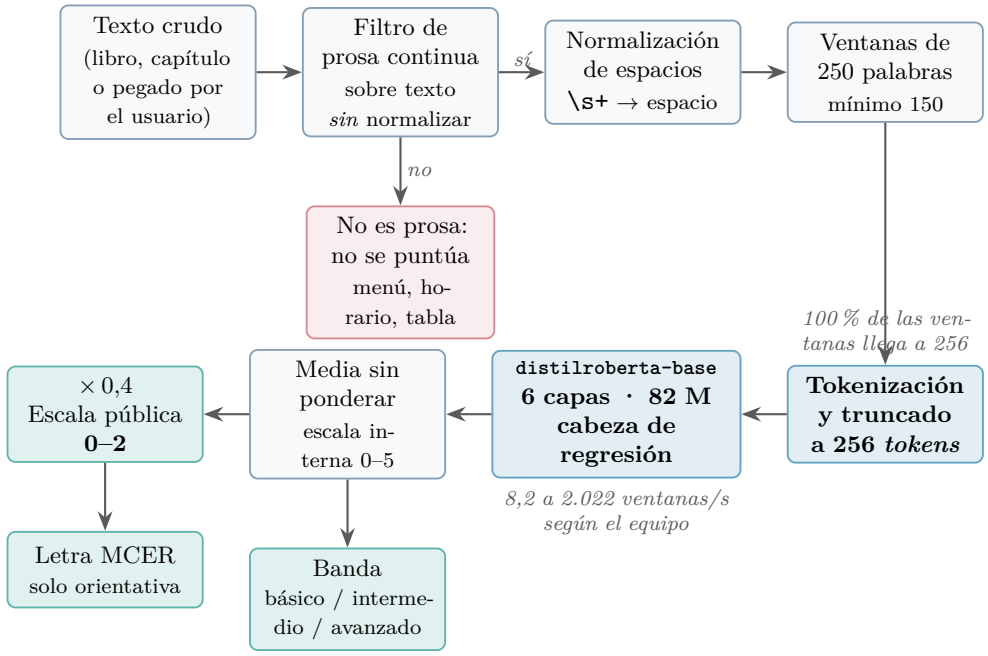


Figura 1: Cadena de medición, de la ecuación (1) al número que ve el lector. El filtro de prosa se aplica sobre el texto crudo, antes de normalizar espacios: hacerlo al revés lo desactivaba en producción (cuadro 10, T1). Las ventanas de un texto de más de 250 palabras ocupan siempre 256 *tokens* tras truncar, así que no llevan relleno y reagruparlas no movió ningún decimal en la comprobación de 300 ventanas del apartado 8.3. Cuando se mezclan capítulos cortos en un mismo lote sí hay relleno, y la diferencia medida es de $4{,}8 \times 10^{-7}$: por debajo de los tres decimales que se guardan.

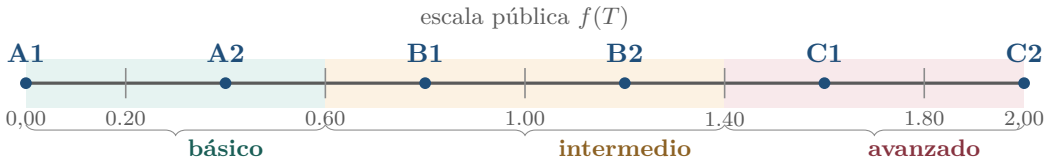


Figura 2: La escala pública 0–2 y sus anclas. Los puntos azules son los seis niveles MCER tal como los coloca la ecuación (1) (nivel entero × 0,4); las marcas grises son los cortes que decide qué letra se muestra, y las llaves inferiores, las tres bandas con las que la interfaz comunica la incertidumbre en lugar de fingir dos decimales de precisión. *La letra es orientación, no certificación.* Cortes tomados de `datos_figuras/escala_cefr.dat`.

2.2 Lo que el problema no es

Tres delimitaciones que evitan malentendidos y que la aplicación repite en pantalla:

1. **No es certificación.** El modelo se ancló a etiquetas MCER durante el entrenamiento; eso no lo convierte en un examinador acreditado. Devuelve una posición en una recta continua, y la letra que muestra es simplemente el ancla más cercana.
2. **No es un medidor universal de texto.** El modelo solo vio prosa continua. Una carta de menú, un horario de vuelos o una tabla no son prosa, y puntuarlos daría un número sin significado. La aplicación los rechaza con un filtro estructural explícito (apartado 6.1).
3. **No mide el interés ni la calidad literaria.** Mide dificultad de lectura. Un libro fácil puede ser magnífico y uno difícil, aburrido.

2.3 Criterio de éxito

El proyecto se considera resuelto si se cumplen tres condiciones simultáneas, recogidas en el cuadro 1.

#	Condición	Cómo se verifica
C1	El orden por nivel MCER se conserva en corpus externo no visto	Medias por nivel estrictamente crecientes
C2	La señal supera a la trivial	Correlación parcial descontando la longitud del texto
C3	Un usuario sin formación técnica completa el recorrido	Prueba con lectora ajena al proyecto

Cuadro 1: Criterios de éxito del proyecto. Se cumplen y se documentan, respectivamente, en los apartados 7.4, 7.5 y 3.3.

3 Estrategia

3.1 La apuesta, en un párrafo

La lectura extensiva es uno de los métodos con más respaldo para aprender una segunda lengua, y sin embargo casi nadie la practica bien, porque elegir el libro adecuado es un problema que el lector no puede resolver solo. LiteraLevel convierte una medida continua de dificultad —producida por un modelo que lee el texto entero, no la portada— en tres decisiones cotidianas: **qué leer ahora**, **por dónde se va a complicar** y **qué significa esta palabra en esta frase**. El activo defendible no es el modelo, que es pequeño y replicable: es la cadena completa desde el corpus hasta el pulgar de una persona de quince años en un teléfono.

3.2 Descripción de usuarios

Tres perfiles, con lo que cada uno necesita y con lo que hoy hace en su lugar. No son personas inventadas para rellenar: el primero está observado directamente (apartado 3.3) y los otros dos se derivan de las peticiones reales recogidas durante el desarrollo.

3.2.1 Usuaria primaria: la estudiante de preparatoria

Perfil. 14 a 18 años. Estudia inglés en la escuela, entiende bastante más de lo que cree, no sabe qué es el MCER y no le interesa. Entra desde el teléfono, casi siempre en vertical, y en pantallas de unos 390 px de ancho. Su tolerancia a la fricción es de segundos. Sus necesidades y la respuesta del producto están en el cuadro 2.

Necesidad	Cómo se atiende
Saber por dónde empezar sin sentirse examinada	Seis preguntas sobre hábitos observables —con qué frecuencia lee, si necesita diccionario, si ve series sin subtítulos, si ha terminado un libro entero— y **cero jerga gramatical**
Juzgarse ante algo real y no ante una descripción	Tres fragmentos literarios en escalera (*Alice*, Sherlock Holmes, *Frankenstein*), pintados con la tipografía del lector para que se lean como un libro y no como un formulario. Pesan 0,65 en el cálculo del nivel: delante de un texto real la gente se juzga mejor que describiéndose
Que le propongan algo, no una biblioteca	Un botón de «Sorpréndeme con algo de mi nivel» además de la búsqueda
Poder usarlo con el pulgar	Objetivos táctiles de 44 px, controles repartidos en filas que caben en 390 px, mandos de navegación también debajo del texto
No perderse	Al terminar el cuestionario, un enlace que salta directamente al buscador **con la recomendación ya hecha**

Cuadro 2: Necesidades de la usuaria primaria y respuesta del producto. Qué hace hoy en su lugar: elige por portada o por título conocido, abandona a las tres páginas y concluye que el problema es ella.

3.2.2 Usuario secundario: el adulto autodidacta

Perfil. 25 a 55 años. Ya lee en inglés con esfuerzo. Su problema no es empezar, es **subir de escalón sin abandonar**. Tiene libros a medias y no recuerda por dónde iba en ninguno.

- **Continuidad.** «Mis libros» guarda cada libro empezado con su barra de avance y el capítulo por el que iba, y lo reabre exactamente ahí. Es la petición literal que originó el módulo: *«un apartado con mis libros, los que estoy leyendo, que se queden guardados, en qué partes voy»*.
- **Saber a qué se enfrenta antes de comprometerse.** La ficha del libro dice cuánto tarda en leerlo **a 180 o 110 palabras por minuto** según le quede por debajo o por encima de su nivel, cuánto es diálogo y qué palabras se repiten. Las palabras y el tiempo salen del fichero completo; la longitud de frase, el diálogo y el vocabulario, de una muestra con tope de 60.000 palabras.
- **Vocabulario que persista.** «Mis palabras» guarda cada consulta con su frase y su libro, que es la unidad que sirve para recordar. Deliberadamente **no hay puntos ni rachas**: la evidencia sobre recompensas externas (Deci y col., 1999) indica que premiar una actividad que ya gusta la deteriora, y leer ya es gratificante.
- **Pronunciación.** Lee bien y suena mal, y nadie se lo corrige. La aplicación marca palabra por palabra qué sonó bien y qué no.

3.2.3 Usuario institucional: el docente de inglés

Perfil. Da clase a grupos heterogéneos y necesita repartir lecturas graduadas. No puede leerse cuarenta libros para clasificarlos.

- Un catálogo **medido**, no etiquetado a ojo, con la dificultad por capítulo para poder asignar fragmentos y no obras completas.
- Una declaración honesta de lo que la herramienta no es, para poder usarla sin incurrir en una promesa que no puede cumplir: **LiteraLevel no certifica ningún nivel del MCER**.
- Reproducibilidad: poder comprobar de dónde salen los números.

Este perfil es el que justifica dos decisiones que a un usuario final le dan igual: publicar el guion de validación y mantener el aviso de alcance visible.

3.3 El ciclo de usuario real: Esmeralda

La única prueba que vale es la que hace alguien que no sabe dónde hay que pulsar. **Esmeralda, 15 años, estudiante de preparatoria**, prima del autor, fue la primera persona ajena al proyecto que usó la aplicación. Lo que dijo, sin edulcorar:

> *«Está bien difícil de usar en celular.» — ¿Qué parte? — «Casi todo.»*
>
> *«No me gustan los colores… la página se siente antigua, todo muy recto, muy marcado.»*
>
> *«¿Qué es eso de 10?»*
>
> *«O yo soy muy tonta para esto.»*

La cuarta frase es la importante, y es la que ordena todo lo que vino después. **Cuando un usuario concluye que el tonto es él, el fallo es del diseño.** Krug (2014) formula la misma idea como regla de producto: si el usuario tiene que pensar para entender un control, el control está mal. A partir de ahí se diagnosticó qué producía cada queja y se corrigió (cuadro 3).

Lo que dijo	Diagnóstico	Corrección	Verificación
«¿Qué es eso de 10?»	La etiqueta «Resultados» junto a un número no dice qué cuenta	«¿Cuántos te propongo?», con explicación	Etiqueta reescrita
Creyó que «Recomiéndame por nivel» tendría en cuenta sus gustos	La etiqueta prometía más de lo que hacía	«Sorpréndeme con algo de mi nivel»	Etiqueta reescrita
—	«Ajustar a mi nivel» es abstracto	«Solo libros que pueda leer», con información	Etiqueta reescrita
—	«Medir la dificultad de este capítulo» es lenguaje de laboratorio	«¿Cómo de difícil es este capítulo?»	Etiqueta reescrita
—	«Vistazo rápido a la dificultad» no dice cuánto tarda	«Vistazo rápido (unos segundos)»	Etiqueta reescrita
—	«Analizar el libro entero» no advierte del coste	«Leer el libro entero (tarda más)»	Etiqueta reescrita

Lo que dijo	Diagnóstico	Corrección	Verificación
«No me gustan los colores»	El color es gusto, y el gusto no se discute: se ofrece	**Cinco paletas** con pestaña propia y cambio instantáneo: *hielo* (la original), *amanecer* (clara, crema y naranja), *menta*, *papel* (para leer horas) y *medianoche*	Una prueba automática comprueba las cinco contra el criterio de contraste **WCAG AA (4,5:1)** (World Wide Web Consortium, 2023). Las cinco pasan en las **cuarenta parejas** de color que se comprueban —ocho por paleta, cada una con su umbral: 4,5:1 para el texto normal y 3:1 para el título grande—. La más ajustada del texto normal mide **4,53** y la del título, **3,11**
«Todo muy recto, muy marcado»	Esto no es gusto, es diseño, y se corrige para todas las paletas	Esquinas de 14 px, bordes finos, sombras suaves y las opciones de lista como fichas tocables	—
«Difícil de usar en celular… casi todo»	En un móvil, el círculo de un botón de radio es un blanco de 12 px	La ficha entera pasa a ser el blanco: **44 px**	—

Cuadro 3: Del comentario de una usuaria a un cambio verificable.

3.3.1 Lo que ya se había corregido antes, por la misma vía

El ciclo de Esmeralda no fue el primero. Probar la aplicación en un teléfono real —y no en el navegador del escritorio— había descubierto antes fallos que **ninguna de las 205 pruebas automáticas podía encontrar, porque todos necesitaban un dedo y una pantalla pequeña**:

- El doble toque para consultar una palabra **no funcionaba en el móvil**: el código escuchaba solo el evento del ratón, que iOS no emite al seleccionar con el dedo. La instrucción en pantalla prometía algo que el dispositivo no hacía.
- Los títulos de la tabla de resultados eran enlaces a `gutenberg.org`, así que tocarlos **sacaba al lector fuera de la aplicación**.
- El resultado del nivel se pintaba en la parte superior de la página, fuera de la pantalla: la usuaria no se enteraba de que había terminado.

- Al pedir «traer una frase del capítulo» sin frase disponible, el campo se vaciaba y **borraba lo que el usuario había escrito**, sin decir nada.
- «Mis libros» mostraba 24 entradas llamadas `vacio.txt`, `falso.txt` y similares: la batería de pruebas anotaba sus ficheros de ataque en la biblioteca **real** de quien las ejecutara. Los datos personales del usuario eran el banco de pruebas.

3.3.2 La lección, en una línea

El valor de una prueba de usuario no está en el promedio de satisfacción, sino en la frase que duele. Con $n = 1$ no se puede estimar nada, pero se pueden encontrar los fallos que hacen que una persona se culpe a sí misma. Nielsen (2000) sitúa en cinco usuarios el punto donde se detecta la mayor parte de los problemas de usabilidad; el accionable A8 lleva la prueba hasta ahí.

3.4 Usabilidad del modelo

Un modelo es usable cuando el usuario puede confiar en él sin entenderlo. Eso se construye con cinco decisiones, todas medidas.

3.4.1 La espera se traslada, no se pide

Medir un libro largo son minutos. Pedirle esos minutos al lector en el momento en que quiere leer es perderlo. La estrategia es **mover el cómputo antes de la consulta**: el catálogo se precalcula fuera de línea y, cuando el lector busca, el trabajo ya está hecho. Los números que hacen viable esa decisión están en el cuadro 21 y en la figura 12: 8,19 ventanas/s en CPU, 112,7 en la GPU local y **2.022 en una A100**, con lo que los 61.642 libros en inglés de Project Gutenberg son **entre tres y cinco horas** de cómputo.

Cuando el cómputo sí tiene que ocurrir en vivo, se ofrecen **dos velocidades y se dice cuál se usó**: un vistazo (30 capítulos repartidos, 2 ventanas de cada uno) o el libro entero sin muestrear. Y el atajo está cuantificado, no prometido: 8 ventanas dan **1,784** y el recorrido completo del mismo capítulo, **1,743**.

3.4.2 La incertidumbre se comunica en bandas

El modelo devuelve un número continuo, pero su escala está comprimida (predicho $\approx 0{,}72 \times$ real $+ 0{,}38$; véase la figura 8). Presentar «1,27 sobre 2» como si fueran dos decimales de precisión sería mentir con exactitud. La interfaz muestra **bandas** —básico $< 0{,}6 \leq$ intermedio $< 1{,}4 \leq$ avanzado, tal como las dibuja la figura 2— y la letra MCER únicamente como orientación, siempre junto al número y con la tabla de correspondencia a la vista.

Un fallo real de esta decisión, encontrado y corregido, ilustra el nivel de cuidado que exige: el redondeo por defecto de Python resuelve los empates hacia el par, de modo que un 1,00 exacto caía en un nivel y la tabla publicada decía otro. Un usuario que comparase su cifra con la tabla habría encontrado dos respuestas para el mismo número. Ahora hay una sola regla, y una prueba fija los cinco límites.

3.4.3 Nada falla en silencio, y nada se rompe del todo

La regla transversal del sistema es la **degradación elegante**: sin clave de servicio externo, la aplicación sigue dando diccionario, fonética, buscador y puntuación, porque nada de eso sale a la red; el audio de Wiktionary es un enlace a `upload.wikimedia.org` que descarga el navegador del lector, así que necesita conexión, pero no clave ni servicio de pago. Solo se apagan la explicación en contexto y la corrección de pronunciación, y se dice con palabras que el lector entienda —«se

ha agotado el presupuesto mensual de explicaciones; el diccionario, la fonética y el audio siguen funcionando»— en lugar del error técnico en crudo.

La regla que verifican las 205 pruebas de robustez es una sola: **ningún manejador puede lanzar una excepción hacia la interfaz**. Lo que falla vuelve como texto legible.

3.4.4 Cada número dice de dónde viene

En la ficha del libro conviven dos clases de información y **la separación se ve en pantalla**: lo *contado* sobre el fichero (palabras, tiempo de lectura, proporción de diálogo, vocabulario) sale solo al abrirlo, es instantáneo y no necesita red; el *resumen* escrito por un modelo generativo va detrás de un botón, se guarda en disco y viene marcado como lo que es. **Ninguna cifra de la ficha la dice un modelo generativo.** En el diccionario, la regla equivalente: el modelo de lenguaje explica el contexto y la gramática, y tiene prohibido redefinir la palabra; la definición es siempre la de Wiktionary.

3.4.5 La latencia se reparte para que la pantalla no se quede quieta

De los 28 a 44 segundos de una consulta léxica nueva, **23 a 39 son espera al servicio externo**; todo el trabajo local —lema, diccionario, desambiguación, fonética— son **40 milisegundos**. Por eso la ficha se pinta en dos etapas: lo local aparece al instante y la explicación se añade cuando llega. El trabajo tarda lo mismo; deja de parecer que la aplicación se colgó. La misma idea gobierna la curva de dificultad, que se repinta cada pocos capítulos mientras mide (el repintado cuesta 25 ms, medido) y los recursos pesados, que se cargan al primer uso y no al arrancar.

3.5 Accionables

Diez acciones concretas (cuadro 4), ordenadas por puntos de rúbrica protegidos u obtenidos por hora de trabajo. Cada una lleva coste real y criterio de terminado. No son «se podría»: son «se hace».

#	Acción	Por qué	Coste	Terminado cuando
A1	**Publicar el modelo y el diccionario** como repositorios abiertos	Desbloquea que el cuaderno corra en un Colab ajeno. Es el mayor rendimiento por hora de todo el proyecto	∼30 min; gratuito. Requiere un token que solo el autor puede crear	**HECHO a medias**: el modelo está en `MikeMaki1763/literalevel-v4`, público y con la descarga sin credenciales verificada; el diccionario (243 MB) sigue sin publicar

#	Acción	Por qué	Coste	Terminado cuando
A2	**Desplegar en enlace permanente**	El enlace anterior era un túnel temporal que moría al apagar el equipo, y era el mayor riesgo de la entrega	**7 USD/mes**: un Space de Gradio exige cuenta Hugging Face Pro (9 USD de tarifa, 7 con descuento). El hardware `cpu-basic` no añade coste	**HECHO**: `MikeMaki1763/literalevel`, público y en marcha; queda el disco persistente, que es A4
A3	**Terminar la remedición del catálogo** con el modelo v4, libro entero	Sustituye las etiquetas heredadas —predicciones de un modelo v1 sobre las primeras ∼190 palabras— por medidas reales. Es la deuda técnica más visible	Entre 3 y 5 h de A100, dentro del crédito disponible; la descarga va ahora en un solo archivo de 11,3 GB	El catálogo publica niveles medidos y el aviso sobre las etiquetas heredadas se retira
A4	**Montar almacenamiento persistente** para los datos del lector	Un servicio que duerme y despierta con la estantería vacía deja en ridículo «Mis libros». Hoy todo eso vive en disco efímero	12 USD por TB y mes; el proyecto ocupa 7,4 MB, así que el coste es despreciable	Cerrar y reabrir tras un reinicio conserva libros, avance, cuaderno y perfil
A5	**Conseguir un micrófono** (auriculares con micro)	El equipo actual no tiene. Sin él no se puede demostrar la corrección de pronunciación, que es la función más vistosa y la que mejor encaja con «usabilidad para el usuario final»	Coste mínimo de hardware	Se graba una frase desde el equipo del autor y la corrección palabra por palabra aparece en pantalla
A6	**Retirar del catálogo los 1.049 registros no descargables** o marcarlos como fichas informativas sin botón de lectura	Hoy son el 87,6 % del catálogo y no se pueden abrir. Ya no aparecen en el desplegable, pero siguen ocupando el índice	Media jornada	El catálogo lista solo lo que se puede leer, o distingue visualmente ambas cosas sin ambigüedad
A7	**Calibrar la escala** con una transformación afín de dos parámetros ajustada sobre entrenamiento, sin tocar los pesos	La escala está comprimida y un A2 puntúa cerca de B1. La técnica ya se aplicó con éxito a una variante anterior	Una tarde	Las medias por nivel siguen estrictamente crecientes **y** se acercan a sus anclas

#	Acción	Por qué	Coste	Terminado cuando
A8	**Repetir la prueba de usuario con cinco lectores** de perfiles distintos, con guion de tareas y observación en silencio	$n = 1$ encuentra fallos graves; cinco encuentran la mayoría (Nielsen, 2000)	Cinco sesiones de 20 min	Existe una lista priorizada de hallazgos y las tres primeras correcciones están hechas
A9	**Instrumentar la métrica que de verdad importa**: proporción de libros empezados que se terminan, con recomendación y sin ella	Todo lo demás son métricas de proceso. Esta es la única que valida la propuesta de valor	Una jornada de instrumentación, respetando el aislamiento por sesión	Hay una cifra base con la que comparar dentro de un mes
A10	**Ampliar el corpus de anclaje MCER** más allá de los 654 documentos actuales	Es el eslabón más delgado de la cadena de evidencia y el que limita la confianza en la letra que se muestra	Trabajo de corpus, sin coste de cómputo	El corpus de anclaje supera los 1.000 documentos con niveles de fuente institucional

Cuadro 4: Accionables, con coste y criterio de terminado.

Orden de ejecución si el tiempo aprieta: A1 → A2 → A5 → A3 → A4. Los tres primeros son los que protegen o desbloquean más puntos de rúbrica por hora invertida, y ninguno de ellos es un problema de modelado: son despliegue, publicación y un micrófono.

3.6 Métricas de éxito

Nivel	Métrica	Estado
Modelo	Orden estrictamente creciente por nivel MCER en corpus externo	**Cumplido**: 0,5040 · 0,5561 · 0,9276 · 1,2414 · 1,4952
Modelo	Señal por encima de la longitud del texto	**Cumplido**: correlación parcial 0,668
Producto	Un usuario sin formación técnica completa el recorrido	**Cumplido con reservas**: lo completó, y de esa sesión salieron 8 correcciones
Producto	Accesibilidad de color	**Cumplido**: las cuarenta parejas de color de las cinco paletas superan WCAG AA; las más ajustadas, 4,53 (texto) y 3,11 (título)
Producto	Robustez	**Cumplido**: 205 pruebas de estrés y 27 pasos de integración, ningún manejador lanza hacia la interfaz
Operación	Enlace permanente disponible	**Cumplido**: `MikeMaki1763/literalevel` en Hugging Face Spaces, público y en marcha. Sin disco persistente todavía (A4)
Operación	Catálogo medido, no heredado	**En curso** (A3)
Impacto	Proporción de libros terminados	**Sin instrumentar** (A9)

Cuadro 5: Métricas por nivel, con su estado real.

3.7 Riesgos

Riesgo	Impacto	Mitigación
El enlace de la demostración muere durante la evaluación	Alto	A2: despliegue permanente, probado desde un dispositivo ajeno antes de la fecha
El servicio externo de lenguaje agota su presupuesto en mitad de una demostración	Medio	Ya mitigado: la aplicación degrada con un mensaje legible y conserva diccionario, fonética, audio, buscador y puntuación
Que la letra MCER se lea como una certificación	Alto, reputacional	Declaración de alcance en el documento y aviso permanente en pantalla
Que la remedición del catálogo no termine a tiempo	Medio	El proceso es reanudable por bloques y los resultados se guardan por lotes; lo medido ya es utilizable aunque falte el resto
Sobrecarga del espejo de descarga de Project Gutenberg	Medio, ético	Seis hilos y no treinta, cada uno con su pausa entre peticiones; y el vocabulario se obtuvo del SPGC, no rascando el sitio
Contenido inapropiado para una lectora menor de edad	Medio	Decisión razonada de **no filtrar por contenido** y avisar en la ficha; se argumenta en el apartado 8.4

Cuadro 6: Riesgos y mitigaciones.

4 Descripción de los datos

Todos los datos de este trabajo provienen de **corpus académicos publicados, APIs y descarga directa de repositorios de dominio público**. No se usó Kaggle como fuente de datos en ningún punto del proyecto, conforme a la restricción del módulo. Cuando un corpus tiene licencia restrictiva se dice, y su texto crudo nunca sale del entorno de cómputo: solo estadísticas agregadas.

4.1 Inventario de fuentes

4.2 Relevancia de cada fuente

CLEAR es el corpus central del modelado. Su variable objetivo, `BT_easiness`, no es una fórmula de legibilidad: es una escala construida a partir de comparaciones pareadas juzgadas por lectores humanos, lo que evita que el modelo aprenda a reproducir un contador de sílabas. Además trae precalculadas once métricas clásicas (Flesch, Flesch-Kincaid, ARI, SMOG, Dale-Chall, CAREC, CAREC_M, CML2RI, conteos de palabras, oraciones y párrafos) y dos variables de estratificación —`Categ` (literario/informativo) y `Lexile Band`— que permiten comprobar si el modelo funciona igual de bien en narrativa que en divulgación. Esa comprobación por dominio se hizo y aparece en el apartado 7.3.

OneStopEnglish aporta algo que CLEAR no puede: el mismo artículo reescrito en tres niveles. Como el contenido es idéntico y solo cambia la complejidad lingüística, permite medir el orden dentro de cada artículo, una prueba mucho más exigente y limpia que comparar textos distintos entre sí.

British Council es la única fuente con niveles MCER asignados por una institución de enseñanza de idiomas, que es exactamente la escala que el producto muestra al usuario. Es el juez final.

SPGC existe por una razón de higiene: descargar decenas de miles de libros uno a uno desde `gutenberg.org` viola su política de acceso automatizado. El SPGC publica los conteos de palabras ya calculados, con lo que se obtiene la distribución léxica del catálogo completo sin tocar el servidor de Gutenberg.

Kaikki/Wiktionary sustituyó a una API comercial de diccionario. La decisión fue de producto y de derechos: un SQLite local de 1,48 millones de entradas no tiene límite de peticiones,

Fuente	Qué aporta	Tamaño	Origen	Licencia / acceso
CLEAR Corpus	Etiqueta continua de legibilidad (`BT_easiness`) para el modelado supervisado	4.724 extractos	Repositorio público del proyecto CLEAR (Crossley y col., 2023)	Uso investigador, descarga directa
OneStop-English	Corpus de **afinado** de la variante v2 (151 artículos) y validación ordinal en 3 niveles sobre los 38 reservados	567 textos (189 por nivel)	GitHub (Vajjala & Lučić, 2018)	CC BY-SA 4.0
British Council LearnEnglish	Validación externa contra niveles MCER oficiales	59 textos A1–C1	Descarga de los PDF públicos	Con derechos: no se distribuye ni se imprime texto
SPGC (Standardized Project Gutenberg Corpus)	Lista global de frecuencia de palabras (solo conteos, sin texto)	45.345 libros en inglés de 55.905	Zenodo, registro 2422561 (Gerlach & Font-Clos, 2018, 2020)	Abierta
Project Gutenberg	Catálogo de obras a medir y a leer dentro de la app	79.337 entradas; 61.642 libros de texto en inglés	Catálogo oficial (Project Gutenberg, 2026) + espejo `gutenberg.pglaf.org`	Dominio público
Kaikki / Wiktionary	Diccionario, IPA británica y americana, audio	1.487.639 filas en SQLite (243 MB)	Volcado de kaikki.org (Ylönen, 2022)	Libre
StoryWeaver / Global Digital Library	Lecturas graduadas del catálogo heredado	1.049 registros	API pública de contenidos	Abierta, pero sin descarga de texto

Cuadro 7: Fuentes de datos, con volumen y procedencia.

no cuesta dinero por consulta y no puede desaparecer si un proveedor cambia sus condiciones. Se descartó explícitamente Oxford Dictionaries.

4.3 Calidad de los datos: lo que está bien y lo que no

Un apartado de calidad que solo diga «los datos están limpios» no informa. Estos son los problemas reales encontrados y qué se hizo con cada uno.

(a) El corpus de validación MCER no es homogéneo. De los 59 textos de British Council, una parte no es prosa: en A1 hay un menú de restaurante, un horario de estudio, un tablero de salidas de aeropuerto, tarjetas de visita y mensajes de texto. Se definió un filtro de prosa continua por dos vías independientes —por palabras clave del título y por estructura (≥ 7 palabras por línea y densidad de puntuación final de frase en el intervalo $(0; 0{,}11]$)—, que coinciden en 53 de 59 casos, el 89,8 %.

Ese filtro es el del análisis, no el que aplica la aplicación, y conviene no confundirlos porque dan resultados distintos. Lo que corre en producción es `scoring.continuous_prose`, con otras reglas: al menos 150 palabras, al menos cuatro frases, entre 5 y 55 palabras de media por frase, y rechazo si hay dos o más viñetas o más del 35 % de líneas cortas. Coinciden en el propósito —tirar menús, listas y tablas— pero no en los umbrales.

Y aquí hay que contar la secuencia real, porque el filtro no se fijó antes de mirar ningún resultado. El orden fue el contrario: primero se puntuaron los 59 textos, se vio que el modelo daba resultados absurdos con el menú y el tablero de salidas, y **de ese diagnóstico salió la idea del filtro**. Que las dos vías se definieran sin volver a mirar las puntuaciones, y que coincidan entre sí en el 89,8 % de los casos, es lo que impide que sea un filtro hecho a medida de las notas. Pero no es un criterio *a priori*, y llamarlo así sería regalarse una garantía que no se tiene.

(b) Las etiquetas del catálogo heredado no son fiables, y hay que decirlo. El catálogo con el que la aplicación funciona hoy tiene **1.197 libros** —no 12.752, como sugiere un `wc -l` ingenuo: el campo `hook` contiene saltos de línea entrecomillados y hay que contar con un lector de CSV real—. Su columna `nivel_cefr` **no es anotación humana ni metadato del editor**: son predicciones de un modelo anterior (v1) sobre las primeras ∼190 palabras de cada obra, con cortes MCER obtenidos por cuantiles. El resultado es un reparto que no resiste el sentido común (cuadro 8 y figura 3).

Nivel	Libros	%
A1	723	60,4
A2	185	15,5
C2	115	9,6
B1	69	5,8
C1	53	4,4
B2	52	4,3
Total	**1.197**	**100**

Cuadro 8: Reparto de niveles del catálogo heredado. Son predicciones de un modelo v1 sobre las primeras ∼190 palabras, no anotación fiable.

Hay cuentos infantiles etiquetados C1 y clásicos muy distintos entre sí todos en C2. Y el tramo B1–B2, donde está la mayoría de los lectores reales, son 121 libros de 1.197. Estas etiquetas sirven para ordenar y filtrar de forma aproximada, **no son una medida fiable libro a libro**, y así se declara tanto en el repositorio como en la aplicación. Es la razón de ser del precálculo descrito en 8.3: remedir todo el catálogo, libro entero, con el modelo final.

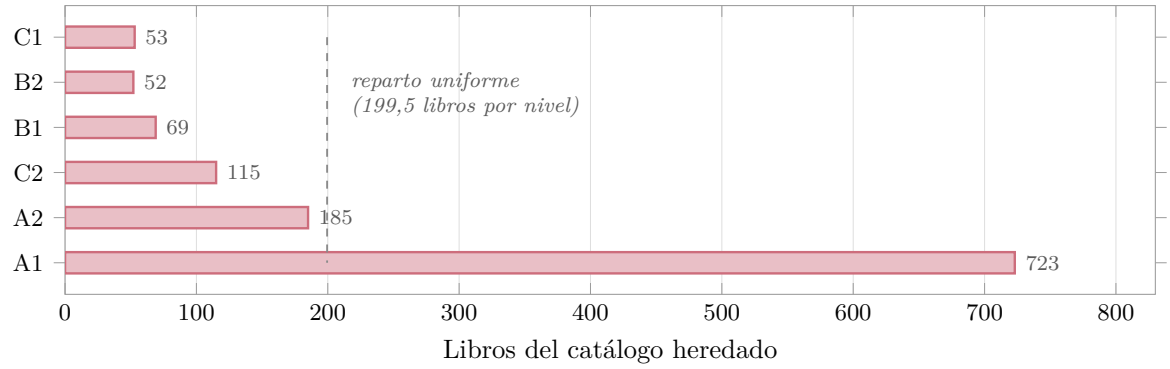


Figura 3: El sesgo del clasificador v1, visto de una vez. Seis de cada diez libros de dominio público quedaron etiquetados A1 y el tramo B1–B2 —donde está la mayoría de los lectores reales— reúne 121 de 1.197 obras. Una distribución así no describe la literatura en dominio público: describe el clasificador que la produjo. Datos del cuadro 8.

(c) De esos 1.197 libros, solo 148 se pueden abrir. Son los de Project Gutenberg. Los otros 1.049 provienen de StoryWeaver y no tienen fichero descargable, de modo que aparecían en el desplegable de lectura como opciones muertas. Peor aún: su identificador se había usado para construir enlaces a Gutenberg extrayendo sus dígitos, con lo que `SWgdlgdl201` apuntaba al libro 201 de Gutenberg, que es otra obra. Un enlace al libro equivocado es peor que ningún enlace. Hoy el desplegable lista solo lo que se puede abrir, la tabla marca los descargables y una línea dice cuántos de cuántos son.

(d) La licencia de Project Gutenberg se estaba puntuando como si fuera novela. El texto legal viene pegado al último capítulo: en *Alice's Adventures in Wonderland*, 2.900 de las 5.042 palabras del capítulo XII son licencia. Eso contaminaba tanto la puntuación como las estadísticas de la ficha (`gutenberg` y `project` aparecían entre las palabras más repetidas del libro). Se recorta por las marcas START/END dentro del capítulo, sin descartar el capítulo, que contiene el final de la obra.

(e) La portada no es un capítulo. En un `.txt` de Gutenberg, las 4.957 palabras previas al capítulo I (portada, índice, pies de ilustración) se estaban puntuando como si fueran la novela. En el análisis de *War and Peace*, el «capítulo más fácil del libro» resultó ser la portadilla. Se descarta con la etiqueta que el propio lector de ficheros asigna, «Antes del primer capítulo». Se probó descartar por el filtro de prosa continua y **no sirve**: se llevaba por delante dos capítulos reales de *Alice*.

5 Análisis exploratorio

Siguiendo la organización canónica del módulo, el análisis se presenta en tres niveles: univariado, bivariado y multivariado. Todas las figuras y cuadros citados se generan en el cuaderno que acompaña a este documento.

5.1 Análisis univariado

La variable objetivo. `BT_easiness` es continua y aproximadamente simétrica alrededor de cero. No hay clases desbalanceadas que corregir porque no hay clases: el problema es de regresión. Cuando se necesitó una versión categórica para comparar modelos, se construyó por cuantiles (`qcut`), lo que garantiza seis grupos equifrecuentes y hace que la exactitud sea comparable entre modelos.

Las variables textuales derivadas. Sobre cada extracto se calcularon, a partir de sus *tokens*, seis variables de ingeniería propia: longitud media de oración, *type-token ratio*, longitud media de palabra, proporción de palabras raras, sílabas medias por palabra y porcentaje de polisílabos. Todas son positivas y con cola derecha, como es habitual en variables de conteo sobre texto.

La distribución del vocabulario inglés. El agregado de los 45.345 libros del SPGC arroja **2.838.258.803 palabras** y un vocabulario único de **3.295.146 formas**. La distribución sigue la ley de Zipf (Zipf, 1949) con precisión: unas pocas miles de palabras cubren la mayor parte del texto corrido. Este hecho, que parece de trivia, tiene una consecuencia práctica que se documenta en 5.2.

El catálogo. El cuadro 8 y la figura 3 muestran el reparto de niveles del catálogo heredado. Su forma —60 % en A1— es en sí misma un hallazgo del análisis exploratorio: una distribución así no describe la literatura en dominio público, describe el sesgo del clasificador que la produjo.

La dificultad dentro de un libro. La unidad de análisis del producto no es el libro sino el capítulo, y la figura 10 muestra por qué: los 362 capítulos de *War and Peace*, medidos sin muestrear, se reparten entre 1,333 y 1,990 con media 1,735. La figura 11 añade dos libros más y confirma que la dispersión interna es la norma, no la excepción.

5.2 Análisis bivariado

Cada variable frente a la dificultad. La matriz de correlación de las variables derivadas contra `BT_easiness` confirma el sentido esperado: los textos más fáciles tienen oraciones más cortas, palabras más cortas, menos polisílabos y menor proporción de palabras raras. La correlación de `rare_word_ratio` con `BT_easiness` es negativa, como debe ser.

El experimento de saturación léxica. La variable «palabra rara» depende de qué lista de palabras familiares se use. Se probaron tres, de menor a mayor (cuadro 9).

Lista de palabras familiares	Libros	Correlación de `rare_word_ratio` con `BT_easiness`
Corpus Gutenberg de NLTK	18	−0,379
Muestra propia de Gutenberg	397	−0,330
SPGC completo, en inglés	**45.345**	**−0,326**

Cuadro 9: Efecto de escalar el corpus de referencia léxica. La correlación no mejora.

Este es un **resultado negativo y se reporta como tal**: multiplicar por 2.500 el corpus de referencia no mejora la señal, e incluso la baja marginalmente. La exactitud del clasificador de tres clases se mantuvo en 0,51 con las tres listas. La explicación está en la ley de Zipf: la distribución de frecuencias del inglés converge muy rápido, así que las 3.000 palabras más frecuentes de 18 libros y las de 45.345 libros son casi el mismo conjunto. El valor del paso no está en la métrica sino en la cobertura: la lista del SPGC generaliza mejor a texto nuevo arbitrario, que es lo que la aplicación recibe.

Dificultad frente a longitud, la variable incómoda. Sobre los 47 textos de British Council medibles en local, contar las palabras del texto —sin modelo alguno— alcanza una correlación de Spearman de **0,807** con el nivel oficial. El modelo alcanza 0,860. Es decir: en ese corpus, nivel y longitud están confundidos, porque los materiales de examen gradúan también la extensión de la tarea. Publicar ese *baseline* antes de que lo pregunte el evaluador es más creíble que omitirlo; en el apartado 7.5 se cuantifica cuánta señal aporta el modelo por encima de él.

Dificultad frente a dominio. El nivel del texto está correlacionado con su tipo documental. Al filtrar los 59 textos de British Council a prosa continua, el nivel A1 desaparece casi por completo y el rango evaluable **de esa tanda de análisis** se encoge de cinco niveles a cuatro

(A2–C1): el catálogo gratuito de British Council no tiene C2, así que el corpus nunca tuvo seis. La reproducción local del cuadro 16 sí conserva los cinco, con tres textos en A1, porque filtra con otras reglas. Por eso el *baseline* de contar palabras cae de 0,879 a 0,765 al filtrar: parte de la señal del conjunto completo era simplemente que los textos A1 son cortos. Las correlaciones antes y después del filtro **no son comparables entre sí**, y se reportan por separado. Los conjuntos de textos que aparecen aquí y en el apartado 7.4 están todos, con lo que se puede y no se puede hacer con cada uno, en el cuadro 14.

5.3 Análisis multivariado

Las variables clásicas se estorban entre sí. Las métricas de legibilidad tradicionales (Flesch, Flesch-Kincaid, ARI, SMOG, Dale-Chall) son transformaciones distintas de los mismos dos ingredientes —longitud de oración y longitud de palabra— y por tanto están fuertemente correlacionadas entre ellas. Meterlas todas en un modelo lineal no añade información: añade multicolinealidad. Por eso el conjunto de trabajo se redujo a **tres** variables poco redundantes entre sí y con interpretación distinta: `avg_sentence_length` (complejidad sintáctica), `rare_word_ratio` (carga léxica) y `type_token_ratio` (diversidad de vocabulario).

Hasta dónde llegan las variables clásicas. Con esas tres variables, un clasificador de seis clases alcanza 0,29 de exactitud con regresión logística (Pedregosa y col., 2011) y 0,28 con XGBoost (Chen & Guestrin, 2016). Que un ensamble de árboles —capaz de capturar interacciones no lineales arbitrarias— no supere a un modelo lineal es la prueba de que **el cuello de botella no era el modelo sino la representación del texto**. Tres números por documento no bastan para separar seis clases.

Conviene decir qué sostiene ese argumento y qué no. Lo que se comprueba es que **subir la capacidad del algoritmo sobre estas variables no mueve el resultado**, y eso se ve en cuatro modelos distintos. Lo que no se demuestra es que exista un límite teórico: nadie ha probado todas las combinaciones posibles de conteos, y el cuadernillo enseña un caso donde ampliar de tres a diecisiete variables sí mejora. La conclusión honesta es empírica, no un techo.

Representación densa. Al sustituir las tres variables por un *embedding* de 384 dimensiones de `all-MiniLM-L6-v2` (Reimers & Gurevych, 2019), la exactitud salta a 0,37 y el error ordinal medio baja de 1,39 a 0,93 niveles. El modelo híbrido (*embedding* + las tres variables clásicas) da 0,37 y 0,91: prácticamente lo mismo. Esto indica que **el *embedding* ya contiene la información que aportaban las tres variables**, y bastante más. La figura 4 recoge la progresión completa.

Estructura por dominio. La comparación por subconjuntos de CLEAR (literario frente a informativo, y por banda Lexile) muestra que el rendimiento no es uniforme: el modelo funciona mejor en texto informativo que en literario, y peor en la banda más fácil (Lexile 500) que en la más difícil (Lexile 1300). Los números están en el cuadro 13.

6 Procesamiento de datos

Cada transformación se documenta con su justificación. La regla que se siguió es la del módulo 1 del diplomado: **no se transforma sin medir qué se rompió**.

6.1 Sobre el texto de entrada

El cuadro 10 recoge las ocho transformaciones que sufre el texto antes de llegar al modelo; la figura 1 las sitúa en la cadena completa.

#	Transformación	Por qué	Evidencia / consecuencia
T1	**Filtro de prosa continua** antes de puntuar: se rechaza si hay ≥ 2 viñetas o ≥ 6 líneas cortas	El modelo solo vio prosa; puntuar un menú da un número sin significado	El filtro estaba muerto en producción: se normalizaba *antes* de comprobar, y `normalize()` colapsa los saltos de línea, así que el detector recibía siempre una sola línea. Una carta de menú de 432 palabras se puntuaba como prosa. Corregido: el filtro va sobre el texto crudo
T2	**Normalización de espacios** (`\s+` → espacio) después del filtro	Estabiliza el troceado en bloques	Sin efecto sobre la puntuación; solo sobre el corte
T3	**Troceado en bloques de 250 palabras, mínimo 150**	Es la unidad con la que se entrenó; un bloque más corto no tiene señal suficiente	Constante del entrenamiento: cambiarla invalidaría las métricas reportadas
T4	**Truncado a 256 *tokens***	Límite de contexto del modelo	Medido: de 200 bloques de 250 palabras, el **100 %** llega exactamente a 256 *tokens* tras truncar, porque en prosa inglesa real 250 palabras superan siempre los 256 BPE. Dentro de un texto troceado así no hay relleno; agrupando ventanas de capítulos distintos sí lo hay, y eso se trata en el §8.3
T5	**Recorte de la licencia de Gutenberg** por las marcas START/END, dentro del capítulo	2.900 de las 5.042 palabras del capítulo XII de *Alice* son texto legal	Sin esto, el modelo puntuaba texto jurídico como narrativa y la ficha listaba «gutenberg» entre las palabras más frecuentes del libro
T6	**Descarte de portada, índice y portadilla** por la etiqueta «Antes del primer capítulo»	4.957 palabras de paratexto se puntuaban como novela	Se probó descartar por el filtro de prosa continua y se rechazó: eliminaba dos capítulos reales de *Alice*
T7	**Muestreo de hasta 8 bloques repartidos por el documento** para la puntuación rápida	Dar un número en segundos, no en minutos	Cuantificado: 8 bloques dan 1,784 y el recorrido completo de las 23 ventanas del mismo capítulo da 1,743. El atajo se desvía 0,041 sobre una escala de 0 a 2
T8	**Recorte de entradas del usuario en el servidor** (40 caracteres por palabra, 400 por oración, 20 MB por fichero)	El límite del navegador es una sugerencia, no una defensa	Una cadena de 3.000 caracteres pasaba el filtro de «máximo cuatro palabras» y se pintaba como encabezado: 9.312 caracteres llenando la pantalla del móvil

Cuadro 10: Transformaciones sobre el texto, con su justificación y su evidencia.

6.2 Sobre las variables del modelado clásico

#	Transformación	Por qué
T9	**Partición agrupada por libro** (`GroupShuffleSplit` sobre `Title`, 20 % de prueba, semilla 42)	Un mismo libro aporta varios extractos a CLEAR. Con una partición aleatoria por fila, fragmentos del mismo libro caerían a ambos lados y el modelo memorizaría el estilo del autor en lugar de aprender dificultad. Es fuga de datos por diseño, y se evita por diseño
T10	**Estandarización** (`StandardScaler`) ajustada solo en entrenamiento	Ajustar el escalador con los datos de prueba filtra su distribución al modelo
T11	**Discretización por cuantiles** (`qcut`) para las versiones categóricas	Produce grupos equifrecuentes, con lo que la exactitud entre modelos es comparable y el azar tiene una probabilidad conocida ($1/6 = 16{,}7\,\%$)
T12	**Lista de palabras familiares construida solo con el conjunto de entrenamiento**	Si se cuentan también las palabras de los extractos de prueba, esas palabras entran en la definición de una variable de entrada: es fuga de datos. Medida la diferencia, resulta despreciable —cambian 228 de 3.000 palabras y los resultados se mueven en la tercera decimal—, pero era fuga y se quitó
T13	**Lista alternativa a escala**: las 3.000 más frecuentes del SPGC	Sustituye una lista de 18 libros por una de 45.345. Es un experimento de cobertura, no la lista que usan los modelos del cuadernillo, y **el sistema desplegado no consulta ninguna lista de palabras**: puntúa con el transformador

Cuadro 11: Transformaciones sobre las variables tabulares.

6.3 Sobre el corpus de vocabulario (procesamiento distribuido)

Los conteos del SPGC son 45.345 ficheros pequeños. Agregarlos secuencialmente es un mal uso del tiempo y del sistema de ficheros, de modo que la agregación se hizo con **PySpark** (Zaharia y col., 2016): los ficheros se distribuyen en 200 particiones, un `flatMap` los convierte en pares (palabra, conteo) y un `reduceByKey` los suma en una única lista global de frecuencia. Es el patrón canónico de conteo distribuido y es lo que hace tratable un corpus de 2.838 millones de palabras en una sesión de Colab.

6.4 Sobre el diccionario

El volcado de Kaikki llega como JSONL de líneas independientes. Se filtra a entradas en inglés con palabra no vacía y se ingesta en SQLite con un esquema plano (`palabra`, `pos`, `sentidos` como JSON, `ipa_uk`, `ipa_us`, `audio_uk`, `audio_us`) y un índice por `palabra`. La justificación es de latencia: la primera consulta sobre 1.487.639 filas tarda **0,001 s** con el índice puesto y la base abierta en modo solo lectura. Los 243 MB del fichero no cuestan nada en tiempo de respuesta.

Un dato de cobertura que condiciona el diseño de la aplicación: solo **7.003 de las 1.487.639 entradas (0,5 %) traen audio de pronunciación**. Es decir, casi cualquier palabra que un lector consulte por primera vez necesitará síntesis de voz. Esa medición es la que justificó paralelizar las dos llamadas de red de una consulta en lugar de encadenarlas.

7 Modelación

7.1 Diseño experimental

Todos los modelos comparten la **misma partición agrupada por libro** (3.774 extractos de entrenamiento y 950 de prueba) y la misma semilla, de modo que las diferencias entre ellos son atribuibles al modelo y no al reparto de los datos. Se comparan sobre los mismos 950 extractos reservados, con dos métricas: exactitud sobre seis clases y **error ordinal medio**, que penaliza proporcionalmente a la distancia del fallo.

Dos precisiones sobre ese conjunto, porque cambian cómo hay que leer las cifras. La primera: esos 950 extractos son también los que sirvieron para **elegir la época** del transformador, de modo que funcionan como validación de selección y no como un test independiente; sus números pueden ser algo optimistas. La segunda: las seis clases salen de partir `BT_easiness` en **sextiles de este corpus**, no de anotaciones del Marco Común Europeo. Se les dan nombres A1–C2 para poder ordenarlos, pero no son niveles MCER certificados ni equivalen a los del modelo desplegado, que se ancla con otro corpus. Las dos cosas son ciertas.

7.2 Progresión de modelos

Modelo	Representación del texto	Exactitud (6 clases)	Error ordinal medio	Tanda
Regresión logística	3 variables clásicas	0,29	1,39	histórica
XGBoost	3 variables clásicas	0,28	1,42	histórica
Regresión logística	3 variables clásicas	**0,313**	**1,295**	recalculada
Regresión logística	**17 variables**	**0,352**	**1,061**	recalculada
XGBoost	**17 variables**	**0,340**	**1,081**	recalculada
Regresión logística	*Embedding* MiniLM (384 d)	0,37	0,93	histórica
Regresión logística	Híbrido (*embedding* + 3 variables)	0,37	0,91	histórica
`roberta-base` afinado	**Texto crudo, atención**	**0,46**	**0,67**	histórica

Cuadro 12: Progresión de modelos sobre los mismos 950 extractos reservados, con la tanda de la que procede cada fila. La mejora acompaña siempre al enriquecimiento de la representación, no a la complejidad del clasificador.

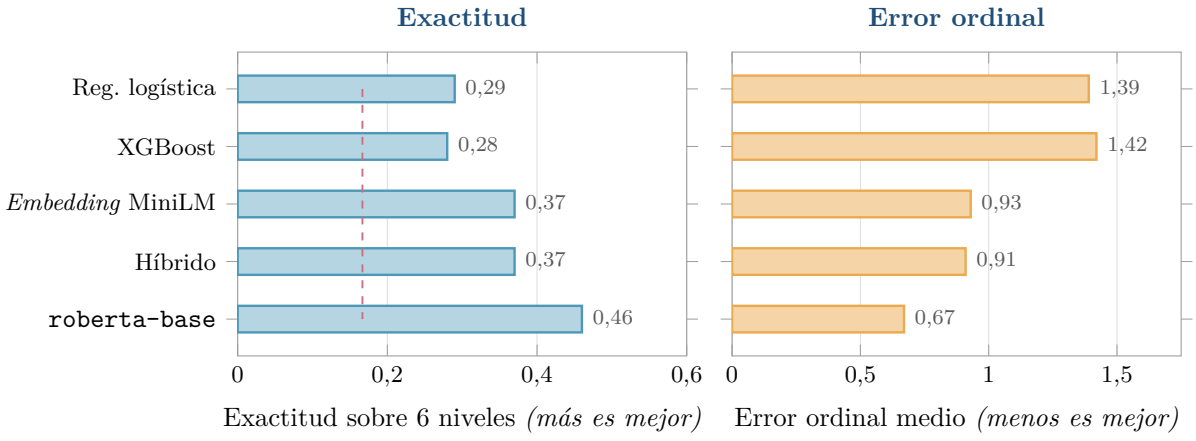


Figura 4: La tesis metodológica del trabajo, en dos ejes. Los dos primeros modelos comparten *representación* (tres variables clásicas) y solo cambian de clasificador: XGBoost no mejora a la regresión logística, incluso empeora el error ordinal. Los saltos ocurren cuando cambia la representación del texto: *embedding* denso primero, texto crudo con atención después. La línea roja discontinua del panel izquierdo marca el azar ($1/6 = 0{,}167$), que es lo que acertaría un clasificador que no leyese nada. Datos del cuadro 12.

La lectura del cuadro 12 es la tesis metodológica del trabajo: **cada vez que se le dio al**

modelo una representación más rica del texto, el desempeño subió; y cuando solo se aumentó la potencia del clasificador sobre la misma representación pobre, no subió. XGBoost sobre tres variables es marginalmente peor que una regresión logística sobre las mismas tres variables.

El modelo afinado directamente sobre el texto es un `roberta-base` de 125 millones de parámetros con cabeza de regresión sobre `BT_easiness`, y alcanza además **RMSE 0,560** y **correlación de Pearson 0,89** con la etiqueta continua real.

Y aquí hay que evitar una confusión que el documento invitaba a hacer. Ese `roberta-base` **no es el modelo que se despliega**. El que va en la aplicación es un `distil roberta-base` —la mitad de capas, 82 millones de parámetros— y se entrenó sobre otro corpus, el de anclaje MCER, no sobre `BT_easiness`. Las cifras de este apartado son del experimento sobre CLEAR; las del modelo desplegado están en el §7.4 y no se pueden encadenar con estas. La diferencia de calidad entre las dos arquitecturas sobre CLEAR **no se midió**, así que la decisión de usar la destilada se tomó por tamaño y velocidad, no porque se comprobara que costaba poco.

Sobreajuste, visto y controlado. El entrenamiento corrió seis épocas con tasa de aprendizaje 2e-5, decaimiento de pesos 0,01, calentamiento y precisión mixta. El RMSE de validación mejoró hasta la época 3 (0,560) y a partir de ahí empeoró de forma monótona —época 4: 0,578; época 5: 0,637; época 6: 0,660— mientras la pérdida de entrenamiento seguía bajando (figura 5). Es un caso de libro. Como se guardaba un punto de control por época y se cargaba automáticamente el mejor al terminar, **el modelo reportado es el de la época 3, no el de la última**.

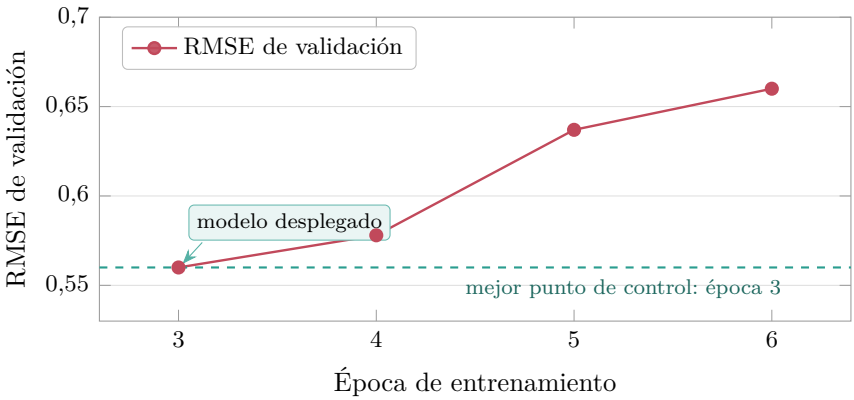


Figura 5: El sobreajuste, medido. El RMSE de validación toca su mínimo en la época 3 y empeora de forma monótona después, mientras la pérdida de entrenamiento seguía bajando. Se guardó un punto de control por época y se cargó automáticamente el mejor: el modelo desplegado es el de la época 3, no el de la sexta.

7.3 Dónde funciona y dónde no: análisis por dominio

Un modelo que se evalúa solo en agregado esconde sus propios puntos ciegos. Se midió la correlación con la dificultad real por subconjunto, comparando dos variantes del modelo entrenadas sobre corpus distintos (v1 sobre `BT_easiness`, v2 afinado sobre material graduado para aprendices).

Por qué la casilla de OneStopEnglish está vacía para v2, y no es un olvido. La cifra que ocupaba ese hueco —un 0,840 que hacía ganar a v2 con holgura— estaba medida sobre los 567 textos completos, y **v2 se afinó precisamente con 151 de los 189 artículos de ese corpus**. El 80 % de esos textos era su propio entrenamiento, y se comparaban contra un v1 que no los había visto nunca. No es que la cifra fuera falsa: es que no medía lo que la tabla decía medir. Se retira en lugar de maquillarla.

Dominio	n	v1	v2
Literatura (CLEAR, `Lit`)	461	**0,848**	0,760
Informativo (CLEAR, `Info`)	489	**0,905**	0,837
Banda Lexile 500 (más fácil)	62	**0,651**	0,459
Banda Lexile 1300 (más difícil)	272	**0,877**	0,773
Periodístico (OneStopEnglish)	567	0,458	*no comparable*
Exámenes MCER (British Council)	59	−0,239	**0,175**

Cuadro 13: Matriz modelo × dominio. Correlación orientada con la dificultad real; más alto es mejor.

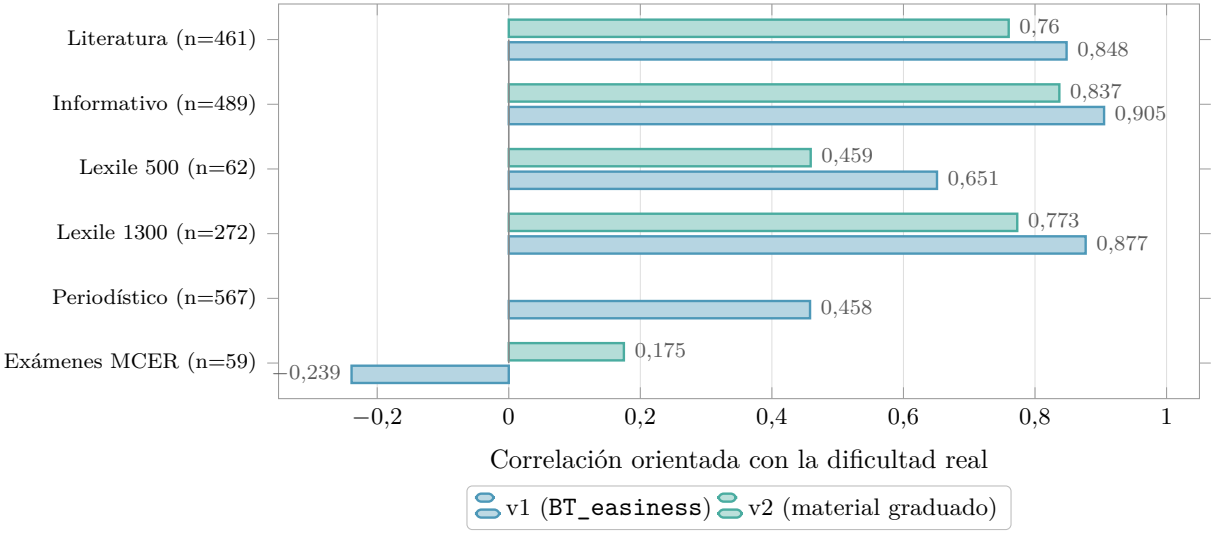


Figura 6: v1 domina en las cuatro filas de CLEAR, donde la etiqueta son juicios de lectores nativos sobre prosa continua. **A v2 le falta la barra de la fila periodística a propósito**: la cifra que ocupaba ese hueco estaba medida sobre los 567 textos de OneStopEnglish, y v2 se afinó con 151 de sus 189 artículos, así que el 80 % de ese conjunto era su propio entrenamiento. Lo detectó una auditoría externa y se retira en lugar de maquillarse. Queda por tanto sin respaldo la lectura simétrica —que v2 gane donde la etiqueta es una graduación para aprendices—, porque la única fila que la sostenía estaba contaminada. Datos del cuadro 13.

Eso obliga a rebajar la conclusión que colgaba de ella. Lo que sigue en pie es que **v1 gana en dificultad de lectura tipo CLEAR** —juicios de lectores nativos sobre prosa continua—, con ventaja en las cuatro filas medidas limpiamente. Lo que **ya no se sostiene con esta evidencia** es la afirmación simétrica de que v2 gane donde la etiqueta es una graduación para aprendices: la única fila que la respaldaba estaba contaminada, y la de British Council, donde v2 sí aventaja a v1, tiene una correlación de 0,175, demasiado baja para sostener nada por sí sola.

La decisión de qué escala presentar al usuario precede a la de qué modelo desplegar; se eligió la escala anclada al MCER, y con ella el modelo correspondiente. Esa decisión no cambia, pero conviene saber que se tomó con menos evidencia de la que este cuadro aparentaba dar.

7.4 El modelo desplegado y su validación

El modelo en producción, **v4**, es un `distilroberta-base` (Liu y col., 2019; Sanh y col., 2019) de seis capas y 82 millones de parámetros, con cabeza de regresión, servido con *Transformers* (Wolf y col., 2020) y cuyos pesos ocupan 328 MB en disco. Puntúa bloques de 250 palabras truncados a 256 *tokens* y promedia sin ponderar, con un tope de **ocho ventanas por documento** repartidas a lo largo del texto: es lo que mantiene el análisis en **alrededor de un segundo** en una CPU —0,96 a 1,04 s medidos sobre ocho ventanas en el equipo del autor, un Ryzen 5 2600—, y por eso un vistazo mide una muestra del texto y no el texto entero. El precálculo del catálogo, en cambio, recorre el libro completo sin muestrear y publica una dificultad por capítulo; esa remedición está **en curso** (accionable A3), así que las etiquetas que hoy lleva el catálogo siguen siendo las heredadas del v1. Su escala interna es 0–5 —un valor por nivel MCER, con posiciones intermedias (A1+, A2+, B1+, B2+)— y la pública es esa misma escala multiplicada por 0,4. **El modelo es final y no se reentrena.**

Antes de las cifras, las reglas del juego. Por este apartado y por el siguiente circulan **cinco conjuntos de textos distintos**, y confundirlos es fácil porque cuatro de los cinco salen del mismo material de British Council. No son subconjuntos ordenados unos de otros y sus tamaños no se restan entre sí. El cuadro 14 dice qué es cada uno, qué se mide con él y qué *no* se puede hacer con él; el resto del apartado los cita por su nombre.

Cuadro 14: Los cinco conjuntos de textos que aparecen en la validación. Cuatro de los cinco salen del mismo catálogo de British Council, con extracciones y filtros distintos: no son subconjuntos unos de otros y sus tamaños no se restan.

Conjunto	n	De dónde sale	Qué se mide con él	Qué *no* se puede hacer con él
Validación ciega (interno)	144	Partición de validación del corpus de anclaje MCER: 654 documentos aceptados, 510 de entrenamiento y 144 reservados	Exactitud, acierto dentro de ±1 nivel y Spearman 0,908 del modelo desplegado (cuadro 15)	Presentarlo como validación externa. Sale del mismo corpus con el que se afinaron los pesos, así que su 0,908 no es comparable con las cifras de British Council
British Council, tanda de Colab	38	Extracción de los PDF hecha en Colab durante el entrenamiento, con su propio filtro	Spearman 0,829 y el 100 % dentro de ±1 (cuadro 15); las cuatro medias por nivel que ajustan la recta de compresión (figura 8)	Restarlo de los 47. Es otra tanda, con otra extracción y otro filtro: la diferencia no son «nueve textos concretos» que se puedan nombrar

Conjunto	n	De dónde sale	Qué se mide con él	Qué *no* se puede hacer con él
British Council, reproducción local	47	Los 59 publicados, menos 2 sin cuerpo localizable al extraer el PDF y 10 rechazados por el filtro de prosa (cuadro 17)	**El resultado principal**: el orden creciente por nivel (cuadro 16) y las tres cifras del *baseline* —0,860, 0,807 y 0,668— del cuadro 18	Leerlo como «los textos que la aplicación aceptaría». El validador local filtra más flojo que la app (§7.7)
Los que pasan el filtro completo	31	Esos mismos 47 refiltrados conservando los saltos de línea, es decir con las cuatro reglas del filtro de prosa continua activas	Cuánto depende el conjunto evaluado de una regla que el validador desactiva: sobreviven 31 y A1 se queda con un solo texto (§7.7)	Sostener el orden sobre cinco niveles. No se usa para ninguna cifra publicada en este documento
Publicados por British Council	59	Todos los PDF descargados del catálogo gratuito. Los nombres de los 59 están en el manifiesto del corpus externo	El diagnóstico del §4.3: que el corpus no es homogéneo, y el 89,8 % de coincidencia entre las dos vías con que se definió el filtro	Usarlo como corpus de validación. Incluye menús, pósters y horarios, y las correlaciones medidas sobre él no se comparan con las de después de filtrar

El corpus de anclaje MCER con el que se afinó son 654 documentos aceptados —57 descartados por longitud insuficiente—, repartidos en 510 de entrenamiento y 144 de validación. Esos 144 documentos son el conjunto de validación ciega que produce las cifras de la primera fila del cuadro 15.

De dónde salen esas cifras, dicho con precisión. De la ejecución de entrenamiento del v4, que vive en Google Drive y no en este repositorio: aquí **no hay ningún archivo que las respalde**, y una versión anterior de este documento citaba una tarjeta `metricas_literalevel_v4.json` que no existe. Lo único comprobable desde el repositorio es la aritmética interna —$510 + 144 = 654$, $77/144 = 53{,}47\,\%$ y $140/144 = 97{,}22\,\%$—, que cuadra. Quien quiera verificar el resto tiene que confiar en esa ejecución o rehacerla.

Conjunto	n	Exacto	Dentro de ±1 nivel	Spearman
Validación ciega	144	53,5 %	**97,2 %**	**0,908**
British Council (externo)	38	50,0 %	**100 %**	0,829

Cuadro 15: Métricas del modelo desplegado. MAE de 0,499 niveles de la escala interna 0–5 —0,200 en la escala pública 0–2— en el conjunto de validación.

Un 97,2 % suena a mucho, y conviene poner al lado con qué se compara. Con seis niveles, acertar «dentro de ±1» es más fácil de lo que parece: contestar **al azar** acierta el 44,4 % de las veces, y contestar **siempre B1**, sin mirar el texto, el 50 % —ambas cifras suponiendo el nivel verdadero repartido por igual entre los seis—. El modelo llega al 97,2 %.

Esas dos referencias son teóricas y hay que leerlas como tales. Suponen el nivel verdadero repartido por igual entre los seis, y **la distribución real de los 144 documentos de validación no está publicada**. Si ese conjunto estuviera concentrado en los niveles centrales, «contestar siempre B1» acertaría bastante más del 50 %. Lo honesto es decir que un 97,2 % está muy por encima de lo que da el azar bajo una hipótesis razonable, no que la ventaja empírica sobre un predictor constante esté medida: no lo está, porque faltan los recuentos por nivel de ese conjunto.

El resultado que de verdad sostiene el trabajo no es ninguno de esos porcentajes, sino el orden. Esto es lo que se midió: los **47 textos de la reproducción local de British Council**, cada uno con un nivel MCER oficial asignado por la institución que lo publica y ninguno usado para ajustar los pesos, puntuados con `validar_local.py` y agrupados después por su nivel. Y esto es lo que salió: **las medias por nivel quedan estrictamente crecientes en los cinco niveles disponibles**, de A1 a C1 —0,5040 · 0,5561 · 0,9276 · 1,2414 · 1,4952 en la escala 0–2—, y la correlación de Spearman con el nivel oficial es de **0,860** (cuadro 16, figura 7 y cuadro 18). Ese orden —no el acierto exacto— es el resultado que el trabajo afirma haber conseguido, y es el que se cita en las conclusiones.

Nivel oficial	n (local)	Media en escala 0–2	Desviación
A1	3	0,5040	0,111
A2	8	0,5561	0,223
B1	12	0,9276	0,198
B2	12	1,2414	0,236
C1	12	1,4952	0,172

Cuadro 16: Reproducción local de la validación externa, sobre los 47 textos que quedan tras la extracción de los PDF **y el filtro de prosa continua**. Fuente: `datos_figuras/validacion.dat`.

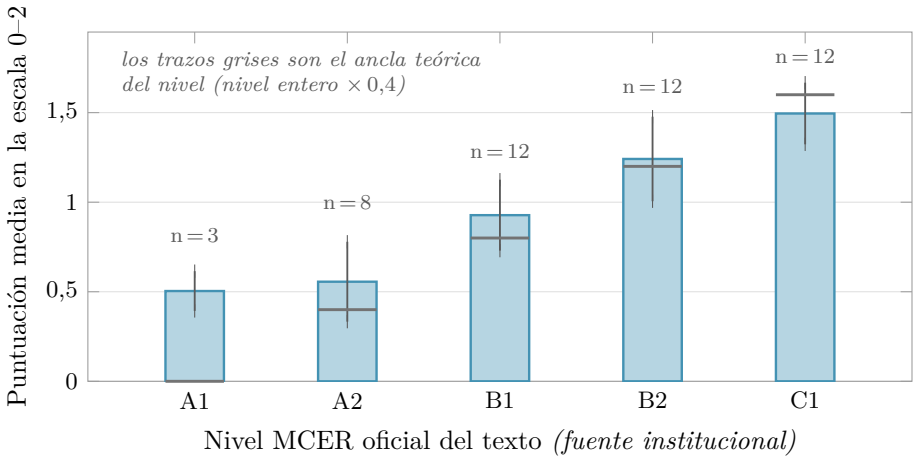


Figura 7: El resultado que sostiene el trabajo: las medias por nivel quedan **estrictamente crecientes** sobre textos externos con nivel MCER asignado por una institución de enseñanza. Las barras de error son la desviación dentro de cada nivel; con n de 3 a 12 textos, lo que se afirma es el orden global y no cada comparación por pares. Datos de `datos_figuras/validacion.dat` (cuadro 16).

La letra pequeña de ese resultado

Aquí empieza la letra pequeña, y conviene leerla antes de citar la cifra. Son cuatro salvedades. Ninguna anula la afirmación anterior, pero cada una acota lo que puede hacerse con ella.

Una: el escalón A1–A2 está dentro del ruido. Es de 0,052 sobre desviaciones de 0,111 y 0,223, y descansa en tres textos. Los tres escalones siguientes, no. Lo que se afirma es el orden global de las cinco medias, no cada comparación por pares: con n de 3 a 12 textos por nivel, el primer escalón no se sostendría por sí solo.

Dos: es una reproducción local, no una reproducción independiente. El cuadro 16 se **recalcula** con `validar_local.py` en cualquier máquina que tenga los mismos PDF y los mismos pesos, pero los PDF de British Council tienen derechos y no acompañan al repositorio, así que

quien quiera rehacerla tiene que reunirlos por su cuenta. Lo que se reproduce exactamente es **el orden**; las medias difieren ligeramente de las obtenidas en Colab (C1 coincide hasta la tercera cifra decimal —1,4952 frente a 1,4950—, A2 se desvía 0,09).

Tres: los 38 de Colab y los 47 de aquí son dos tandas distintas, y no se restan. La diferencia tiene dos causas —otra extracción de los PDF y otro filtro—, así que $47 - 38$ no son nueve textos que se puedan nombrar. Contado sobre los archivos reales, el balance de esta tanda cierra así:

	Textos
Publicados por British Council	59
menos: sin cuerpo localizable al extraer el PDF	−2
menos: **rechazados por `scoring.continuous_prose`**	**−10**
Evaluados	**47**

Cuadro 17: De 59 a 47, paso a paso. La primera resta es de extracción; la segunda es el filtro de prosa continua.

Y cuatro: el validador local filtra más flojo que la propia aplicación. Con el filtro completo de la app sobreviven **31 de esos 47** y A1 se queda con un solo texto, de modo que el orden creciente sobre cinco niveles está medido sobre un conjunto que la aplicación habría filtrado más. Por qué ocurre, qué regla se desactiva y qué textos caen se explica entero en el §7.7, al final del §7.

7.5 El *baseline* propio, y qué aporta el modelo por encima de él

Señal	**Spearman con el nivel oficial (47 textos)**
Modelo v4	**0,860**
Contar las palabras del texto, sin modelo	0,807
Modelo, descontando la longitud (correlación parcial)	**0,668**

Cuadro 18: El modelo frente a la señal trivial. Las tres cifras las calcula `validar_local.py` sobre los mismos 47 textos, con Spearman sobre rangos y la correlación parcial en la misma escala.

Un contador de palabras llega casi tan lejos como el modelo en ese corpus, y omitirlo sería deshonesto. Lo que sostiene al modelo es la tercera fila: **aporta señal por encima de la longitud**, que es precisamente lo que un contador de palabras no puede hacer —y conviene decirlo con precisión: no es que su correlación parcial sea peor, es que **no está definida**, porque descontar la longitud de la propia longitud deja un residuo de varianza cero—. Además, el modelo no recibe la longitud del documento como variable —puntúa bloques de tamaño fijo y promedia—, aunque su salida correlacione 0,732 con ella, porque los corpus de examen gradúan también la extensión de la tarea.

La escala está comprimida, y la aplicación lo asume. Contra el ancla real, el ajuste ronda predicho $\approx 0{,}72 \times \text{real} + 0{,}38$ (figura 8). Conviene decir de dónde sale esa recta, porque no está ajustada sobre los textos uno a uno: son **mínimos cuadrados sobre las cuatro medias por nivel que reportó Colab** (A2 a C1; el catálogo gratuito de British Council no tiene C2 y aquella tanda no traía A1), y dan $0{,}7196x + 0{,}3760$. Rehecha sobre las cinco medias locales de hoy sale $0{,}67x + 0{,}41$: cambian los decimales, no la conclusión, que es que la pendiente está muy por debajo de 1. De modo que un texto A2 tiende a puntuar cerca de B1. Por eso la interfaz muestra **bandas** (básico $< 0{,}6 \leq$ intermedio $< 1{,}4 \leq$ avanzado) y la letra MCER solo como orientación, en lugar de fingir una precisión de dos decimales que el modelo no tiene.

Los cortes de esas bandas salen del MCER, y esa es una corrección posterior. Al principio estaban en 0,8 y 1,6, que además **ni siquiera partían el 0–2 en tres partes iguales**: dejaban dos tramos de 0,8 y uno de 0,4. Pero como el modelo comprime sus predicciones, con esos cortes un texto C1 caía en «intermedio» y «avanzado» solo lo alcanzaba un C2: tres de los cinco niveles medidos compartían banda. Ahora la banda se deriva del ancla MCER, con el agrupamiento del propio marco —usuario básico A1–A2, independiente B1–B2, competente C1–C2—, y las fronteras quedan en **0,6 y 1,4**. Así la palabra y la letra no pueden contradecirse por construcción. Ninguna puntuación cambió: solo cambió cómo se agrupan.

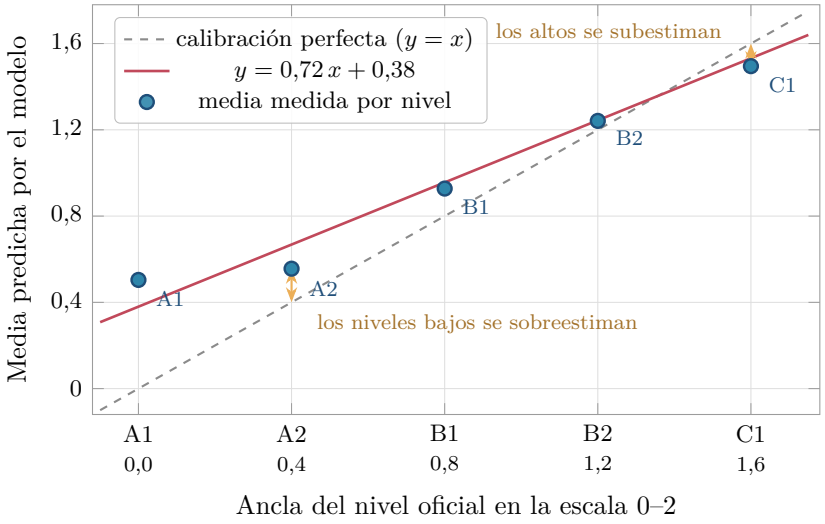


Figura 8: Por qué la interfaz muestra bandas y no decimales. Los puntos son las medias medidas por nivel (cuadro 16) frente al ancla teórica de ese nivel. El orden se conserva —que es el objetivo—, pero la pendiente es claramente menor que 1: los niveles bajos se sobreestiman y los altos se subestiman. La recta dibujada es $0{,}72x + 0{,}38$, ajustada sobre las **cuatro medias que reportó Colab** (A2 a C1); ajustada sobre los **cinco puntos locales** que se ven aquí sale $0{,}67x + 0{,}41$. Se dibuja la primera porque es la que cita el texto, y las dos dicen lo mismo: la pendiente está muy por debajo de 1. Calibrar esa recta afín sin tocar los pesos del modelo es el accionable A7 (cuadro 4).

7.6 Cuadro de decisiones metodológicas

Incluye las hipótesis que se probaron y se rechazaron (cuadro 19). Reportarlas es parte del resultado.

Decisión	Razón	Evidencia / consecuencia
Regresión, no clasificación	La dificultad es continua; clasificar tira información ordinal	El error ordinal medio baja de 1,39 a 0,67 en la progresión completa
Partición agrupada por libro	Evitar fuga de datos entre extractos **del mismo libro**. No separa autores: dos obras del mismo autor pueden caer a ambos lados, y eso no se comprobó	Aplicada a *todos* los modelos comparados, no solo al final

Decisión	Razón	Evidencia / consecuencia
`distilroberta` y no `roberta-base` completo	La aplicación debe correr en CPU en el equipo de un estudiante	328 MB y 0,9 s de carga, frente a 1,5× más parámetros (125 M contra 82 M). **La diferencia de calidad entre las dos no se midió**: la decisión se tomó por tamaño y velocidad, no porque se comprobara que costaba poco
Promediar bloques sin ponderar, con la **ventana** como unidad	Simplicidad y reproducibilidad; ponderar por longitud reintroduce la longitud como señal	Constante del entrenamiento. La app y el precálculo del catálogo usan ahora el mismo estimador: durante un tiempo la app promedió las medias de cada capítulo y el catálogo todas las ventanas, y con capítulos de tamaño desigual **no son el mismo número** (0,004 de diferencia máxima sobre cinco libros; la medición se hizo en su momento y **no queda guion que la reproduzca**, así que se da como orden de magnitud, no como cifra auditable)
Rechazada: XGBoost sobre variables clásicas	Se esperaba que un ensamble superase al modelo lineal	No lo hace: 0,28 frente a 0,29, y error ordinal peor (1,42 *vs.* 1,39). El límite estaba en las variables
Rechazada: modelo híbrido *embedding* + variables	Se esperaba complementariedad	Ganancia nula (0,37 y 0,37; 0,91 *vs.* 0,93). El *embedding* ya contiene esa información
Rechazada: escalar la lista léxica al SPGC completo por rendimiento	Se esperaba mejorar `rare_word_ratio`	La correlación pasa de −0,330 a −0,326. Se conserva igualmente por cobertura, no por métrica
Rechazada: cuantización dinámica int8	+18 % de velocidad en CPU	MAE de 0,210 sobre una escala de 0 a 2 y sesgo sistemático de −0,21. Un desplazamiento así cambia la letra MCER en el **52 %** de la escala y la banda en el **21 %**: no degrada la cifra, le cambia la etiqueta al libro. Inaceptable
Rechazada: precisión media (fp16) en la GPU local	Se esperaba acelerar	Es **4,8× más lenta** que fp32 en una GTX 1650 SUPER: el chip TU116 no tiene *tensor cores*. En una A100 sí compensa, y allí la desviación observada fue de unos 0,00037 de media; **tampoco quedó guardada**: mismo caso que la fila de arriba
Rechazada: `inference_mode` en lugar de `no_grad`	Se esperaba menos sobrecarga	0,4 % de diferencia, por debajo del ruido
Rechazado: esfuerzo de razonamiento «mínimo» en la explicación léxica	Es el doble de rápido (7,4 s frente a 14,9 s)	Con él, «had peeped» se explicó como pasado simple cuando es pasado perfecto. La gramática es justo lo que se evalúa

Decisión	Razón	Evidencia / consecuencia
Filtrar prosa continua para la validación externa	Excluir textos porque el modelo falla en ellos invalida la validación	El criterio salió del diagnóstico, no es *a priori*, y así se dice en §4.3. Lo que lo sostiene es que se definió por **dos vías independientes** —título y estructura— que coinciden en el 89,8 % sin volver a mirar las puntuaciones

Cuadro 19: Decisiones metodológicas, incluidas las hipótesis rechazadas.

7.7 Qué filtra el validador local y qué filtra la aplicación

Este apartado desarrolla la cuarta salvedad del §7.4: el guion que reproduce el cuadro 16 no aplica el mismo filtro que la aplicación, y conviene ponerlo aquí y no esconderlo en el código.

Qué regla se desactiva, y por qué. El guion de reproducción une las líneas del PDF con un espacio, y eso **desactiva una de las cuatro reglas** de `scoring.continuous_prose`, la del maquetado de lista: sus dos comprobaciones —dos viñetas seguidas, o más de un tercio de líneas muy cortas— necesitan saltos de línea para ver nada. Es decir, este validador filtra **más flojo que la propia aplicación**, que sí recibe saltos de párrafo. Medido cambiando una cosa y sólo una: con saltos de línea sobreviven **31 textos en vez de 47**, y A1 se queda con uno solo, con lo que la comprobación de orden creciente ya no se puede hacer sobre cinco niveles.

Por qué se conserva así. Porque la unión con espacio es la que reproduce el cuadro 16 de este documento, que es la reproducción local. **No reproduce las cifras de Colab**, y nada aquí lo hace: aquella tanda son 38 textos y A2 se desvía 0,09. Pero el guion imprime las dos cuentas en cada ejecución, así que la diferencia queda a la vista de quien lo ejecute.

Qué textos se caen, y por qué regla. En el cuadro 17, la primera resta es de extracción. La segunda no: son **diez textos —nueve de A1 y uno de B1— que rechaza** `scoring.continuous_prose`, y conviene decir con qué regla, porque el filtro tiene cuatro. Los diez caen por la misma: **se quedan por debajo de las 150 palabras** una vez recortados entre «Reading text» y «Tasks». Son pósters, menús, horarios y tarjetas, es decir, textos que en el original ya son cortos; el detector de maquetado de lista ni siquiera llega a dispararse, porque el de longitud actúa antes. Los dos entornos filtraron con reglas distintas, no solo extrajeron distinto.

Lo que esto le hace al resultado principal. Los tres textos A1 que sostienen el escalón más débil del cuadro 16 **no pasan el filtro de la aplicación**: pasan el de este guion, que es el más flojo de los dos. Con el filtro completo, dos de los tres caen por maquetado de lista. Dicho de otro modo: una parte de esos 47 son textos que la app rechazaría por parecer listas, y el escalón A1 es justo donde más pesa. Los nombres de los 59 archivos están en `entrega/manifiesto_corpus_externo.md`, y `validar_local.py` imprime los diez rechazados con su motivo.

8 Resolución del problema

8.1 De la métrica a la decisión del lector

Una correlación de 0,908 no le sirve de nada a un adolescente. Lo que le sirve son tres decisiones, y el producto está construido para producir exactamente esas tres (cuadro 20).

8.2 Un recorrido completo, con números reales

Tomemos el caso concreto de un lector cuyo perfil da 1,20 sobre 2 (banda intermedia, ancla B2). La figura 9 resume el recorrido y los seis pasos que siguen lo detallan.

Pregunta del lector	Qué la responde	Coste para él
¿Cuál es mi nivel?	Seis preguntas sobre hábitos observables y tres fragmentos reales en escalera; o bien subir un libro que ya lee cómodo	Menos de dos minutos
¿Qué leo ahora?	Búsqueda semántica en español sobre el catálogo, acotada al rango de lectura del perfil	Segundos
¿Por dónde se va a complicar?	Curva de dificultad capítulo a capítulo, medida sobre el libro entero sin muestrear (figura 10)	De 12,7 s (vistazo, medido sobre *Crime and Punishment*) a minutos (libro completo)
¿Qué significa esta palabra *aquí*?	Doble toque sobre la palabra: lema, IPA británica y americana, definición de Wiktionary, el sentido concreto en esa frase, gramática y audio	Instantáneo en local; la explicación contextual tarda más
¿Lo estoy pronunciando bien?	Lectura en voz alta marcada palabra por palabra, con el sonido concreto que falla	Una frase

Cuadro 20: Del modelo a las decisiones del usuario.

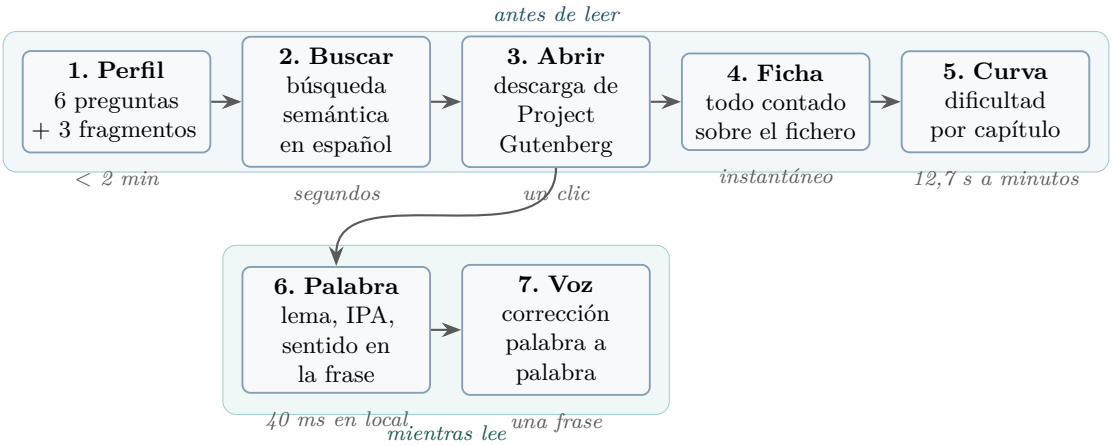


Figura 9: El recorrido completo, con los tiempos medidos de cada paso. No es un modelo con una interfaz encima: es una secuencia de decisiones que el lector no podía tomar antes. Lo único lento es la explicación contextual, que sale a la red; por eso la ficha se pinta en dos etapas.

1. Busca. Escribe *«dostoyevski»*, mal escrito, y el rescate por parecido ortográfico lo lleva igualmente a quien busca —«chejov» y «Shakespear» funcionan igual— sin estorbar a las búsquedas por tema, porque el buscador no busca por título sino por significado, sobre *embeddings* multilingües. Podría haber escrito en español lo que le apetece —*«una novela de detectives victoriana»*— y el buscador respondería igual.

   Y aquí conviene decir algo que el propio recorrido enseña. Lo que devuelve la búsqueda **no está filtrado por el nivel del lector**: ordena por cercanía al tema, y la dificultad va al lado de cada resultado para que el lector decida. En este recorrido eso importa, porque el libro que abre mide 1,73 y él está en 1,20: le queda por encima, y el valor de la herramienta es precisamente que **lo sabe antes de la primera página**.

2. Abre el libro. Se descarga de Project Gutenberg y se abre dentro de la aplicación, sin salir a buscarlo.

3. Aparece la ficha, **contada sobre el texto y no sobre metadatos**, aunque no toda sobre el libro entero: las palabras y el tiempo de lectura salen del fichero completo, y la longitud de frase, el diálogo y el vocabulario se calculan sobre una muestra con **tope de 60.000 palabras**, repartido a partes iguales entre los capítulos —la variedad léxica, sobre las primeras 20.000 de esa muestra—, porque recorrer *Guerra y paz* entero para pintar una ficha haría esperar al lector. Lo que trae: palabras reales, tiempo de lectura estimado a 180 o 110 palabras por minuto según el texto le quede por debajo o por encima de su nivel —no es su ritmo medido, que la aplicación no conoce—, longitud media de frase, proporción de diálogo, variedad de vocabulario y palabras más repetidas. La proporción de diálogo distingue de verdad entre obras —*Alice* 73 %, *Pride and Prejudice* 28 %, *Crime and Punishment* 31 %—, cosa que no hacía cuando se medía por párrafo en lugar de por oración, porque un epub no conserva los saltos de párrafo y las tres daban 100 %.

4. Pide la curva de dificultad. Sobre *Notes from a Dead House*, el modelo recorre **487 ventanas de 130.104 palabras en 86 segundos** y devuelve una media de 1,73 sobre 2, además de decir si el libro se va complicando o soltando y cuáles son su capítulo más llevadero y su capítulo más exigente. La segunda vez tarda 0,02 s porque queda guardada. Las figuras 10 y 11 muestran ese producto sobre tres libros medidos.

5. Toca una palabra que no conoce. El trabajo local —lema, categoría gramatical, consulta al diccionario, desambiguación por similitud, IPA— son **40 milisegundos**. La explicación contextual, que sale a la red, es lo único lento, y por eso la ficha se pinta en dos etapas: lo local aparece al instante y la explicación se añade cuando llega.

6. Lee una frase en voz alta y recibe la corrección palabra por palabra.

Ese recorrido es la unidad de valor del producto: **no es un modelo con una interfaz encima, es una secuencia de decisiones que el lector no podía tomar antes**.

8.3 Escalado: el catálogo entero, precalculado

La curva de dificultad de un libro largo son minutos de cómputo. Hacer esperar eso a cada visitante no es aceptable, de modo que el catálogo se precalcula. Las mediciones que hicieron viable esa decisión están en el cuadro 21 y en la figura 12.

Dos comprobaciones acompañan a ese cuadro, porque acelerar no puede costar exactitud:

- **La GPU da los mismos números que la CPU.** Sobre 840 ventanas de *Crime and Punishment*, 839 son idénticas a tres decimales y una difiere en 0,001; el MAE es 0,000001 sobre la escala 0–2.

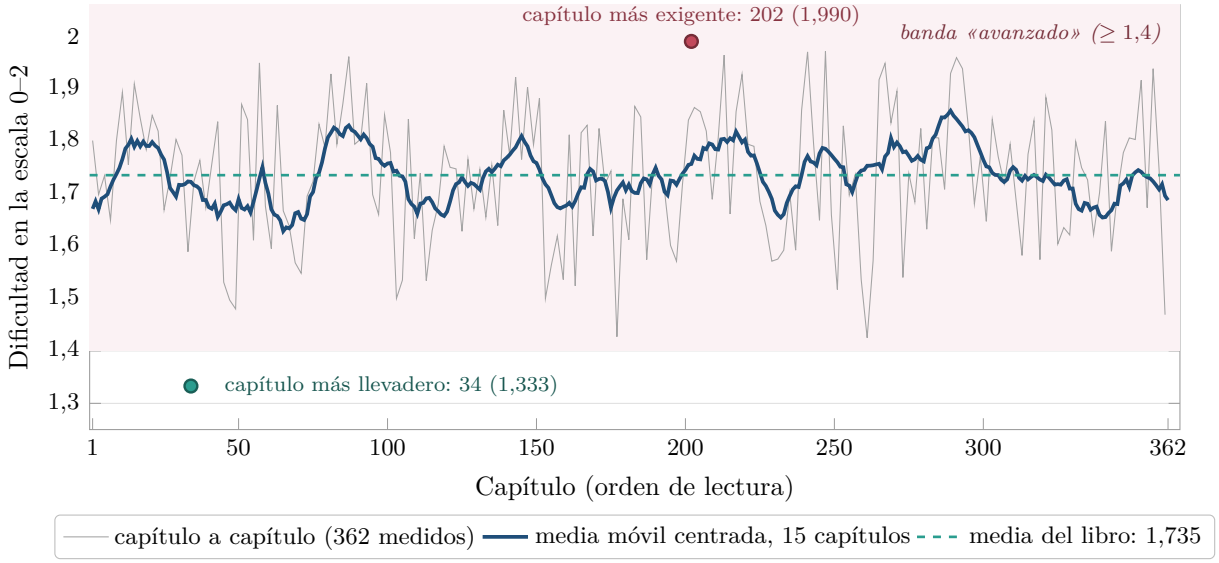


Figura 10: La figura que mejor explica el producto. Los 362 capítulos de *War and Peace* medidos sin muestrear —2.459 ventanas de 250 palabras, análisis completo— sobre la escala pública 0–2. La serie fina es la medición capítulo a capítulo (dibujada con un punto de cada dos por legibilidad); la línea gruesa es la media móvil centrada de 15 capítulos, calculada sobre *todos* los puntos. Un libro no tiene una dificultad: tiene un recorrido. Aquí va de 1,333 a 1,990 —0,657 de la escala— con media 1,735, y la novela se endurece de forma sostenida hacia el tramo central. Fuente: `datos_figuras/curva_War_and_Peace.dat`.

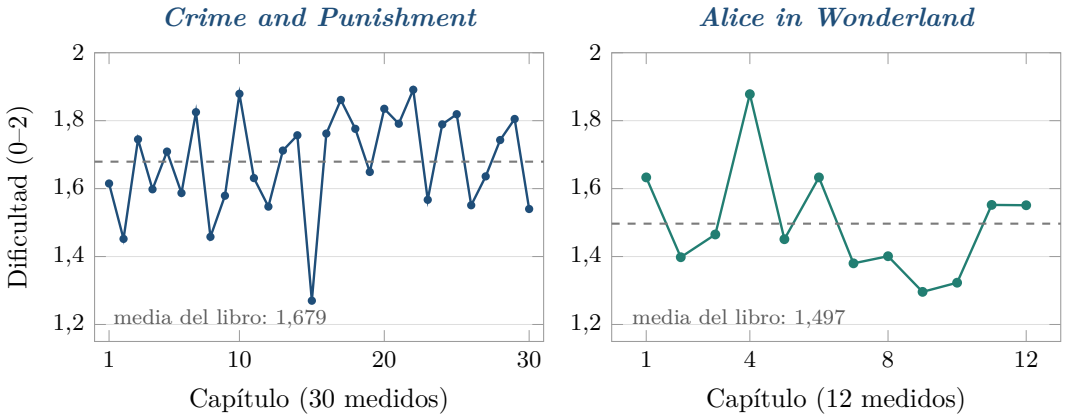


Figura 11: La dispersión interna es la norma, no la excepción. Dos libros más, medidos en *modo rápido* (el vistazo que la aplicación ofrece en segundos): *Crime and Punishment* recorre 1,270–1,891 y *Alice* 1,296–1,878, pese a que sus medias las separa casi dos décimas. Elegir libro por su media esconde justamente esto. Fuente: `datos_figuras/curva_Crime_and_Punishment.dat` y `datos_figuras/curva_Alice_s_Adventures_in_Wonder.dat`.

Entorno	Configuración	Ventanas/s	Factor
CPU (Ryzen 5 2600)	12 hilos, lote 64	8,19	1×
GPU local (GTX 1650 SUPER)	fp32, lote 128	112,7	13,8×
GPU A100 (Colab)	fp16, lote grande	2.022	247×

Cuadro 21: Rendimiento medido de extremo a extremo, incluida la tokenización y las transferencias. Son cifras del precálculo, que agrupa en lotes fijos de 64 en CPU y 128 en GPU. **La aplicación en vivo no llega a esos lotes**: agrupa por capítulo, y no por conveniencia sino para poder ir repintando la curva mientras mide; un capítulo son unas veinte ventanas, así que el rendimiento interactivo real está más cerca de las 6,96 ventanas/s del agrupado por capítulo que de las 8,19 de esta fila. Fuente: `datos_figuras/velocidad.dat`.

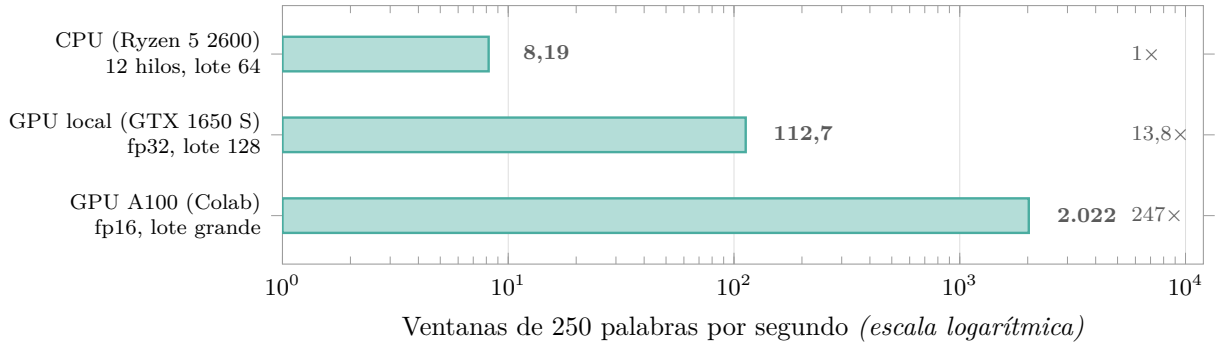


Figura 12: Tres órdenes de magnitud entre el equipo del autor y la GPU alquilada, medidos de extremo a extremo (tokenización y transferencias incluidas). La escala es logarítmica porque el rango va de 8,19 a 2.022 ventanas por segundo. Es lo que convierte «medir los 61.642 libros en inglés de Project Gutenberg» en unas pocas horas de cómputo en lugar de casi tres meses de CPU. Datos de `datos_figuras/velocidad.dat` (cuadro 21).

- **Reagrupar en lotes distintos no mueve ninguna cifra que se publique**, y conviene decirlo con precisión, porque hay dos casos y solo uno es exacto. Cuando se trocea **un texto de más de 250 palabras**, todas sus ventanas miden 250 palabras exactas y, en prosa inglesa real, pasan siempre de 256 *tokens* BPE, así que se truncan a 256 —comprobado: la ventana más corta de un texto de prueba da 258; un texto artificial de 250 monosílabos daría 252 y no llegaría, pero eso no es prosa—: no hay relleno, y la fila de cada ventana no depende de con quién vaya agrupada. Es el caso de la comprobación: las mismas **300 ventanas** puntuadas de una en una y en un solo lote de 300 salen **300/300 idénticas**, con MAE 0,000000. El precálculo del catálogo, en cambio, mete en el mismo lote las ventanas de **todos los capítulos** de un libro, y un capítulo de menos de 250 palabras aporta una ventana corta: ahí el relleno sí actúa hasta la ventana más larga del lote, y el resultado **no es idéntico bit a bit**. También está medido, sobre *Alicia en el País de las Maravillas*, 112 ventanas: **103 coinciden exactamente y el resto difiere como mucho en** $4{,}8 \times 10^{-7}$. Las cifras del catálogo se guardan con tres decimales, así que una diferencia de ese tamaño no puede mover ninguna.

Con 2.022 ventanas por segundo, medir los 61.642 libros en inglés de Project Gutenberg **son entre 3 y 5 horas de A100**, y conviene decir de qué depende esa horquilla en vez de dar una cifra sola: del número medio de ventanas por libro, que **todavía no está medido sobre el catálogo**. Con las 350 que asume el código del precálculo salen **2,96 h**; con las 606,4 que promedian las cinco novelas largas medidas en local —una muestra sesgada hacia arriba, porque son clásicos extensos— salen **5,14 h**. Cualquier cifra fuera de esa horquilla no se sigue de ninguno de los dos supuestos. El cuello de botella real resultó no ser el modelo sino la descarga: en serie, a 0,3 libros/s, los libros tardarían 57 horas en bajar. Y no era la pausa de cortesía entre peticiones, era la latencia —cada petición al espejo se pasa casi todo su tiempo esperando la ida y vuelta—, así que con seis hilos esas esperas se solapan. Seis y no treinta a propósito: el espejo lo mantiene alguien de forma gratuita, y cada hilo conserva su pausa.

8.4 Dos decisiones de producto que merecen argumento

Se ofrecen dos velocidades de análisis y siempre se dice cuál se usó. El vistazo rápido toma 30 capítulos repartidos por la obra y 2 ventanas de cada uno; el análisis completo no muestrea. El número 30 no es redondo por gusto: sale de la velocidad medida de la máquina. Y el resumen declara cuál de los dos se ejecutó, porque un vistazo que presumiera de haber leído el libro entero acabaría citado como si lo hubiera hecho. La diferencia entre ambos modos se ve al comparar la figura 10 (completo, 362 capítulos) con la figura 11 (vistazo).

No se filtra el catálogo por contenido. Se implementó un filtro basado en las materias que

asigna el propio Project Gutenberg —90 libros de 61.642— y después se retiró, deliberadamente. El razonamiento: esto es una plataforma de literatura, y la literatura es donde esas cosas aparecen. Filtrar por etiqueta habría eliminado también obras que son literatura por derecho propio, como *Fanny Hill*, perseguida judicialmente y relevante precisamente por eso. En su lugar se usa un mecanismo que ya existía: la ficha de cada libro trae un campo de aviso que se muestra como «Antes de empezar». **Se informa al lector y se le deja elegir; no se elige por él.** Es una decisión discutible y por eso se argumenta en lugar de ocultarse.

8.5 Contra quién compite esto

Un proyecto que no sabe contra qué compite no puede decir qué aporta. La versión larga está en el documento de estrategia; aquí van las tres alternativas reales y la cifra que resume cada una.

Alternativa	Cifra publicada	La nuestra
Fórmulas clásicas (FKGL, ARI)	Pearson **0,517** en CLEAR	**0,89**
Mejor LLM *zero-shot* publicado	Pearson **0,725** en CLEAR	**0,89**
Lexile, tarifa de creador de contenido	**3.824–54.636** USD/año	3–5 h de A100

Cuadro 22: Cifras publicadas frente a las de este proyecto. **No son comparaciones cara a cara**: las dos primeras filas vienen de un estudio ajeno sobre el mismo corpus, con otra partición y otro protocolo. Justifican la decisión de afinar un codificador; no demuestran una victoria medida.

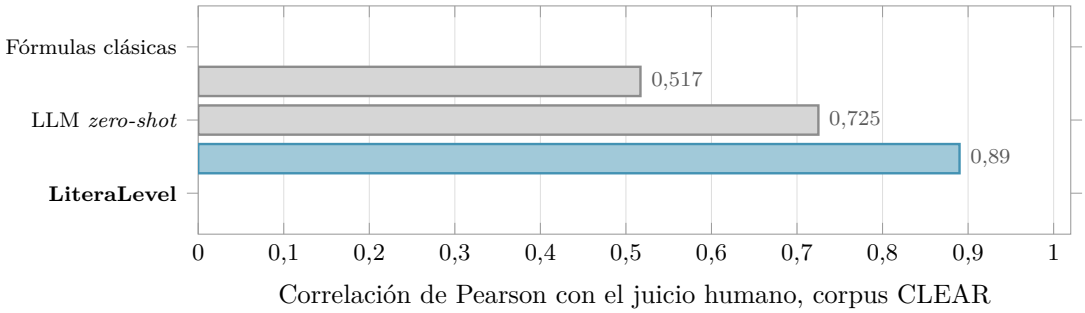


Figura 13: Las fórmulas clásicas cuentan sílabas y llegan a 0,517. Un modelo de lenguaje grande con un buen *prompt*, sin afinar, llega a 0,725. El codificador afinado de este proyecto, a 0,89. Las tres cifras están medidas en el mismo corpus, que es la única forma de que la comparación signifique algo.

Los 61.642 libros del catálogo caen en el tramo más alto de la tarifa de Lexile; medirlos aquí cabe en la cuota de una suscripción de unos 10 USD al mes. **No es una razón monetaria estricta** —una licencia anual y unas horas de cómputo no se dividen— y tampoco son servicios equivalentes: Lexile vende una escala aceptada por instituciones. Lo que sí se sostiene es que el **coste de procesamiento está en otro orden de magnitud**, y eso es lo que hace viable medir un catálogo entero en un trabajo de estudiante.

Dónde se pierde, que también hay que decirlo. Lexile tiene treinta años de validación y una escala que **acepta un colegio**; la de aquí no la acepta nadie. *TeakReader* ya da nivel MCER por capítulo y es una aplicación publicada en dos tiendas, mientras esto vive en un enlace. Y las lecturas graduadas de editorial tienen algo que ningún modelo da: el nivel se lo puso una persona que leyó la obra.

Lo que queda, y basta para justificar el trabajo, son tres cosas: se recorre el libro **entero, capítulo a capítulo**, en lugar de dar un número global; está escrito para un **hispa-**

nohablante que elige qué leer, no para un profesor que clasifica textos; y es **auditable en lo que se puede auditar y de acceso gratuito para el lector**, con el modelo publicado y el código a la vista.

Esa tercera hay que acotarla: el código y la inferencia desde los pesos públicos se pueden rehacer, **las métricas del v4 no**, porque su corpus de anclaje tiene derechos. Y las fórmulas clásicas también son gratuitas y reproducibles, así que la ventaja no está en la auditabilidad sola, sino en tenerla junto con un modelo que lee el texto. Lo que ninguna alternativa reúne son las **tres a la vez**.

9 Limitaciones

Antes de la lista, de dónde sale. Este trabajo se sometió a **cinco auditorías externas** hechas por modelos de dos familias distintas, con el encargo explícito de ser duros y sin decirles qué se había corregido antes. Entre las cinco señalaron alrededor de setenta hallazgos: fugas de datos, cifras que no cuadraban entre archivos, métricas atribuidas al corpus equivocado, pruebas que no podían fallar y conclusiones más fuertes que su evidencia. Los informes están en `auditoria/` y las correcciones, en el historial del repositorio.

Varias de las limitaciones que siguen no las encontró el autor, y algunas contradicen lo que este mismo documento afirmaba en una versión anterior. Parece razonable decirlo una vez, al principio de la lista, en lugar de repetirlo en cada párrafo corregido.

1. **La escala 0–2 es propia y no es una certificación.** El MCER fue el ancla del entrenamiento. LiteraLevel no acredita ningún nivel, y decirlo en el documento no basta: la aplicación lo repite en pantalla.

2. **La escala está comprimida.** El ajuste contra el ancla real ronda predicho $\approx 0{,}72\times\text{real}+0{,}38$ (figura 8; mínimos cuadrados sobre las cuatro medias por nivel de Colab, y $0{,}67x + 0{,}41$ con las cinco locales), así que los niveles bajos se sobreestiman y los altos se subestiman. Es la razón de mostrar bandas y no decimales.

3. **Las etiquetas del catálogo heredado no son fiables** (cuadro 8). Son predicciones de un modelo v1 sobre las primeras ∼190 palabras. La remedición está en curso y es el trabajo pendiente más importante.

4. **De los 1.197 libros del catálogo actual, solo 148 son descargables.** Los 1.049 de StoryWeaver no tienen fichero que abrir.

5. **Los tamaños muestrales de la validación externa son pequeños**: 38 textos en Colab, 47 en local, con 3 textos en A1. Una diferencia de 0,05 entre dos niveles adyacentes con esas n no es significativa; lo que se afirma es el orden global, no cada comparación por pares.

6. **La validación no es enteramente independiente de la exploración.** El corpus de British Council se usó primero para diagnosticar (descubrir que el modelo no sabe leer menús) y después para validar. El filtro de prosa se definió por dos vías independientes precisamente para acotar ese problema, pero salió de ese diagnóstico y el conjunto ha sido mirado y ya no es virgen.

7. **La longitud del texto es un confusor en el corpus de examen.** Contar palabras alcanza 0,807 donde el modelo alcanza 0,860 (cuadro 18).

8. **El modelo solo mide prosa continua en inglés.** Poesía, teatro, diálogo muy fragmentado y cualquier lengua distinta del inglés quedan fuera.

9. **El corpus de anclaje MCER es pequeño** (654 documentos aceptados) y el guion de entrenamiento del v4 vive en Google Drive, no en el repositorio. Las cifras del apartado 7.4 se

reportan **tal como salieron de aquella ejecución**, sin ningún archivo en el repositorio que las respalde. **Y su composición no está publicada**: no se dice cuántos documentos vienen de cada fuente ni cuántos por nivel. Eso importa más de lo que parece, porque la validación externa del apartado 7.4 se apoya en que las fuentes usadas para validar sean ajenas a las usadas para entrenar, y sin esa tabla nadie puede comprobarlo desde fuera. Publicar los recuentos no exige redistribuir ni una línea de texto con derechos.

10. **Dos corpus no se pueden redistribuir**: British Council tiene derechos y el corpus de validación de 144 documentos no acompaña al repositorio, de modo que las cifras de 0,908 y 97,2 % **no son verificables clonando el proyecto**. Lo que sí se reproduce en cualquier máquina es el cuadro 16.

11. **El cuaderno corre entero en un Colab limpio, pero correr no es recalcular.** Los pesos del v4 están publicados en Hugging Face (`MikeMaki1763/literalevel-v4`, repositorio público, descarga sin credenciales), así que el cuaderno se ejecuta de principio a fin y demuestra la inferencia sobre texto real. Lo que **no** recalcula son las métricas del v4 —el 0,908 y el 97,2 %—, porque el corpus de anclaje MCER incluye material con derechos y no se puede redistribuir. **Pero conviene separar tres cosas que aquí se mezclaban en una:** repetir el entrenamiento, volver a ejecutar la inferencia y recalcular la aritmética de las métricas. Lo tercero **sí se podría comprobar sin publicar un solo texto**, publicando las 144 parejas de etiqueta y predicción con un identificador anónimo. No está hecho, y decir que «no se arregla publicando nada» era falso.

12. **El despliegue está en el escalón más barato, y eso tiene dos consecuencias.** La aplicación está publicada en Hugging Face Spaces (`MikeMaki1763/literalevel`, hardware `cpu-basic`), con dirección fija que sobrevive a apagar el equipo del autor. Cuesta **7 USD al mes**: un Space de Gradio exige cuenta Pro, y el hardware elegido, `cpu-basic`, es el que no añade coste sobre esa suscripción. Pero ese hardware **suspende el servicio tras 48 h sin visitas** (`gcTimeout` = 172.800 s según la API de Hugging Face), de modo que el primer visitante después de una pausa paga un arranque en frío mientras se cargan *torch* y los 328 MB del modelo. Está medido: reiniciando el Space, **31 s hasta que el runtime dice `RUNNING` y 32 s hasta que la página responde**. Es la cota inferior, porque ahí la imagen del contenedor ya estaba construida; despertar de una suspensión de 48 h añade traerla. Y **no da almacenamiento persistente**, así que la estantería, el avance de lectura y el cuaderno del lector viven en disco efímero y no sobreviven a un reinicio del contenedor. Lo segundo es la acción A4 de la estrategia.

13. **La prueba de usuario tiene $n = 1$.** Esmeralda es una sola lectora. Su valor es cualitativo y de diagnóstico, no estadístico: sirve para encontrar fallos de usabilidad graves —y encontró varios—, no para estimar satisfacción media.

14. **La explicación contextual depende de un servicio externo de pago.** Sin clave, la aplicación sigue funcionando en todo lo que no sale a la red desde el servidor: diccionario, fonética, buscador y puntuación. Los enlaces de audio de Wiktionary son aparte, porque los descarga el navegador del lector: necesitan conexión, aunque no clave. Lo que se apaga sin clave es la explicación en contexto y la corrección de pronunciación.

10 Trabajo futuro

1. Terminar la remedición del catálogo completo y sustituir las etiquetas heredadas por medidas del v4 sobre el libro entero.

2. Reunir un corpus de anclaje MCER redistribuible, que es lo único que permitiría recalcular las métricas del v4 en lugar de citarlas. Los pesos ya están publicados; el corpus es el que no

puede estarlo.

3. Ampliar el corpus de anclaje MCER, que hoy es el eslabón más delgado de la cadena de evidencia.
4. Calibrar explícitamente la escala comprimida (una transformación afín de dos parámetros ajustada sobre entrenamiento, sin tocar los pesos) y comprobar si el orden se conserva tras calibrar.
5. Repetir la prueba de usuario con cinco o seis lectores de perfiles distintos, que según Nielsen (2000) es donde se detecta la mayor parte de los problemas de usabilidad.
6. Medir el efecto real sobre el abandono: comparar la tasa de libros terminados entre lectores que eligen con recomendación y sin ella. Es la única métrica que verdaderamente valida la propuesta.

11 Conclusiones

Se cumplió el objetivo ordinal, que era el objetivo. Hay dos resultados y vienen de corpus distintos, así que conviene no mezclarlos. Sobre **textos externos con nivel MCER oficial** —los 47 de British Council— el modelo ordena los niveles de forma estrictamente creciente (0,5040 · 0,5561 · 0,9276 · 1,2414 · 1,4952; figura 7) y alcanza Spearman **0,829** con 38 textos, **0,860** con los 47. El **0,908 y el 97,2 %** son otra cosa: salen del conjunto de validación de **144 documentos del propio corpus de anclaje**, que es interno. Atribuirlos a los externos sería un error. Para el problema planteado —elegir qué leer— acertar el orden es lo que importa; acertar la letra exacta es un lujo.

Y aquí hay que poner un límite que el documento no ponía. Ese orden está medido sobre **textos de examen**, de A1 a C1 y sin C2, no sobre novelas. La aplicación puntúa novelas y dibuja sus curvas, pero **la dificultad de una novela no se ha contrastado contra ninguna etiqueta externa ni contra ningún lector**. Que el modelo ordene bien cinco niveles de material de examen es una señal razonable de que la escala tiene sentido; no es una demostración de que ayude a elegir mejor un libro. Ese vínculo queda pendiente.

En las configuraciones probadas, el cuello de botella no estuvo en el algoritmo sino en la representación del texto. Aumentar la potencia del clasificador sobre las mismas variables no mejoró nada —XGBoost con trescientos árboles queda por detrás de una regresión logística, en las dos tandas—, mientras que cada vez que se enriqueció la representación el resultado subió: de conteos a *embedding* y de ahí a leer el texto crudo con atención, hasta 0,67 niveles de error ordinal (figura 4).

Dicho eso, esto no es un experimento controlado y no conviene venderlo como tal. Entre la fila del *embedding* y la del transformador cambian a la vez la representación, la arquitectura, el preentrenamiento y el objetivo —clasificación de seis clases frente a regresión—, así que el salto no se puede atribuir a un solo factor. Lo que la evidencia sostiene es la observación: **subir la potencia del clasificador no movió el resultado y cambiar la representación sí**. Aislar cuál de los cuatro factores pesa más exigiría comparaciones que este trabajo no hizo.

Sobre el tamaño de ese salto conviene ser preciso, porque el cuadro 12 tiene dos tandas y es fácil restar filas que no se pueden restar. Contra las tres variables clásicas de la tanda histórica, el paso al *embedding* va de 1,39 a 0,93. Pero el cuadernillo entregado ejecuta una regresión logística sobre tres variables clásicas, sobre esa misma partición, y obtiene **1,295**; con diecisiete variables en vez de tres baja a **1,061**.

No son exactamente el mismo modelo, y decir que sí lo eran era impreciso. Las tres variables se llaman igual en las dos tandas, pero `palabras_raras` no contiene lo mismo: en el cuadernillo se calcula contra las 3.000 palabras más frecuentes **del entrenamiento de CLEAR**, y en la tanda histórica contra las listas externas de NLTK y del SPGC (cuadro 9).

Misma partición y misma semilla, sí; misma definición de las variables, no. Esa es la razón más probable de los 0,10 de diferencia.

Medido así, contra unas variables clásicas bien surtidas, la ventaja del *embedding* es bastante menor de lo que sugiere la comparación con tres. **La brecha que no se cierra con más conteos es la del transformador.** La conclusión cualitativa se sostiene; la cifra con la que se vendía, no.

Escalar el corpus no siempre mejora nada, y conviene decirlo. Multiplicar por 2.500 el corpus de referencia léxica —de 18 libros a los 45.345 del SPGC— llevó la correlación de −0,379 a −0,326: **empeoró**. La muestra intermedia de 397 libros daba −0,330. La ley de Zipf explica por qué. El paso se conservó por cobertura, no por métrica, y así se reporta.

La velocidad se ganó sin mover ninguna cifra publicada, y con la salvedad dicha. Doce hilos y lotes de 64 en CPU, fp32 con lote 128 en GPU: +33 % y ×13,8 respectivamente (figura 12), con 839 de 840 ventanas idénticas a tres decimales y la restante a 0,001. No es exactitud bit a bit —eso sería falso— sino diferencias por debajo del redondeo con el que se guarda todo. Y se rechazaron dos palancas más rápidas —int8 y fp16 en la tarjeta local— porque una desviaba 0,210 sobre una escala de 0 a 2 y la otra era 4,8 veces más lenta. **Medir antes de optimizar, y medir también lo que se descarta.**

Lo que convierte esto en un producto no es el modelo, es lo que se hizo con lo que dijo una lectora de quince años. Un ciclo completo —observar, escuchar la queja, diagnosticar el fallo propio y corregirlo— vale más que un punto de correlación. Ese ciclo se documenta en el apartado 3.3, y su resultado son seis etiquetas reescritas, cinco paletas verificadas contra el criterio de contraste WCAG AA y una interfaz que se puede usar con el pulgar.

Y queda pendiente lo que más pesa. La aplicación funciona y ya tiene dirección fija, pero sobre el hardware más barato: se suspende por inactividad y no guarda nada entre reinicios. El catálogo se está remidiendo. Y el cuaderno, aunque ya corre entero desde los pesos publicados, cita las métricas del v4 en vez de recalcularlas, porque su corpus de anclaje no es redistribuible. Las tres cosas están planificadas con coste y criterio de terminado en el cuadro 4.

Y para qué sirve esto, dicho como decisión y no como métrica. Un lector que hoy elige libro por la portada puede, con esta herramienta, hacer tres cosas que antes no podía: saber **antes de empezar** si un libro concreto le queda grande, ver **en qué capítulo** se va a atascar y decidir si lo salta o lo prepara, y llevarse las palabras que consultó **con la frase en la que aparecieron**, que es la unidad con la que se recuerda un idioma. Para quien enseña, el cambio es de otro tipo: un catálogo de dominio público con dificultad medida convierte «lee algo de tu nivel» en una lista concreta, y el coste marginal de añadir un libro es de segundos de cómputo, no de una tarifa por título.

Lo que este proyecto recomienda hacer a continuación, en orden de valor por hora de trabajo, está en el cuadro 4 con coste y criterio de terminado: terminar la remedición del catálogo, que es lo que separa un prototipo de un producto; montar almacenamiento persistente, sin el cual el lector pierde su estantería en cada reinicio; y calibrar la escala, que es la diferencia entre decirle a alguien que un libro es A2 y que lo sea.

Declaración de alcance

LiteraLevel es una herramienta de apoyo a la lectura. **No es un instrumento de evaluación ni de certificación lingüística.** No debe usarse para asignar calificaciones, para decidir la admisión de una persona a un programa, para acreditar un nivel del Marco Común Europeo de Referencia ni para ninguna decisión con consecuencias para el evaluado. La escala 0–2 es propia; las letras A1 a C2 son el ancla con la que se entrenó el modelo y se muestran únicamente como orientación.

El sistema mide dificultad lingüística de prosa continua en inglés. No mide calidad literaria, no mide comprensión del lector y no emite juicios sobre el contenido de las obras. El catálogo no

se filtra por contenido: se informa al lector mediante un aviso en la ficha del libro y la decisión queda en sus manos.

Los datos personales del lector —los libros empezados, el vocabulario consultado y el perfil de nivel— se guardan separados por sesión y no se comparten entre visitantes. Solo la caché de definiciones se comparte, por ser contenido de diccionario y no historial de nadie. Ningún texto con derechos se distribuye ni se imprime fuera del entorno de cómputo: de los corpus con licencia restrictiva solo salen estadísticas agregadas.

Referencias

Abid, A., Abdalla, A., Abid, A., Khan, D., Alfozan, A., & Zou, J. (2019). *Gradio: Hassle-free sharing and testing of ML models in the wild*. arXiv: 1906.02569. https://arxiv.org/abs/1906.02569

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794. https://doi.org/10.1145/2939672.2939785

Council of Europe. (2020). *Common European Framework of Reference for Languages: Learning, teaching, assessment — companion volume*.

Crossley, S., Heintz, A., Choi, J. S., Batchelor, J., Karimi, M., & Malatinszky, A. (2023). A large-scaled corpus for assessing text readability. *Behavior Research Methods*, *55*(2), 491-507. https://doi.org/10.3758/s13428-022-01802-x

Day, R. R., & Bamford, J. (1998). *Extensive reading in the second language classroom*. Cambridge University Press.

Deci, E. L., Koestner, R., & Ryan, R. M. (1999). A meta-analytic review of experiments examining the effects of extrinsic rewards on intrinsic motivation. *Psychological Bulletin*, *125*(6), 627-668. https://doi.org/10.1037/0033-2909.125.6.627

Gerlach, M., & Font-Clos, F. (2018). *Standardized Project Gutenberg Corpus (SPGC)*. Zenodo. https://doi.org/10.5281/zenodo.2422561

Gerlach, M., & Font-Clos, F. (2020). A standardized Project Gutenberg corpus for statistical analysis of natural language and quantitative linguistics. *Entropy*, *22*(1), 126. https://doi.org/10.3390/e22010126

Hu, M., & Nation, P. (2000). Unknown vocabulary density and reading comprehension. *Reading in a Foreign Language*, *13*(1), 403-430.

Krashen, S. D. (1985). *The input hypothesis: Issues and implications*. Longman.

Krug, S. (2014). *Don't make me think, revisited: A common sense approach to web usability* (3.ª ed.). New Riders.

Liu, Y., Ott, M., Goyal, N., Du, J., Joshi, M., Chen, D., Levy, O., Lewis, M., Zettlemoyer, L., & Stoyanov, V. (2019). *RoBERTa: A robustly optimized BERT pretraining approach*. arXiv: 1907.11692. https://arxiv.org/abs/1907.11692

Nakanishi, T. (2015). A meta-analysis of extensive reading research. *TESOL Quarterly*, *49*(1), 6-37. https://doi.org/10.1002/tesq.157

Nation, I. S. P. (2013). *Learning vocabulary in another language* (2.ª ed.). Cambridge University Press.

Nielsen, J. (2000, 18 de marzo). *Why you only need to test with 5 users*. Nielsen Norman Group. https://www.nngroup.com/articles/why-you-only-need-to-test-with-5-users/

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, *12*, 2825-2830.

Project Gutenberg. (2026). *Project Gutenberg*. https://www.gutenberg.org

Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using Siamese BERT-networks. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*, 3982-3992. https://doi.org/10.18653/v1/D19-1410

Sanh, V., Debut, L., Chaumond, J., & Wolf, T. (2019). *DistilBERT, a distilled version of BERT: Smaller, faster, cheaper and lighter*. arXiv: 1910.01108. https://arxiv.org/abs/1910.01108

Vajjala, S., & Lučić, I. (2018). OneStopEnglish corpus: A new corpus for automatic readability assessment and text simplification. *Proceedings of the 13th Workshop on Innovative Use*

of NLP for Building Educational Applications, 297-304. https://doi.org/10.18653/v1/W18-0535

Wolf, T., Debut, L., Sanh, V., Chaumond, J., Delangue, C., Moi, A., Cistac, P., Rault, T., Louf, R., Funtowicz, M., Davison, J., Shleifer, S., von Platen, P., Ma, C., Jernite, Y., Plu, J., Xu, C., Le Scao, T., Gugger, S., … Rush, A. M. (2020). Transformers: State-of-the-art natural language processing. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, 38-45. https://doi.org/10.18653/v1/2020.emnlp-demos.6

World Wide Web Consortium. (2023). *Web content accessibility guidelines (WCAG) 2.2*. W3C. https://www.w3.org/TR/WCAG22/

Ylönen, T. (2022). Wiktextract: Wiktionary as machine-readable structured data. *Proceedings of the 13th Language Resources and Evaluation Conference*, 1317-1325.

Zaharia, M., Xin, R. S., Wendell, P., Das, T., Armbrust, M., Dave, A., Meng, X., Rosen, J., Venkataraman, S., Franklin, M. J., Ghodsi, A., Gonzalez, J., Shenker, S., & Stoica, I. (2016). Apache Spark: A unified engine for big data processing. *Communications of the ACM*, *59*(11), 56-65. https://doi.org/10.1145/2934664

Zipf, G. K. (1949). *Human behavior and the principle of least effort*. Addison-Wesley.