**Universidad Nacional Autónoma de México**
FACULTAD DE ESTUDIOS SUPERIORES ACATLÁN

# LiteraLevel

Medición automática de la dificultad de lectura en inglés y su entrega a un lector real

**Proyecto integrador — Módulo 5**

**Alumno:**
Miguel Reyes Carrillo

**Profesor:**
Mtro. Fernando Barranco Rodríguez

Diplomado en Ciencia de Datos — Generación 34

| 0,908 | A1 < · · · < C1 | 97,2 % |
|---|---|---|
| Spearman, validación ciega | orden MCER creciente en corpus externo | dentro de ±1 nivel |

Ciudad de México, septiembre de 2026

## Resumen

Aprender inglés leyendo funciona, pero solo si el libro está al nivel de quien lo abre. Un lector que elige un libro demasiado difícil no aprende: lo abandona. Y hoy no hay forma sencilla de saber, antes de empezar, si *ese* libro concreto está a su alcance.

LiteraLevel es una aplicación que responde esa pregunta. Le da al lector un número entre 0 y 2 que dice cuánta dificultad tiene un texto en inglés, y lo hace leyendo el texto de verdad, no contando páginas. Con ese número le busca libros que pueda terminar, se los abre dentro de la propia aplicación, le enseña la dificultad capítulo a capítulo —los libros no son igual de difíciles de principio a fin—, le explica cualquier palabra en la frase en la que aparece y le corrige la pronunciación cuando lee en voz alta.

Debajo hay un modelo de lenguaje pequeño (`distilroberta-base`) afinado para predecir dificultad como un número continuo. En validación ciega alcanza una correlación de Spearman de 0,908 con el nivel de referencia y, sobre un corpus externo que nunca vio, ordena los niveles del Marco Común Europeo de forma estrictamente creciente: A1 0,5040 · A2 0,5480 · B1 0,9276 · B2 1,2478 · C1 1,4952. Ese orden —no el acierto exacto— es el resultado que sostiene el trabajo.

Conviene decirlo desde la primera página: **la escala 0–2 es propia y LiteraLevel no certifica ningún nivel del Marco Común Europeo**. Las letras A1 a C2 fueron el ancla con la que se entrenó el modelo, no un título que la aplicación expida. Sirven para elegir qué leer, no para acreditar nada.

El proyecto se cierra con una aplicación funcionando —ocho pestañas en Gradio 6.26 (Abid y col., 2019), probada por una lectora de quince años ajena al proyecto— y con un catálogo en curso de remedición: los 61.642 libros en inglés de dominio público de Project Gutenberg, leídos enteros por el modelo, que a la velocidad medida en una GPU A100 son unas 6,3 horas de cómputo.

**Palabras clave:** legibilidad automática, MCER, adquisición de segundas lenguas, lectura extensiva, transformers, Project Gutenberg, Gradio.

**Nota sobre la estructura de la entrega.** La *Estrategia*, que la rúbrica pide como entregable propio y como sección exigida del documento, se desarrolla completa en el **apartado 3** y no en un anexo: ocupa el lugar que le corresponde en el orden de secciones y sostiene por sí sola el resto del texto. Las cifras que allí se citan y que se miden más adelante van referidas con su cuadro o figura. **Todas las figuras de este documento están dibujadas en LaTeX** (TikZ/pgfplots) a partir de los datos medidos que acompañan a la entrega; no hay ninguna captura de pantalla ni imagen externa.

# Índice

**Resumen** **1**

**1. Introducción y motivación** **5**

**2. Planteamiento del problema** **5**
2.1. Formulación . . . 5
2.2. Lo que el problema no es . . . 6
2.3. Criterio de éxito . . . 7

**3. Estrategia** **7**
3.1. La apuesta, en un párrafo . . . 7
3.2. Descripción de usuarios . . . 7
3.2.1. Usuaria primaria: la estudiante de preparatoria . . . 7
3.2.2. Usuario secundario: el adulto autodidacta . . . 7
3.2.3. Usuario institucional: el docente de inglés . . . 8
3.3. El ciclo de usuario real: Esmeralda . . . 8
3.3.1. Lo que ya se había corregido antes, por la misma vía . . . 10
3.3.2. La lección, en una línea . . . 10
3.4. Usabilidad del modelo . . . 10
3.4.1. La espera se traslada, no se pide . . . 10
3.4.2. La incertidumbre se comunica en bandas . . . 10
3.4.3. Nada falla en silencio, y nada se rompe del todo . . . 11
3.4.4. Cada número dice de dónde viene . . . 11
3.4.5. La latencia se reparte para que la pantalla no se quede quieta . . . 11
3.5. Accionables . . . 11
3.6. Métricas de éxito . . . 13
3.7. Riesgos . . . 13

**4. Descripción de los datos** **13**
4.1. Inventario de fuentes . . . 14
4.2. Relevancia de cada fuente . . . 14
4.3. Calidad de los datos: lo que está bien y lo que no . . . 14

**5. Análisis exploratorio** **17**
5.1. Análisis univariado . . . 17
5.2. Análisis bivariado . . . 18
5.3. Análisis multivariado . . . 18

**6. Procesamiento de datos** **19**
6.1. Sobre el texto de entrada . . . 19
6.2. Sobre las variables del modelado clásico . . . 20
6.3. Sobre el corpus de vocabulario (procesamiento distribuido) . . . 20
6.4. Sobre el diccionario . . . 20

**7. Modelación** **20**
7.1. Diseño experimental . . . 21
7.2. Progresión de modelos . . . 21
7.3. Dónde funciona y dónde no: análisis por dominio . . . 23
7.4. El modelo desplegado y su validación . . . 23
7.5. El *baseline* propio, y qué aporta el modelo por encima de él . . . 25

7.6. Cuadro de decisiones metodológicas . . . . . 26

**8. Resolución del problema** **27**
8.1. De la métrica a la decisión del lector . . . . . 27
8.2. Un recorrido completo, con números reales . . . . . 27
8.3. Escalado: el catálogo entero, precalculado . . . . . 29
8.4. Dos decisiones de producto que merecen argumento . . . . . 29

**9. Limitaciones** **30**

**10. Trabajo futuro** **31**

**11. Conclusiones** **32**

**Declaración de alcance** **32**

**Referencias** **34**

# Índice de figuras

1. Cadena de medición de LiteraLevel . . . . . 6
2. La escala 0–2 y sus anclas MCER . . . . . 6
3. Reparto de niveles del catálogo heredado . . . . . 16
4. Progresión de modelos: la representación manda . . . . . 22
5. Sobreajuste visto y controlado . . . . . 22
6. Matriz modelo × dominio . . . . . 23
7. Validación externa por nivel MCER . . . . . 24
8. La escala comprimida . . . . . 25
9. El recorrido del lector . . . . . 27
10. Curva de dificultad de *War and Peace* . . . . . 28
11. Curvas de dificultad en modo vistazo . . . . . 29
12. Velocidad de inferencia por entorno . . . . . 30

# 1 Introducción y motivación

Cientos de millones de personas estudian inglés como segunda lengua. De todos los métodos con respaldo empírico, la **lectura extensiva** —leer mucho, por gusto, en textos ligeramente por encima del nivel actual— es uno de los que mejor se sostiene: el metaanálisis de Nakanishi (2015) sobre décadas de estudios encuentra efectos consistentes en comprensión y vocabulario, y Day y Bamford (1998) la formalizan como programa de aula. Krashen (1985) llamó a esa franja «*input* comprensible»: material que se entiende casi todo, con lo justo de novedad para aprender.

El problema es operativo, no teórico. Para que la lectura extensiva funcione, el texto tiene que caer en esa franja, y Hu y Nation (2000) la cuantifican: se necesita reconocer alrededor del 98 % de las palabras corridas de un texto para comprenderlo sin ayuda —umbral coherente con el trabajo posterior de Nation (2013) sobre tamaño de vocabulario y cobertura léxica—. Un punto porcentual por debajo y la lectura se convierte en trabajo de diccionario. Es decir: **el mismo libro es excelente para un lector y una pérdida de tiempo para otro que está dos niveles por debajo**, y nada en la portada lo dice.

Hoy el lector hispanohablante que quiere leer en inglés se enfrenta a decenas de miles de libros gratuitos en dominio público y a ninguna señal fiable sobre cuál le corresponde. Las etiquetas que circulan (A2, B1, C1) casi nunca las puso alguien que haya leído la obra completa, y además tratan el libro como si tuviera una sola dificultad, cuando en realidad cambia de capítulo a capítulo. La figura 10 lo muestra sobre un libro entero medido: la dificultad de *War and Peace* recorre casi setenta centésimas de la escala pública entre su capítulo más llevadero y el más exigente.

**Pregunta que guía el trabajo:** ¿es posible estimar automáticamente, con un modelo de lenguaje entrenado sobre corpus públicos, una medida de dificultad de un texto en inglés que (a) ordene correctamente los niveles del MCER (Council of Europe, 2020) en material externo que el modelo nunca vio, y (b) sea lo bastante rápida y comprensible para ponerse en manos de un lector adolescente sin entrenamiento previo?

Este documento responde a las dos mitades. La primera es un problema de modelado y se resuelve en los apartados 4 a 7. La segunda es un problema de producto y de usabilidad, que es lo que el módulo declara evaluar, y se desarrolla en los apartados 3 y 8.

# 2 Planteamiento del problema

## 2.1 Formulación

Sea $T$ un texto en inglés en prosa continua. Se busca una función $f(T) \to [0, 2]$ tal que, para dos textos $T_i$ y $T_j$ cuyos niveles oficiales de referencia cumplen $\text{nivel}(T_i) < \text{nivel}(T_j)$, se cumpla $f(T_i) < f(T_j)$ con la mayor frecuencia posible.

Obsérvese que **el objetivo es ordinal, no de clasificación exacta**. La frontera entre B1 y B2 es una convención pedagógica, no un hecho físico: confundir B1 con B2 es un error muy distinto de confundir B1 con C2. Por eso las métricas principales del trabajo son la correlación de Spearman y el **error ordinal medio** (distancia media en niveles entre lo predicho y lo real), y no la exactitud de clase.

Un texto largo no se puntúa de una vez. Se parte en bloques de 250 palabras (mínimo 150) y se puntúa cada bloque; la salida del documento es la media sin ponderar de sus bloques. Formalmente, si $B(T) = \{b_1, \ldots, b_n\}$ son los bloques de $T$ y $g$ es el modelo por bloque,

$$f(T) \;=\; 0{,}4 \cdot \text{clip}\left( \frac{1}{n} \sum_{k=1}^{n} g(b_k),\; 0,\; 5 \right), \tag{1}$$

donde el factor 0,4 convierte la escala interna del modelo (0–5, un valor por cada nivel A1…C2) en la escala pública 0–2 que ve el usuario. La figura 1 recorre esa cadena completa, del texto

crudo a la banda que se muestra en pantalla, y la figura 2 sitúa las anclas MCER sobre la recta 0–2 resultante.

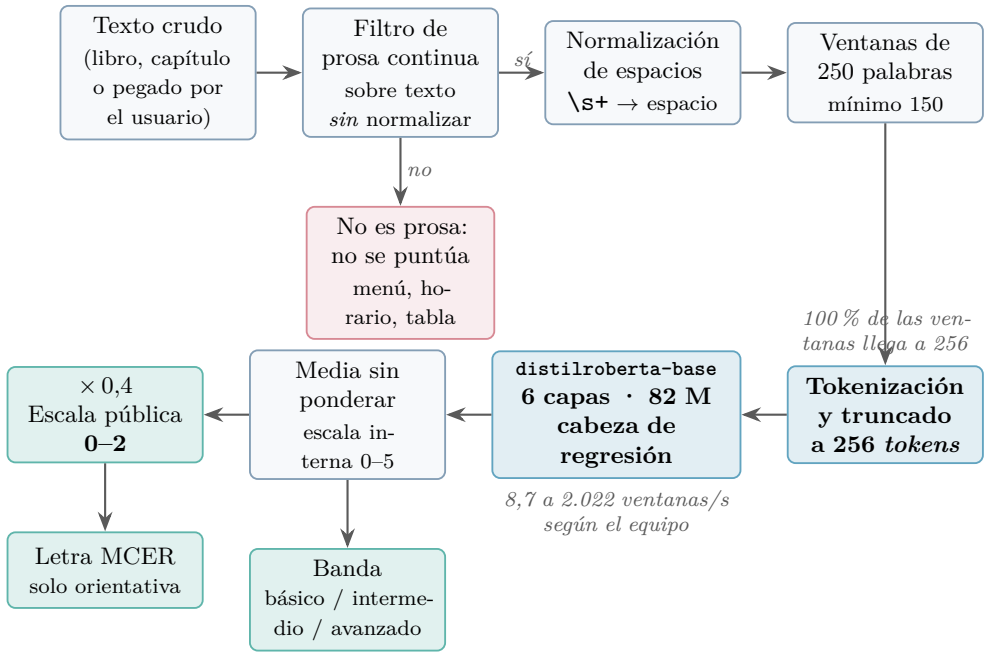



**Figura 1:** Cadena de medición, de la ecuación (1) al número que ve el lector. El filtro de prosa se aplica sobre el texto crudo, antes de normalizar espacios: hacerlo al revés lo desactivaba en producción (cuadro 10, T1). Todas las ventanas ocupan exactamente 256 *tokens* tras truncar, de modo que no hay relleno y reagrupar en lotes distintos no puede mover un decimal.

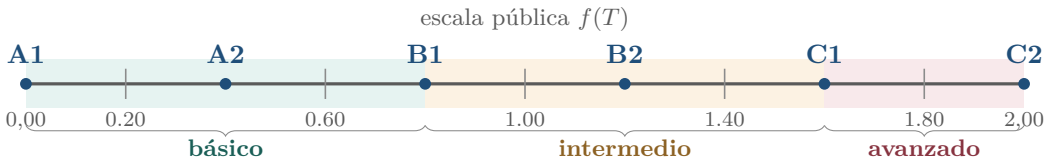



**Figura 2:** La escala pública 0–2 y sus anclas. Los puntos azules son los seis niveles MCER tal como los coloca la ecuación (1) (nivel entero × 0,4); las marcas grises son los cortes que decide qué letra se muestra, y las llaves inferiores, las tres bandas con las que la interfaz comunica la incertidumbre en lugar de fingir dos decimales de precisión. *La letra es orientación, no certificación.* Cortes tomados de `datos_figuras/escala_cefr.dat`.

## 2.2 Lo que el problema no es

Tres delimitaciones que evitan malentendidos y que la aplicación repite en pantalla:

1. **No es certificación.** El modelo se ancló a etiquetas MCER durante el entrenamiento; eso no lo convierte en un examinador acreditado. Devuelve una posición en una recta continua, y la letra que muestra es simplemente el ancla más cercana.
2. **No es un medidor universal de texto.** El modelo solo vio prosa continua. Una carta de menú, un horario de vuelos o una tabla no son prosa, y puntuarlos daría un número sin significado. La aplicación los rechaza con un filtro estructural explícito (apartado 6.1).
3. **No mide el interés ni la calidad literaria.** Mide dificultad de lectura. Un libro fácil puede ser magnífico y uno difícil, aburrido.

### 2.3 Criterio de éxito

El proyecto se considera resuelto si se cumplen tres condiciones simultáneas, recogidas en el cuadro 1.

| # | Condición | Cómo se verifica |
|---|---|---|
| C1 | El orden por nivel MCER se conserva en corpus externo no visto | Medias por nivel estrictamente crecientes |
| C2 | La señal supera a la trivial | Correlación parcial descontando la longitud del texto |
| C3 | Un usuario sin formación técnica completa el recorrido | Prueba con lectora ajena al proyecto |

**Cuadro 1:** Criterios de éxito del proyecto. Se cumplen y se documentan, respectivamente, en los apartados 7.4, 7.5 y 3.3.

## 3 Estrategia

### 3.1 La apuesta, en un párrafo

La lectura extensiva es uno de los métodos con más respaldo para aprender una segunda lengua, y sin embargo casi nadie la practica bien, porque elegir el libro adecuado es un problema que el lector no puede resolver solo. LiteraLevel convierte una medida continua de dificultad —producida por un modelo que lee el texto entero, no la portada— en tres decisiones cotidianas: **qué leer ahora**, **por dónde se va a complicar** y **qué significa esta palabra en esta frase**. El activo defendible no es el modelo, que es pequeño y replicable: es la cadena completa desde el corpus hasta el pulgar de una persona de quince años en un teléfono.

### 3.2 Descripción de usuarios

Tres perfiles, con lo que cada uno necesita y con lo que hoy hace en su lugar. No son personas inventadas para rellenar: el primero está observado directamente (apartado 3.3) y los otros dos se derivan de las peticiones reales recogidas durante el desarrollo.

#### 3.2.1 Usuaria primaria: la estudiante de preparatoria

**Perfil.** 14 a 18 años. Estudia inglés en la escuela, entiende bastante más de lo que cree, no sabe qué es el MCER y no le interesa. Entra desde el teléfono, casi siempre en vertical, y en pantallas de unos 390 px de ancho. Su tolerancia a la fricción es de segundos. Sus necesidades y la respuesta del producto están en el cuadro 2.

#### 3.2.2 Usuario secundario: el adulto autodidacta

**Perfil.** 25 a 55 años. Ya lee en inglés con esfuerzo. Su problema no es empezar, es **subir de escalón sin abandonar**. Tiene libros a medias y no recuerda por dónde iba en ninguno.

- **Continuidad.** «Mis libros» guarda cada libro empezado con su barra de avance y el capítulo por el que iba, y lo reabre exactamente ahí. Es la petición literal que originó el módulo: *«un apartado con mis libros, los que estoy leyendo, que se queden guardados, en qué partes voy»*.
- **Saber a qué se enfrenta antes de comprometerse.** La ficha del libro dice cuánto tarda en leerlo **a su ritmo**, cuánto es diálogo y qué palabras se repiten, todo contado sobre el fichero.

| Necesidad | Cómo se atiende |
|---|---|
| Saber por dónde empezar sin sentirse examinada | Seis preguntas sobre hábitos observables —con qué frecuencia lee, si necesita diccionario, si ve series sin subtítulos, si ha terminado un libro entero— y **cero jerga gramatical** |
| Juzgarse ante algo real y no ante una descripción | Tres fragmentos literarios en escalera (*Alice*, Sherlock Holmes, *Frankenstein*), pintados con la tipografía del lector para que se lean como un libro y no como un formulario. Pesan 0,65 en el cálculo del nivel: delante de un texto real la gente se juzga mejor que describiéndose |
| Que le propongan algo, no una biblioteca | Un botón de «Sorpréndeme con algo de mi nivel» además de la búsqueda |
| Poder usarlo con el pulgar | Objetivos táctiles de 44 px, controles repartidos en filas que caben en 390 px, mandos de navegación también debajo del texto |
| No perderse | Al terminar el cuestionario, un enlace que salta directamente al buscador **con la recomendación ya hecha** |

**Cuadro 2:** Necesidades de la usuaria primaria y respuesta del producto. Qué hace hoy en su lugar: elige por portada o por título conocido, abandona a las tres páginas y concluye que el problema es ella.

- **Vocabulario que persista.** «Mis palabras» guarda cada consulta con su frase y su libro, que es la unidad que sirve para recordar. Deliberadamente **no hay puntos ni rachas**: la evidencia sobre recompensas externas (Deci y col., 1999) indica que premiar una actividad que ya gusta la deteriora, y leer ya es gratificante.
- **Pronunciación.** Lee bien y suena mal, y nadie se lo corrige. La aplicación marca palabra por palabra qué sonó bien y qué no.

#### 3.2.3 Usuario institucional: el docente de inglés

**Perfil.** Da clase a grupos heterogéneos y necesita repartir lecturas graduadas. No puede leerse cuarenta libros para clasificarlos.

- Un catálogo **medido**, no etiquetado a ojo, con la dificultad por capítulo para poder asignar fragmentos y no obras completas.
- Una declaración honesta de lo que la herramienta no es, para poder usarla sin incurrir en una promesa que no puede cumplir: **LiteraLevel no certifica ningún nivel del MCER**.
- Reproducibilidad: poder comprobar de dónde salen los números.

Este perfil es el que justifica dos decisiones que a un usuario final le dan igual: publicar el guion de validación y mantener el aviso de alcance visible.

### 3.3 El ciclo de usuario real: Esmeralda

La única prueba que vale es la que hace alguien que no sabe dónde hay que pulsar. **Esmeralda, 15 años, estudiante de preparatoria**, prima del autor, fue la primera persona ajena al proyecto que usó la aplicación. Lo que dijo, sin edulcorar:

> *«Está bien difícil de usar en celular.» — ¿Qué parte? — «Casi todo.»*

> *«No me gustan los colores… la página se siente antigua, todo muy recto, muy marcado.»*

*«¿Qué es eso de 10?»*

*«O yo soy muy tonta para esto.»*

La cuarta frase es la importante, y es la que ordena todo lo que vino después. **Cuando un usuario concluye que el tonto es él, el fallo es del diseño.** Krug (2014) formula la misma idea como regla de producto: si el usuario tiene que pensar para entender un control, el control está mal. A partir de ahí se diagnosticó qué producía cada queja y se corrigió (cuadro 3).

| **Lo que dijo** | **Diagnóstico** | **Corrección** | **Verificación** |
|---|---|---|---|
| «¿Qué es eso de 10?» | La etiqueta «Resultados» junto a un número no dice qué cuenta | «¿Cuántos te propongo?», con explicación | Etiqueta reescrita |
| Creyó que «Recomiéndame por nivel» tendría en cuenta sus gustos | La etiqueta prometía más de lo que hacía | «Sorpréndeme con algo de mi nivel» | Etiqueta reescrita |
| — | «Ajustar a mi nivel» es abstracto | «Solo libros que pueda leer», con información | Etiqueta reescrita |
| — | «Medir la dificultad de este capítulo» es lenguaje de laboratorio | «¿Cómo de difícil es este capítulo?» | Etiqueta reescrita |
| — | «Vistazo rápido a la dificultad» no dice cuánto tarda | «Vistazo rápido (unos segundos)» | Etiqueta reescrita |
| — | «Analizar el libro entero» no advierte del coste | «Leer el libro entero (tarda más)» | Etiqueta reescrita |
| «No me gustan los colores» | El color es gusto, y el gusto no se discute: se ofrece | **Cinco paletas** con pestaña propia y cambio instantáneo: *hielo* (la original), *amanecer* (clara, crema y naranja), *menta*, *papel* (para leer horas) y *medianoche* | Una prueba automática comprueba las cinco contra el criterio de contraste **WCAG AA (4,5:1)** (World Wide Web Consortium, 2023). Las cinco pasan; la peor mide **9,51** |
| «Todo muy recto, muy marcado» | Esto no es gusto, es diseño, y se corrige para todas las paletas | Esquinas de 14 px, bordes finos, sombras suaves y las opciones de lista como fichas tocables | — |
| «Difícil de usar en celular… casi todo» | En un móvil, el círculo de un botón de radio es un blanco de 12 px | La ficha entera pasa a ser el blanco: **44 px** | — |

**Cuadro 3:** Del comentario de una usuaria a un cambio verificable.

#### 3.3.1 Lo que ya se había corregido antes, por la misma vía

El ciclo de Esmeralda no fue el primero. Probar la aplicación en un teléfono real —y no en el navegador del escritorio— había descubierto antes fallos que **ninguna de las 183 pruebas automáticas podía encontrar, porque todos necesitaban un dedo y una pantalla pequeña**:

- El doble toque para consultar una palabra **no funcionaba en el móvil**: el código escuchaba solo el evento del ratón, que iOS no emite al seleccionar con el dedo. La instrucción en pantalla prometía algo que el dispositivo no hacía.
- Los títulos de la tabla de resultados eran enlaces a `gutenberg.org`, así que tocarlos **sacaba al lector fuera de la aplicación**.
- El resultado del nivel se pintaba en la parte superior de la página, fuera de la pantalla: la usuaria no se enteraba de que había terminado.
- Al pedir «traer una frase del capítulo» sin frase disponible, el campo se vaciaba y **borraba lo que el usuario había escrito**, sin decir nada.
- «Mis libros» mostraba 24 entradas llamadas `vacio.txt`, `falso.txt` y similares: la batería de pruebas anotaba sus ficheros de ataque en la biblioteca **real** de quien las ejecutara. Los datos personales del usuario eran el banco de pruebas.

#### 3.3.2 La lección, en una línea

**El valor de una prueba de usuario no está en el promedio de satisfacción, sino en la frase que duele.** Con $n = 1$ no se puede estimar nada, pero se pueden encontrar los fallos que hacen que una persona se culpe a sí misma. Nielsen (2000) sitúa en cinco usuarios el punto donde se detecta la mayor parte de los problemas de usabilidad; el accionable A8 lleva la prueba hasta ahí.

### 3.4 Usabilidad del modelo

Un modelo es usable cuando el usuario puede confiar en él sin entenderlo. Eso se construye con cinco decisiones, todas medidas.

#### 3.4.1 La espera se traslada, no se pide

Medir un libro largo son minutos. Pedirle esos minutos al lector en el momento en que quiere leer es perderlo. La estrategia es **mover el cómputo antes de la consulta**: el catálogo se precalcula fuera de línea y, cuando el lector busca, el trabajo ya está hecho. Los números que hacen viable esa decisión están en el cuadro 19 y en la figura 12: 8,7 ventanas/s en CPU, 101,7 en la GPU local y **2.022 en una A100**, con lo que los 61.642 libros en inglés de Project Gutenberg son unas **6,3 horas** de cómputo.

Cuando el cómputo sí tiene que ocurrir en vivo, se ofrecen **dos velocidades y se dice cuál se usó**: un vistazo (30 capítulos repartidos, 2 ventanas de cada uno) o el libro entero sin muestrear. Y el atajo está cuantificado, no prometido: 8 ventanas dan **1,784** y el recorrido completo del mismo capítulo, **1,743**.

#### 3.4.2 La incertidumbre se comunica en bandas

El modelo devuelve un número continuo, pero su escala está comprimida (predicho $\approx 0{,}72 \times$ real $+ 0{,}38$; véase la figura 8). Presentar «1,27 sobre 2» como si fueran dos decimales de precisión sería mentir con exactitud. La interfaz muestra **bandas** —básico $< 0{,}6 \leq$ intermedio $< 1{,}4 \leq$

avanzado, tal como las dibuja la figura 2— y la letra MCER únicamente como orientación, siempre junto al número y con la tabla de correspondencia a la vista.

Un fallo real de esta decisión, encontrado y corregido, ilustra el nivel de cuidado que exige: el redondeo por defecto de Python resuelve los empates hacia el par, de modo que un 1,00 exacto caía en un nivel y la tabla publicada decía otro. Un usuario que comparase su cifra con la tabla habría encontrado dos respuestas para el mismo número. Ahora hay una sola regla, y una prueba fija los cinco límites.

### 3.4.3 Nada falla en silencio, y nada se rompe del todo

La regla transversal del sistema es la **degradación elegante**: sin clave de servicio externo, la aplicación sigue dando diccionario, fonética, audio de Wiktionary, buscador y puntuación, porque nada de eso usa red. Solo se apagan la explicación en contexto y la corrección de pronunciación, y se dice con palabras que el lector entienda —«se ha agotado el presupuesto mensual de explicaciones; el diccionario, la fonética y el audio siguen funcionando»— en lugar del error técnico en crudo.

La regla que verifican las 183 pruebas de robustez es una sola: **ningún manejador puede lanzar una excepción hacia la interfaz**. Lo que falla vuelve como texto legible.

### 3.4.4 Cada número dice de dónde viene

En la ficha del libro conviven dos clases de información y **la separación se ve en pantalla**: lo *contado* sobre el fichero (palabras, tiempo de lectura, proporción de diálogo, vocabulario) sale solo al abrirlo, es instantáneo y no necesita red; el *resumen* escrito por un modelo generativo va detrás de un botón, se guarda en disco y viene marcado como lo que es. **Ninguna cifra de la ficha la dice un modelo generativo.** En el diccionario, la regla equivalente: el modelo de lenguaje explica el contexto y la gramática, y tiene prohibido redefinir la palabra; la definición es siempre la de Wiktionary.

### 3.4.5 La latencia se reparte para que la pantalla no se quede quieta

De los 28 a 44 segundos de una consulta léxica nueva, **23 a 39 son espera al servicio externo**; todo el trabajo local —lema, diccionario, desambiguación, fonética— son **40 milisegundos**. Por eso la ficha se pinta en dos etapas: lo local aparece al instante y la explicación se añade cuando llega. El trabajo tarda lo mismo; deja de parecer que la aplicación se colgó. La misma idea gobierna la curva de dificultad, que se repinta cada pocos capítulos mientras mide (el repintado cuesta 25 ms, medido) y los recursos pesados, que se cargan al primer uso y no al arrancar.

## 3.5 Accionables

Diez acciones concretas (cuadro 4), ordenadas por puntos de rúbrica protegidos u obtenidos por hora de trabajo. Cada una lleva coste real y criterio de terminado. No son «se podría»: son «se hace».

| # | Acción | Por qué | Coste | Terminado cuando |
|---|---|---|---|---|
| **A1** | **Publicar el modelo (328 MB) y el diccionario (243 MB)** como repositorios abiertos, con el guion de subida ya escrito | Desbloquea la reproducibilidad del cuaderno, que hoy no corre en un Colab ajeno. Es el mayor rendimiento por hora de todo el proyecto | ∼30 min; gratuito. Requiere un token que solo el autor puede crear | El cuaderno corre de principio a fin en un Colab limpio, sin errores ni advertencias |
| **A2** | **Desplegar en enlace permanente** (Gradio sobre plan de pago personal) | El enlace actual es un túnel temporal que muere al apagar el equipo. Es el mayor riesgo de la entrega, y no es técnico | 9 USD un mes | El enlace se abre desde un móvil ajeno y sobrevive a reiniciar el equipo del autor |
| **A3** | **Terminar la remedición del catálogo** con el modelo v4, libro entero | Sustituye las etiquetas heredadas —predicciones de un modelo v1 sobre las primeras ∼190 palabras— por medidas reales. Es la deuda técnica más visible | ∼6,3 h de A100, dentro del crédito disponible; descarga con 6 hilos | El catálogo publica niveles medidos y el aviso sobre las etiquetas heredadas se retira |
| **A4** | **Montar almacenamiento persistente** para los datos del lector | Un servicio que duerme y despierta con la estantería vacía deja en ridículo «Mis libros». Hoy todo eso vive en disco efímero | 12 USD por TB y mes; el proyecto ocupa 7,4 MB, así que el coste es despreciable | Cerrar y reabrir tras un reinicio conserva libros, avance, cuaderno y perfil |
| **A5** | **Conseguir un micrófono** (auriculares con micro) | El equipo actual no tiene. Sin él no se puede demostrar la corrección de pronunciación, que es la función más vistosa y la que mejor encaja con «usabilidad para el usuario final» | Coste mínimo de hardware | Se graba una frase desde el equipo del autor y la corrección palabra por palabra aparece en pantalla |
| **A6** | **Retirar del catálogo los 1.049 registros no descargables** o marcarlos como fichas informativas sin botón de lectura | Hoy son el 87,6 % del catálogo y no se pueden abrir. Ya no aparecen en el desplegable, pero siguen ocupando el índice | Media jornada | El catálogo lista solo lo que se puede leer, o distingue visualmente ambas cosas sin ambigüedad |
| **A7** | **Calibrar la escala** con una transformación afín de dos parámetros ajustada sobre entrenamiento, sin tocar los pesos | La escala está comprimida y un A2 puntúa cerca de B1. La técnica ya se aplicó con éxito a una variante anterior | Una tarde | Las medias por nivel siguen estrictamente crecientes **y** se acercan a sus anclas |
| **A8** | **Repetir la prueba de usuario con cinco lectores** de perfiles distintos, con guion de tareas y observación en silencio | $n = 1$ encuentra fallos graves; cinco encuentran la mayoría (Nielsen, 2000) | Cinco sesiones de 20 min | Existe una lista priorizada de hallazgos y las tres primeras correcciones están hechas |

| # | Acción | Por qué | Coste | Terminado cuando |
|---|---|---|---|---|
| **A9** | **Instrumentar la métrica que de verdad importa**: proporción de libros empezados que se terminan, con recomendación y sin ella | Todo lo demás son métricas de proceso. Esta es la única que valida la propuesta de valor | Una jornada de instrumentación, respetando el aislamiento por sesión | Hay una cifra base con la que comparar dentro de un mes |
| **A10** | **Ampliar el corpus de anclaje MCER** más allá de los 654 documentos actuales | Es el eslabón más delgado de la cadena de evidencia y el que limita la confianza en la letra que se muestra | Trabajo de corpus, sin coste de cómputo | El corpus de anclaje supera los 1.000 documentos con niveles de fuente institucional |

**Cuadro 4:** Accionables, con coste y criterio de terminado.

**Orden de ejecución si el tiempo aprieta:** A1 → A2 → A5 → A3 → A4. Los tres primeros son los que protegen o desbloquean más puntos de rúbrica por hora invertida, y ninguno de ellos es un problema de modelado: son despliegue, publicación y un micrófono.

### 3.6 Métricas de éxito

| Nivel | Métrica | Estado |
|---|---|---|
| Modelo | Orden estrictamente creciente por nivel MCER en corpus externo | **Cumplido**: 0,5040 · 0,5480 · 0,9276 · 1,2478 · 1,4952 |
| Modelo | Señal por encima de la longitud del texto | **Cumplido**: correlación parcial 0,657 |
| Producto | Un usuario sin formación técnica completa el recorrido | **Cumplido con reservas**: lo completó, y de esa sesión salieron 8 correcciones |
| Producto | Accesibilidad de color | **Cumplido**: las cinco paletas superan WCAG AA; la peor, 9,51 |
| Producto | Robustez | **Cumplido**: 183 pruebas de estrés y 27 pasos de integración, ningún manejador lanza hacia la interfaz |
| Operación | Enlace permanente disponible | **Pendiente** (A2) |
| Operación | Catálogo medido, no heredado | **En curso** (A3) |
| Impacto | Proporción de libros terminados | **Sin instrumentar** (A9) |

**Cuadro 5:** Métricas por nivel, con su estado real.

### 3.7 Riesgos

## 4 Descripción de los datos

Todos los datos de este trabajo provienen de **corpus académicos publicados, APIs y descarga directa de repositorios de dominio público**. No se usó Kaggle como fuente de datos en ningún punto del proyecto, conforme a la restricción del módulo. Cuando un corpus tiene licencia restrictiva se dice, y su texto crudo nunca sale del entorno de cómputo: solo estadísticas agregadas.

| Riesgo | Impacto | Mitigación |
|---|---|---|
| El enlace de la demostración muere durante la evaluación | Alto | A2: despliegue permanente, probado desde un dispositivo ajeno antes de la fecha |
| El servicio externo de lenguaje agota su presupuesto en mitad de una demostración | Medio | Ya mitigado: la aplicación degrada con un mensaje legible y conserva diccionario, fonética, audio, buscador y puntuación |
| Que la letra MCER se lea como una certificación | Alto, reputacional | Declaración de alcance en el documento y aviso permanente en pantalla |
| Que la remedición del catálogo no termine a tiempo | Medio | El proceso es reanudable por bloques y los resultados se guardan por lotes; lo medido ya es utilizable aunque falte el resto |
| Sobrecarga del espejo de descarga de Project Gutenberg | Medio, ético | Seis hilos y no treinta, cada uno con su pausa entre peticiones; y el vocabulario se obtuvo del SPGC, no rascando el sitio |
| Contenido inapropiado para una lectora menor de edad | Medio | Decisión razonada de **no filtrar por contenido** y avisar en la ficha; se argumenta en el apartado 8.4 |

**Cuadro 6:** Riesgos y mitigaciones.

## 4.1 Inventario de fuentes

## 4.2 Relevancia de cada fuente

**CLEAR** es el corpus central del modelado. Su variable objetivo, `BT_easiness`, no es una fórmula de legibilidad: es una escala construida a partir de comparaciones pareadas juzgadas por lectores humanos, lo que evita que el modelo aprenda a reproducir un contador de sílabas. Además trae precalculadas once métricas clásicas (Flesch, Flesch-Kincaid, ARI, SMOG, Dale-Chall, CAREC, CAREC_M, CML2RI, conteos de palabras, oraciones y párrafos) y dos variables de estratificación —`Categ` (literario/informativo) y `Lexile Band`— que permiten comprobar si el modelo funciona igual de bien en narrativa que en divulgación. Esa comprobación por dominio se hizo y aparece en el apartado 7.3.

**OneStopEnglish** aporta algo que CLEAR no puede: el mismo artículo reescrito en tres niveles. Como el contenido es idéntico y solo cambia la complejidad lingüística, permite medir el orden dentro de cada artículo, una prueba mucho más exigente y limpia que comparar textos distintos entre sí.

**British Council** es la única fuente con niveles MCER asignados por una institución de enseñanza de idiomas, que es exactamente la escala que el producto muestra al usuario. Es el juez final.

**SPGC** existe por una razón de higiene: descargar decenas de miles de libros uno a uno desde `gutenberg.org` viola su política de acceso automatizado. El SPGC publica los conteos de palabras ya calculados, con lo que se obtiene la distribución léxica del catálogo completo sin tocar el servidor de Gutenberg.

**Kaikki/Wiktionary** sustituyó a una API comercial de diccionario. La decisión fue de producto y de derechos: un SQLite local de 1,48 millones de entradas no tiene límite de peticiones, no cuesta dinero por consulta y no puede desaparecer si un proveedor cambia sus condiciones. Se descartó explícitamente Oxford Dictionaries.

## 4.3 Calidad de los datos: lo que está bien y lo que no

Un apartado de calidad que solo diga «los datos están limpios» no informa. Estos son los problemas reales encontrados y qué se hizo con cada uno.

| Fuente | Qué aporta | Tamaño | Origen | Licencia / acceso |
|---|---|---|---|---|
| **CLEAR Corpus** | Etiqueta continua de legibilidad (`BT_easiness`) para el modelado supervisado | 4.724 extractos | Repositorio público del proyecto CLEAR (Crossley y col., 2023) | Uso investigador, descarga directa |
| **OneStop-English** | Validación externa ordinal en 3 niveles | 567 textos (189 por nivel) | GitHub (Vajjala & Lučić, 2018) | CC BY-SA 4.0 |
| **British Council LearnEnglish** | Validación externa contra niveles MCER oficiales | 59 textos A1–C1 | Descarga de los PDF públicos | Con derechos: no se distribuye ni se imprime texto |
| **SPGC** (Standardized Project Gutenberg Corpus) | Lista global de frecuencia de palabras (solo conteos, sin texto) | 45.345 libros en inglés de 55.905 | Zenodo, registro 2422561 (Gerlach & Font-Clos, 2018, 2020) | Abierta |
| **Project Gutenberg** | Catálogo de obras a medir y a leer dentro de la app | 79.337 entradas; 61.642 libros de texto en inglés | Catálogo oficial (Project Gutenberg, 2026) + espejo `gutenberg.pglaf.org` | Dominio público |
| **Kaikki / Wiktionary** | Diccionario, IPA británica y americana, audio | 1.487.639 filas en SQLite (243 MB) | Volcado de kaikki.org (Ylönen, 2022) | Libre |
| **StoryWeaver / Global Digital Library** | Lecturas graduadas del catálogo heredado | 1.049 registros | API pública de contenidos | Abierta, pero sin descarga de texto |

**Cuadro 7:** Fuentes de datos, con volumen y procedencia.

**(a) El corpus de validación MCER no es homogéneo.** De los 59 textos de British Council, una parte no es prosa: en A1 hay un menú de restaurante, un horario de estudio, un tablero de salidas de aeropuerto, tarjetas de visita y mensajes de texto. Son documentos fragmentarios que el modelo nunca vio. Se definió un filtro de prosa continua **antes de mirar ningún resultado**, para no incurrir en elegir el examen después de ver las notas, y por dos vías independientes: por palabras clave del título y por estructura ($\geq 7$ palabras por línea y densidad de puntuación final de frase en el intervalo $(0; 0{,}11]$). Los dos criterios coinciden en 53 de 59 casos, el 89,8 %.

**(b) Las etiquetas del catálogo heredado no son fiables, y hay que decirlo.** El catálogo con el que la aplicación funciona hoy tiene **1.197 libros** —no 12.752, como sugiere un `wc -l` ingenuo: el campo `hook` contiene saltos de línea entrecomillados y hay que contar con un lector de CSV real—. Su columna `nivel_cefr` **no es anotación humana ni metadato del editor**: son predicciones de un modelo anterior (v1) sobre las primeras ∼190 palabras de cada obra, con cortes MCER obtenidos por cuantiles. El resultado es un reparto que no resiste el sentido común (cuadro 8 y figura 3).

| Nivel | Libros | % |
|---|---|---|
| A1 | 723 | 60,4 |
| A2 | 185 | 15,5 |
| C2 | 115 | 9,6 |
| B1 | 69 | 5,8 |
| C1 | 53 | 4,4 |
| B2 | 52 | 4,3 |
| **Total** | **1.197** | **100** |

**Cuadro 8:** Reparto de niveles del catálogo heredado. Son predicciones de un modelo v1 sobre las primeras ∼190 palabras, no anotación fiable.

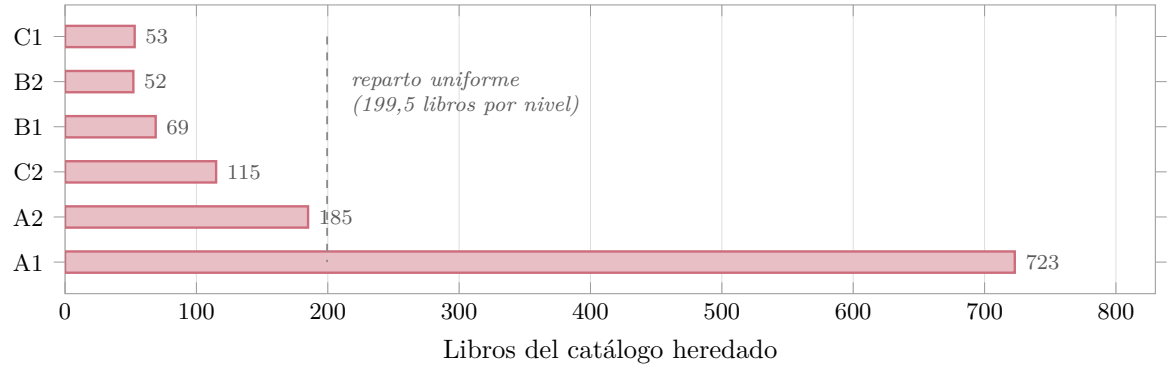



**Figura 3:** El sesgo del clasificador v1, visto de una vez. Seis de cada diez libros de dominio público quedaron etiquetados A1 y el tramo B1–B2 —donde está la mayoría de los lectores reales— reúne 121 de 1.197 obras. Una distribución así no describe la literatura en dominio público: describe el clasificador que la produjo. Datos del cuadro 8.

Hay cuentos infantiles etiquetados C1 y clásicos muy distintos entre sí todos en C2. Y el tramo B1–B2, donde está la mayoría de los lectores reales, son 121 libros de 1.197. Estas etiquetas sirven para ordenar y filtrar de forma aproximada, **no son una medida fiable libro a libro**, y así se declara tanto en el repositorio como en la aplicación. Es la razón de ser del precálculo descrito en 8.3: remedir todo el catálogo, libro entero, con el modelo final.

**(c) De esos 1.197 libros, solo 148 se pueden abrir.** Son los de Project Gutenberg. Los otros 1.049 provienen de StoryWeaver y no tienen fichero descargable, de modo que aparecían

en el desplegable de lectura como opciones muertas. Peor aún: su identificador se había usado para construir enlaces a Gutenberg extrayendo sus dígitos, con lo que `SWgdlgdl201` apuntaba al libro 201 de Gutenberg, que es otra obra. Un enlace al libro equivocado es peor que ningún enlace. Hoy el desplegable lista solo lo que se puede abrir, la tabla marca los descargables y una línea dice cuántos de cuántos son.

**(d) La licencia de Project Gutenberg se estaba puntuando como si fuera novela.** El texto legal viene pegado al último capítulo: en *Alice's Adventures in Wonderland*, 2.900 de las 5.042 palabras del capítulo XII son licencia. Eso contaminaba tanto la puntuación como las estadísticas de la ficha (`gutenberg` y `project` aparecían entre las palabras más repetidas del libro). Se recorta por las marcas START/END dentro del capítulo, sin descartar el capítulo, que contiene el final de la obra.

**(e) La portada no es un capítulo.** En un `.txt` de Gutenberg, las 4.957 palabras previas al capítulo I (portada, índice, pies de ilustración) se estaban puntuando como si fueran la novela. En el análisis de *War and Peace*, el «capítulo más fácil del libro» resultó ser la portadilla. Se descarta con la etiqueta que el propio lector de ficheros asigna, «Antes del primer capítulo». Se probó descartar por el filtro de prosa continua y **no sirve**: se llevaba por delante dos capítulos reales de *Alice*.

# 5 Análisis exploratorio

Siguiendo la organización canónica del módulo, el análisis se presenta en tres niveles: univariado, bivariado y multivariado. Todas las figuras y cuadros citados se generan en el cuaderno que acompaña a este documento.

## 5.1 Análisis univariado

**La variable objetivo.** `BT_easiness` es continua y aproximadamente simétrica alrededor de cero. No hay clases desbalanceadas que corregir porque no hay clases: el problema es de regresión. Cuando se necesitó una versión categórica para comparar modelos, se construyó por cuantiles (`qcut`), lo que garantiza seis grupos equifrecuentes y hace que la exactitud sea comparable entre modelos.

**Las variables textuales derivadas.** Sobre cada extracto se calcularon, a partir de sus *tokens*, seis variables de ingeniería propia: longitud media de oración, *type-token ratio*, longitud media de palabra, proporción de palabras raras, sílabas medias por palabra y porcentaje de polisílabos. Todas son positivas y con cola derecha, como es habitual en variables de conteo sobre texto.

**La distribución del vocabulario inglés.** El agregado de los 45.345 libros del SPGC arroja **2.838.258.803 palabras** y un vocabulario único de **3.295.146 formas**. La distribución sigue la ley de Zipf (Zipf, 1949) con precisión: unas pocas miles de palabras cubren la mayor parte del texto corrido. Este hecho, que parece de trivia, tiene una consecuencia práctica que se documenta en 5.2.

**El catálogo.** El cuadro 8 y la figura 3 muestran el reparto de niveles del catálogo heredado. Su forma —60 % en A1— es en sí misma un hallazgo del análisis exploratorio: una distribución así no describe la literatura en dominio público, describe el sesgo del clasificador que la produjo.

**La dificultad dentro de un libro.** La unidad de análisis del producto no es el libro sino el capítulo, y la figura 10 muestra por qué: los 362 capítulos de *War and Peace*, medidos sin muestrear, se reparten entre 1,333 y 1,990 con media 1,735. La figura 11 añade dos libros más y confirma que la dispersión interna es la norma, no la excepción.

## 5.2 Análisis bivariado

**Cada variable frente a la dificultad.** La matriz de correlación de las variables derivadas contra `BT_easiness` confirma el sentido esperado: los textos más fáciles tienen oraciones más cortas, palabras más cortas, menos polisílabos y menor proporción de palabras raras. La correlación de `rare_word_ratio` con `BT_easiness` es negativa, como debe ser.

**El experimento de saturación léxica.** La variable «palabra rara» depende de qué lista de palabras familiares se use. Se probaron tres, de menor a mayor (cuadro 9).

| Lista de palabras familiares | Libros | Correlación de `rare_word_ratio` con `BT_easiness` |
|---|---|---|
| Corpus Gutenberg de NLTK | 18 | −0,379 |
| Muestra propia de Gutenberg | 397 | −0,330 |
| **SPGC completo, en inglés** | **45.345** | **−0,326** |

**Cuadro 9:** Efecto de escalar el corpus de referencia léxica. La correlación no mejora.

Este es un **resultado negativo y se reporta como tal**: multiplicar por 2.500 el corpus de referencia no mejora la señal, e incluso la baja marginalmente. La exactitud del clasificador de tres clases se mantuvo en 0,51 con las tres listas. La explicación está en la ley de Zipf: la distribución de frecuencias del inglés converge muy rápido, así que las 3.000 palabras más frecuentes de 18 libros y las de 45.345 libros son casi el mismo conjunto. El valor del paso no está en la métrica sino en la cobertura: la lista del SPGC generaliza mejor a texto nuevo arbitrario, que es lo que la aplicación recibe.

**Dificultad frente a longitud, la variable incómoda.** Sobre los 45 textos de British Council medibles en local, contar las palabras del texto —sin modelo alguno— alcanza una correlación de Spearman de **0,807** con el nivel oficial. El modelo alcanza 0,854. Es decir: en ese corpus, nivel y longitud están confundidos, porque los materiales de examen gradúan también la extensión de la tarea. Publicar ese *baseline* antes de que lo pregunte el evaluador es más creíble que omitirlo; en el apartado 7.5 se cuantifica cuánta señal aporta el modelo por encima de él.

**Dificultad frente a dominio.** El nivel del texto está correlacionado con su tipo documental. Al filtrar los 59 textos de British Council a prosa continua, el nivel A1 desaparece casi por completo y el rango evaluable se encoge de seis niveles a cuatro (A2–C1). Por eso el *baseline* de contar palabras cae de 0,879 a 0,765 al filtrar: parte de la señal del conjunto completo era simplemente que los textos A1 son cortos. Las correlaciones antes y después del filtro **no son comparables entre sí**, y se reportan por separado.

## 5.3 Análisis multivariado

**Las variables clásicas se estorban entre sí.** Las métricas de legibilidad tradicionales (Flesch, Flesch-Kincaid, ARI, SMOG, Dale-Chall) son transformaciones distintas de los mismos dos ingredientes —longitud de oración y longitud de palabra— y por tanto están fuertemente correlacionadas entre ellas. Meterlas todas en un modelo lineal no añade información: añade multicolinealidad. Por eso el conjunto de trabajo se redujo a **tres** variables poco redundantes entre sí y con interpretación distinta: `avg_sentence_length` (complejidad sintáctica), `rare_word_ratio` (carga léxica) y `type_token_ratio` (diversidad de vocabulario).

**Hasta dónde llegan las variables clásicas.** Con esas tres variables, un clasificador de seis clases alcanza 0,29 de exactitud con regresión logística (Pedregosa y col., 2011) y 0,28 con XGBoost (Chen & Guestrin, 2016). Que un ensamble de árboles —capaz de capturar interacciones no lineales arbitrarias— no supere a un modelo lineal es la prueba de que **el cuello de botella no era el modelo sino la representación del texto**. Tres números por documento no bastan para separar seis clases.

Conviene decir qué sostiene ese argumento y qué no. Lo que se comprueba es que **subir la capacidad del algoritmo sobre estas variables no mueve el resultado**, y eso se ve en cuatro modelos distintos. Lo que no se demuestra es que exista un límite teórico: nadie ha probado todas las combinaciones posibles de conteos, y el cuadernillo enseña un caso donde ampliar de tres a diecisiete variables sí mejora. La conclusión honesta es empírica, no un techo.

**Representación densa.** Al sustituir las tres variables por un *embedding* de 384 dimensiones de `all-MiniLM-L6-v2` (Reimers & Gurevych, 2019), la exactitud salta a 0,37 y el error ordinal medio baja de 1,39 a 0,93 niveles. El modelo híbrido (*embedding* + las tres variables clásicas) da 0,37 y 0,91: prácticamente lo mismo. Esto indica que **el *embedding* ya contiene la información que aportaban las tres variables**, y bastante más. La figura 4 recoge la progresión completa.

**Estructura por dominio.** La comparación por subconjuntos de CLEAR (literario frente a informativo, y por banda Lexile) muestra que el rendimiento no es uniforme: el modelo funciona mejor en texto informativo que en literario, y peor en la banda más fácil (Lexile 500) que en la más difícil (Lexile 1300). Los números están en el cuadro 13.

# 6 Procesamiento de datos

Cada transformación se documenta con su justificación. La regla que se siguió es la del módulo 1 del diplomado: **no se transforma sin medir qué se rompió**.

## 6.1 Sobre el texto de entrada

El cuadro 10 recoge las ocho transformaciones que sufre el texto antes de llegar al modelo; la figura 1 las sitúa en la cadena completa.

| # | Transformación | Por qué | Evidencia / consecuencia |
|---|---|---|---|
| T1 | **Filtro de prosa continua** antes de puntuar: se rechaza si hay $\geq 2$ viñetas o $\geq 6$ líneas cortas | El modelo solo vio prosa; puntuar un menú da un número sin significado | El filtro estaba muerto en producción: se normalizaba *antes* de comprobar, y `normalize()` colapsa los saltos de línea, así que el detector recibía siempre una sola línea. Una carta de menú de 432 palabras se puntuaba como prosa. Corregido: el filtro va sobre el texto crudo |
| T2 | **Normalización de espacios** (`\s+` → espacio) después del filtro | Estabiliza el troceado en bloques | Sin efecto sobre la puntuación; solo sobre el corte |
| T3 | **Troceado en bloques de 250 palabras, mínimo 150** | Es la unidad con la que se entrenó; un bloque más corto no tiene señal suficiente | Constante del entrenamiento: cambiarla invalidaría las métricas reportadas |
| T4 | **Truncado a 256 *tokens*** | Límite de contexto del modelo | Medido: de 200 bloques, el **100 %** llega exactamente a 256 *tokens* tras truncar, porque 250 palabras inglesas siempre superan 256 BPE. No hay relleno que optimizar |

| # | Transformación | Por qué | Evidencia / consecuencia |
|---|---|---|---|
| T5 | **Recorte de la licencia de Gutenberg** por las marcas START/END, dentro del capítulo | 2.900 de las 5.042 palabras del capítulo XII de *Alice* son texto legal | Sin esto, el modelo puntuaba texto jurídico como narrativa y la ficha listaba «gutenberg» entre las palabras más frecuentes del libro |
| T6 | **Descarte de portada, índice y portadilla** por la etiqueta «Antes del primer capítulo» | 4.957 palabras de paratexto se puntuaban como novela | Se probó descartar por el filtro de prosa continua y se rechazó: eliminaba dos capítulos reales de *Alice* |
| T7 | **Muestreo de hasta 8 bloques repartidos por el documento** para la puntuación rápida | Dar un número en segundos, no en minutos | Cuantificado: 8 bloques dan 1,784 y el recorrido completo de las 23 ventanas del mismo capítulo da 1,743. El atajo se desvía 0,041 sobre una escala de 0 a 2 |
| T8 | **Recorte de entradas del usuario en el servidor** (40 caracteres por palabra, 400 por oración, 20 MB por fichero) | El límite del navegador es una sugerencia, no una defensa | Una cadena de 3.000 caracteres pasaba el filtro de «máximo cuatro palabras» y se pintaba como encabezado: 9.312 caracteres llenando la pantalla del móvil |

**Cuadro 10:** Transformaciones sobre el texto, con su justificación y su evidencia.

### 6.2 Sobre las variables del modelado clásico

### 6.3 Sobre el corpus de vocabulario (procesamiento distribuido)

Los conteos del SPGC son 45.345 ficheros pequeños. Agregarlos secuencialmente es un mal uso del tiempo y del sistema de ficheros, de modo que la agregación se hizo con **PySpark** (Zaharia y col., 2016): los ficheros se distribuyen en 200 particiones, un `flatMap` los convierte en pares (palabra, conteo) y un `reduceByKey` los suma en una única lista global de frecuencia. Es el patrón canónico de conteo distribuido y es lo que hace tratable un corpus de 2.838 millones de palabras en una sesión de Colab.

### 6.4 Sobre el diccionario

El volcado de Kaikki llega como JSONL de líneas independientes. Se filtra a entradas en inglés con palabra no vacía y se ingesta en SQLite con un esquema plano (`palabra`, `pos`, `sentidos` como JSON, `ipa_uk`, `ipa_us`, `audio_uk`, `audio_us`) y un índice por `palabra`. La justificación es de latencia: la primera consulta sobre 1.487.639 filas tarda **0,001 s** con el índice puesto y la base abierta en modo solo lectura. Los 243 MB del fichero no cuestan nada en tiempo de respuesta.

Un dato de cobertura que condiciona el diseño de la aplicación: solo **7.003 de las 1.487.639 entradas (0,5 %) traen audio de pronunciación**. Es decir, casi cualquier palabra que un lector consulte por primera vez necesitará síntesis de voz. Esa medición es la que justificó paralelizar las dos llamadas de red de una consulta en lugar de encadenarlas.

## 7 Modelación

| # | Transformación | Por qué |
|---|---|---|
| T9 | **Partición agrupada por libro** (`GroupShuffleSplit` sobre `Title`, 20 % de prueba, semilla 42) | Un mismo libro aporta varios extractos a CLEAR. Con una partición aleatoria por fila, fragmentos del mismo libro caerían a ambos lados y el modelo memorizaría el estilo del autor en lugar de aprender dificultad. Es fuga de datos por diseño, y se evita por diseño |
| T10 | **Estandarización** (`StandardScaler`) ajustada solo en entrenamiento | Ajustar el escalador con los datos de prueba filtra su distribución al modelo |
| T11 | **Discretización por cuantiles** (`qcut`) para las versiones categóricas | Produce grupos equifrecuentes, con lo que la exactitud entre modelos es comparable y el azar tiene una probabilidad conocida (1/6 = 16,7 %) |
| T12 | **Lista de palabras familiares construida solo con el conjunto de entrenamiento** | Si se cuentan también las palabras de los extractos de prueba, esas palabras entran en la definición de una variable de entrada: es fuga de datos. Medida la diferencia, resulta despreciable —cambian 228 de 3.000 palabras y los resultados se mueven en la tercera decimal—, pero era fuga y se quitó |
| T13 | **Lista alternativa a escala**: las 3.000 más frecuentes del SPGC | Sustituye una lista de 18 libros por una de 45.345. Es un experimento de cobertura, no la lista que usan los modelos del cuadernillo, y **el sistema desplegado no consulta ninguna lista de palabras**: puntúa con el transformador |

**Cuadro 11:** Transformaciones sobre las variables tabulares.

## 7.1 Diseño experimental

Todos los modelos comparten la **misma partición agrupada por libro** (3.774 extractos de entrenamiento y 950 de prueba) y la misma semilla, de modo que las diferencias entre ellos son atribuibles al modelo y no al reparto de los datos. Se comparan sobre los mismos 950 extractos reservados, con dos métricas: exactitud sobre seis clases y **error ordinal medio**, que penaliza proporcionalmente a la distancia del fallo.

Dos precisiones sobre ese conjunto, porque cambian cómo hay que leer las cifras. La primera: esos 950 extractos son también los que sirvieron para **elegir la época** del transformador, de modo que funcionan como validación de selección y no como un test independiente; sus números pueden ser algo optimistas. La segunda: las seis clases salen de partir `BT_easiness` en **sextiles de este corpus**, no de anotaciones del Marco Común Europeo. Se les dan nombres A1–C2 para poder ordenarlos, pero no son niveles MCER certificados ni equivalen a los del modelo desplegado, que se ancla con otro corpus. Ambas cosas las señaló una auditoría externa y ambas son ciertas.

## 7.2 Progresión de modelos

| Modelo | Representación del texto | Exactitud (6 niveles) | Error ordinal medio |
|---|---|---|---|
| Regresión logística | 3 variables clásicas | 0,29 | 1,39 |
| XGBoost | 3 variables clásicas | 0,28 | 1,42 |
| Regresión logística | *Embedding* MiniLM (384 d) | 0,37 | 0,93 |
| Regresión logística | Híbrido (*embedding* + 3 variables) | 0,37 | 0,91 |
| **Transformer afinado** | **Texto crudo, atención** | **0,46** | **0,67** |

**Cuadro 12:** Progresión completa sobre el mismo conjunto de prueba (950 extractos). La mejora acompaña siempre al enriquecimiento de la representación, no a la complejidad del clasificador.

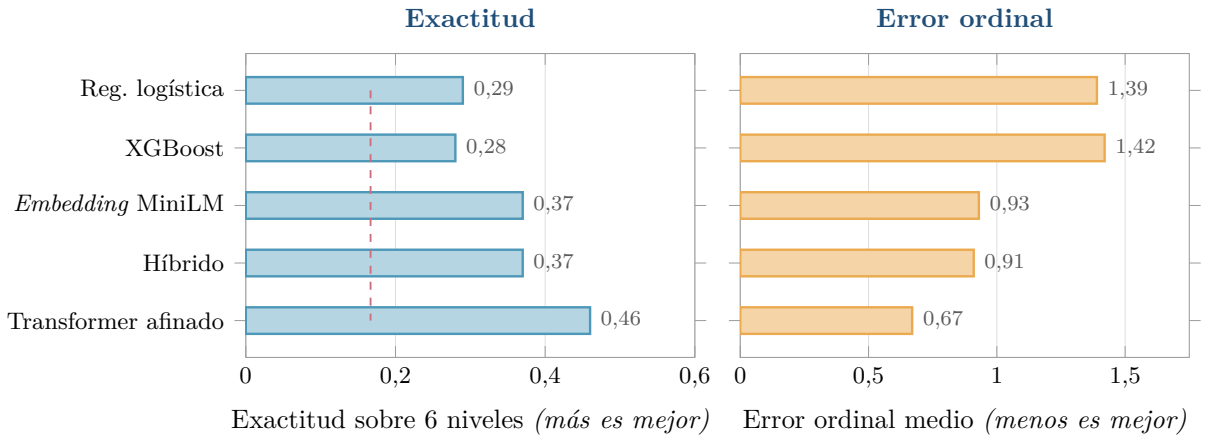



**Figura 4:** La tesis metodológica del trabajo, en dos ejes. Los dos primeros modelos comparten *representación* (tres variables clásicas) y solo cambian de clasificador: XGBoost no mejora a la regresión logística, incluso empeora el error ordinal. Los saltos ocurren cuando cambia la representación del texto: *embedding* denso primero, texto crudo con atención después. La línea roja discontinua del panel izquierdo marca el azar ($1/6 = 0{,}167$), que es lo que acertaría un clasificador que no leyese nada. Datos del cuadro 12.

La lectura del cuadro 12 es la tesis metodológica del trabajo: **cada vez que se le dio al modelo una representación más rica del texto, el desempeño subió; y cuando solo se aumentó la potencia del clasificador sobre la misma representación pobre, no subió**. XGBoost sobre tres variables es marginalmente peor que una regresión logística sobre las mismas tres variables.

El modelo afinado directamente sobre el texto, con cabeza de regresión sobre `BT_easiness`, alcanza además **RMSE 0,560** y **correlación de Pearson 0,89** con la etiqueta continua real, que es un resultado sólido para este problema.

**Sobreajuste, visto y controlado.** El entrenamiento corrió seis épocas con tasa de aprendizaje 2e-5, decaimiento de pesos 0,01, calentamiento y precisión mixta. El RMSE de validación mejoró hasta la época 3 (0,560) y a partir de ahí empeoró de forma monótona —época 4: 0,578; época 5: 0,637; época 6: 0,660— mientras la pérdida de entrenamiento seguía bajando (figura 5). Es un caso de libro. Como se guardaba un punto de control por época y se cargaba automáticamente el mejor al terminar, **el modelo reportado es el de la época 3, no el de la última**.

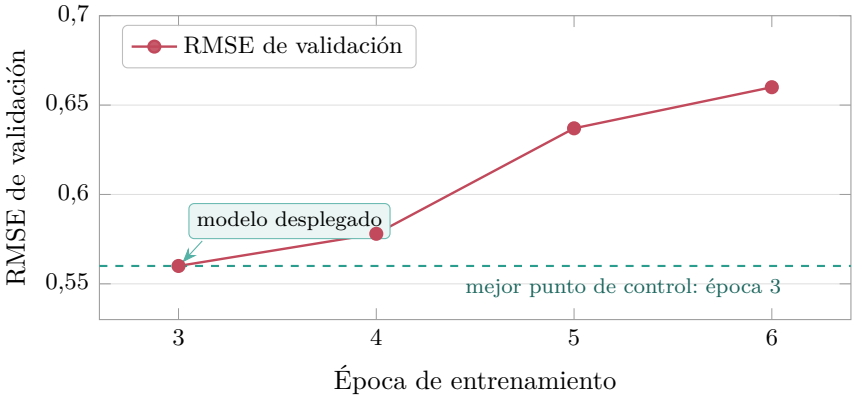



**Figura 5:** El sobreajuste, medido. El RMSE de validación toca su mínimo en la época 3 y empeora de forma monótona después, mientras la pérdida de entrenamiento seguía bajando. Se guardó un punto de control por época y se cargó automáticamente el mejor: el modelo desplegado es el de la época 3, no el de la sexta.

## 7.3 Dónde funciona y dónde no: análisis por dominio

Un modelo que se evalúa solo en agregado esconde sus propios puntos ciegos. Se midió la correlación con la dificultad real por subconjunto, comparando dos variantes del modelo entrenadas sobre corpus distintos (v1 sobre `BT_easiness`, v2 afinado sobre material graduado para aprendices).

| Dominio | n | v1 | v2 |
|---|---|---|---|
| Literatura (CLEAR, `Lit`) | 461 | **0,848** | 0,760 |
| Informativo (CLEAR, `Info`) | 489 | **0,905** | 0,837 |
| Banda Lexile 500 (más fácil) | 62 | **0,651** | 0,459 |
| Banda Lexile 1300 (más difícil) | 272 | **0,877** | 0,773 |
| Periodístico (OneStopEnglish) | 567 | 0,458 | **0,840** |
| Exámenes MCER (British Council) | 59 | −0,239 | **0,175** |

**Cuadro 13:** Matriz modelo × dominio. Correlación orientada con la dificultad real; más alto es mejor.

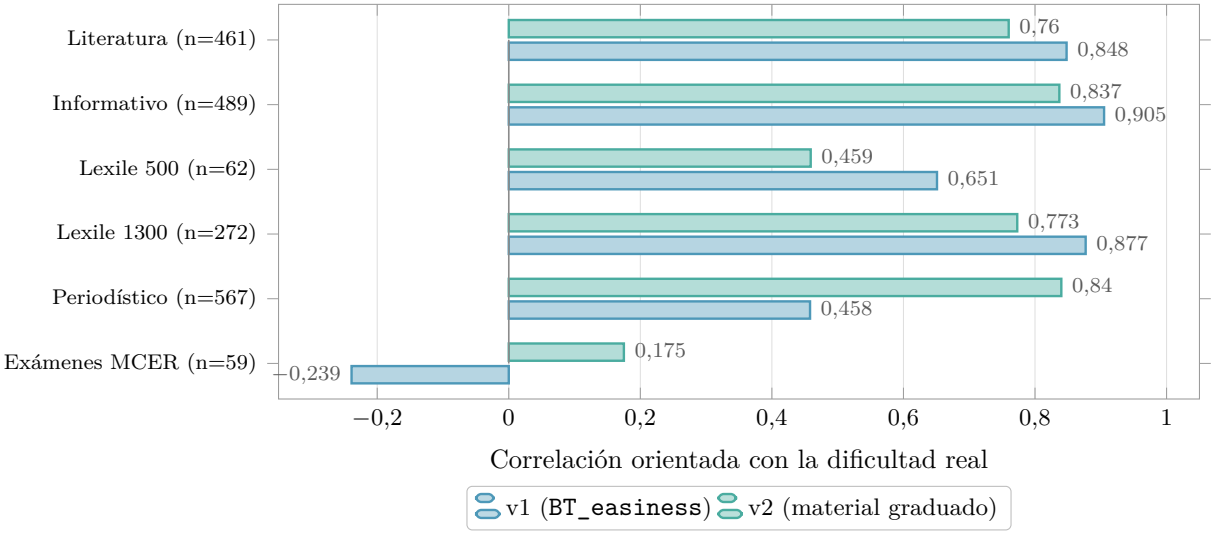



**Figura 6:** Los dos modelos no compiten: miden cosas distintas. v1 domina donde la etiqueta son juicios de lectores nativos sobre prosa continua (CLEAR); v2 domina donde la etiqueta es una graduación pensada para aprendices de segunda lengua, que es la misma construcción que mide el MCER. Como el producto muestra una escala anclada al MCER, se desplegó el modelo de la familia v2. Datos del cuadro 13.

La conclusión no es que uno sea bueno y otro malo: **miden cosas distintas**. v1 gana en dificultad de lectura tipo CLEAR —juicios de lectores nativos sobre prosa continua— y v2 gana donde la etiqueta es una graduación pensada para aprendices de segunda lengua, que es la misma construcción que mide el MCER. La decisión de qué escala presentar al usuario precede a la decisión de qué modelo desplegar; se eligió la escala anclada al MCER, y con ella el modelo correspondiente.

## 7.4 El modelo desplegado y su validación

El modelo en producción, **v4**, es un `distilroberta-base` (Liu y col., 2019; Sanh y col., 2019) de seis capas y 82 millones de parámetros, con cabeza de regresión, servido con *Transformers* (Wolf y col., 2020) y cuyos pesos ocupan 328 MB en disco. Puntúa bloques de 250 palabras truncados a 256 *tokens* y promedia sin ponderar. Su escala interna es 0–5 —un valor por nivel MCER, con posiciones intermedias (A1+, A2+, B1+, B2+)— y la pública es esa misma escala multiplicada por 0,4. **El modelo es final y no se reentrena.**

Su tarjeta de modelo (`metricas_literalevel_v4.json`, 5 de septiembre de 2026) registra el corpus de anclaje MCER con el que se afinó: 654 documentos aceptados —57 descartados por longitud insuficiente—, repartidos en 510 de entrenamiento y 144 de validación. Esos 144 documentos son el conjunto de validación ciega que produce las cifras de la primera fila del cuadro 14.

| **Conjunto** | **n** | **Exacto** | **Dentro de ±1 nivel** | **Spearman** |
|---|---|---|---|---|
| Validación ciega | 144 | 53,5 % | **97,2 %** | **0,908** |
| British Council (externo) | 38 | 50,0 % | **100 %** | 0,829 |

**Cuadro 14:** Métricas del modelo desplegado. MAE de 0,499 niveles en el conjunto de validación.

**El resultado que de verdad sostiene el trabajo no es ninguno de esos porcentajes, sino el orden.** Sobre textos externos con nivel MCER oficial, las medias por nivel quedan estrictamente crecientes (cuadro 15 y figura 7).

| **Nivel oficial** | **n (local)** | **Media en escala 0–2** | **Desviación** |
|---|---|---|---|
| A1 | 3 | 0,5040 | 0,111 |
| A2 | 7 | 0,5480 | 0,237 |
| B1 | 12 | 0,9276 | 0,198 |
| B2 | 11 | 1,2478 | 0,246 |
| C1 | 12 | 1,4952 | 0,172 |

**Cuadro 15:** Reproducción local de la validación externa, sobre los 45 textos que sobreviven a la extracción de los PDF. Fuente: `datos_figuras/validacion.dat`.

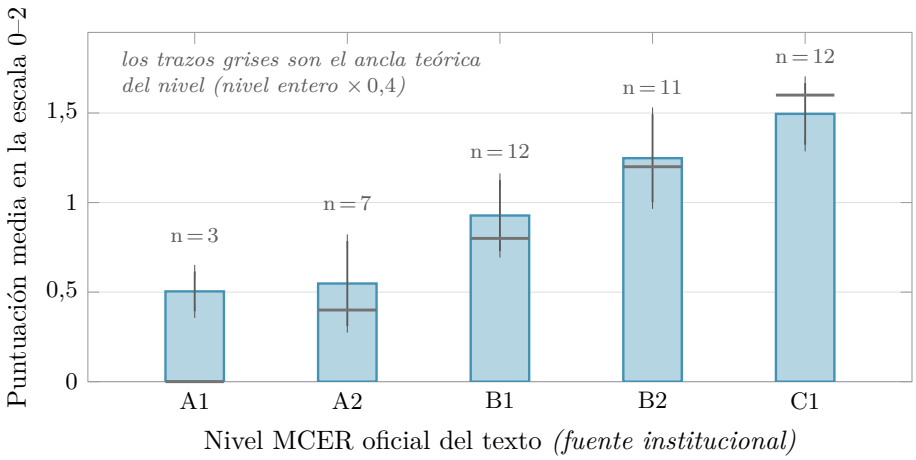



**Figura 7:** El resultado que sostiene el trabajo: las medias por nivel quedan **estrictamente crecientes** sobre textos externos con nivel MCER asignado por una institución de enseñanza. Las barras de error son la desviación dentro de cada nivel; con $n$ de 3 a 12 textos, lo que se afirma es el orden global y no cada comparación por pares. Datos de `datos_figuras/validacion.dat` (cuadro 15).

Esta tabla se reproduce en cualquier máquina con el guion `validar_local.py`. Lo que se reproduce exactamente es **el orden**; las medias difieren ligeramente de las obtenidas en Colab (C1 coincide hasta la cuarta cifra, A2 se desvía 0,10) porque la extracción de texto de los PDF conserva 45 de los 59 textos originales y el anclaje de la sección de lectura recorta distinto. Se reporta la discrepancia en lugar de citar solo la cifra que coincide.

## 7.5 El *baseline* propio, y qué aporta el modelo por encima de él

| Señal | Spearman con el nivel oficial (45 textos) |
|---|---|
| Modelo v4 | **0,854** |
| Contar las palabras del texto, sin modelo | 0,807 |
| Modelo, descontando la longitud (correlación parcial) | **0,657** |

**Cuadro 16:** El modelo frente a la señal trivial.

Un contador de palabras llega casi tan lejos como el modelo en ese corpus, y omitirlo sería deshonesto. Lo que sostiene al modelo es la tercera fila: **aporta señal por encima de la longitud**, que es precisamente lo que un contador de palabras no puede hacer. Además, el modelo no recibe la longitud del documento como variable —puntúa bloques de tamaño fijo y promedia—, aunque su salida correlacione 0,730 con ella, porque los corpus de examen gradúan también la extensión de la tarea.

**La escala está comprimida, y la aplicación lo asume.** Contra el ancla real, el ajuste ronda predicho $\approx 0{,}72 \times \text{real} + 0{,}38$ (figura 8), de modo que un texto A2 tiende a puntuar cerca de B1. Por eso la interfaz muestra **bandas** (básico $< 0{,}6 \leq$ intermedio $< 1{,}4 \leq$ avanzado) y la letra MCER solo como orientación, en lugar de fingir una precisión de dos decimales que el modelo no tiene.

Los cortes de esas bandas no son tercios de la escala, y esa es una corrección posterior. Al principio estaban en 0,8 y 1,6 —el 0–2 partido en tres—, pero como el modelo comprime sus predicciones, con esos cortes un texto C1 caía en «intermedio» y «avanzado» solo lo alcanzaba un C2: tres de los cinco niveles medidos compartían banda. Ahora la banda se deriva del ancla MCER, con el agrupamiento del propio marco —usuario básico A1–A2, independiente B1–B2, competente C1–C2—, y las fronteras quedan en extbf0,6 y 1,4. Así la palabra y la letra no pueden contradecirse por construcción. Ninguna puntuación cambió: solo cambió cómo se agrupan.

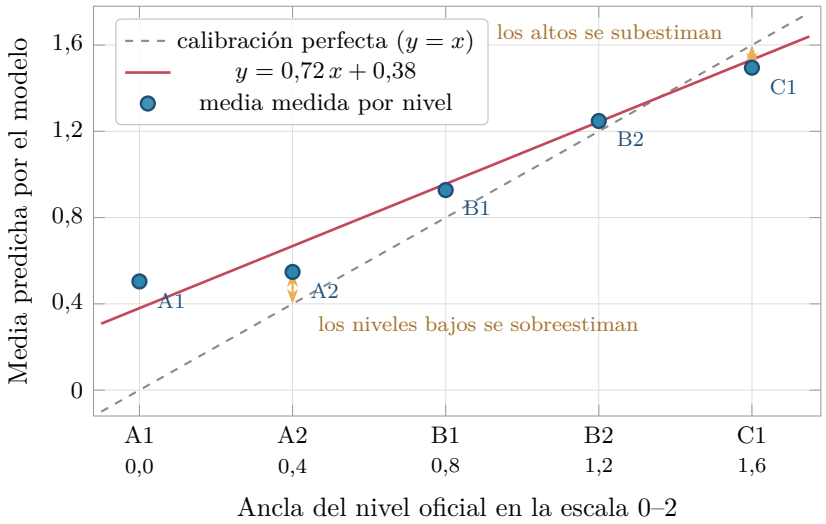



**Figura 8:** Por qué la interfaz muestra bandas y no decimales. Los puntos son las medias medidas por nivel (cuadro 15) frente al ancla teórica de ese nivel. El orden se conserva —que es el objetivo—, pero la pendiente es 0,72 y no 1: los niveles bajos se sobreestiman y los altos se subestiman. Calibrar esa recta afín sin tocar los pesos del modelo es el accionable A7 (cuadro 4).

## 7.6 Cuadro de decisiones metodológicas

Incluye las hipótesis que se probaron y se rechazaron (cuadro 17). Reportarlas es parte del resultado.

| Decisión | Razón | Evidencia / consecuencia |
|---|---|---|
| Regresión, no clasificación | La dificultad es continua; clasificar tira información ordinal | El error ordinal medio baja de 1,39 a 0,67 en la progresión completa |
| Partición agrupada por libro | Evitar fuga de datos entre extractos del mismo autor | Aplicada a *todos* los modelos comparados, no solo al final |
| `distilroberta` y no `roberta-base` completo | La aplicación debe correr en CPU en el equipo de un estudiante | 328 MB y 0,9 s de carga; la diferencia de calidad no justificaba 3× de tamaño |
| Promediar bloques sin ponderar | Simplicidad y reproducibilidad; ponderar por longitud reintroduce la longitud como señal | Constante del entrenamiento, replicada literalmente en la app |
| **Rechazada: XGBoost sobre variables clásicas** | Se esperaba que un ensamble superase al modelo lineal | No lo hace: 0,28 frente a 0,29, y error ordinal peor (1,42 *vs.* 1,39). El límite estaba en las variables |
| **Rechazada: modelo híbrido *embedding* + variables** | Se esperaba complementariedad | Ganancia nula (0,37 y 0,37; 0,91 *vs.* 0,93). El *embedding* ya contiene esa información |
| **Rechazada: escalar la lista léxica al SPGC completo por rendimiento** | Se esperaba mejorar `rare_word_ratio` | La correlación pasa de −0,330 a −0,326. Se conserva igualmente por cobertura, no por métrica |
| **Rechazada: cuantización dinámica int8** | +18 % de velocidad en CPU | MAE de 0,210 sobre una escala de 0 a 2 y sesgo sistemático de −0,21. Un desplazamiento así cambia la letra MCER en el **52 %** de la escala y la banda en el **21 %**: no degrada la cifra, le cambia la etiqueta al libro. Inaceptable |
| **Rechazada: precisión media (fp16) en la GPU local** | Se esperaba acelerar | Es **4,8× más lenta** que fp32 en una GTX 1650 SUPER: el chip TU116 no tiene *tensor cores*. En una A100 sí compensa, y allí la desviación medida es 0,00037 de media |
| **Rechazada: `inference_mode` en lugar de `no_grad`** | Se esperaba menos sobrecarga | 0,4 % de diferencia, por debajo del ruido |
| **Rechazado: esfuerzo de razonamiento «mínimo» en la explicación léxica** | Es el doble de rápido (7,4 s frente a 14,9 s) | Con él, «had peeped» se explicó como pasado simple cuando es pasado perfecto. La gramática es justo lo que se evalúa |
| Filtrar prosa continua *antes* de ver resultados | Excluir textos porque el modelo falla en ellos invalida la validación | El criterio se fijó a priori y por dos vías independientes que coinciden en 89,8 % |

**Cuadro 17:** Decisiones metodológicas, incluidas las hipótesis rechazadas.

# 8 Resolución del problema

## 8.1 De la métrica a la decisión del lector

Una correlación de 0,908 no le sirve de nada a un adolescente. Lo que le sirve son tres decisiones, y el producto está construido para producir exactamente esas tres (cuadro 18).

| Pregunta del lector | Qué la responde | Coste para él |
|---|---|---|
| ¿Cuál es mi nivel? | Seis preguntas sobre hábitos observables y tres fragmentos reales en escalera; o bien subir un libro que ya lee cómodo | Menos de dos minutos |
| ¿Qué leo ahora? | Búsqueda semántica en español sobre el catálogo, acotada al rango de lectura del perfil | Segundos |
| ¿Por dónde se va a complicar? | Curva de dificultad capítulo a capítulo, medida sobre el libro entero sin muestrear (figura 10) | De 12,7 s (vistazo, medido sobre *Crime and Punishment*) a minutos (libro completo) |
| ¿Qué significa esta palabra *aquí*? | Doble toque sobre la palabra: lema, IPA británica y americana, definición de Wiktionary, el sentido concreto en esa frase, gramática y audio | Instantáneo en local; la explicación contextual tarda más |
| ¿Lo estoy pronunciando bien? | Lectura en voz alta marcada palabra por palabra, con el sonido concreto que falla | Una frase |

**Cuadro 18:** Del modelo a las decisiones del usuario.

## 8.2 Un recorrido completo, con números reales

Tomemos el caso concreto de un lector cuyo perfil da 1,20 sobre 2 (banda intermedia, ancla B2). La figura 9 resume el recorrido y los seis pasos que siguen lo detallan.

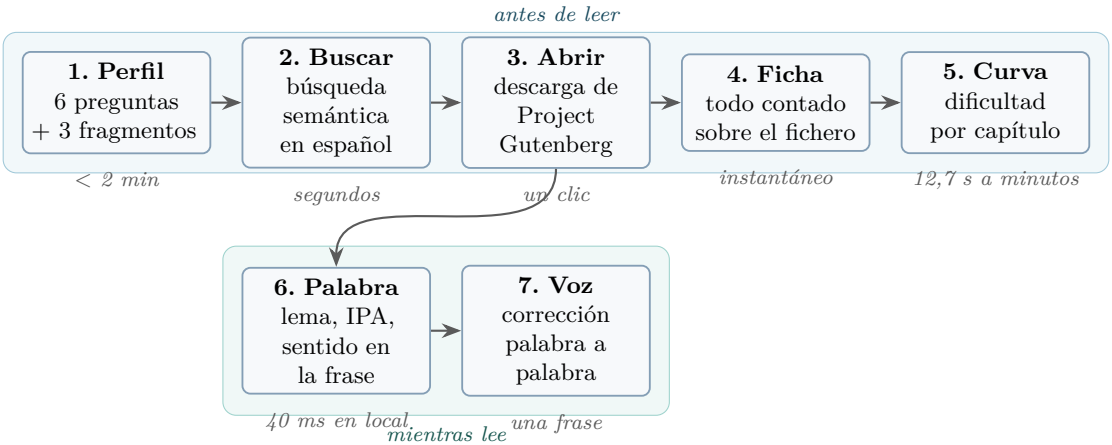



**Figura 9:** El recorrido completo, con los tiempos medidos de cada paso. No es un modelo con una interfaz encima: es una secuencia de decisiones que el lector no podía tomar antes. Lo único lento es la explicación contextual, que sale a la red; por eso la ficha se pinta en dos etapas.

1. Describe en español lo que le apetece: *«una novela de detectives victoriana»*. El buscador no busca por título sino por significado, sobre *embeddings* multilingües, y le devuelve obras

dentro de su rango. Un rescate por parecido ortográfico atiende además los nombres mal escritos —«dostoyevski», «chejov», «Shakespear» encuentran a quien deben— sin estorbar a las búsquedas por tema.

2. Abre el libro. Se descarga de Project Gutenberg y se abre dentro de la aplicación, sin salir a buscarlo.

3. Aparece la ficha, y todo lo que dice está **contado sobre el fichero**: palabras reales, tiempo de lectura a su ritmo, longitud media de frase, proporción de diálogo, variedad de vocabulario y palabras más repetidas. La proporción de diálogo distingue de verdad entre obras —*Alice* 73 %, *Pride and Prejudice* 28 %, *Crime and Punishment* 31 %—, cosa que no hacía cuando se medía por párrafo en lugar de por oración, porque un epub no conserva los saltos de párrafo y las tres daban 100 %.

4. Pide la curva de dificultad. Sobre *Notes from a Dead House*, el modelo recorre **487 ventanas de 130.104 palabras en 86 segundos** y devuelve una media de 1,73 sobre 2, además de decir si el libro se va complicando o soltando y cuáles son su capítulo más llevadero y su capítulo más exigente. La segunda vez tarda 0,02 s porque queda guardada. Las figuras 10 y 11 muestran ese producto sobre tres libros medidos.

5. Toca una palabra que no conoce. El trabajo local —lema, categoría gramatical, consulta al diccionario, desambiguación por similitud, IPA— son **40 milisegundos**. La explicación contextual, que sale a la red, es lo único lento, y por eso la ficha se pinta en dos etapas: lo local aparece al instante y la explicación se añade cuando llega.

6. Lee una frase en voz alta y recibe la corrección palabra por palabra.

Ese recorrido es la unidad de valor del producto: **no es un modelo con una interfaz encima, es una secuencia de decisiones que el lector no podía tomar antes**.

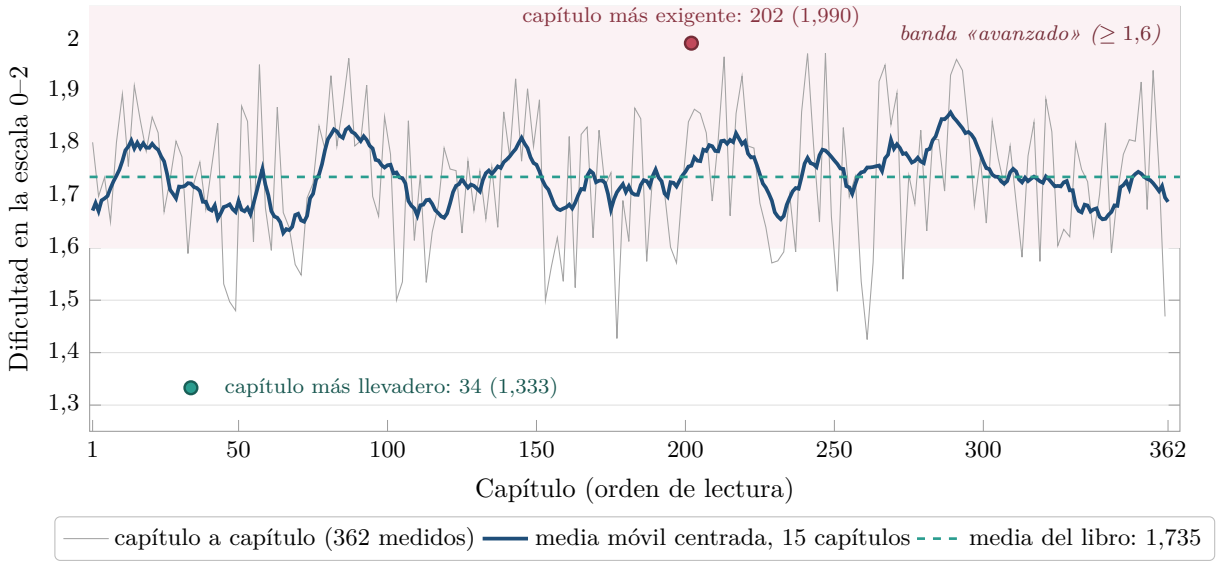



**Figura 10: La figura que mejor explica el producto.** Los 362 capítulos de *War and Peace* medidos sin muestrear —2.459 ventanas de 250 palabras, análisis completo— sobre la escala pública 0–2. La serie fina es la medición capítulo a capítulo (dibujada con un punto de cada dos por legibilidad); la línea gruesa es la media móvil centrada de 15 capítulos, calculada sobre *todos* los puntos. Un libro no tiene una dificultad: tiene un recorrido. Aquí va de 1,333 a 1,990 —0,657 de la escala— con media 1,735, y la novela se endurece de forma sostenida hacia el tramo central. Fuente: `datos_figuras/curva_War_and_Peace.dat`.

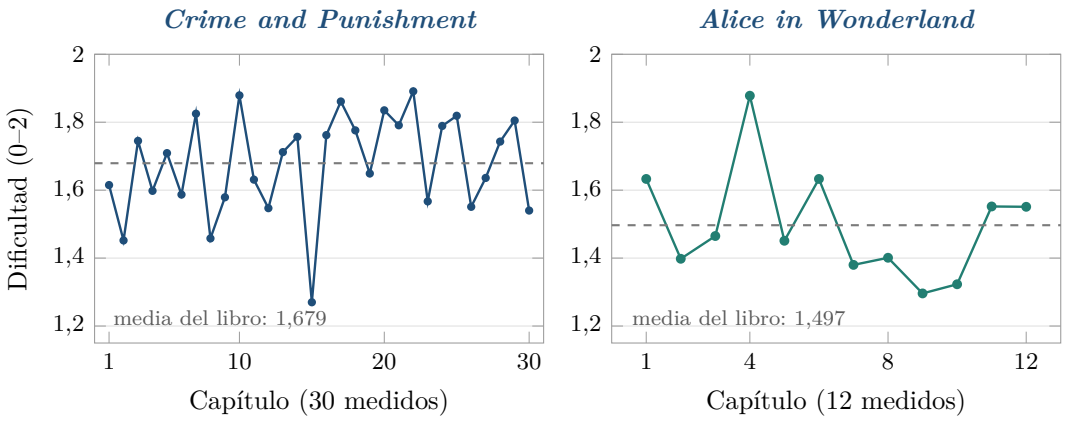



**Figura 11:** La dispersión interna es la norma, no la excepción. Dos libros más, medidos en *modo rápido* (el vistazo que la aplicación ofrece en segundos): *Crime and Punishment* recorre 1,270–1,891 y *Alice* 1,296–1,878, pese a que sus medias las separa casi dos décimas. Elegir libro por su media esconde justamente esto. Fuente: `datos_figuras/curva_Crime_and_Punishment.dat` y `datos_figuras/curva_Alice_s_Adventures_in_Wonder.dat`.

## 8.3 Escalado: el catálogo entero, precalculado

La curva de dificultad de un libro largo son minutos de cómputo. Hacer esperar eso a cada visitante no es aceptable, de modo que el catálogo se precalcula. Las mediciones que hicieron viable esa decisión están en el cuadro 19 y en la figura 12.

| Entorno | Configuración | Ventanas/s | Factor |
|---|---|---|---|
| CPU (Ryzen 5 2600) | 12 hilos, lote 64 | 8,7 | 1× |
| GPU local (GTX 1650 SUPER) | fp32, lote 128 | 101,7 | 11,7× |
| GPU A100 (Colab) | fp16, lote grande | 2.022 | 232× |

**Cuadro 19:** Rendimiento medido de extremo a extremo, incluida la tokenización y las transferencias. Fuente: `datos_figuras/velocidad.dat`.

Dos comprobaciones acompañan a ese cuadro, porque acelerar no puede costar exactitud:

- **La GPU da los mismos números que la CPU.** Sobre 840 ventanas de *Crime and Punishment*, 839 son idénticas a tres decimales y una difiere en 0,001; el MAE es 0,0000012 sobre la escala 0–2.
- **Reagrupar en lotes distintos no puede mover un decimal**, y no es una suposición: como todas las ventanas ocupan exactamente 256 *tokens* tras truncar, no hay relleno, y 286 ventanas puntuadas de una en una y en un solo lote dan 286/286 valores idénticos con MAE 0,000000000.

Con 2.022 ventanas por segundo, **medir los 61.642 libros en inglés de Project Gutenberg son unas 6,3 horas de A100**. El cuello de botella real resultó no ser el modelo sino la descarga: en serie, a 0,3 libros/s, los libros tardarían 57 horas en bajar. Y no era la pausa de cortesía entre peticiones, era la latencia —cada petición al espejo se pasa casi todo su tiempo esperando la ida y vuelta—, así que con seis hilos esas esperas se solapan. Seis y no treinta a propósito: el espejo lo mantiene alguien de forma gratuita, y cada hilo conserva su pausa.

## 8.4 Dos decisiones de producto que merecen argumento

**Se ofrecen dos velocidades de análisis y siempre se dice cuál se usó.** El vistazo rápido toma 30 capítulos repartidos por la obra y 2 ventanas de cada uno; el análisis completo

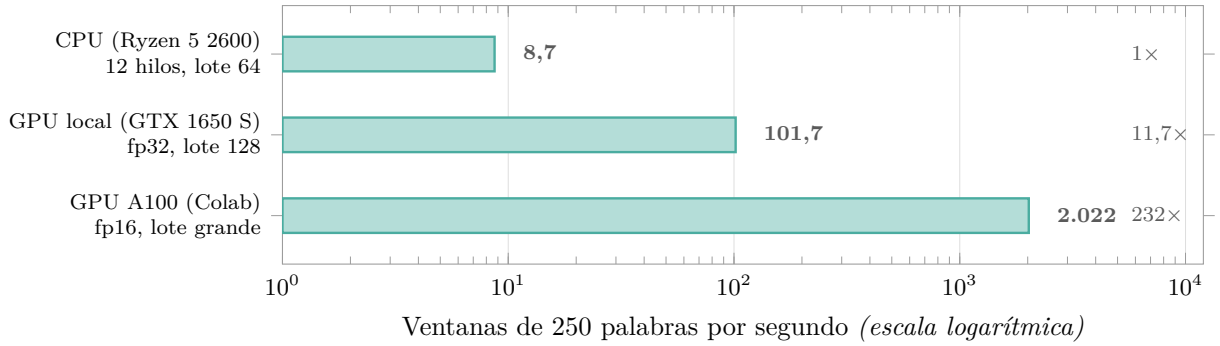



**Figura 12:** Tres órdenes de magnitud entre el equipo del autor y la GPU alquilada, medidos de extremo a extremo (tokenización y transferencias incluidas). La escala es logarítmica porque el rango va de 8,7 a 2.022 ventanas por segundo. Es lo que convierte «medir los 61.642 libros en inglés de Project Gutenberg» en unas 6,3 horas de cómputo en lugar de casi tres meses de CPU. Datos de `datos_figuras/velocidad.dat` (cuadro 19).

no muestrea. El número 30 no es redondo por gusto: sale de la velocidad medida de la máquina. Y el resumen declara cuál de los dos se ejecutó, porque un vistazo que presumiera de haber leído el libro entero acabaría citado como si lo hubiera hecho. La diferencia entre ambos modos se ve al comparar la figura 10 (completo, 362 capítulos) con la figura 11 (vistazo).

**No se filtra el catálogo por contenido.** Se implementó un filtro basado en las materias que asigna el propio Project Gutenberg —90 libros de 61.642— y después se retiró, deliberadamente. El razonamiento: esto es una plataforma de literatura, y la literatura es donde esas cosas aparecen. Filtrar por etiqueta habría eliminado también obras que son literatura por derecho propio, como *Fanny Hill*, perseguida judicialmente y relevante precisamente por eso. En su lugar se usa un mecanismo que ya existía: la ficha de cada libro trae un campo de aviso que se muestra como «Antes de empezar». **Se informa al lector y se le deja elegir; no se elige por él.** Es una decisión discutible y por eso se argumenta en lugar de ocultarse.

## 9 Limitaciones

1. **La escala 0–2 es propia y no es una certificación.** El MCER fue el ancla del entrenamiento. LiteraLevel no acredita ningún nivel, y decirlo en el documento no basta: la aplicación lo repite en pantalla.

2. **La escala está comprimida.** El ajuste contra el ancla real ronda predicho $\approx 0{,}72\times$real$+0{,}38$ (figura 8), así que los niveles bajos se sobreestiman y los altos se subestiman. Es la razón de mostrar bandas y no decimales.

3. **Las etiquetas del catálogo heredado no son fiables** (cuadro 8). Son predicciones de un modelo v1 sobre las primeras ∼190 palabras. La remedición está en curso y es el trabajo pendiente más importante.

4. **De los 1.197 libros del catálogo actual, solo 148 son descargables.** Los 1.049 de StoryWeaver no tienen fichero que abrir.

5. **Los tamaños muestrales de la validación externa son pequeños**: 38 textos en Colab, 45 en local, con 3 textos en A1. Una diferencia de 0,05 entre dos niveles adyacentes con esas $n$ no es significativa; lo que se afirma es el orden global, no cada comparación por pares.

6. **La validación no es enteramente independiente de la exploración.** El corpus de British Council se usó primero para diagnosticar (descubrir que el modelo no sabe leer menús)

y después para validar. El filtro de prosa se fijó a priori precisamente para acotar ese problema, pero el conjunto ha sido mirado y ya no es virgen.

7. **La longitud del texto es un confusor en el corpus de examen.** Contar palabras alcanza 0,807 donde el modelo alcanza 0,854 (cuadro 16).

8. **El modelo solo mide prosa continua en inglés.** Poesía, teatro, diálogo muy fragmentado y cualquier lengua distinta del inglés quedan fuera.

9. **El corpus de anclaje MCER es pequeño** (654 documentos aceptados) y el guion de entrenamiento del v4 vive en Google Drive, no en el repositorio. Las cifras del apartado 7.4 se reportan tal como constan en la tarjeta del modelo.

10. **Dos corpus no se pueden redistribuir**: British Council tiene derechos y el corpus de validación de 144 documentos no acompaña al repositorio, de modo que las cifras de 0,908 y 97,2 % **no son verificables clonando el proyecto**. Lo que sí se reproduce en cualquier máquina es el cuadro 15.

11. **La reproducibilidad del cuaderno depende de publicar dos artefactos**: el modelo (328 MB) y el diccionario (243 MB) viven hoy en un disco local. Mientras no estén publicados, el cuaderno no corre de principio a fin en un Colab ajeno.

12. **La aplicación no está desplegada de forma permanente.** El enlace actual es un túnel temporal. El consumo medido —1,05 GB de memoria residente, con picos realistas de 1,2 a 1,5 GB— descarta cualquier plan gratuito de 512 MB.

13. **La prueba de usuario tiene $n = 1$.** Esmeralda es una sola lectora. Su valor es cualitativo y de diagnóstico, no estadístico: sirve para encontrar fallos de usabilidad graves —y encontró varios—, no para estimar satisfacción media.

14. **La explicación contextual depende de un servicio externo de pago.** Sin clave, la aplicación sigue funcionando en todo lo que no usa red —diccionario, fonética, audio de Wiktionary, buscador y puntuación— pero se apagan la explicación en contexto y la corrección de pronunciación.

## 10 Trabajo futuro

1. Terminar la remedición del catálogo completo y sustituir las etiquetas heredadas por medidas del v4 sobre el libro entero.

2. Publicar modelo y diccionario en un repositorio abierto, con lo que el cuaderno pasa a ser reproducible desde cualquier Colab.

3. Ampliar el corpus de anclaje MCER, que hoy es el eslabón más delgado de la cadena de evidencia.

4. Calibrar explícitamente la escala comprimida (una transformación afín de dos parámetros ajustada sobre entrenamiento, sin tocar los pesos) y comprobar si el orden se conserva tras calibrar.

5. Repetir la prueba de usuario con cinco o seis lectores de perfiles distintos, que según Nielsen (2000) es donde se detecta la mayor parte de los problemas de usabilidad.

6. Medir el efecto real sobre el abandono: comparar la tasa de libros terminados entre lectores que eligen con recomendación y sin ella. Es la única métrica que verdaderamente valida la propuesta.

# 11 Conclusiones

**Se cumplió el objetivo ordinal, que era el objetivo.** Sobre textos externos con nivel MCER oficial, el modelo desplegado ordena los niveles de forma estrictamente creciente (0,5040 · 0,5480 · 0,9276 · 1,2478 · 1,4952; figura 7), con una correlación de Spearman de 0,908 en validación ciega y el 97,2 % de los documentos dentro de un nivel de error. Para el problema planteado —elegir qué leer— acertar el orden es lo que importa; acertar la letra exacta es un lujo.

**El cuello de botella nunca fue el algoritmo, fue la representación del texto.** La progresión completa lo demuestra sobre un mismo conjunto de prueba (figura 4): tres variables clásicas dan 1,39 niveles de error ordinal tanto con regresión logística como con XGBoost; un *embedding* lo baja a 0,93; leer el texto crudo con atención lo baja a 0,67. Aumentar la potencia del clasificador sobre una representación pobre no sirvió de nada, y eso también es un resultado.

**Escalar el corpus no siempre mejora nada, y conviene decirlo.** Multiplicar por 2.500 el corpus de referencia léxica —de 18 libros a los 45.345 del SPGC— dejó la correlación en −0,326 frente a −0,330. La ley de Zipf explica por qué. El paso se conservó por cobertura, no por métrica, y así se reporta.

**La velocidad se ganó sin mover un decimal, y se demostró.** Doce hilos y lotes de 64 en CPU, fp32 con lote 128 en GPU: +24 % y ×11,7 respectivamente (figura 12), con 839 de 840 ventanas idénticas a tres decimales. Y se rechazaron dos palancas más rápidas —int8 y fp16 en la tarjeta local— porque una desviaba 0,210 sobre una escala de 0 a 2 y la otra era 4,8 veces más lenta. **Medir antes de optimizar, y medir también lo que se descarta.**

**Lo que convierte esto en un producto no es el modelo, es lo que se hizo con lo que dijo una lectora de quince años.** Un ciclo completo —observar, escuchar la queja, diagnosticar el fallo propio y corregirlo— vale más que un punto de correlación. Ese ciclo se documenta en el apartado 3.3, y su resultado son seis etiquetas reescritas, cinco paletas verificadas contra el criterio de contraste WCAG AA y una interfaz que se puede usar con el pulgar.

**Y queda pendiente lo que más pesa.** La aplicación funciona, pero su enlace es temporal; el cuaderno es correcto, pero no reproducible mientras el modelo no esté publicado; y el catálogo se está remidiendo. Las tres cosas están planificadas con coste y criterio de terminado en el cuadro 4.

# Declaración de alcance

LiteraLevel es una herramienta de apoyo a la lectura. **No es un instrumento de evaluación ni de certificación lingüística.** No debe usarse para asignar calificaciones, para decidir la admisión de una persona a un programa, para acreditar un nivel del Marco Común Europeo de Referencia ni para ninguna decisión con consecuencias para el evaluado. La escala 0–2 es propia; las letras A1 a C2 son el ancla con la que se entrenó el modelo y se muestran únicamente como orientación.

El sistema mide dificultad lingüística de prosa continua en inglés. No mide calidad literaria, no mide comprensión del lector y no emite juicios sobre el contenido de las obras. El catálogo no se filtra por contenido: se informa al lector mediante un aviso en la ficha del libro y la decisión queda en sus manos.

Los datos personales del lector —los libros empezados, el vocabulario consultado y el perfil de nivel— se guardan separados por sesión y no se comparten entre visitantes. Solo la caché de definiciones se comparte, por ser contenido de diccionario y no historial de nadie. Ningún texto con derechos se distribuye ni se imprime fuera del entorno de cómputo: de los corpus con licencia restrictiva solo salen estadísticas agregadas.

## Referencias


Abid, A., Abdalla, A., Abid, A., Khan, D., Alfozan, A., & Zou, J. (2019). *Gradio: Hassle-free sharing and testing of ML models in the wild*. arXiv: 1906.02569. https://arxiv.org/abs/1906.02569

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794. https://doi.org/10.1145/2939672.2939785

Council of Europe. (2020). *Common European Framework of Reference for Languages: Learning, teaching, assessment — companion volume*.

Crossley, S., Heintz, A., Choi, J. S., Batchelor, J., Karimi, M., & Malatinszky, A. (2023). A large-scaled corpus for assessing text readability. *Behavior Research Methods*, *55*(2), 491-507. https://doi.org/10.3758/s13428-022-01802-x

Day, R. R., & Bamford, J. (1998). *Extensive reading in the second language classroom*. Cambridge University Press.

Deci, E. L., Koestner, R., & Ryan, R. M. (1999). A meta-analytic review of experiments examining the effects of extrinsic rewards on intrinsic motivation. *Psychological Bulletin*, *125*(6), 627-668. https://doi.org/10.1037/0033-2909.125.6.627

Gerlach, M., & Font-Clos, F. (2018). *Standardized Project Gutenberg Corpus (SPGC)*. Zenodo. https://doi.org/10.5281/zenodo.2422561

Gerlach, M., & Font-Clos, F. (2020). A standardized Project Gutenberg corpus for statistical analysis of natural language and quantitative linguistics. *Entropy*, *22*(1), 126. https://doi.org/10.3390/e22010126

Hu, M., & Nation, P. (2000). Unknown vocabulary density and reading comprehension. *Reading in a Foreign Language*, *13*(1), 403-430.

Krashen, S. D. (1985). *The input hypothesis: Issues and implications*. Longman.

Krug, S. (2014). *Don't make me think, revisited: A common sense approach to web usability* (3.ª ed.). New Riders.

Liu, Y., Ott, M., Goyal, N., Du, J., Joshi, M., Chen, D., Levy, O., Lewis, M., Zettlemoyer, L., & Stoyanov, V. (2019). *RoBERTa: A robustly optimized BERT pretraining approach*. arXiv: 1907.11692. https://arxiv.org/abs/1907.11692

Nakanishi, T. (2015). A meta-analysis of extensive reading research. *TESOL Quarterly*, *49*(1), 6-37. https://doi.org/10.1002/tesq.157

Nation, I. S. P. (2013). *Learning vocabulary in another language* (2.ª ed.). Cambridge University Press.

Nielsen, J. (2000, 18 de marzo). *Why you only need to test with 5 users*. Nielsen Norman Group. https://www.nngroup.com/articles/why-you-only-need-to-test-with-5-users/

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, *12*, 2825-2830.

Project Gutenberg. (2026). *Project Gutenberg*. https://www.gutenberg.org

Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using Siamese BERT-networks. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*, 3982-3992. https://doi.org/10.18653/v1/D19-1410

Sanh, V., Debut, L., Chaumond, J., & Wolf, T. (2019). *DistilBERT, a distilled version of BERT: Smaller, faster, cheaper and lighter*. arXiv: 1910.01108. https://arxiv.org/abs/1910.01108

Vajjala, S., & Lučić, I. (2018). OneStopEnglish corpus: A new corpus for automatic readability assessment and text simplification. *Proceedings of the 13th Workshop on Innovative Use*

*of NLP for Building Educational Applications*, 297-304. https://doi.org/10.18653/v1/W18-0535

Wolf, T., Debut, L., Sanh, V., Chaumond, J., Delangue, C., Moi, A., Cistac, P., Rault, T., Louf, R., Funtowicz, M., Davison, J., Shleifer, S., von Platen, P., Ma, C., Jernite, Y., Plu, J., Xu, C., Le Scao, T., Gugger, S., … Rush, A. M. (2020). Transformers: State-of-the-art natural language processing. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, 38-45. https://doi.org/10.18653/v1/2020.emnlp-demos.6

World Wide Web Consortium. (2023). *Web content accessibility guidelines (WCAG) 2.2*. W3C. https://www.w3.org/TR/WCAG22/

Ylönen, T. (2022). Wiktextract: Wiktionary as machine-readable structured data. *Proceedings of the 13th Language Resources and Evaluation Conference*, 1317-1325.

Zaharia, M., Xin, R. S., Wendell, P., Das, T., Armbrust, M., Dave, A., Meng, X., Rosen, J., Venkataraman, S., Franklin, M. J., Ghodsi, A., Gonzalez, J., Shenker, S., & Stoica, I. (2016). Apache Spark: A unified engine for big data processing. *Communications of the ACM*, *59*(11), 56-65. https://doi.org/10.1145/2934664

Zipf, G. K. (1949). *Human behavior and the principle of least effort*. Addison-Wesley.