Pléyade (proyecto LiteraLevel) — Estrategia

Proyecto integrador — Módulo 5 (Integrador) Diplomado en Ciencia de Datos, FES Acatlán (UNAM), Generación 34 Profesor: Mtro. Fernando Barranco Rodríguez Autor: Miguel Reyes Carrillo Octubre de 2026

> Documento complementario de `documento.md`, al que corresponde el apartado 3. Aquí se desarrollan las tres piezas que la rúbrica pide de forma explícita: **descripción de usuarios**, **usabilidad del modelo** y **accionables concretos**. Todas las cifras citadas están medidas; su procedencia se indica en cada caso.

El marco: Peldaño, una compañía ficticia

Este trabajo se plantea como el primer producto de **Peldaño**, una compañía ficticia de inteligencia artificial aplicada a la educación. La ficción es un requisito del módulo y conviene decir desde el principio **qué es ficticio y qué no**: la empresa lo es; el modelo, la aplicación desplegada, el corpus, las métricas y cada cifra de este documento, no. Todo lo que se afirma aquí está medido, y qué parte se puede además *reproducir* y cuál no está dicho sin adornos en el documento principal: con lo público —los pesos del v4 en Hugging Face, CLEAR, el catálogo de Project Gutenberg y el manifiesto de hashes de British Council— se rehacen la inferencia y la cadena entera del cuaderno; los guiones de verificación (`validar_local.py`, `tools/bajar_corpus_bc.py`, `entrenamiento_v4/`) no viajan con los entregables y se comparten a petición; y el corpus de British Council no se redistribuye, se reconstruye con su manifiesto.

Tres nombres para tres cosas. Peldaño es la compañía; **Pléyade** es su aplicación, el nombre que ve el lector desde el 26 de septiembre de 2026; y **LiteraLevel** es el nombre del proyecto y de su modelo (`literalevel-v4`). Los repositorios, los Spaces de Hugging Face y el paquete de Python lo conservan a propósito: renombrarlos habría roto los enlaces publicados y la descarga que hace el cuaderno. Una *pléyade* es un grupo de personas célebres de una misma época, sobre todo en las letras, y las Pléyades son un cúmulo de estrellas de Tauro: el nombre junta la literatura y el cielo, y el emblema —un pegaso sobre un libro abierto cuyas páginas son alas— lo dice en imagen.

El nombre de la compañía no es decorativo. En adquisición de segundas lenguas, la hipótesis del *input* comprensible sostiene que se aprende con material que está justo un escalón por encima de lo que uno ya domina (Krashen, 1985). Ese escalón es el peldaño, y encontrarlo es exactamente el problema que el lector no puede resolver solo.

El nicho. Peldaño no compite en el mercado general de aprendizaje de idiomas, que está saturado y lo dominan aplicaciones de repetición espaciada. Se sitúa en un hueco más estrecho y peor atendido: **la lectura extensiva en inglés para hispanohablantes que ya tienen base**, entre A2 y B2. Es el tramo donde el estudiante ya no cabe en el material graduado, todavía no aguanta una novela sin ayuda, y abandona. El apartado 5 documenta contra quién se compite y dónde se pierde.

La propuesta de valor, en una frase. Convertir una biblioteca gratuita e inabarcable —Project Gutenberg— en una estantería personal ordenada por lo que cada lector puede leer hoy.

Cómo se sostendría. La pregunta de negocio no es cómo cobrar por el modelo, que es pequeño y replicable, sino quién paga la parte cara. Medido en este proyecto: **medir un libro, leerlo, buscar y consultar el diccionario no cuestan nada** —corren en local sobre datos abiertos—, y solo tres acciones salen a un servicio externo de pago: explicar una palabra en su frase, resumir un libro y corregir la

pronunciación. Esa separación, que en la aplicación es una puerta de acceso con cupo por perfil, es también la frontera natural entre un nivel gratuito y uno de pago, y no hubo que diseñarla: salió de medir qué costaba cada cosa.

El cliente institucional —el docente de inglés del apartado 2.3— es el que justificaría una tarifa, porque su necesidad no es leer sino *asignar*: repartir lecturas de dificultad medida, y medida capítulo a capítulo, sin tener que leerse cuarenta libros antes. Conviene decir qué es esto y qué no: hoy el producto **no hace seguimiento de alumnos**, ni puede hacerlo tal como está construido —los datos de cada lector se guardan separados y no se comparten—, y la declaración de alcance del documento principal descarta expresamente usar esta medida para decisiones con consecuencias para el evaluado. El producto que hay sirve al docente para *elegir textos*; un panel de seguimiento sería otro producto.

Lo que Peldaño no promete. No promete enseñar inglés, ni certificar un nivel, ni sustituir a un profesor. Mide la dificultad de un texto en una escala propia de 0 a 2 y la pone al lado del nivel estimado del lector. Las limitaciones del documento principal enumeran los límites de esa medida, y la aplicación los dice en pantalla en vez de esconderlos.

---

1. La apuesta, en un párrafo

La lectura extensiva es uno de los métodos con más respaldo para aprender una segunda lengua (Nakanishi, 2015), y sin embargo casi nadie la practica bien, porque elegir el libro adecuado es un problema que el lector no puede resolver solo. Pléyade convierte una medida continua de dificultad —producida por un modelo que lee el texto entero, no la portada— en tres decisiones cotidianas: **qué leer ahora**, **por dónde se va a complicar** y **qué significa esta palabra en esta frase**. El activo defendible no es el modelo, que es pequeño y replicable: es la cadena completa desde el corpus hasta el pulgar de una persona de quince años en un teléfono.

---

2. Descripción de usuarios

Tres perfiles, con lo que cada uno necesita y con lo que hoy hace en su lugar. No son personas inventadas para rellenar: el primero está observado directamente (apartado 3) y los otros dos se derivan de las peticiones reales recogidas durante el desarrollo.

2.1 Usuaria primaria — la estudiante de preparatoria

Perfil. 14 a 18 años. Estudia inglés en la escuela, entiende bastante más de lo que cree, no sabe qué es el MCER y no le interesa. Entra desde el teléfono, casi siempre en vertical, y en pantallas de unos 390 px de ancho. Su tolerancia a la fricción es de segundos.

Qué necesita.

Necesidad	Cómo se atiende
Saber por dónde empezar sin sentirse examinada	Seis pasos, uno por pantalla: tres preguntas sobre hábitos observables —con qué frecuencia lee, si ha terminado un libro entero, qué puede contar de una página que acaba de leer—, intercaladas con los tres fragmentos de la fila siguiente, y **cero jerga gramatical**

Necesidad	Cómo se atiende
Juzgarse ante algo real y no ante una descripción	Tres fragmentos literarios en escalera (*Alice*, Sherlock Holmes, *Frankenstein*), pintados con la tipografía del lector para que se lean como un libro y no como un formulario. Pesan 0,65 en el cálculo del nivel: delante de un texto real la gente se juzga mejor que describiéndose
Que le propongan algo, no una biblioteca	La pestaña «A mi nivel» de *Encontrar*, que propone lecturas sin escribir nada
Poder usarlo con el pulgar	Objetivos táctiles de 44 px, controles repartidos en filas que caben en 390 px, mandos de navegación también debajo del texto
No perderse	Al terminar el cuestionario, un enlace que salta directamente al buscador **con la recomendación ya hecha**

Qué hace hoy en su lugar: elige por portada o por título conocido, abandona a las tres páginas y concluye que el problema es ella.

2.2 Usuario secundario — el adulto autodidacta

Perfil. 25 a 55 años. Ya lee en inglés con esfuerzo. Su problema no es empezar, es **subir de escalón sin abandonar**. Tiene libros a medias y no recuerda por dónde iba en ninguno.

Qué necesita.

- **Continuidad.** *Mi espacio* («Donde lo dejaste») guarda cada libro empezado con su barra de avance y el capítulo por el que iba, y lo reabre exactamente ahí. Es la petición literal que originó el módulo: *«un apartado con mis libros, los que estoy leyendo, que se queden guardados, en qué partes voy»*.
- **Saber a qué se enfrenta antes de comprometerse.** La ficha del libro dice cuánto tarda en leerlo **a 180 o 110 palabras por minuto** según le quede por debajo o por encima de su nivel, cuánto es diálogo y qué palabras se repiten, todo contado sobre el fichero.
- **Vocabulario que persista.** «Mis palabras» guarda cada consulta con su frase y su libro, que es la unidad que sirve para recordar. Deliberadamente **no hay puntos ni rachas**: la evidencia sobre recompensas externas (Deci, Koestner & Ryan, 1999) indica que premiar una actividad que ya gusta la deteriora, y leer ya es gratificante.
- **Pronunciación.** Lee bien y suena mal, y nadie se lo corrige. La aplicación marca palabra por palabra qué sonó bien y qué no.

2.3 Usuario institucional — el docente de inglés

Perfil. Da clase a grupos heterogéneos y necesita repartir lecturas graduadas. No puede leerse cuarenta libros para clasificarlos.

Qué necesita.

- Un catálogo **medido**, no etiquetado a ojo, con la dificultad por capítulo para poder asignar fragmentos y no obras completas.
- Una declaración honesta de lo que la herramienta no es, para poder usarla sin incurrir en una promesa que no puede cumplir: **Pléyade no certifica ningún nivel del MCER**.
- Reproducibilidad: poder comprobar de dónde salen los números.

Este perfil es el que justifica dos decisiones que a un usuario final le dan igual: publicar el guion de validación y mantener el aviso de alcance visible.

---

3. El ciclo de usuario real: Esmeralda

La única prueba que vale es la que hace alguien que no sabe dónde hay que pulsar. **Esmeralda, 15 años, estudiante de preparatoria**, prima del autor, fue la primera persona ajena al proyecto que usó la aplicación. Lo que dijo, sin edulcorar:

> *«Está bien difícil de usar en celular.»* — ¿Qué parte? — *«Casi todo.»*
>
> *«No me gustan los colores… la página se siente antigua, todo muy recto, muy marcado.»*
>
> *«¿Qué es eso de 10?»*
>
> *«O yo soy muy tonta para esto.»*

La cuarta frase es la importante, y es la que ordena todo lo que vino después. **Cuando un usuario concluye que el tonto es él, el fallo es del diseño.** Krug (2014) formula la misma idea como regla de producto: si el usuario tiene que pensar para entender un control, el control está mal. A partir de ahí se diagnosticó qué producía cada queja y se corrigió.

3.1 Diagnóstico y corrección

Lo que dijo	Diagnóstico	Corrección	Verificación
«¿Qué es eso de 10?»	La etiqueta «Resultados» junto a un número no dice qué cuenta	«¿Cuántos te propongo?», con explicación	Etiqueta reescrita
Creyó que «Recomiéndame por nivel» tendría en cuenta sus gustos	La etiqueta prometía más de lo que hacía	«Sorpréndeme con algo de mi nivel»	Etiqueta reescrita
—	«Ajustar a mi nivel» es abstracto	«Acercar los resultados a mi nivel · no descarta libros»	Etiqueta reescrita **dos veces**: la primera versión, «Solo libros que pueda leer», prometía un filtro que la búsqueda no hace
—	«Medir la dificultad de este capítulo» es lenguaje de laboratorio	«¿Cómo de difícil es este capítulo?»	Etiqueta reescrita
—	«Vistazo rápido a la dificultad» no dice cuánto tarda	«Vistazo rápido (unos segundos)»	Etiqueta reescrita
—	«Analizar el libro entero» no advierte del coste	«Leer el libro entero (tarda más)»	Etiqueta reescrita

Lo que dijo	Diagnóstico	Corrección	Verificación
«No me gustan los colores»	El color es gusto, y el gusto no se discute: se ofrece	**Cinco paletas** con pestaña propia y cambio instantáneo: *hielo* (la original), *amanecer* (clara, crema y naranja), *menta*, *papel* (para leer horas) y *medianoche*	Una prueba automática comprueba las cinco contra el criterio de contraste **WCAG AA (4,5:1)**. Las cinco pasan en las **ochenta y cinco parejas** de color que se comprueban —diecisiete por paleta, cada una con su umbral: 4,5:1 para el texto normal y 3:1 para el título grande—. La más ajustada del texto normal mide **4,53** y la del título, **3,11**
«Todo muy recto, muy marcado»	Esto no es gusto, es diseño, y se corrige para todas las paletas	Esquinas de 14 px, bordes finos, sombras suaves y las opciones de lista como fichas tocables	—
«Difícil de usar en celular… casi todo»	En un móvil, el círculo de un botón de radio es un blanco de 12 px	La ficha entera pasa a ser el blanco: **44 px**	—

Cuadro 1. Del comentario de una usuaria a un cambio verificable.

3.2 Lo que ya se había corregido antes, por la misma vía

El ciclo de Esmeralda no fue el primero. Probar la aplicación en un teléfono real —y no en el navegador del escritorio— había descubierto antes fallos que **ninguna de las 303 pruebas automáticas podía encontrar, porque todos necesitaban un dedo y una pantalla pequeña**:

- El doble toque para consultar una palabra **no funcionaba en el móvil**: el código escuchaba solo el evento del ratón, que iOS no emite al seleccionar con el dedo. La instrucción en pantalla prometía algo que el dispositivo no hacía. Hoy la palabra se consulta manteniéndola presionada —con ratón, doble clic — y el lector lee la selección, que en iOS llega por `selectionchange`.
- Los títulos de la tabla de resultados eran enlaces a `gutenberg.org`, así que tocarlos **sacaba al lector fuera de la aplicación**.
- El resultado del nivel se pintaba en la parte superior de la página, fuera de la pantalla: la usuaria no se enteraba de que había terminado.
- Al pedir «traer una frase del capítulo» sin frase disponible, el campo se vaciaba y **borraba lo que el usuario había escrito**, sin decir nada.
- «Mis libros» mostraba 24 entradas llamadas `vacio.txt`, `falso.txt` y similares: la batería de pruebas anotaba sus ficheros de ataque en la biblioteca **real** de quien las ejecutara. Los datos personales del usuario eran el banco de pruebas.

3.3 El segundo ciclo: Laura

El 12 de septiembre de 2026 la probó **Laura**, hermana del autor y desarrolladora web, sobre la aplicación **desplegada**: primero en la laptop y después en su teléfono Android. Mandó tres capturas y dos notas de voz, que se transcribieron y se conservan íntegras en `auditoria/feedback_laura_2026-09-12.md`. Su crítica es de usuaria y de diseñadora a la vez:

> *«Hago el movimiento de deslizar con el dedo y dos, tres segundos y la página se empieza a mover.»*

> *«No dejas un espacio entre el cuadro y lo que escribes… se come el palito de la P.»*
>
> *«Doy a siguiente capítulo y me deja ahí mismo abajo.»*
>
> *«Lo que pones en los tres circulitos son configuraciones, no son funcionalidades.»*
>
> *«No entiendo el sonido W que es diferente a la letra B.»*

Lo que dijo	Diagnóstico	Corrección	Verificación
Retraso de 2-3 s al deslizar en el teléfono	`backdrop-filter` en más de cien bloques y fondo con `background-attachment: fixed`: repintado completo en cada fotograma	Los dos efectos, solo en dispositivos con ratón	Con emulación táctil quedan desactivados; **falta confirmarlo en un teléfono real**
El texto toca el borde redondeado	Los bloques de Markdown de la interfaz de entonces (Gradio) no tienen relleno, pero aquí todos llevan fondo de panel	Relleno interior a los bloques con contenido	Medido y capturado a 390 y 1440 px
En modo oscuro no distingue las secciones	Panel al 72 % sobre casi negro y borde al 16 % en *hielo*, la paleta por defecto	Panel y borde más claros en las dos paletas oscuras	Las 85 parejas de contraste WCAG siguen pasando
Quiere una barra de navegación con las funciones y los ajustes aparte	*Colores* y *Estado* eran pestañas como leer o pronunciar. **El profesor había dicho lo mismo**: «Colores toma demasiada presencia»	Botón ⚙ **Ajustes** en la cabecera; barra de pestañas fija arriba al bajar y centrada en escritorio	Probado en el navegador; a 390 px «Pronunciar» sigue en el menú «…»
«Siguiente capítulo» la deja al final	Los botones no movían la página	Al cambiar de capítulo sube al principio del texto	Teléfono: el lector queda justo bajo la barra con el capítulo nuevo
Borrar a mano la frase para practicar otra	No había forma de empezar de nuevo	Botón **«Otra frase ↺»** bajo la corrección	Probado en el navegador
No entiende «/w/ diferente a la b» y pide «los símbolos»	La explicación comparaba con una letra, no enseñaba el AFI y ni siquiera sabía qué se había oído	Explicación anclada a palabras del español y a lo que se entendió; símbolo AFI; transcripción de la palabra sacada del diccionario local; 41 audios pregrabados, uno por fonema, que no gastan créditos (≈ 0,19 USD una sola vez)	Probada de punta a punta con un audio que dice «fix» por «fox»: ahora culpa a la vocal y no a la /f/. **Los audios aún no los ha escuchado nadie**
Captura: «don’t» marcado como «don» y «t»	El apóstrofo tipográfico de los libros partía la contracción	Se normaliza antes de comparar	Dos pruebas nuevas
Captura: «Tolstoy, Leo, graf»	El título nobiliario de Gutenberg se tomaba por parte del nombre	El autor corto se queda con apellido y nombre	Prueba nueva

Cuadro 1b. El segundo ciclo, de la crítica a la verificación.

Dos de las correcciones fallaron la primera vez, y las 306 pruebas automáticas no lo vieron. La primera versión del arreglo del lector sacaba la cabecera del libro letra a letra. La del botón de siguiente capítulo no movía nada, porque el texto nuevo llega después y los botones que pulsó Laura eran los de debajo del texto. Las dos se descubrieron midiendo la página en un navegador controlado a ancho de teléfono. Es la misma lección del apartado 3.2, repetida.

Lo que vino después de ese ciclo cambió la interfaz entera. Ese mismo 12 de septiembre, en la revisión del avance, el profesor Barranco pidió que la aplicación entregada no fuera la de Gradio sino un front propio, separado del motor. La interfaz pasó a Angular sobre una API (apartado 4.6). Las correcciones del Cuadro 1b se hicieron primero en Gradio, que sigue en marcha como motor, y las que tocan la pantalla se llevaron al front: los ajustes fuera de la navegación, el lector que sube al cambiar de capítulo, «Otra frase» y la ficha de cada sonido.

3.4 El tercer ciclo: Ismael, y una segunda nota de Laura

Los días 14 y 15 de septiembre de 2026 la probó **Ismael**, hermano del autor, que abrió en un teléfono Android el enlace que le mandaron por WhatsApp, sin que nadie le explicara nada y —según Miguel, que habló con él; no es algo que hayamos medido— sin haber iniciado sesión. Su nota de voz:

> *«Cuesta un poquito entenderle… le falta hacerla más intuitiva, o a lo mejor unos cuadros de diálogo que te diga qué hace cada cosa.»*

Por esos mismos días llegó una segunda nota, esta vez de **Laura**, que ya había probado la aplicación en septiembre (apartado 3.3) y que en esta ocasión **sí había entrado con su cuenta**:

> *«Entré y ya inicié sesión, pero le pisas al micrófono y no te dice que hables, no se activa la grabación… a lo mejor no tan saturada la página, los textos están largos y tienes que hacerle scroll, y te pierdes, no sabes qué hacer.»*

Lo que dijo	Diagnóstico	Corrección	Verificación
«Le falta hacerla más intuitiva… unos cuadros de diálogo que te diga qué hace cada cosa»	Recorrido a 390 px sin cuenta: «Entrar» abría *Ajustes* por arriba y «Tu perfil» quedaba fuera de la pantalla; el botón de la cabecera era un icono sin texto; y la tarjeta «Mídeme» prometía una estimación desde la primera pregunta que ya no ocurre	**Primera tanda:** «Entrar» abre «Tu perfil» con el cursor en «Usuario», el botón dice **Ajustes** y «Mídeme» pierde la promesa. **Tercera tanda:** bienvenida de tres pasos la primera vez en Inicio, con «Saltar» y «Ver la bienvenida otra vez» en *Ajustes*	5 pruebas de `entrar-perfil` y 6 de `bienvenida` en el front; recorrido en el navegador a 390 px

Lo que dijo	Diagnóstico	Corrección	Verificación
«Le pisas al micrófono y no te dice que hables, no se activa la grabación» *(Laura, con su cuenta ya iniciada)*	**Un fallo medido y corregido, y un caso que sigue abierto.** Al investigar la queja apareció un fallo real y medido: en el front anterior, el aviso de error del micrófono y el «Grabando…» se pintaban **debajo de la barra fija** —y de 750 a 849, con la barra empezando en 687—, así que no se veían. Laura había entrado, así que no era falta de cuenta, y en el teléfono de Miguel, con cuenta, el micrófono graba bien (16 de septiembre), así que tampoco es un fallo general de la aplicación: queda abierto en qué teléfono o navegador ocurrió, y que fuera el navegador interno de WhatsApp es una **hipótesis**, no algo comprobado	Una línea de estado **dentro** de la barra, con un mensaje por caso —«Grabando: habla ahora», permiso pendiente, permiso negado, sin micrófono, micrófono ocupado, sin frase— (`601788b`). El aviso para el WebView de Android se queda como precaución, no como explicación de este caso	11 pruebas de `pronunciar.microfono` y el navegador a 390 px. Comprobado además en lo publicado entonces (revisión `48d748d` del Space, del commit `940c275`) a 390×844: la línea va dentro de la barra, acaba en 688 y se lee sin desplazar en los cinco finales de pulsar —el del permiso pendiente, en dos momentos —, ninguno de ellos mudo (e6, `auditoria/microfono_casos_a_b_2026-09-16.md`). **Queda abierto en qué teléfono y navegador ocurrió**: en el de Miguel, con cuenta, graba bien
«No tan saturada la página, los textos están largos… te pierdes» *(Laura)*	Medido a 390 px: el lector enseñaba dos avisos a la vez y dejaba ver unas dos líneas del libro, y *Pronunciar* ponía 46 palabras antes de la caja de la frase	**Segunda tanda:** un solo aviso en el lector —«Mantén presionada una palabra para ver qué significa; desliza para cambiar de página.»— y, en *Pronunciar*, una línea de ayuda en lugar del subtítulo; las dos se cierran con ✕ y vuelven con «?»	Comprobado en el front publicado a 390 px táctil el 15 de septiembre

Cuadro 1c. El tercer ciclo, de la nota de voz al código publicado.

La lección de este ciclo es que la atribución también es un dato. La nota del micrófono se contó primero como de Ismael y sin sesión, y de ahí salió una causa —el navegador interno con el que WhatsApp abre los enlaces— que no se sostenía: la nota es de Laura y ella había entrado. Lo medido no cambia: los avisos del micrófono se pintaban bajo la barra fija y no se veían, que es exactamente por qué al pulsar no parecía pasar nada, y eso está corregido en `601788b`, y comprobado en lo publicado entonces —revisión `48d748d` del Space, del commit `940c275`—: los cinco finales de pulsar enseñan un mensaje visible dentro de la barra. Lo que queda abierto es dónde ocurrió, porque en el teléfono de Miguel, con cuenta, el micrófono graba bien. Caben tres explicaciones, ninguna comprobada: que la nota sea anterior al arreglo, que el mensaje saliera y no se leyera —es una línea fina encima del botón— o que el fallo esté después del permiso, en `MediaRecorder`. Y de los sitios donde se midió saturación queda sin tocar el índice de la ficha, a casi dos pantallas del principio.

Y de medir esa pantalla salió un fallo distinto del que ella describía. Al recorrer *Pronunciar* a 390 px sin sesión apareció el único «pulso y no pasa nada» **comprobado** de la aplicación, y no era el micrófono: «Corrígeme» iba apagado, sin explicación al alcance —la razón quedaba 309 px más arriba— y pulsarlo no contestaba nada. Desde el 16 de septiembre el botón se pulsa (704–768) y contesta dentro de la barra, en 625–696, con el atributo `role` en `alert`, unos 71 px y hasta cuatro líneas contando el «Entrar», ochenta por encima de la navegación. El panel de *Ajustes* ya no se abre solo, que era lo que tapaba el propio aviso: `elementFromPoint` sobre él devuelve ahora el aviso, y el panel se abre solo si el lector pulsa «Entrar». Publicado en la revisión `9b4a3b5` del Space, del commit `a1c4268`, y comprobado desde lo servido.

3.5 La lección, en una línea

El valor de una prueba de usuario no está en el promedio de satisfacción, sino en la frase que duele. Con n = 3 no se puede estimar nada, pero se pueden encontrar los fallos que hacen que una persona se culpe a sí misma, y ya hay una coincidencia: a los tres les costó el teléfono, y a las dos lectoras no les gustó la paleta por defecto. Nielsen (2000) sitúa en cinco usuarios el punto donde se detecta la mayor parte de los problemas de usabilidad; el accionable A8 lleva la prueba hasta ahí.

---

4. Usabilidad del modelo

Un modelo es usable cuando el usuario puede confiar en él sin entenderlo. Eso se construye con cinco decisiones, todas medidas, y con la interfaz que las pone delante del lector (4.6).

4.1 La espera se traslada, no se pide

Medir un libro largo son minutos. Pedirle esos minutos al lector en el momento en que quiere leer es perderlo. La estrategia es **mover el cómputo antes de la consulta**: el catálogo se precalcula fuera de línea y, cuando el lector busca, el trabajo ya está hecho. Los números que hacen viable esa decisión están en el Cuadro 21 del PDF —el 16 de la copia de lectura—: 8,19 ventanas/s en CPU, 112,7 en la GPU local y **2.022 en una A100**, con lo que los 61.642 libros en inglés de Project Gutenberg son **unas tres horas** de cómputo puro. De extremo a extremo son **unas diecisiete**, y la diferencia no la pone la tarjeta sino el disco. **Y se hizo**: el 12 de septiembre de 2026 quedaron medidos 53.179 libros y 585.111 capítulos, en tandas reanudables que guardaban en Drive y, desde el 12, en Hugging Face: hasta el 10 de septiembre en una A100 de pago de Colab Pro, y desde entonces en una T4 gratuita; la última, 9.795 libros, tardó 55 minutos.

Cuando el cómputo sí tiene que ocurrir en vivo, se ofrecen **dos velocidades y se dice cuál se usó**: un vistazo (30 capítulos repartidos, 2 ventanas de cada uno) o el libro entero sin muestrear. Y el atajo está cuantificado, no prometido: 8 ventanas dan **1,784** y el recorrido completo del mismo capítulo, **1,743**.

4.2 La incertidumbre se comunica en bandas

El modelo devuelve un número continuo, pero su escala está comprimida (`predicho ≈ 0,72 × real + 0,38`). Presentar «1,27 sobre 2» como si fueran dos decimales de precisión sería mentir con exactitud. La interfaz muestra **bandas** —básico < 0,6 ≤ intermedio < 1,4 ≤ avanzado, que son los cortes del propio MCER, y no los 0,8 y 1,6 de antes, que ni siquiera partían el 0–2 en tres partes iguales— y la letra MCER únicamente como orientación, siempre junto al número y con la tabla de correspondencia a la vista.

Un fallo real de esta decisión, encontrado y corregido, ilustra el nivel de cuidado que exige: el redondeo por defecto de Python resuelve los empates hacia el par, de modo que un 1,00 exacto caía en un nivel y la tabla publicada decía otro. Un usuario que comparase su cifra con la tabla habría encontrado dos respuestas para el mismo número. Ahora hay una sola regla, y una prueba fija los cinco límites.

4.3 Nada falla en silencio, y nada se rompe del todo

La regla transversal del sistema es la **degradación elegante**: sin clave de servicio externo, la aplicación sigue dando diccionario, fonética, buscador y puntuación, porque nada de eso sale a la red desde el servidor; el audio de Wiktionary es un enlace a `upload.wikimedia.org` que descarga el navegador del lector, así que necesita conexión pero no clave. Solo se apagan tres cosas —la explicación en contexto, la corrección de

pronunciación y el resumen de «¿de qué trata?» de la ficha—, y se dice con palabras que el lector entienda —«se ha agotado el presupuesto mensual de explicaciones; el diccionario, la fonética y el audio siguen funcionando»— en lugar del error técnico en crudo.

La regla de diseño es que los fallos vuelvan como texto legible en vez de excepciones sin tratar. Las pruebas cubren escenarios concretos; no demuestran que ningún manejador pueda fallar. El corte de verificación actual se distingue de las baterías históricas en el apartado 4.6.

4.4 Cada número dice de dónde viene

En la ficha del libro conviven dos clases de información y **la separación se ve en pantalla**: lo *contado* sobre el fichero (palabras, tiempo de lectura, proporción de diálogo, vocabulario) sale solo al abrirlo, es instantáneo y no necesita red; el *resumen* escrito por un modelo generativo va detrás de un botón, se guarda en disco y viene marcado como lo que es. **Ninguna cifra de la ficha la dice un modelo generativo.** En el diccionario, la regla equivalente: el modelo de lenguaje explica el contexto y la gramática sin sustituir una acepción utilizable de Wiktionary. Si no existe, desde el 13 de septiembre puede proponer una definición marcada como generada por IA, solo con acceso autorizado. La definición de diccionario y el texto generado no son lo mismo. Y si la elección entre acepciones es dudosa —menos de 0,05 de afinidad entre las dos más cercanas— y no hay explicación de OpenAI, desde `bf3a9f2` la ficha no afirma una: dice «Puede ser» y enseña la acepción principal de cada entrada del diccionario, si hay al menos dos.

4.5 La latencia se reparte para que la pantalla no se quede quieta

En una consulta léxica nueva, casi todo el tiempo es **espera al servicio externo**: la explicación contextual se midió en **14,9 segundos** con el esfuerzo de razonamiento `low` que usa la aplicación —eran 67,7 con el esfuerzo medio de antes—, mientras todo el trabajo local —lema, diccionario, desambiguación, fonética— son **40 milisegundos** de trabajo en el servidor; en el teléfono, con la red de por medio, la hoja tarda unos 0,7 s en caliente y unos 5 s la primera consulta de la sesión (medido el 15 de septiembre de 2026 a 390 px). Por eso la ficha se pinta en dos etapas: lo local aparece primero y la explicación se añade cuando llega. El trabajo tarda lo mismo; deja de parecer que la aplicación se colgó. La misma idea gobierna la curva de dificultad, que se repinta cada pocos capítulos mientras mide (el repintado cuesta 25 ms, medido) y los recursos pesados, que se cargan al primer uso y no al arrancar.

4.6 La interfaz entregada: un front de Angular sobre una API

Hasta el 12 de septiembre de 2026 la aplicación era una sola pieza: ocho pestañas de Gradio que hacían de interfaz y de motor a la vez. En la revisión del avance de ese día, el profesor Barranco pidió que la entrega fuera un front propio, separado del motor. Se hizo al día siguiente, y es lo que se entrega:

- **El front** es una aplicación de Angular 22 (componentes independientes, sin `zone.js`): HTML, CSS y JavaScript ya compilados, así que no se duerme. Desde el 26 de septiembre de 2026 se publica en **Vercel** (https://pleyade-app.vercel.app, plan gratuito), como pidió el profesor, y se vuelve a publicar sola con cada cambio de la rama principal del repositorio; el **Space estático** de Hugging Face (`MikeMaki1763/literalevel-front`) sirve la misma aplicación como respaldo. Tiene cinco sitios en vez de ocho pestañas —*Mi espacio*, *Leer*, *Encontrar*, *Pronunciar* y *Tu nivel*—, más *Mis palabras* y *Repasar*; los ajustes (tema, tamaño de letra, idioma de las explicaciones) y el estado del servicio salen de la navegación, que es lo que Laura y el profesor habían pedido por separado.
- **La API** es un servicio FastAPI (`app/api.py`, 44 rutas bajo `/api` a fecha de `06a16db`, el commit que publica el Space en su revisión `103eef5`) **montado en el mismo Space de Gradio** que ya existía, con Gradio en la raíz como motor y respaldo. **Reutiliza el motor y ayudantes de Gradio**, pero sus adaptadores contienen lógica propia: topes, cobro, aislamiento y degradación requieren pruebas también en la API.

Compartir funciones no basta para demostrar equivalencia. El inicio de sesión frena los intentos fallidos en una hora: 15 por IP y, desde `514786b`, 20 por usuario, porque la IP sale de una cabecera que puede escribir el cliente. Solo cuentan los que fallan, y son valores por defecto que se cambian por variable de entorno. Medir tampoco es ilimitado: cada medida ocupa la CPU del único proceso del Space, así que desde el 14 de septiembre hay topes por IP y hora —40 medidas de nivel o de capítulo y 6 curvas nuevas — y como mucho 4 curvas en cola a la vez; lo ya medido no gasta ficha. En el Space, en su revisión `2bb1276` (del commit `0ba8219`), la séptima curva seguida dio 429 y un libro ya medido siguió respondiendo. Lo mismo protege lo que cuesta dinero, con sus propios topes por hora y conexión: 10 correcciones de voz, 30 explicaciones en contexto, 6 resúmenes y 20 libros nuevos. **Y hay un dato que conviene contar, porque es el que enseña algo:** el propio autor se topó con uno de esos topes probando su aplicación, sin esperarlo. Un tope que no se anuncia se vive como una avería, y esa es la lección de usabilidad, no la cifra. **No se sube para la entrega**, porque protege la factura y la CPU del único proceso del Space; lo que se cambia después es **avisar antes de grabar**, y hoy no se puede porque el contador no se expone en la API. La identidad del lector viaja en una cabecera (`X-Lector`) y sus datos siguen en el bucket montado en `/data`. Desde el 26 de septiembre, quien entra con usuario y contraseña deja de ser un navegador: sus libros, sus palabras y su nivel pasan a ser **de la cuenta** (`cuentas/<nombre>` en el bucket) y se ven igual en el teléfono, la tableta o el equipo; sin cuenta siguen siendo de ese navegador. Salió de un caso real: con la misma cuenta, el teléfono y la tableta del autor enseñaban dos lectores distintos. El primer montaje falló —el proxy de renderizado en servidor de Gradio no dejaba pasar `/api`— y el segundo, sin ese proxy, es el que está en marcha.

- **Regla de entrega:** una función existe cuando tiene ruta en la API **y** pantalla en el front. Lo que solo vive en Gradio no cuenta como entregado.
- **Verificación del 13 de septiembre, corte actualizado el 14:** 32 de 35 pruebas API pasaron en el entorno aislado; tres quedaron sin validar por dependencias NLP ausentes. Pasaron además 7 pruebas de concurrencia de voz, 10 del despliegue y 11 del pipeline de portadas. No se suman como una prueba completa de usuario ni sustituyen la batería histórica del motor. El backend publicado —revisión `e56cf08` del Space, subida selectiva de `app/api.py` y `app/voz.py` desde `a87caa8` y `71e4b52` (anterior a que el script exigiera commit)— se cotejó por hash y se comprobó salud JSON, lectura de Alicia en Angular, diccionario sin perfil y rechazo de voz anónima. No se probó OpenAI real ni micrófono físico en ese cierre. Evidencia: `auditoria/despliegue_codex_2026-09-13_noche.md`. Recuento sin claves del 15 de septiembre sobre el árbol del despliegue `0319290` (`1643c4b`, cada suite corrida sola): 66 de 66 pruebas API, 351 pruebas extremas sin ningún fallo y 48 de 48 de corpus (`DESPLIEGUE.md`). Las 34 de 34 de lectura natural son del corte anterior, `d58b0be`. La última publicación de la API (26 de septiembre, revisión `103eef5` del Space, del commit `06a16db`) pasó 70 de 70 pruebas API, las extremas sin fallos y 464 de 464 del front; en vivo, la misma cuenta entró desde dos aparatos nuevos y los dos vieron los mismos datos (`DESPLIEGUE.md`).

Lo que el front añadió a la usabilidad en un día. Tres cosas, y las tres salieron de mirar cómo se usa un teléfono:

- **Uso con una sola mano.** Un estudio propio (`investigacion/una_mano.md`) fijó diez reglas a partir de la literatura sobre el alcance del pulgar y el tamaño de los objetivos; las primeras ya están en el front: en el lector, una barra única abajo con capítulo y página anterior y siguiente y el índice, que se esconde con la navegación; nada primario en el cuarto superior de la pantalla; en *Pronunciar*, una barra de acción fija abajo con el micrófono en el centro, que no se mueve entre grabar, parar y corregir.
- **Corrección de pronunciación con fonema determinista.** Con la misma grabación, el modelo generativo señalaba un sonido distinto en cada llamada. Ahora el fonema que falla sale de **alinear la transcripción de lo que había que decir con la de lo que se entendió** —las dos de diccionario: Wiktionary y, donde no la trae, CMUdict (Carnegie Mellon University, s. f.), 126.052 palabras bajo

licencia BSD— y el consejo de boca, lengua y aire sale de una ficha fija por fonema. Del modelo queda el resumen. La selección del fonema es determinista dadas las mismas palabras y transcripciones; esto no hace determinista al reconocimiento de voz.

- **Animación del corte de la boca.** Para cada uno de los 41 sonidos del inglés americano (y los 44 del británico), un corte sagital animado —labios, dientes, paladar, velo, lengua y mandíbula— que va del reposo a la posición del sonido y vuelve; y para la palabra entera, la secuencia de sus sonidos a partir de su transcripción. Son SVG animados con CSS, sin JavaScript, generados una vez en el servidor y servidos por la API; el front los enseña en la ficha de cada sonido y en la corrección —primero el sonido que falla y después la palabra—, y con «reducir movimiento» del sistema los deja quietos.

Boca 3D, a 26 de septiembre de 2026. En *Pronunciar*, junto al corte 2D, hay una boca 3D didáctica que se descarga solo al abrirla, con el corte 2D de respaldo si no carga. La cabeza parte de un escaneo publicado bajo CC BY 3.0 —*Infinite, 3D Head Scan*, de Lee Perry-Smith (Perry-Smith, s. f.)—, cuya atribución se sirve con el modelo; los labios, la lengua, el corte anatómico y los materiales son adaptación propia en Blender. Enseña el aire y la vibración de cada sonido, lee palabras y frases al compás del audio, y tiene zoom, cámara lenta («Despacio») y giro libre («Explorar»). El 26 de septiembre sus texturas pasaron a WebP y lo que baja por la red se quedó en 1,7 MB en vez de 3,5 (commit `1f5f2c9`). Es un corte esquemático, no anatomía validada clínicamente. Las portadas publicadas son **tipográficas**: una de 12 familias según los temas del catálogo, con una paleta de cinco colores sacada de la huella del identificador y el título a un contraste de al menos 4,5:1. El lector toma el fondo y el acento de esa paleta, con el texto a 7:1 o más y el acento a 4,5:1 sobre el fondo (sobre el color suave del acento, la pista del lector baja a 4,17:1 en algunos libros en tema claro, como SWV369), y el ajuste «Color del libro en el lector» lo apaga; la prueba del front que fija esos contrastes recorre 12 familias, 200 libros y dos temas (`b2003e5`). El pipeline de portadas FLUX está bloqueado por defecto; no generó imágenes nuevas ni consumió GPU. Sus 1.200 candidatos tienen 746 motivos temáticos y 454 genéricos, pendientes de muestra y revisión visual.

Lectura natural, medida con diez frases. En *Pronunciar*, además del sonido que falla, la aplicación mide el ritmo de la lectura y enseña cómo se dice la frase de corrido: énfasis, enlaces entre palabras y reducciones (*want to* → *wanna*). Lo propone un modelo generativo y lo filtra un validador: las reducciones solo salen de una lista cerrada y los enlaces se comprueban con la pronunciación de diccionario. Con diez frases reales del catálogo evaluadas a mano (`auditoria/bateria_lectura_natural_2026-09-14.md`), el modelo propuso 11 reducciones y 29 enlaces; llegaron al lector 2 reducciones y 4 enlaces, **todos correctos**, y las diez versiones naturales quedaron fieles a la frase (8 reconstruidas por el validador). La exhaustividad es baja: se quedan fuera enlaces claros como *an argument*. En esa batería todo lo que llegó al lector era correcto, y eso no es una garantía: desde el 15 de septiembre el validador exige además un verbo detrás de *gonna*, *wanna* o *gotta* (antes aceptaba «I am gonna school» si el modelo lo proponía) y no enlaza a través de un punto. La frase de la demostración, «Don't you want to come with us?», da en el Space, en su revisión `7c09d90`, las reducciones *doncha* y *wanna*, marcadas como generadas por IA, y ningún enlace. Esa comprobación es anterior a la pantalla de hoy, donde la lectura natural va plegada bajo «Para sonar más natural»; como la propone un modelo generativo, la respuesta puede cambiar, y el guion de la demostración la vuelve a comprobar con cuenta antes de enseñarla.

Primeros usuarios. Desde el 14 de septiembre hay cuentas repartidas a los primeros usuarios (`auditoria/feedback_usuarios_2026-09-14.md`), y la primera respuesta ya enseñó un fallo: una lectora B1 buscó libros de amor y encontró pocos. No faltaban en el catálogo; fallaba la búsqueda. En la franja que la aplicación da a un lector B1 (dificultad de 0,35 a 1,25) hay 114 textos libres con *love* o *romance* en el título, frente a 4 libros de Gutenberg (recuento sobre el catálogo que carga la aplicación, `auditoria/ronda1_consolidado_2026-09-14.md`); pero la búsqueda devolvía los más parecidos de todo el catálogo, y con «amor» o «Historias de amor» y nivel B1 los 24 primeros eran de Gutenberg, sin ninguno de esos cuentos. Desde el reinicio 25 (15 de septiembre), detrás de esos resultados van hasta 12 textos de la franja del

lector que se parecen a lo buscado: con «amor» y nivel B1 se marcan 12, y 8 llevan el amor en el título. En *Encontrar*, contados a mano, unos 7 de los resultados de «Historias de amor» que caen en el nivel del lector o un poco por encima son de amor, en sentido amplio. Recontado el 15 de septiembre con el catálogo que carga la aplicación y con el Space publicado (`auditoria/chips_reinicio25_2026-09-15.md`).

Límites de la búsqueda, declarados. Tres quedan sin cambio de código porque los arreglos probados estropeaban más búsquedas de las que salvaban (medido el 15 de septiembre sobre el Space del reinicio 28, `DESPLIEGUE.md`). Con perfil, un autor buscado por una sola palabra trae cuentos sin relación: con 1,20, «dostoyevski» marca 15 textos en la franja y «tolstoy», «cervantes» y «oscar wilde», 12, porque el modelo de parecido acerca a «historias de X» y «libros sobre X» títulos de misterio, bestias o fantasía; con título y autor, «Crimen y castigo de Dostoyevski» da 0. En las consultas de varias palabras el título pesa demasiado: «Historias de amor» marca cuentos titulados «My stories», y solo unos 5 (A2) y 7 (B1) de sus resultados son de amor. Y con una sola palabra sube un título que solo la contiene: «rosa» trae «The Water Supply of the El Paso…» y «luna», con B1, «Luna, The Rajapalayam Puppy».

El enlace del lector es https://pleyade-app.vercel.app, y el de respaldo, https://mikemaki1763-literalevel-front.static.hf.space/ .

Lo añadido entre el 16 y el 26 de septiembre. Todo está publicado y registrado en `DESPLIEGUE.md`:

- **Mi espacio**, la pantalla de inicio y primera pestaña: los libros empezados, las palabras pendientes de practicar y *Mi progreso*, que enseña las palabras consultadas por día en las dos últimas semanas y los resultados de los últimos repasos, con las cifras siempre a la vista y sin gráficas en cero cuando todavía no hay datos. **Repasar** enseña hasta cinco palabras guardadas: el lector intenta recordarlas, ve la respuesta y dice si la sabía, dudó o no, y eso se guarda.
- **Leer en voz alta, en vivo.** En el lector, la aplicación escucha mientras se lee un pasaje y marca en el texto las palabras leídas, la actual y las saltadas; al terminar da un resumen con el ritmo. Usa un servicio de transcripción en tiempo real de pago, así que pide cuenta, gasta un uso por sesión y se corta a los tres minutos. Está probado de extremo a extremo con una lectura sintética; con la voz real de un lector, pendiente.
- **La boca 3D didáctica** y **los datos por cuenta**, descritos arriba. La boca se mueve con un segundo modelo, aprendido de vídeos de caras reales, que se describe en el apartado 7.8 del documento principal.
- **Eos en Pronunciar.** Desde el 28 de septiembre hay 85 sonidos pregrabados con la cara de frente. Las frases nuevas dependen de un trabajador en esta PC; si no responde, queda disponible la boca 3D didáctica. Su utilidad para aprender todavía no se ha medido con lectores (documento, apartado 7.9).
- **La marca Pléyade**: nombre, emblema, un texto «Sobre Pléyade» que se abre al pulsar el logo, y un fondo de galaxia en todas las pantallas, con cada una sobre una lámina translúcida de su tema (claro, noche o papel). **El contraste de este tema sobre la galaxia no se ha medido**: las pruebas de contraste del front cubren las portadas y el lector teñido, no el fondo.

Las capturas de la interfaz hasta el 26 de septiembre están en `capturas/`, con su procedencia en `capturas/registro.txt`; no documentan Eos, publicada después.

---

5. Contra quién compite esto

Un proyecto que no sabe contra qué compite no puede decir qué aporta. Esta sección responde a tres preguntas incómodas: si alguien ya lo hace, si lo hace mejor, y qué queda entonces para nosotros.

5.1 Las tres alternativas reales

Las fórmulas clásicas —Flesch, Dale-Chall, ATOS— son gratis, instantáneas e interpretables al cien por cien, y llevan setenta años en las aulas. Su límite está medido: alcanzan **Pearson 0,517** contra el juicio humano en el corpus CLEAR, donde el modelo de este proyecto llega a **0,89**. Cuentan sílabas; no leen.

Lexile es el competidor comercial serio y hay que reconocerle lo que tiene: una escala validada durante treinta años, cientos de miles de títulos medidos, integración con bibliotecas y pruebas oficiales, y algo que aquí solo se aproxima —una escala común que compara al lector con el texto—. **Su medida la acepta un colegio; la nuestra no.** Lo que no tiene es precio accesible. Su tarifa publicada para creadores de contenido (MetaMetrics, 2026) va de **3.824 a 54.636 USD al año** según el volumen, y los 53.179 libros del catálogo medido caen en el tramo más alto.

Medirlos aquí **sí usó cómputo de pago**, sin cifra en dólares que dar porque no quedó registrado cuántas unidades se gastaron: hasta el 10 de septiembre de 2026 el cuaderno de Colab corría en una A100 con unidades de la cuenta Colab Pro, y hasta esa tarde se midieron 27.776 libros (los 29.875 medidos el 10 menos los 2.099 de la primera tanda en T4). Desde entonces se midió en una T4 gratuita, en tandas reanudables —la última, 9.795 libros en 55 minutos—, y los textos libres en la CPU local. Las «2,8 h de A100» del registro son la estimación de tarjeta para los 61.642 libros, no horas gastadas. Al ritmo medido en la A100, 61 libros por minuto, los 53.179 habrían sido **unas catorce horas y media de reloj**. **No es una razón monetaria estricta** —una licencia anual y unas horas de cómputo no se dividen la una por la otra— y tampoco son servicios equivalentes: Lexile vende una escala aceptada por instituciones, no solo un número. Lo que sí se puede afirmar es que **el coste de procesamiento está en otro orden de magnitud**, y que eso es lo que hace viable medir un catálogo entero en un trabajo de estudiante.

Un LLM con un buen prompt es la alternativa que todo el mundo propone hoy. La evidencia publicada apunta a que un codificador afinado le lleva ventaja en esta tarea: sobre CLEAR, el mejor método *zero-shot* documentado alcanza **0,725** (Grossman y Chen, 2026; n = 1.890, diez modelos abiertos), y este proyecto mide **0,89** en el mismo corpus. Kogan et al. (2025) encontraron algo parecido con el conjunto Ace-CEFR: un BERT afinado de 45,7 millones de parámetros, con menos error que PaLM 2-L.

Pero eso no es una comparación cara a cara y no conviene venderla como tal. Son dos experimentos distintos sobre el mismo corpus, con particiones y protocolos que no se han igualado; compartir el nombre del corpus no es compartir los textos de prueba. Lo que estas referencias justifican es la *decisión* de afinar un codificador en lugar de escribir un *prompt*. La comparación bajo el mismo protocolo está sin hacer, y sería un buen trabajo futuro.

5.2 Dónde perdemos, dicho sin adornos

TeakReader (TeakReader, s. f.) es el producto que más se nos parece, y va por delante en lo que importa a un usuario: es una aplicación terminada y publicada en dos tiendas, mientras que esto vive en un enlace. Da nivel MCER por capítulo —aunque por conteo de vocabulario, no con un modelo de lenguaje— y su señal está personalizada a lo que cada lector declara conocer. La nuestra no.

Las lecturas graduadas de editorial tienen algo que ningún modelo da: el nivel se lo puso una persona que leyó la obra entera. El nuestro se lo puso un modelo con una escala comprimida.

Y frente a **cualquiera de las alternativas**, este proyecto arrastra una dependencia que ellas no tienen: 654 documentos de anclaje. Ese es el techo real del modelo, y está dicho en las limitaciones del documento.

5.3 Qué queda entonces, y por qué basta

Tres cosas, y solo tres.

Recorremos el libro entero, capítulo a capítulo. Lexile da un número por libro; las fórmulas, uno por fragmento; las lecturas graduadas, una etiqueta de colección. Aquí se dibuja la curva completa y se ve dónde se pone cuesta arriba una novela y dónde da respiro. Para decidir si abandonas *Guerra y paz* en el capítulo veinte, eso es más útil que un número global.

Está pensado para un hispanohablante que quiere elegir qué leer, no para un profesor que quiere clasificar un texto. La interfaz está en español, la explicación de cada palabra también, y la pregunta que responde no es «¿qué nivel tiene este texto?» sino «¿puedo leer esto yo, hoy?».

Es auditable y de acceso gratuito para el lector. El modelo está publicado, el código está a la vista y las métricas vienen con su *n* y sus limitaciones. Conviene precisar qué significa aquí «auditable»: el código, la inferencia desde los pesos públicos **y** las métricas internas del v4 se pueden rehacer —recalculadas el 12 de septiembre de 2026, idénticas a cuatro decimales—. Y «gratuito» se refiere a quien usa la aplicación: alojarla y servirla cuesta dinero, y ese coste aparece en los accionables A2 y A4.

Las fórmulas clásicas también son gratuitas y reproducibles, así que la ventaja no es la auditabilidad por sí sola: es tenerla **junto con** un modelo que lee el texto en lugar de contar sílabas.

5.4 La cifra que hay que saber defender

En el corpus de exámenes de British Council, **contar palabras sin modelo alguno alcanza 0,807 donde el modelo alcanza 0,860**. Es la comparación más desfavorable del proyecto y conviene llevarla preparada en lugar de esperar a que alguien la encuentre: en ese corpus la longitud del texto está correlacionada con el nivel, así que un contador de palabras aprovecha un atajo que en una biblioteca real no existe. Descontando la longitud, la correlación parcial del modelo se sostiene en **0,668**. La del contador de palabras no es que sea peor: es que **no está definida**, porque descontar la longitud de la propia longitud deja un residuo de varianza cero. Dicho de otro modo, el contador no aporta nada por encima de la longitud porque es la longitud; el modelo sí.

Y una cifra que parecía mejor y hubo que retirar. Sobre UniversalCEFR (Imperial et al., 2025) el modelo daba 0,946 y contar palabras 0,663. Pero el v4 se entrenó con uno de sus dos conjuntos (ELG CEFR English; Breuker, 2023) y el otro está contenido en él, así que era medir el entrenamiento. Conviene llevarlo preparado igual que el 0,807: a la pregunta «¿habéis comprobado que la validación no se solapa con el entrenamiento?» la respuesta es que sí, que se encontró un solapamiento, y que la cifra se retiró.

Y la que sí se puede defender, con un corpus que el v4 no vio. En OneStopEnglish el modelo llega a 0,800 y contar palabras a 0,692, y descontando la longitud el modelo conserva 0,688. Conviene no vender de más la cifra más vistosa de ese corpus: dentro de cada artículo el modelo ordena las tres versiones en 183 de 185, pero la longitud sola ya acierta 179.

Y tres bibliotecas infantiles graduadas, que no dicen lo mismo. En StoryWeaver el modelo ordena sus cuatro niveles con 0,426 y conserva 0,206 descontando la longitud, con intervalos que no tocan el cero: es la validación externa más sólida. En African Storybook la longitud sola predice mejor el nivel (0,81) porque ese editor gradúa sobre todo por extensión. Y Let's Read no valida: más de la mitad son traducciones que heredan el nivel del libro original en otro idioma. Si alguien pregunta «¿y por qué no promediáis las tres?», la respuesta es esa: cada una mide una cosa distinta, y promediarlas escondería justo lo que se aprendió. Además, a fecha de `740eb84` (reinicio 21), el catálogo de la aplicación suma 15.367 textos de licencia libre de esas bibliotecas y de VOA (14.506 de StoryWeaver, de Pratham Books; 328 de Let's Read, de The Asia Foundation; 280 de African Storybook, de Saide; y 253 de VOA Learning English), con la dificultad que mide el modelo. Un cuento corto medido dentro de un bloque lo dice (`medido_en_bloque`); la atribución que

exige su licencia se enseña pero no se puntúa («Doggie is Happy», 0,349 con ella y 0,007 sin ella); el texto servido sale sin páginas repetidas ni U+FEFF sin cambiar lo medido; y al recomendar por nivel ocupan un tercio de las tarjetas, por cercanía al nivel del lector (revisión `7c09d90` del Space).

---

6. Accionables

Diez acciones concretas, ordenadas por puntos de rúbrica protegidos u obtenidos por hora de trabajo. Cada una lleva coste real y criterio de terminado. No son «se podría»: son «se hace».

#	Acción	Por qué	Coste	Terminado cuando
A1	**Publicar modelo y diccionario**	El modelo público permite inferencia en Colab; el diccionario ampliaría la reproducción léxica, pero no interviene en este cuaderno	~30 min; gratuito; requiere token del autor	**PARCIAL**: v4 público y descargable en `MikeMaki1763/literalevel-v4`; diccionario (243 MB) pendiente. No bloquea el cuaderno
A2	**Desplegar en enlace permanente**	El enlace anterior era un túnel temporal que moría al apagar el equipo, y era el mayor riesgo de la entrega	**7 USD/mes**: el Space de Gradio que aloja el motor y la API exige cuenta Hugging Face Pro (9 USD de tarifa, 7 con descuento); el hardware `cpu-basic` no añade coste, y el front, en Vercel y en el Space estático, es gratuito	**HECHO**: el front en Vercel (https://pleyade-app.vercel.app), con respaldo en `MikeMaki1763/literalevel-front` (el front) y `MikeMaki1763/literalevel` (API y motor), públicos y en marcha. El disco persistente es A4
~~**A3**~~ **HECHO**	**Terminar la remedición del catálogo** con el modelo v4, libro entero	Sustituye las etiquetas heredadas —predicciones de un modelo v1 sobre las primeras ~190 palabras— por medidas reales	T4 gratuita; la descarga por `common-pile/project_gutenberg` (Kandpal et al., 2025; 57.226 textos en 7,7 minutos) y los resultados en Hugging Face, no en Drive, que pedía un permiso en cada sesión	**Cumplido el 12 de septiembre de 2026**: 53.179 libros y 585.111 capítulos medidos, y la aplicación los usa
~~**A4**~~ **HECHO**	**Montar almacenamiento persistente** para los datos del lector	Un servicio que duerme y despierta con la estantería vacía deja en ridículo «Mis libros»	18 USD por TB y mes en repositorio privado; los datos del lector ocupan **10,9 MB** medidos, así que el coste es despreciable	**Cumplido y verificado**: bucket montado en `/data`, se fijó un perfil, se reinició el Space y el perfil seguía ahí. Desde el 26 de septiembre, con cuenta, los datos son de la cuenta y se ven en cualquier aparato

#	Acción	Por qué	Coste	Terminado cuando
A5 · HECHO	**Conseguir un micrófono** (auriculares con micro)	El equipo actual no tiene. Sin él no se puede demostrar la corrección de pronunciación, que es la función más vistosa y la que mejor encaja con «usabilidad para el usuario final»	Coste mínimo de hardware	**Cumplido con el teléfono**: el 16 de septiembre, desde el teléfono del autor y con cuenta, el micrófono grabó y la corrección salió; se vuelve a ensayar antes de la demo
A6 · HECHO	**Sustituir el catálogo heredado** de 1.197 registros	Incluía 1.049 registros sin texto descargable, el 87,6 % de aquella versión, no de la actual	Incluido en A3	El catálogo medido actual contiene 53.179 IDs de Gutenberg; a fecha de `db366b8` se excluyen al recomendar y al buscar 600 que no son lectura (índices, catálogos, directorios) y, desde `3524357` (163 entonces, 203 hoy), textos libres que no son lectura en inglés (relleno o en otra lengua), y por nivel solo se ofrecen obras literarias. Una medida del precálculo se corrige al cargar (`correcciones_catalogo.csv`): PG2242, *A Midsummer Night's Dream* del First Folio, guardó 0,697 y releída por el mismo camino da 1,713 (C1)
A7	**Calibrar la escala** con una transformación afín de dos parámetros ajustada sobre entrenamiento, sin tocar los pesos	La escala está comprimida y un A2 puntúa cerca de B1. La técnica ya se aplicó con éxito a una variante anterior	Una tarde	Las medias por nivel siguen estrictamente crecientes **y** se acercan a sus anclas
A8	**Repetir la prueba de usuario con cinco lectores** de perfiles distintos sobre Angular, con guion de tareas y observación en silencio	Los dos ciclos previos encontraron fallos graves; no validan todos los cambios del nuevo front (Nielsen, 2000)	Cinco sesiones de 20 min	Estará hecho cuando exista una lista priorizada de hallazgos y las tres primeras correcciones estén hechas
A9	**Instrumentar la métrica que de verdad importa**: proporción de libros empezados que se terminan, con recomendación y sin ella	Todo lo demás son métricas de proceso. Esta es la única que valida la propuesta de valor	Una jornada de instrumentación, respetando el aislamiento por sesión	Hay una cifra base con la que comparar dentro de un mes
A10	**Ampliar el corpus de anclaje MCER** más allá de los 654 documentos actuales	Es el eslabón más delgado de la cadena de evidencia y el que limita la confianza en la letra que se muestra	Trabajo de corpus, sin coste de cómputo	El corpus de anclaje supera los 1.000 documentos con niveles de fuente institucional

Cuadro 2. Accionables, con coste y criterio de terminado.

Orden de ejecución actualizado: volver a ensayar la voz con cuenta (A5), recorrer Angular con usuarios (A8), revisar el comercial terminado y comprobar los archivos de entrega. A2, A3, A4 y la sustitución del catálogo de A6 ya tienen evidencia de cierre; no se vuelven a presentar como trabajo por empezar. Las mejoras visuales pendientes no deben desplazar el ensayo de la demo.

---

7. Métricas de éxito

Nivel	Métrica	Estado
Modelo	Orden estrictamente creciente por nivel MCER en corpus externo	**Cumplido**: 0,5040 · 0,5561 · 0,9276 · 1,2414 · 1,4952
Modelo	Señal por encima de la longitud del texto	**Cumplido**: correlación parcial 0,668
Producto	Un usuario sin formación técnica completa el recorrido	**Cumplido con reservas, sobre la interfaz anterior**: lo completó en Gradio, y de esa sesión salieron las nueve correcciones del Cuadro 1 —seis de ellas etiquetas—; sobre el front de Angular, pendiente (A8)
Producto	Accesibilidad de color	**Cumplido en la interfaz anterior**: las ochenta y cinco parejas de color de las cinco paletas de Gradio superan WCAG AA; las más ajustadas, 4,53 (texto) y 3,11 (título). En el front, las portadas y el lector teñido tienen pruebas de contraste; el tema de la marca sobre el fondo de galaxia, **sin medir**
Producto	Robustez	**Parcial**: recuento sin claves del 15 de septiembre sobre el árbol del despliegue `0319290` —API 66 de 66, 351 pruebas extremas sin ningún fallo y corpus 48 de 48—, más lectura natural 34 de 34 y voz concurrente 10 de 10 del corte anterior `d58b0be`; la última publicación de la API (26 de septiembre, `06a16db`): API 70 de 70, extremas sin fallos y front 464 de 464. No equivalen a una prueba completa de usuario
Operación	Enlace permanente disponible	**Cumplido**: el front en Vercel (https://pleyade-app.vercel.app), con respaldo en `MikeMaki1763/literalevel-front`, y la API con el motor en `MikeMaki1763/literalevel`, en Hugging Face Spaces, con los datos del lector o de su cuenta en un bucket montado en `/data`
Operación	Catálogo medido, no heredado	**Cumplido** el 12 de septiembre de 2026: 53.179 libros y 585.111 capítulos medidos por el v4 (A3)
Impacto	Proporción de libros terminados	**Sin instrumentar** (A9)

Cuadro 3. Métricas por nivel, con su estado real.

8. Riesgos

Riesgo	Impacto	Mitigación
El enlace de la demostración muere durante la evaluación	Alto	A2: despliegue permanente, probado desde un dispositivo ajeno antes de la fecha
El servicio externo de lenguaje agota su presupuesto en mitad de una demostración	Medio	Ya mitigado: la aplicación degrada con un mensaje legible y conserva diccionario, fonética, audio, buscador y puntuación
Que la letra MCER se lea como una certificación	Alto, reputacional	Declaración de alcance en el documento y aviso permanente en pantalla
Que la remedición del catálogo no termine a tiempo	~~Medio~~ **Resuelto**	Terminada el 12 de septiembre de 2026: sin Drive, con los resultados en Hugging Face tras cada lote, 0 errores y ningún libro medido dos veces
Sobrecarga del espejo de descarga de Project Gutenberg	Medio, ético	Seis hilos y no treinta, cada uno con su pausa entre peticiones; y el vocabulario se obtuvo del SPGC, no rascando el sitio
Contenido inapropiado para una lectora menor de edad	Medio	Decisión razonada de **no filtrar por contenido** y avisar en la ficha (una lista curada: 2 títulos a fecha de `db366b8`, que no encabezan la recomendación por nivel y no se quitan); se argumenta en el apartado 8.4 del documento principal

Cuadro 4. Riesgos y mitigaciones.

Referencias

Breuker, M. (2023). CEFR labelling and assessment services. En G. Rehm (Ed.), *European Language Grid* (pp. 277–282). Springer. https://doi.org/10.1007/978-3-031-17258-8_16

Carnegie Mellon University. (s. f.). *The CMU Pronouncing Dictionary* [Conjunto de datos]. https://github.com/cmusphinx/cmudict

Deci, E. L., Koestner, R., & Ryan, R. M. (1999). A meta-analytic review of experiments examining the effects of extrinsic rewards on intrinsic motivation. *Psychological Bulletin, 125*(6), 627–668. https://doi.org/10.1037/0033-2909.125.6.627

Grossman, R., & Chen, Y. (2026). *Zero-shot large language models for automatic readability assessment* (arXiv:2604.24470). arXiv. https://arxiv.org/abs/2604.24470

Imperial, J. M., Barayan, A., Stodden, R., Wilkens, R., Muñoz Sánchez, R., Gao, L., Torgbi, M., Knight, D., Forey, G., Jablonkai, R. R., Kochmar, E., Reynolds, R. J., Ribeiro, E., Saggion, H., Volodina, E., Vajjala, S., François, T., Alva-Manchego, F., & Tayyar Madabushi, H. (2025). UniversalCEFR: Enabling open

multilingual research on language proficiency assessment. En *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing* (pp. 9703–9755). Association for Computational Linguistics. https://doi.org/10.18653/v1/2025.emnlp-main.491

Kandpal, N., Lester, B., Raffel, C., Majstorovic, S., Biderman, S., Abbasi, B., Soldaini, L., Shippole, E., Cooper, A. F., Skowron, A., Kirchenbauer, J., Longpre, S., Sutawika, L., Albalak, A., Xu, Z., Penedo, G., Ben Allal, L., Bakouch, E., Pressman, J. D., … Murray, T. (2025). *The Common Pile v0.1: An 8TB dataset of public domain and openly licensed text* (arXiv:2506.05209). arXiv. https://arxiv.org/abs/2506.05209

Kogan, D., Schumacher, M., Nguyen, S., Suzuki, M., Smith, M., Bellows, C. S., & Bernstein, J. (2025). *Ace-CEFR: A dataset for automated evaluation of the linguistic difficulty of conversational texts for LLM applications* (arXiv:2506.14046). arXiv. https://arxiv.org/abs/2506.14046

Krashen, S. D. (1985). *The input hypothesis: Issues and implications*. Longman.

Krug, S. (2014). *Don't make me think, revisited: A common sense approach to web usability* (3ª ed.). New Riders.

MetaMetrics. (2026). *Lexile® Text Analyzer content creator annual tiered pricing program*. https://www2.metametricsinc.com/content-creator-annual-pricing

Nakanishi, T. (2015). A meta-analysis of extensive reading research. *TESOL Quarterly, 49*(1), 6–37. https://doi.org/10.1002/tesq.157

Nielsen, J. (2000, 18 de marzo). *Why you only need to test with 5 users*. Nielsen Norman Group. https://www.nngroup.com/articles/why-you-only-need-to-test-with-5-users/

Perry-Smith, L. (s. f.). *Infinite, 3D Head Scan* [Modelo 3D, licencia CC BY 3.0]. Infinite-Realities. http://www.ir-ltd.net/

Pratham Books. (s. f.). *StoryWeaver* [Biblioteca digital]. https://storyweaver.org.in

Saide. (s. f.). *African Storybook* [Biblioteca digital]. https://www.africanstorybook.org

TeakReader. (s. f.). *English reading level checker for books*. https://teakreader.com/english-reading-level-checker-for-books

The Asia Foundation. (s. f.). *Let's Read* [Biblioteca digital]. https://www.letsreadasia.org

Voice of America. (s. f.). *VOA Learning English*. https://learningenglish.voanews.com

World Wide Web Consortium. (2023). *Web Content Accessibility Guidelines (WCAG) 2.2*. W3C. https://www.w3.org/TR/WCAG22/