

**Universidad Nacional Autónoma de México**

FACULTAD DE ESTUDIOS SUPERIORES ACATLÁN




# LiteraLevel

¿Está este libro en inglés a tu nivel de lectura?

Miguel Reyes Carrillo

Proyecto integrador — Módulo 5 · Generación 34

Mtro. Fernando Barranco Rodríguez

# Antes de comenzar

Un hispanohablante elige un libro en inglés que suena bien,
lo abre... y a las tres páginas lo cierra.

**No porque no sepa inglés.**
**Porque eligió mal el libro.**

Nadie le dijo antes de abrirlo si estaba a su altura.

# Los datos, en cifras

**4.724**
extractos con dificultad medida por lectores (CLEAR)

**654**
documentos anclados a niveles del MCER

**61.642**
libros en inglés de Project Gutenberg

Ninguno viene de Kaggle: catálogo oficial, repositorio público y descarga directa de los PDF.

# Objetivos

01 **Situar al lector** en una escala continua, con un cuestionario breve o midiendo un texto que ya lee cómodo.

02 **Medir un libro entero**, capítulo a capítulo, y no una muestra de sus primeras páginas.

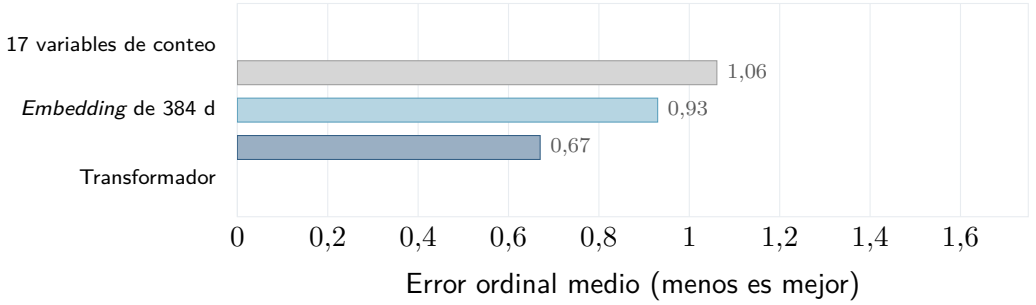
03 **Recomendar qué leer hoy**, con la dificultad puesta al lado del nivel del lector.

04 **Acompañar la lectura**: definición en contexto y corrección de pronunciación.

# Hallazgo 1 · El cuello de botella era la representación

Con las mismas 950 muestras reservadas, cambiando solo cómo se representa el texto:

Esas 950 muestras eligieron además la época del transformador: son validación de selección, no un test independiente. El error ordinal es sobre sextiles de CLEAR, no sobre niveles MCER.




Subir la potencia del clasificador sobre las mismas variables **no movió el resultado**: un XGBoost de 300 árboles queda por detrás de una regresión logística. Cambiar la representación sí.

# Hallazgo 2 · Contar palabras llega casi igual de lejos

**0,860**

el modelo, contra el nivel oficial de 47 textos

**0,807**

**contar las palabras**, sin modelo alguno

En un corpus de exámenes, el nivel y la extensión de la tarea van juntos, así que un contador de palabras aprovecha un atajo ligado al diseño de esos exámenes, cuya utilidad fuera de ese corpus no está demostrada. **Lo que sostiene al modelo es lo que aporta por encima de la longitud**: descontándola, conserva **0,668**.

Se enseña porque es la comparación más desfavorable del proyecto, y ocultarla sería el peor error posible.

# El modelo desplegado

**distilroberta-base** · 82 M de parámetros · regresión, no clasificación

| **Conjunto** | **n** | **Dentro de $\pm 1$ nivel** | **Spearman** |
|---|---|---|---|
| Validación interna | 144 | 97,2 % | 0,908 |
| British Council, externo | 38 | 100 % | 0,829 |

Métricas internas reportadas de la ejecución de entrenamiento: las 144 parejas de etiqueta y predicción no están publicadas.

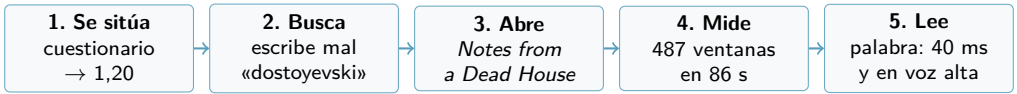
Sobre textos externos con nivel oficial, las medias por nivel salen **estrictamente crecientes**:

A1 **0,504** · A2 **0,556** · B1 **0,928** · B2 **1,241** · C1 **1,495**

El orden es el resultado, no el porcentaje. El escalón A1–A2 descansa en 3 textos y está dentro del ruido; los otros tres, no.

# Ejemplo de uso y aplicación

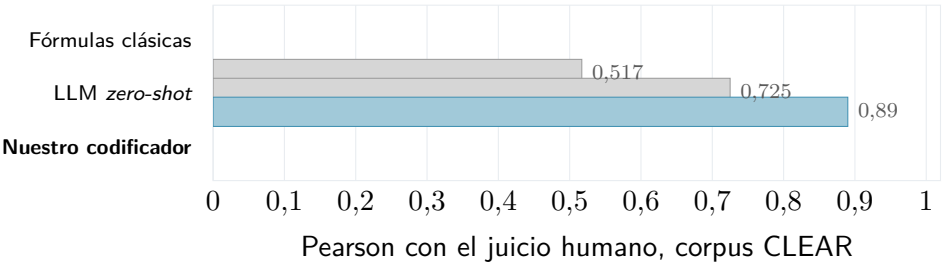
**El recorrido del apartado 8.2 del documento**, paso a paso: una lectora cuyo perfil da **1,20 sobre 2**, banda intermedia. Los pasos y las cifras son los de la aplicación; la lectora ilustra, no es una sesión registrada. La única prueba de usuario real es la de Esmeralda, $n = 1$, y está en el documento.




| Paso | Lo que produce |
|---|---|
| Se sitúa | 1,20 sobre 2, banda *intermedia*, ancla B2 |
| Busca | búsqueda por significado; el nombre mal escrito llega igual |
| Abre | ficha sobre el texto: 130.104 palabras, diálogo, repeticiones |
| Mide | 487 ventanas en 86 s → media **1,73**; la segunda vez, 0,02 s |
| Lee | la palabra en 40 ms; la voz alta, corregida palabra por palabra |

**1,73 frente a 1,20**: el libro le queda por encima, y lo sabe antes de la primera página.

# Contra quién compite




**No son comparaciones cara a cara**: las dos primeras vienen de un estudio ajeno sobre el mismo corpus, con otra partición. Justifican la decisión de afinar un codificador; no demuestran una victoria medida.

**Y dónde se pierde:** Lexile tiene treinta años de validación y una escala **que acepta un colegio**; la de aquí no la acepta nadie.

# Estrategia

Tres acciones, con coste real y criterio de terminado.

| **Qué** | **Cuánto cuesta** | **Cuándo está hecho** |
|---|---|---|
| Publicar el modelo | 30 min, gratis | **Hecho**: el cuaderno corre en un Colab limpio |
| Desplegar de forma permanente | 7 USD/mes | **Hecho**: dirección fija que no muere al apagar |
| Terminar la medición del catálogo | ≈3–5 h de cómputo A100, *estimadas*; la descarga va aparte | **En curso**: hoy las etiquetas son heredadas de un modelo v1. Terminado cuando el catálogo publique niveles medidos por el v4 |

El coste de medir el catálogo entero está en otro orden de magnitud que la tarifa de la alternativa comercial. Eso es lo que hace viable el proyecto, no la métrica.

# Lo que esto no es

**No certificamos ningún nivel del MCER.**

La letra que se enseña es la etiqueta más cercana en una escala continua propia.

Sirve para elegir qué leer. No para acreditar nada.

## Funcionando ahora mismo

`huggingface.co/spaces/MikeMaki1763/literalevel`

Modelo público: `huggingface.co/MikeMaki1763/literalevel-v4`

Si alguna vez abandonaste un libro en inglés pensando que el problema eras tú:
**no lo eras. Era el libro.**