

Universidad Nacional Autónoma de México

FACULTAD DE ESTUDIOS SUPERIORES ACATLÁN



LiteraLevel

¿Está este libro en inglés a tu nivel de lectura?

Miguel Reyes Carrillo

Proyecto integrador — Módulo 5 · Generación 34

Mtro. Fernando Barranco Rodríguez

Antes de comenzar

Un hispanohablante elige un libro en inglés que suena bien,
lo abre... y a las tres páginas lo cierra.

Quizá no era falta de capacidad.
Quizá necesitaba otra lectura.

Nadie le dijo antes de abrirlo si estaba a su altura.

Peldaño

La compañía —**ficticia**, como pide el módulo— que hace esto.

El modelo, la aplicación y todas las cifras que siguen no lo son.

El nicho

Lectura extensiva en inglés para hispanohablantes **entre A2 y B2**: ya no caben en el material graduado y todavía no aguantan una novela sola.

El nombre

Se aprende con lo que está **un escalón** por encima de lo que uno domina. Encontrar ese peldaño es el problema.

Quién paga qué

Medir un libro, leerlo, buscar y el diccionario: **gratis**, corren en local sobre datos abiertos.

Explicar el contexto, traducir, resumir y corregir la pronunciación: usan OpenAI, con permiso y cuota.

Sin clave, **la lectura y el diccionario local siguen disponibles**.

Los datos, en cifras

4.724
extractos con dificultad medida por lectores (CLEAR)

654
documentos anclados a niveles del MCER

61.642
libros objetivo en inglés Gutenberg, 7 sep. 2026

Ninguno viene de Kaggle: catálogo oficial, repositorio público y descarga directa de los PDF.

Objetivos

01 **Situar al lector** en una escala continua, con un cuestionario breve o midiendo un texto que ya lee cómodo.

02 **Medir un libro entero**, capítulo a capítulo, y no una muestra de sus primeras páginas.

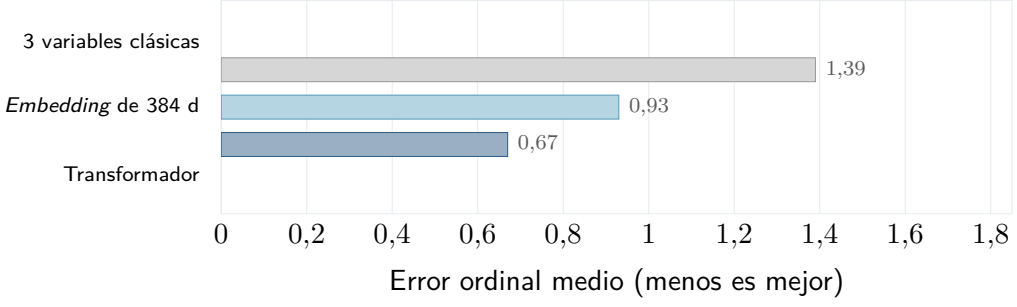
03 **Recomendar qué leer hoy**, con la dificultad puesta al lado del nivel del lector.

04 **Acompañar la lectura**: diccionario, explicación contextual y práctica de pronunciación.

Hallazgo 1 · El cuello de botella era la representación

Con las mismas 950 muestras reservadas, cambiando solo cómo se representa el texto:

Esas 950 muestras eligieron además la época del transformador: son validación de selección, no un test independiente. El error ordinal es sobre sextiles de CLEAR, no sobre niveles MCER.



Con las mismas variables, un XGBoost de 300 árboles queda por detrás de una regresión logística. Cambiar la representación sí mejora el resultado. Las tres barras proceden de **la misma tanda**.

Hallazgo 2 · Contar palabras llega casi igual de lejos

0,860

el modelo, contra el nivel oficial de 47 textos

0,807

contar las palabras, sin modelo alguno

En un corpus de exámenes, el nivel y la extensión de la tarea van juntos, así que un contador de palabras aprovecha un atajo ligado al diseño de esos exámenes, cuya utilidad fuera de ese corpus no está demostrada. **Lo que sostiene al modelo es lo que aporta por encima de la longitud**: descontándola, conserva **0,668**.

Se enseña porque es la comparación más desfavorable del proyecto, y ocultarla sería el peor error posible.

El modelo desplegado

distilroberta-base · 82 M de parámetros · regresión, no clasificación

Conjunto	**n**	**Dentro de ± 1 nivel**	**Spearman**
Validación interna	144	97,2 %	0,908
British Council, desarrollo	38	100 %	0,829

Métricas internas recalculadas el 12 de septiembre con el guion de entrenamiento y datos públicos: idénticas a cuatro decimales.

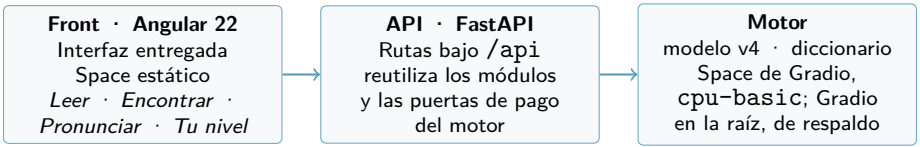
Sobre textos externos con nivel oficial, las medias por nivel salen **estrictamente crecientes**:

A1 **0,504** · A2 **0,556** · B1 **0,928** · B2 **1,241** · C1 **1,495**

El orden es el resultado, no el porcentaje. El escalón A1–A2 descansa en 3 textos y está dentro del ruido; los otros tres, no.

La aplicación entregada

Angular es la interfaz del lector; la API conecta con el motor de Python.



Con una mano

Barra de lectura al alcance del pulgar y acceso al micrófono desde la vista de pronunciación.

Voz e IPA

Compara lo dicho con la frase objetivo; ofrece IPA de diccionario, audio y orientación para practicar el sonido.

Apoyo articulatorio

Modelo Blender de 38 piezas en la ficha IPA y la corrección. El 3D se carga al abrirlo, con respaldo 2D. Apoyo didáctico, no clínico.

Las portadas FLUX siguen pendientes; la demostración no depende de imágenes aún no generadas.

Lo que hace por el lector

Lo añadido en los dos últimos días, ya publicado en el *front*.

Ver la boca mientras suena

El corte de perfil y la boca 3D se mueven al compás del audio del sonido o de la palabra, también en modo lento. La lengua se distingue del paladar y un aro marca dónde toca.

Leer con naturalidad

Mide dónde se paró el lector y qué tramos van lentos para su nivel. Marca énfasis, enlaces (*with us*) y reducciones (*don't you* → *doncha*), y lo hace escuchar dicho de corrido.

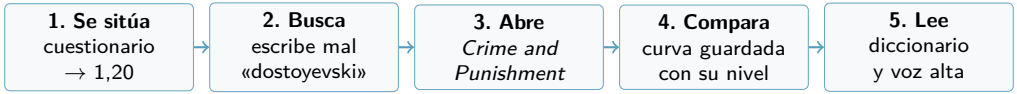
Más lectura a su nivel

15.357 textos de licencia libre medidos con el v4 —StoryWeaver, Let's Read, African Storybook y VOA— junto a los **53.179** libros de Gutenberg.

Las reducciones solo salen de una lista cerrada y los enlaces se comprueban con la pronunciación de diccionario; lo que escribe la IA va marcado.

Ejemplo de uso y aplicación

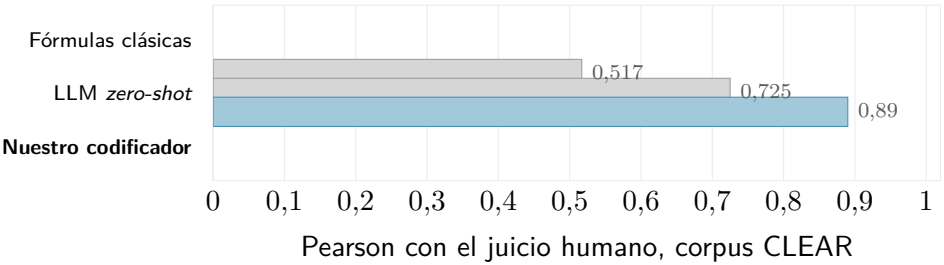
Caso ilustrativo del documento: perfil **1,20 sobre 2**, banda intermedia. No es una sesión registrada ni un resultado fijo del cuestionario.



Paso	Lo que produce
Se sitúa	1,20 sobre 2, banda *intermedia*, ancla B2
Busca	búsqueda por significado; el nombre mal escrito llega igual
Abre	ficha sobre el texto: extensión, diálogo y repeticiones
Compara	ejemplo registrado: dificultad **1,70** frente a perfil **1,20**
Lee	diccionario primero; explicación de IA después, si está habilitada

La medición histórica del libro no es una promesa de latencia HTTP. En la demo se muestran los valores que devuelve la app.

Contra quién compite



No son comparaciones cara a cara: las dos primeras vienen de un estudio ajeno sobre el mismo corpus, con otra partición. Justifican la decisión de afinar un codificador; no demuestran una victoria medida.

Y dónde se pierde: Lexile tiene treinta años de validación y una escala **que acepta un colegio**; la de aquí no la acepta nadie.

Estrategia

Acciones operativas y siguiente validación con lectores.

Acción	**Recursos**	**Criterio de terminado**
Servir interfaz y motor	Angular estático + API en Space de Gradio; IA con cuota	**Publicado**: comprobar navegación y respuesta JSON antes de la demo
Ofrecer lecturas ajustadas	Catálogo medido por v4 y corpus graduados abiertos	**Disponible**: 53.179 libros de Gutenberg (585.111 capítulos) y 15.357 textos libres medidos
Validar la utilidad	Pruebas con lectores y registro de tareas	**Pendiente**: medir comprensión y continuidad con usuarios

La consulta local no llama a OpenAI. El servicio remoto y la IA sí tienen costes operativos.

Lo que esto no es

No certificamos ningún nivel del MCER.

La letra que se enseña es la etiqueta más cercana
en una escala continua propia.

Sirve para elegir qué leer. No para acreditar nada.

Funcionando ahora mismo

`mikemaki1763-literalevel-front.static.hf.space`

API y motor: `huggingface.co/spaces/MikeMaki1763/literalevel`

Modelo público: `huggingface.co/MikeMaki1763/literalevel-v4`

Elige una lectura, compara su dificultad con tu nivel
y prueba si te ayuda a seguir leyendo.