

Universidad Nacional Autónoma de México

FACULTAD DE ESTUDIOS SUPERIORES ACATLÁN



LiteraLevel

¿Está este libro en inglés a tu nivel de lectura?

Miguel Reyes Carrillo

Proyecto integrador — Módulo 5 · Generación 34

Mtro. Fernando Barranco Rodríguez

Antes de comenzar

Un hispanohablante elige un libro en inglés que suena bien,
lo abre... y a las tres páginas lo cierra.

No porque no sepa inglés.
Porque eligió mal el libro.

Nadie le dijo antes de abrirlo si estaba a su altura.

Peldaño

La compañía —**ficticia**, como pide el módulo— que hace esto.

El modelo, la aplicación y todas las cifras que siguen no lo son.

El nicho

Lectura extensiva en inglés para hispanohablantes **entre A2 y B2**: ya no caben en el material graduado y todavía no aguantan una novela sola.

El nombre

Se aprende con lo que está **un escalón** por encima de lo que uno domina. Encontrar ese peldaño es el problema.

Quién paga qué

Medir un libro, leerlo, buscar y el diccionario: **gratis**, corren en local sobre datos abiertos.

Explicar una palabra, resumir y corregir la pronunciación: salen a un servicio de pago.

Esa frontera no se diseñó: **salió de medir qué costaba cada cosa**.

Los datos, en cifras

4.724
extractos con dificultad medida por lectores (CLEAR)

654
documentos anclados a niveles del MCER

61.642
libros en inglés de Project Gutenberg

Ninguno viene de Kaggle: catálogo oficial, repositorio público y descarga directa de los PDF.

Objetivos

01 **Situar al lector** en una escala continua, con un cuestionario breve o midiendo un texto que ya lee cómodo.

02 **Medir un libro entero**, capítulo a capítulo, y no una muestra de sus primeras páginas.

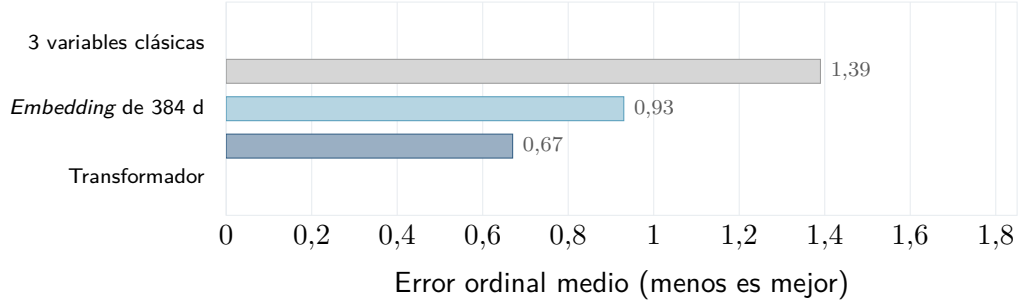
03 **Recomendar qué leer hoy**, con la dificultad puesta al lado del nivel del lector.

04 **Acompañar la lectura**: definición en contexto y corrección de pronunciación.

Hallazgo 1 · El cuello de botella era la representación

Con las mismas 950 muestras reservadas, cambiando solo cómo se representa el texto:

Esas 950 muestras eligieron además la época del transformador: son validación de selección, no un test independiente. El error ordinal es sobre sextiles de CLEAR, no sobre niveles MCER.



Subir la potencia del clasificador sobre las mismas variables **no movió el resultado**: un XGBoost de 300 árboles queda por detrás de una regresión logística. Cambiar la representación sí. Las tres barras salen de **la misma tanda**: aquí decía 1,06, que es la tanda recalculada, y restarle las otras dos es la resta que el documento dice que no se puede hacer.

Hallazgo 2 · Contar palabras llega casi igual de lejos

0,860

el modelo, contra el nivel oficial de 47 textos

0,807

contar las palabras, sin modelo alguno

En un corpus de exámenes, el nivel y la extensión de la tarea van juntos, así que un contador de palabras aprovecha un atajo ligado al diseño de esos exámenes, cuya utilidad fuera de ese corpus no está demostrada. **Lo que sostiene al modelo es lo que aporta por encima de la longitud**: descontándola, conserva **0,668**.

Se enseña porque es la comparación más desfavorable del proyecto, y ocultarla sería el peor error posible.

El modelo desplegado

distilroberta-base · 82 M de parámetros · regresión, no clasificación

Conjunto	**n**	**Dentro de ± 1 nivel**	**Spearman**
Validación interna	144	97,2 %	0,908
British Council, externo	38	100 %	0,829

Métricas internas reportadas de la ejecución de entrenamiento: las 144 parejas de etiqueta y predicción no están publicadas.

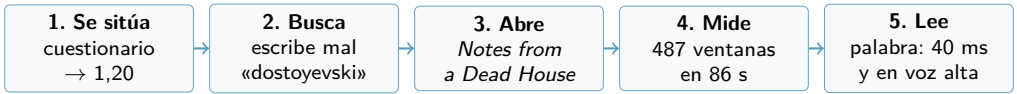
Sobre textos externos con nivel oficial, las medias por nivel salen **estrictamente crecientes**:

A1 **0,504** · A2 **0,556** · B1 **0,928** · B2 **1,241** · C1 **1,495**

El orden es el resultado, no el porcentaje. El escalón A1–A2 descansa en 3 textos y está dentro del ruido; los otros tres, no.

Ejemplo de uso y aplicación

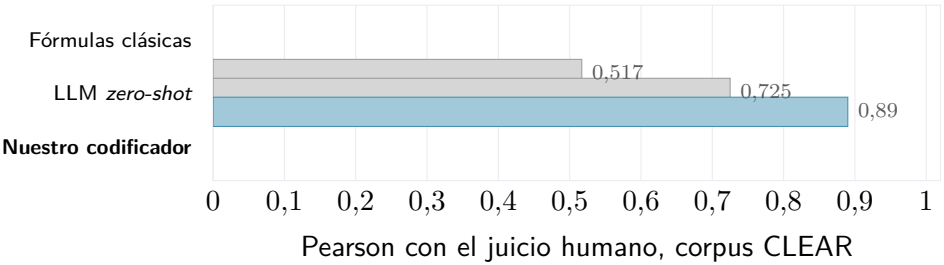
El recorrido del apartado 8.2 del documento, paso a paso: una lectora cuyo perfil da **1,20 sobre 2**, banda intermedia. Los pasos y las cifras son los de la aplicación; la lectora ilustra, no es una sesión registrada. La única prueba de usuario real es la de Esmeralda, $n = 1$, y está en el documento.



Paso	Lo que produce
Se sitúa	1,20 sobre 2, banda *intermedia*, ancla B2
Busca	búsqueda por significado; el nombre mal escrito llega igual
Abre	ficha sobre el texto: 130.104 palabras, diálogo, repeticiones
Mide	487 ventanas en 86 s → media **1,73**; la segunda vez, 0,02 s
Lee	la palabra en 40 ms; la voz alta, corregida palabra por palabra

1,73 frente a 1,20: el libro le queda por encima, y lo sabe antes de la primera página.

Contra quién compite



No son comparaciones cara a cara: las dos primeras vienen de un estudio ajeno sobre el mismo corpus, con otra partición. Justifican la decisión de afinar un codificador; no demuestran una victoria medida.

Y dónde se pierde: Lexile tiene treinta años de validación y una escala **que acepta un colegio**; la de aquí no la acepta nadie.

Estrategia

Tres acciones, con coste real y criterio de terminado.

Qué	**Cuánto cuesta**	**Cuándo está hecho**
Publicar el modelo	30 min, gratis	**Hecho**: el cuaderno corre en un Colab limpio
Desplegar de forma permanente	7 USD/mes	**Hecho**: dirección fija que no muere al apagar
Terminar la medición del catálogo	$\approx$3 h de tarjeta, $\approx$17 h de reloj *(medidas)*; la descarga va aparte	**En curso**: hoy las etiquetas son heredadas de un modelo v1. Terminado cuando el catálogo publique niveles medidos por el v4

El coste de medir el catálogo entero está en otro orden de magnitud que la tarifa de la alternativa comercial. Eso es lo que hace viable el proyecto, no la métrica.

Lo que esto no es

No certificamos ningún nivel del MCER.

La letra que se enseña es la etiqueta más cercana
en una escala continua propia.

Sirve para elegir qué leer. No para acreditar nada.

Funcionando ahora mismo

`huggingface.co/spaces/MikeMaki1763/literalevel`

Modelo público: `huggingface.co/MikeMaki1763/literalevel-v4`

Si alguna vez abandonaste un libro en inglés pensando que el problema eras tú:
no lo eras. Era el libro.