

Universidad Nacional Autónoma de México

FACULTAD DE ESTUDIOS SUPERIORES ACATLÁN



LiteraLevel

¿Está este libro en inglés a tu nivel de lectura?

Miguel Reyes Carrillo

Proyecto integrador — Módulo 5 · Generación 34

Mtro. Fernando Barranco Rodríguez

Antes de comenzar

Un hispanohablante elige un libro en inglés que suena bien,
lo abre... y a las tres páginas lo cierra.

No porque no sepa inglés.
Porque eligió mal el libro.

Nadie le dijo antes de abrirlo si estaba a su altura.

Los datos, en cifras

4.724
extractos con dificultad medida por lectores (CLEAR)

654
documentos anclados a niveles del MCER

61.642
libros en inglés de Project Gutenberg

Ninguno viene de Kaggle: catálogo oficial, repositorio público y descarga directa de los PDF.

Objetivos

01 **Situar al lector** en una escala continua, con un cuestionario breve o midiendo un texto que ya lee cómodo.

02 **Medir un libro entero**, capítulo a capítulo, y no una muestra de sus primeras páginas.

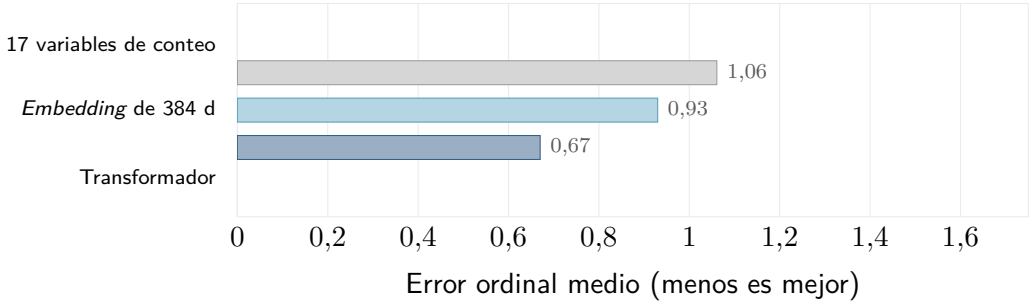
03 **Recomendar qué leer hoy**, con la dificultad puesta al lado del nivel del lector.

04 **Acompañar la lectura**: definición en contexto y corrección de pronunciación.

Hallazgo 1 · El cuello de botella era la representación

Con las mismas 950 muestras reservadas, cambiando solo cómo se representa el texto:

Esas 950 muestras eligieron además la época del transformador: son validación de selección, no un test independiente. El error ordinal es sobre sextiles de CLEAR, no sobre niveles MCER.



Subir la potencia del clasificador sobre las mismas variables **no movió el resultado**: un XGBoost de 300 árboles queda por detrás de una regresión logística. Cambiar la representación sí.

Hallazgo 2 · Contar palabras llega casi igual de lejos

0,855

el modelo, contra el nivel oficial de 46 textos

0,799

contar las palabras, sin modelo alguno

En un corpus de exámenes, el nivel y la extensión de la tarea van juntos, así que un contador de palabras aprovecha un atajo ligado al diseño de esos exámenes, cuya utilidad fuera de ese corpus no está demostrada. **Lo que sostiene al modelo es lo que aporta por encima de la longitud**: descontándola, conserva **0,665**.

Se enseña porque es la comparación más desfavorable del proyecto, y ocultarla sería el peor error posible.

El modelo desplegado

distilroberta-base · 82 M de parámetros · regresión, no clasificación

Conjunto	**n**	**Dentro de ± 1 nivel**	**Spearman**
Validación interna	144	97,2 %	0,908
British Council, externo	38	100 %	0,829

Métricas internas reportadas de la ejecución de entrenamiento: las 144 parejas de etiqueta y predicción no están publicadas.

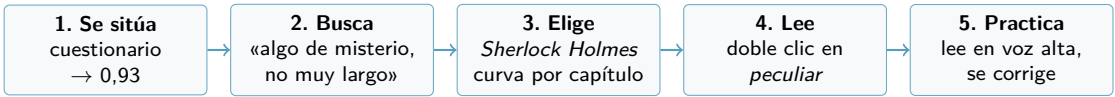
Sobre textos externos con nivel oficial, las medias por nivel salen **estrictamente crecientes**:

A1 **0,504** · A2 **0,548** · B1 **0,928** · B2 **1,241** · C1 **1,495**

El orden es el resultado, no el porcentaje. El escalón A1–A2 descansa en 3 textos y está dentro del ruido; los otros cuatro, no.

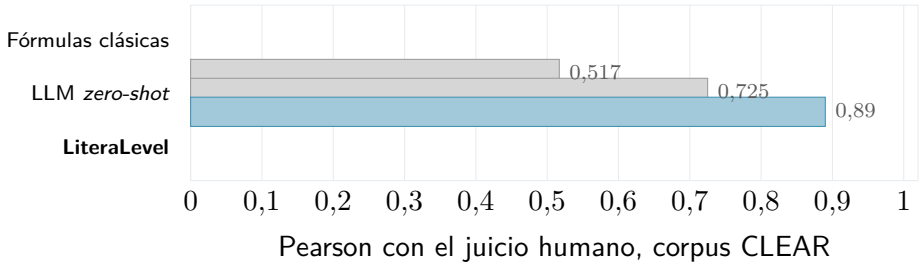
Ejemplo de uso y aplicación

Recorrido de ejemplo, paso a paso: una lectora de 15 años que el sistema sitúa en 0,93. Los pasos y lo que produce cada uno son los de la aplicación; el nombre y el perfil ilustran, no son una sesión registrada. La única prueba de usuario real del proyecto es la de Esmeralda, $n = 1$, y está en el documento.



Paso	Lo que produce
Se sitúa	nivel 0,93 en la escala 0–2, banda *intermedio*
Busca	diez libros ordenados por cercanía a su nivel
Elige	curva de dificultad capítulo a capítulo, con el más duro señalado
Lee	*peculiar*: definición en esa frase, IPA y audio
Practica	las palabras que se le escaparon, en rojo

Contra quién compite



No son comparaciones cara a cara: las dos primeras vienen de un estudio ajeno sobre el mismo corpus, con otra partición. Justifican la decisión de afinar un codificador; no demuestran una victoria medida.

Y dónde se pierde: Lexile tiene treinta años de validación y una escala **que acepta un colegio**; la de aquí no la acepta nadie.

Estrategia

Tres acciones, con coste real y criterio de terminado.

Qué	**Cuánto cuesta**	**Cuándo está hecho**
Publicar el modelo	30 min, gratis	**Hecho**: el cuaderno corre en un Colab limpio
Desplegar de forma permanente	7 USD/mes	**Hecho**: dirección fija que no muere al apagar
Terminar la medición del catálogo	≈3–5 h de cómputo A100, *estimadas*; la descarga va aparte	**En curso**: hoy las etiquetas son heredadas de un modelo v1. Terminado cuando el catálogo publique niveles medidos por el v4

El coste de medir el catálogo entero está en otro orden de magnitud que la tarifa de la alternativa comercial. Eso es lo que hace viable el proyecto, no la métrica.

Lo que esto no es

No certificamos ningún nivel del MCER.

La letra que se enseña es la etiqueta más cercana en una escala continua propia.

Sirve para elegir qué leer. No para acreditar nada.

Funcionando ahora mismo

`huggingface.co/spaces/MikeMaki1763/literalevel`

Modelo público: `huggingface.co/MikeMaki1763/literalevel-v4`

Si alguna vez abandonaste un libro en inglés pensando que el problema eras tú:
no lo eras. Era el libro.